



凸优化



你这个学历的基米无权哈我

目录

全书说明	vii
全书路线图与依赖图	ix
第一部分 导引篇	1
第 1 章 前言与导论	2
1.1 当变量不再是向量：从 Boyd 到函数空间	2
1.2 为什么必须上拓扑、弱收敛与对偶	3
1.3 这本书该怎么读	4
第二部分 无穷维的基石	5
第 2 章 拓扑空间与描述集合论初步	6
2.1 拓扑基础与网的收敛	6
2.1.1 拓扑语言与定向集	6
2.1.2 闭包与连续性的网刻画	7
2.2 Baire 纲定理及其推论	9
2.2.1 稀疏集、第一纲集与 Baire 空间	9
2.2.2 完备度量空间中的 Baire 纲定理	10
2.2.3 局部紧 Hausdorff 空间的版本	10
2.2.4 等价刻画与前瞻性推论	11
2.3 完备性与 Polish 空间	12
2.3.1 可完备度量化与 Polish 空间	12
2.3.2 开子空间与 G_δ 子集	13
2.3.3 典型模型	14
2.4 Baire 空间与 Lusin 空间	15
2.4.1 标准 Baire 空间的角色	15
2.4.2 Suslin 空间作为过渡层	15
第 3 章 测度论与随机空间基础	18
3.1 σ -代数与测度延拓	18
3.1.1 可测结构与生成的 σ -代数	18
3.1.2 外测度与 Carathéodory 可测性	19
3.1.3 预备测度的延拓	20
3.2 积分论与收敛定理	21
3.2.1 Lebesgue 积分的构造	21
3.2.2 单调收敛、Fatou 引理与控制收敛	22
3.3 拓扑空间上的测度	24
3.3.1 Borel 测度与 Radon 测度	24
3.3.2 连续函数上的正线性泛函	25
3.3.3 Riesz 表示定理	26

3.4	概率空间与随机过程微积分初步	27
3.4.1	概率空间、随机变量与条件期望	27
3.4.2	独立性、滤过、适应过程与鞅	28
3.4.3	Brownian motion 与 Itô 积分	29
3.4.4	Itô 公式与最小量级的随机微分方程	30
第 4 章	泛函分析与算子代数	32
4.1	Banach 空间与 Hilbert 空间	32
4.1.1	赋范空间与完备性	32
4.1.2	内积、正交与 Hilbert 空间	33
4.1.3	Hilbert 空间的 Riesz 表示定理	34
4.2	弱拓扑与弱星拓扑	36
4.2.1	由函数族诱导的最弱拓扑	36
4.2.2	典范嵌入与自反性	37
4.2.3	Banach-Alaoglu 定理与弱紧性	37
4.3	线性算子与伴随算子	39
4.3.1	有界线性算子与算子空间	39
4.3.2	Banach 空间中的对偶伴随	40
4.3.3	Hilbert 空间中的伴随	41
4.4	算子代数初步	42
4.4.1	谱与谱半径	42
4.4.2	紧算子、自伴算子与正算子	43
4.4.3	紧自伴算子的谱定理	45
第三部分	凸性、分离与微分	49
第 5 章	凸集与超平面分离	50
5.1	无穷维向量空间中的凸集	50
5.1.1	基本对象	50
5.2	代数内部与相对内部	52
5.2.1	两种内部概念	53
5.2.2	core 与分离之间的桥梁	54
5.3	Hahn-Banach 定理	55
5.3.1	次线性泛函与一维延拓	56
5.3.2	几何分离	57
5.4	极点与 Krein-Milman 定理	60
5.4.1	极点与面	60
第 6 章	凸泛函与无穷维微积分	63
6.1	下半连续性与极值定理	63
6.1.1	Proper 凸泛函与下半连续性	63
6.1.2	弱紧集上的极小值存在	64
6.1.3	自反空间中的直接法	64
6.1.4	典型例子	65
6.2	方向导数: Gâteaux 微分与 Fréchet 微分	66

6.2.1	方向导数与 Gâteaux 微分	66
6.2.2	Fréchet 微分与 Hilbert 梯度	66
6.2.3	凸可微泛函的一阶信息	67
6.2.4	典型例子	68
6.3	对偶空间中的次微分	68
6.3.1	次微分的定义	69
6.3.2	次微分的非空性	70
6.3.3	闭图性质	70
6.3.4	典型例子	71
6.4	次微分演算	72
6.4.1	和规则与法锥	72
6.4.2	Moreau–Rockafellar 和公式	73
6.4.3	线性映射下的拉回	74
6.4.4	典型例子	74
第 7 章	共轭理论与无穷维对偶	76
7.1	Fenchel 共轭与 Fenchel-Young 不等式	76
7.1.1	Fenchel 共轭的定义	76
7.1.2	Fenchel-Young 不等式与取等条件	76
7.1.3	典型例子	77
7.2	双共轭与闭凸包	78
7.2.1	双共轭的定义与基本不等式	79
7.2.2	Fenchel–Moreau 定理	79
7.2.3	上图像闭凸包与闭凸正则化	80
7.2.4	典型例子	81
7.3	下确界卷积	81
7.3.1	下确界卷积的定义	82
7.3.2	共轭与下确界卷积交换	82
7.3.3	Moreau 包络	83
7.3.4	典型例子	83
7.4	Fenchel–Rockafellar 对偶框架	84
7.4.1	原问题、对偶问题与弱对偶	84
7.4.2	资格条件	85
7.4.3	Fenchel–Rockafellar 对偶定理	86
7.4.4	最优性条件与 KKT 接口	87
7.4.5	典型例子	87
第四部分	Boyd 坍塌	89
第 8 章	抽象空间中的锥优化与 KKT 理论	90
8.1	广义不等式与闭凸锥	90
8.1.1	锥诱导的偏序	90
8.1.2	锥不等式与互补关系	92
8.1.3	典型例子	92
8.2	抽象凸优化问题标准型	93

8.2.1	抽象锥规划标准型	93
8.2.2	与 Fenchel 模板的对应	94
8.2.3	典型例子	94
8.3	广义 Slater 条件	95
8.3.1	严格可行性	95
8.3.2	相对内部与 core 的替代	96
8.3.3	典型例子	97
8.4	广义 KKT 条件	98
8.4.1	KKT 系统的定义	98
8.4.2	广义 KKT 定理	99
8.4.3	典型例子	99
第 9 章	特例坍缩——经典有限维凸优化	101
9.1	欧氏空间的退化	101
9.1.1	有限维范数与拓扑的一致性	101
9.1.2	存在性与内部概念的有限维简化	102
9.1.3	典型例子	102
9.2	线性规划与二次规划的复盘	103
9.2.1	线性规划与其对偶	103
9.2.2	二次规划	104
9.2.3	典型例子	105
9.3	SOCP 与 SDP	105
9.3.1	二阶锥与半正定锥	105
9.3.2	谱语言在矩阵上的坍缩	106
9.3.3	典型例子	107
9.4	几何规划的对偶透视	108
9.4.1	几何规划的基本形式	108
9.4.2	GP 的对偶透视	109
9.4.3	典型例子	109
第五部分	算法	111
第 10 章	单调算子与预解式	112
10.1	极大单调算子	112
10.1.1	Banach 空间中的单调与极大单调	112
10.1.2	Hilbert 识别与 resolvent	113
10.1.3	次微分作为极大单调算子的原型	114
10.1.4	典型例子	115
10.2	邻近算子	116
10.2.1	prox 的定义与 resolvent 解释	116
10.2.2	非扩张性与 Moreau 分解	117
10.2.3	典型例子	118
10.3	Moreau 包络	118
10.3.1	Yosida 近似	119
10.3.2	Moreau–Yosida 正则化	120

10.3.3 典型例子	121
10.4 算子求根问题	122
10.4.1 单调包含与最优化	122
10.4.2 零点与不动点	123
10.4.3 proximal point 作为统一模板	123
10.4.4 典型例子	124
第 11 章 大规模算子分裂算法	125
11.1 前向-后向分裂算法	125
11.1.1 问题模板与基本定义	125
11.1.2 固定点与零点的对应	126
11.1.3 平均映射结构与收敛	126
11.1.4 典型例子	127
11.2 Douglas-Rachford 分裂	128
11.2.1 反射算子与迭代定义	128
11.2.2 固定点与零点恢复	129
11.2.3 平均映射性质	130
11.2.4 典型例子	131
11.3 交替方向乘子法的泛函视角	131
11.3.1 两块模型与增广拉格朗日	132
11.3.2 ADMM 与 Douglas-Rachford 的接口	132
11.3.3 收敛与 KKT 极限	133
11.3.4 典型例子	134
11.4 加速算法与 Hilbert 空间拓展	135
11.4.1 惰性 proximal 模板	135
11.4.2 能量下降与模板性结论	135
11.4.3 典型例子	137
第六部分 应用	138
第 12 章 最优控制与量化交易的泛函建模	139
12.1 连续时间最优控制论	139
12.1.1 控制空间、状态方程与标准型	139
12.1.2 直接法存在性	140
12.1.3 伴随状态与一阶必要条件	140
12.1.4 典型例子	141
12.2 量化金融中的随机优化	142
12.2.1 策略、财富过程与风险泛函	142
12.2.2 CVaR 的对偶表达与风险约束	143
12.2.3 交易执行与风险对偶	144
12.2.4 典型例子	144
12.3 随机控制与 Bellman 动态规划	145
12.3.1 价值函数与 Bellman 算子	145
12.3.2 动态规划原理	146
12.3.3 Bellman 迭代下的凸性保持	146

12.3.4 典型例子	147
第 13 章 图网络、表示学习与智能推荐系统	148
13.1 再生核 Hilbert 空间	148
13.1.1 正定核与 RKHS	148
13.1.2 Tikhonov 正则化与表示定理	149
13.1.3 典型例子	150
13.2 图神经网络的泛函算子解释	151
13.2.1 图信号、拉普拉斯与能量	151
13.2.2 消息传递与图滤波	152
13.2.3 典型例子	153
13.3 多塔模型与无限维特征匹配	153
13.3.1 双塔表示与配对风险	153
13.3.2 表示定理与对偶解释	154
13.3.3 典型例子	155
13.4 大型系统的分布式求解	156
13.4.1 共识模型与分片嵌入	156
13.4.2 ADMM 形式与局部更新	157
13.4.3 典型例子	158
第七部分 附录	159
附录 A 附录 A：实分析速查手册	160
附录 B 附录 B：矩阵分析基础	161
附录 C 附录 C：常用函数的共轭表与次微分表	162

无穷维凸优化专著

全书定位

- 目标：构造一部“无穷维凸优化包容 Boyd 有限维凸优化”的专著控制骨架。
- 组织原则：按“部分目录 -> 章节目录 -> 章 README -> 小节控制卡”落地，确保后续写正文时不会失去结构。
- 独立性：本目录不并入现有 数学基础 / 树，只借用其 Obsidian 组织习惯。

读者路线图

- 纯数学路线：第 0 章前言与导论 -> 第 1 章拓扑空间与描述集合论初步 -> 第 2 章测度论与随机空间基础 -> 第 3 章泛函分析与算子代数 -> 第 4 章凸集与超平面分离 -> 第 5 章凸泛函与无穷维微积分 -> 第 6 章共轭理论与无穷维对偶
- 算法路线：0.1 从有限维到无穷维：优化的升维视角 -> 3.1 Banach 空间与 Hilbert 空间 -> 3.2 弱拓扑与弱星拓扑 -> 第 4 章凸集与超平面分离 -> 第 8 章特例坍塌——经典有限维凸优化 -> 第 9 章单调算子与预解式
- 管理科学与应用路线：2.4 概率空间与随机过程微积分初步 -> 6.4 Fenchel-Rockafellar 对偶框架 -> 第 7 章抽象空间中的锥优化与 KKT 理论 -> 第 10 章大规模算子分裂算法 -> 第 11 章最优控制与量化交易的泛函建模

章节依赖总览

- 总依赖图见 00-全书路线图与依赖图。
- 强存在性主线依赖：弱/弱* 紧性、下半连续性与直接法。
- 强对偶主线依赖：分离、次微分、共轭与资格条件。
- 算法主线依赖：Hilbert 几何、次微分、极大单调算子与原-对偶分裂。

Boyd 覆盖说明

- 接入策略是双层的：每个相关小节单独维护 Boyd 对应，第三部分再集中做“坍塌视角”的收束。
- 当前版本的 可复用例题 / 习题编号先保留“待按手头 Boyd 版本补核”的占位说明，只固定章节、概念与用途摘要，不伪造题号。
- 后续拿到手头 Boyd 原书后，只需批量回填题号，不会打乱目录与依赖骨架。

例子与习题编排原则

- 每个小节至少保留 1 个最小抽象例子、1 个有限维坍塌例子、1 个应用或算法触点例子。
- 例子必须解释“为什么放在这里”，禁止只写标题。
- 每个小节都维护 Boyd 映射题 / 本节自拟题 / 跨章综合题三类习题槽位。
- 章 README 额外汇总“本章 Boyd 映射总表”和“本章习题索引表”，便于后续批量填充。

目录

01-导引篇

- 第 0 章前言与导论

02-第一部分无穷维的基石

- 第 1 章拓扑空间与描述集合论初步
- 第 2 章测度论与随机空间基础
- 第 3 章泛函分析与算子代数

03-第二部分凸性、分离与微分

- 第 4 章凸集与超平面分离
- 第 5 章凸泛函与无穷维微积分
- 第 6 章共轭理论与无穷维对偶

04-第三部分 Boyd 坍塌

- 第 7 章抽象空间中的锥优化与 KKT 理论
- 第 8 章特例坍塌——经典有限维凸优化

05-第四部分算法

- 第 9 章单调算子与预解式
- 第 10 章大规模算子分裂算法

06-第五部分应用

- 第 11 章最优控制与量化交易的泛函建模
- 第 12 章图网络、表示学习与智能推荐系统

07-附录

- 附录 A：实分析速查手册
- 附录 B：矩阵分析基础
- 附录 C：常用函数的共轭表与次微分表

00-全书路线图与依赖图

空间分层声明

- 局部凸空间：用于最一般的分离、共轭与测度/拓扑接口，不默认有范数、投影或强紧性。
- 自反 Banach 空间：用于直接法、弱紧性与一部分原-对偶存在性结论。
- Hilbert 空间：用于投影、邻近算子、分裂算法和加速方法的主工作台。

章节依赖 DAG

```
graph TD
    C0["第0章 导论"] --> C1["第1章 拓扑与描述集合论"]
    C0 --> C2["第2章 测度论与随机空间"]
    C1 --> C2
    C1 --> C3["第3章 泛函分析与算子代数"]
    C2 --> C3
    C3 --> C4["第4章 凸集与分离"]
    C3 --> C5["第5章 凸泛函与微积分"]
    C4 --> C5
    C4 --> C6["第6章 共轭与对偶"]
    C5 --> C6
    C6 --> C7["第7章 抽象锥优化与KKT"]
    C3 --> C7
    C7 --> C8["第8章 Boyd坍塌"]
    C5 --> C9["第9章 单调算子与预解式"]
    C6 --> C9
    C9 --> C10["第10章 算子分裂算法"]
    C7 --> C10
    C2 --> C11["第11章 控制与量化交易"]
    C7 --> C11
    C10 --> C11
    C3 --> C12["第12章 图网络与推荐系统"]
    C6 --> C12
    C10 --> C12
```

四条主线

存在性

- 第 1-3 章建立完备性、弱/弱*紧性与测度正则性。
- 第 5.1 节把弱下半连续、强制性和直接法拼成标准存在性模板。
- 第 7 章以后所有“有解”陈述都必须回链到这些条件，而不是写成无条件断言。

对偶

- 第 4 章的分离与支撑泛函提供对偶的几何来源。
- 第 5 章的次微分与第 6 章的共轭/双共轭构成原-对偶翻译器。

- 第 7.3-7.4 节用资格条件和 KKT 把对偶落成最优性系统。

算法

- 第 3.1 节给出 Hilbert 几何。
- 第 5.3-5.4 节提供次微分与演算规则。
- 第 9-10 章把问题统一写成单调算子零点与原-对偶分裂。

Boyd 坍塌

- 第 0 章先声明整本书不会丢掉有限维参照。
- 第 4-7 章的每个关键小节都单独维护 Boyd 对应。
- 第 8 章集中解释哪些复杂性因维数有限而消失，并把 LP/QP/SOCP/SDP/GP 收束回 Boyd 子集。

Boyd 坍塌回链

- 8.1 回链 3.2: 弱/强拓扑一致后，紧性与存在性条件大幅简化。
- 8.2 回链 7.4: 抽象 KKT 在矩阵语言中的完整退化。
- 8.3 回链 3.4: 自伴谱语言退化为对称矩阵特征值分解。
- 8.4 回链 6.4: Fenchel-Rockafellar 对偶退化成几何规划的标准对偶写法。

Pre-flight Manifesto

> Detected legacy finite-dimensional defaults. Applying Hindsight global rules: > > 1. 显式声明空间环境为“局部凸空间 / 自反 Banach / Hilbert”三层之一。> 2. 任何“极小值存在”陈述都必须绑定弱紧性、强制性或直接法，不得写成自动成立。> 3. 3.4 只保留对优化直接有用的自伴、紧算子与谱工具，不外扩为一般算子代数课程。> 4. Boyd 坍塌桥段从前两部分开始持续嵌入，不延后到书末一次性处理。

第一部分

导引篇

第 1 章 前言与导论

如果控制变量是一个向量，Boyd 的语言几乎总是够用：目标函数写在 $\mathbb{R}^n$ 上，约束由矩阵和超平面给出，极值、乘子和算法都能在欧氏空间里落地。但如果控制变量是函数而不是向量，或者更进一步，控制变量本身是一条轨道、一个概率测度，情况就立刻变了。此时“未知量”不再是有限个坐标，而是一个空间中的点；许多在有限维里被默认的事实，不再自动成立。

最短的桥梁例子是下面这一对问题。一边是有限维二次规划

$$\min_{x \in \mathbb{R}^n} \left\{ \frac{1}{2} x^\top Q x + c^\top x \right\},$$

另一边是把控制变量取为 $u \in L^2(0, T)$ 的变分问题

$$\min_{u \in L^2(0, T)} \left\{ \frac{1}{2} \int_0^T |u(t)|^2 dt + \Phi \left(\int_0^T B(t) u(t) dt \right) \right\}.$$

两者表面上都像“凸目标的极小化”，但后者已经把未知量从向量推进到了函数空间。正是在这一步，有限维直觉开始失效：闭有界集未必紧，极限不能只靠序列描述，导数和乘子必须进入对偶空间，算法也不再只是矩阵迭代，而要转化为算子分裂与邻近更新。

因此，这本书不是简单把 Boyd 的有限维结论“加一点泛函分析背景”而已，而是要把整套凸优化语言真正提升到函数、测度与随机轨道上。第 1.1 节先把“为什么必须升维”说清楚；第 1.2 节解释为什么升维以后必须同时引入拓扑、弱收敛、对偶与算子；第 1.3 节再给出不同读者的进入路径。你可以把这一章当成全书的入口，而不是作者的项目说明书。

1.1 当变量不再是向量：从 Boyd 到函数空间

控制变量是函数而不是向量时，Boyd 为什么不够？更准确地说，Boyd 的有限维母语为什么不能原封不动地搬过来？原因不在于凸性失效了，而在于承载凸性的空间变了。只要未知量从 $\mathbb{R}^n$ 里的向量变成了一个函数、一个测度，或者一条随机轨道，问题就不再只是“坐标更多”，而是整个极限、连续性和对偶对象都换了舞台。

最短的桥梁例子是把有限维二次规划和一个函数空间上的变分问题并排来看。有限维里，我们熟悉

$$\min_{x \in \mathbb{R}^n} \left\{ \frac{1}{2} x^\top Q x + c^\top x \right\}.$$

如果把未知量换成控制函数 $u \in L^2(0, T)$ ，就会自然遇到

$$\min_{u \in L^2(0, T)} \left\{ \frac{1}{2} \int_0^T |u(t)|^2 dt + \Phi \left(\int_0^T B(t) u(t) dt \right) \right\}.$$

这两个问题共享同一层凸优化直觉：目标由一个二次项和一个复合项组成，后者都通过线性映射进入。然而它们的数学成本完全不同。前者的可行集、收敛和乘子都能在矩阵语言中处理；后者则立刻要求我们知道 $L^2(0, T)$ 的拓扑、弱收敛、对偶配对以及算子意义下的最优性条件。

例题 1.1 有限维与无穷维的最短桥 把上面的函数空间问题投影到一个有限维基底

$$u(t) \approx \sum_{k=1}^m \alpha_k \varphi_k(t),$$

就会得到一个关于系数向量 $\alpha \in \mathbb{R}^m$ 的二次规划。反过来看，Boyd 中那些熟悉的二次规划、线性约束和投影算法，正是更一般函数空间问题在有限维离散化后的坍塌版本。把这个例子放在这里，是为了提醒读者：本书不是离开 Boyd，恰恰是在解释 Boyd 的母语来自哪里。

四个失效点

一旦变量不再是向量，至少有四件在有限维里默认成立的事不再自动成立。

1. **紧性失效**：闭有界集未必紧，极小化过程可能只得到有界而得不到强收敛极限。
2. **极限语言升级**：弱拓扑和弱* 拓扑往往不是第一可数的，序列不再足以刻画闭包和紧性。

3. **导数与乘子升级**：梯度不一定还是向量，最优性条件必须进入对偶空间、次微分和伴随算子。

4. **算法接口升级**：矩阵迭代要被重新写成邻近算子、预解式和单调算子分裂。

注 这四个失效点几乎就是本书后文章节安排的理由。拓扑与描述集合论解决“极限怎么说”；测度论与随机空间解决“概率对象怎么放进优化”；泛函分析与对偶理论解决“乘子和支持超平面属于哪里”；单调算子与分裂算法解决“如何把无穷维最优性系统变成可计算更新”。

因此，本书的“升维”不是炫技，而是对问题本身的诚实。只要你关心的是最优控制、随机策略、图信号、核函数表示或分布式一致性，那么变量就早已不是一个向量；剩下的工作，不过是承认这一点，并为它支付必要的数学代价。第 1.2 节接下来要做的，就是把这笔代价拆开说明：为什么必须上拓扑、弱收敛、对偶与算子。Boyd 在这里仍然是重要参照，但他更像一条有限维影子，而不是终点。

1.2 为什么必须上拓扑、弱收敛与对偶

上一节已经把问题摆清楚了：当变量落在函数、测度或轨道空间里时，有限维直觉并没有错，只是不再完整。接下来的问题不是“要不要学更多数学”，而是“哪一类数学分别在补哪一类缺口”。如果不把这些工具和它们所解决的问题对应起来，后文的拓扑、测度、对偶和算子章节就会显得像并列堆料。

第一个缺口是极限。极小化序列、逼近解和离散化解首先都在谈“往哪里收敛”。在有限维里，闭球紧性、序列收敛和连续映射几乎总能接上；但在无穷维里，极限常常只能在弱拓扑或弱*拓扑下获得，于是我们必须引入拓扑语言，特别是网、闭包和下半连续性。第一个问题因此是：一个极值点究竟以什么意义存在？

第二个缺口是最优性。只要未知量不再是有限维向量，“导数 = 梯度向量”的图景就不再可靠。泛函的导数属于对偶空间，约束的法向量会变成连续线性泛函，乘子则通过伴随算子与原变量相连。因此，对偶、支撑超平面、次微分和共轭理论并不是后加的抽象层，而是无穷维最优性条件的自然语言。第二个问题于是变成：局部最优与全局对偶之间，究竟由什么对象沟通？

第三个缺口是算法。有限维中熟悉的梯度法、投影法、ADMM 和 KKT 系统，在无穷维里依然有对应物，但它们的真正母语不再是矩阵，而是邻近算子、预解式、单调算子和原-对偶分裂。算法不是在理论之后才出现的附录，它本身就在逼迫我们采用算子观点。第三个问题于是是：怎样把“求最优解”统一改写为“求某个算子的零点或不动点”？

记号与环境约定

全书默认在三层环境之间切换：

局部凸空间 $\subset$ 自反 Banach 空间 $\subset$ Hilbert 空间

这里的包含不是集合论意义，而是“结构越来越强、可用工具越来越多”的层级。讨论分离与对偶时，局部凸空间往往已经足够；讨论极小值存在和弱紧性时，通常需要自反 Banach 空间；讨论投影、梯度、邻近算子和分裂算法时，则往往要回到 Hilbert 空间。后文凡涉及对偶配对，统一写作

$$\langle x^*, x \rangle.$$

若空间本身是 Hilbert 空间，则通过 Riesz 表示可以把对偶元素重新看成向量，但这种识别必须在明确声明环境后才允许使用。

注 你可以把这一节看成全书的类型系统。一个命题若只在 Hilbert 空间成立，就不能被写成一般 Banach 结论；一个极小值若只在弱拓扑下存在，就不能偷换成强收敛结论；一个乘子若属于对偶空间，就不能直接画成欧氏法向量。后文所有章节的技术细化，本质上都只是把这些环境约定展开。

如果把第 1.1 节的四个失效点重新对齐，那么拓扑和弱收敛负责处理极限，对偶和次微分负责处理最优性，算子和分裂负责处理算法。于是整本书的结构就不再像若干独立模块的拼装，而像对一个中心问题的三次逼近：先问极限是否存在，再问最优性如何表达，最后问如何把它算出来。第 1.3 节接下来只做一件事：告诉不同读者该沿哪条线先走。

1.3 这本书该怎么读

这本书当然可以从头顺读，但未必需要从头顺读。因为它同时服务三种常见读者：想把理论基础补扎实的纯数学读者，已经懂 Boyd 母语、主要关心算法接口的读者，以及更在意建模闭环和应用落点的管理科学读者。不同入口并不意味着不同版本的书，只是意味着你先回答哪个问题。

如果你主要关心纯数学基础，那么最自然的路径是：第 2 章建立拓扑与描述集合论语言，第 3 章进入测度与随机空间，第 4 章和第 5 章建立泛函分析与分离工具，再进入第 6 章和第 7 章的次微分与对偶理论。这条线最慢，但也最稳，因为它把后文一切“算法为何有定义”“乘子为何存在”“弱极限为何足够”这些问题都提前补齐。

如果你主要关心算法，那么不必在一开始就吞下全书。更短的一条路是：先把第 4 章中的 Hilbert 空间、弱拓扑和谱论读到能用，再接第 6 章的次微分、第 10 章的单调算子与预解式，最后进入第 11 章的前向-后向分裂、Douglas-Rachford 和 ADMM。沿这条路线读时，Boyd 会一直作为有限维母语出现，但你会逐步看清：这些算法真正处理的不是矩阵，而是算子零点与原-对偶系统。

如果你主要关心管理科学、控制或应用建模，那么更合适的入口是先读随机过程与对偶接口，再回补基础。具体说，可以从第 3.4 节的随机分析入口读起，接着读第 7.4 节 Fenchel-Rockafellar 对偶、第 8 章锥优化与 KKT，再看第 12 章和第 13 章的控制、交易、图网络与推荐系统。这样你会更快看到闭环：为什么约束资格、风险对偶、分布式一致性和表示匹配都能被放回同一套凸优化语言。

无论从哪条路切入，建议都一样：把 Boyd 留在心里，但不要把它当成天花板。有限维模型是最重要的直觉来源，却不是全部世界。你越早接受“变量可以是函数、测度或轨道”，后文的拓扑、对偶和算子就越不再像门槛，而像一条自然延长线。

第二部分

无穷维的基石

第 2 章 拓扑空间与描述集合论初步

第 1 章已经把问题摆在了桌面上：一旦变量是函数、测度或轨道，而不再只是有限维向量，Boyd 母语里那些默认成立的事实就开始松动。最先失效的通常不是凸性本身，而是极限语言。我们在有限维里习惯于同时依赖序列、闭球、连续映射这些欧氏空间直觉；但在弱拓扑、弱*拓扑和路径空间中，序列不再足够，这些话往往都需要重写。

因此，本章不是抽象的背景铺垫，而是在回答一个非常具体的问题：当优化变量已经离开 $\mathbb{R}^n$ 以后，我们究竟该用什么语言来谈闭包、连续性、紧性、可测性和“典型参数”？第一个答案是网与滤子，它们替代了“只谈序列”的习惯；第二个答案是 Baire 范畴，它解释为什么完备性会决定存在性和稳定性论证；第三个答案是 Polish、Lusin 与 Suslin 空间，它们给后续测度、随机过程和控制问题提供了真正稳定的状态空间舞台。

本章的推进仍然分成四步，但读的时候最好始终记着后文的用途。第 2.1 节解决“为什么弱拓扑里不能只谈序列”；第 2.2 节解决“为什么存在性论证会反复需要完备性和 Baire 方法”；第 2.3 节解释“为什么优化与随机过程的默认舞台往往是 Polish 空间”；第 2.4 节再说明“为什么还需要比 Polish 更宽的可测空间语言”。后文关于极小值存在、对偶构造、随机控制和图模型的很多接口，都会回到这一章来寻找最低层的支点。

2.1 拓扑基础与网的收敛

第 1 章提出的第一个失效点，就是“弱拓扑里不能只谈序列”。这是无穷维分析里最容易被低估的一步：在欧氏空间中，闭包、连续性、紧性和聚点几乎都能靠序列表达，于是我们很自然地把“极限”理解成 $n \rightarrow \infty$ 。但只要进入一般拓扑空间，特别是后文会频繁出现的弱拓扑与弱*拓扑，这种理解就不再够用。

因此，本节的核心不是再发明一种比序列更复杂的语言，而是把极限过程恢复到真正与拓扑相容的层面。网和滤子之所以重要，不是因为它们更抽象，而是因为它们能准确回答：当变量已经是函数、测度或轨道时，闭包究竟该怎样刻画，连续性究竟该怎样检查，紧性又究竟意味着什么。

2.1.1 拓扑语言与定向集

设 X 为拓扑空间， $x \in X$ 。记 $\mathcal{N}(x)$ 为 x 的邻域系， $\bar{A}$ 为子集 $A \subseteq X$ 的闭包。若对任意邻域 $U \in \mathcal{N}(x)$ 都有 $U \cap A \neq \emptyset$ ，则 $x \in \bar{A}$ 。这一定义不依赖于度量，因此比序列极限更基础。

定义 2.1.1 (定向集)

设 D 为非空集合， $\preceq$ 为其上的预序关系，即满足自反性和传递性。若对任意 $\alpha, \beta \in D$ 都存在 $\gamma \in D$ 使得 $\alpha \preceq \gamma$ 且 $\beta \preceq \gamma$ ，则称 $(D, \preceq)$ 为一个定向集。

定向集的角色，是提供“最终足够大”这一概念，而不预设索引必须线性排列。自然数集 $(\mathbb{N}, \leq)$ 是最基本的例子；更能反映一般拓扑结构的例子是邻域系 $\mathcal{N}(x)$ 配以逆包含顺序 $U \preceq V \iff V \subseteq U$ 。

定义 2.1.2 (网与网收敛)

设 $(D, \preceq)$ 为定向集， X 为拓扑空间。映射

$$x_\bullet: D \rightarrow X, \quad \alpha \mapsto x_\alpha$$

称为 X 中的一个网。若对每个邻域 $U \in \mathcal{N}(x)$ ，都存在 $\alpha_0 \in D$ ，使得当 $\alpha \succeq \alpha_0$ 时恒有 $x_\alpha \in U$ ，则称网 $(x_\alpha)_{\alpha \in D}$ 收敛到 x ，记作 $x_\alpha \rightarrow x$ 。

定义 2.1.3 (子网与滤子)

设 $(x_\alpha)_{\alpha \in D}$ 为网。若 $(E, \leq)$ 为定向集, $\varphi: E \rightarrow D$ 满足

1. φ 保序, 即 $\beta_1 \leq \beta_2$ 蕴含 $\varphi(\beta_1) \leq \varphi(\beta_2)$;
2. $\varphi(E)$ 在 D 中共终, 即对每个 $\alpha_0 \in D$, 都存在 $\beta_0 \in E$ 使 $\varphi(\beta) \geq \alpha_0$ 当 $\beta \geq \beta_0$ 时成立,

则称 $(x_{\varphi(\beta)})_{\beta \in E}$ 为原网的一个子网。

另一方面, 设 X 为非空集合。若非空集合族 $\mathcal{B} \subseteq \mathcal{P}(X)$ 满足

1. $\emptyset \notin \mathcal{B}$;
2. 对任意 $B_1, B_2 \in \mathcal{B}$, 都存在 $B_3 \in \mathcal{B}$ 使 $B_3 \subseteq B_1 \cap B_2$,

则称 $\mathcal{B}$ 为 X 上的一个滤子基。滤子基的作用, 是只记录“足够大的集合应该包含什么”, 而不要求对上超集封闭。

若集合族 $\mathcal{F} \subseteq \mathcal{P}(X)$ 进一步满足

1. $\emptyset \notin \mathcal{F}$;
2. 若 $A, B \in \mathcal{F}$, 则 $A \cap B \in \mathcal{F}$;
3. 若 $A \in \mathcal{F}$ 且 $A \subseteq C \subseteq X$, 则 $C \in \mathcal{F}$,

则称 $\mathcal{F}$ 为 X 上的一个滤子。由任意滤子基 $\mathcal{B}$ 都可生成一个最小滤子

$$\langle \mathcal{B} \rangle := \{A \subseteq X : \exists B \in \mathcal{B} \text{ 使 } B \subseteq A\},$$

称为由 $\mathcal{B}$ 生成的滤子。

在拓扑空间中, 点 x 的邻域系 $\mathcal{N}(x)$ 本身就是一个滤子; 如果只取某个邻域基, 则通常先得到的是滤子基。类似地, 网的尾集族

$$E_\alpha := \{x_\beta : \beta \geq \alpha\}, \quad \alpha \in D,$$

正是一个典型的滤子基, 因为定向性保证任意两个尾集都含有更小的公共尾集。由这些尾集生成的滤子, 称为该网的尾滤子。网与滤子在收敛论中携带的是同一类信息: 一个网收敛到 x , 当且仅当它的尾滤子收敛到邻域滤子 $\mathcal{N}(x)$; 一个点是网的聚点, 当且仅当某个比尾滤子更细的滤子收敛到该点。

本书在后续叙述中优先使用网, 而不是直接使用滤子, 主要有两个原因。第一, 子网比“细化滤子”更适合写紧性和提取极限点的过程; 第二, 优化中的算法迭代、逼近族和约束逼近通常天然以索引族出现, 用网语言书写更直接。不过一旦进入可测结构、完备化或抽象收敛论, 滤子视角会帮助我们更清楚地识别“最终行为”究竟依赖于哪些集合论信息。

可以把滤子理解为“忽略有限初段后剩下的全部信息”。对序列而言, 尾滤子正是由集合

$$\{x_n : n \geq N\}, \quad N \in \mathbb{N},$$

生成的; 对邻域收敛而言, 邻域滤子则记录了“一个点附近所有足够小的局部区域”。这两类滤子在形式上十分相似, 这也是为什么网收敛与邻域结构能够自然拼接在一起。

2.1.2 闭包与连续性的网刻画**命题 2.1.1 (闭包的网刻画)**

设 $A \subseteq X$, $x \in X$ 。则

$$x \in \overline{A} \iff \text{存在网 } (x_\alpha)_{\alpha \in D} \subseteq A \text{ 使 } x_\alpha \rightarrow x.$$

证明 若存在这样的网, 则对任意邻域 $U \in \mathcal{N}(x)$, 收敛性保证存在 α_0 使得 $\alpha \geq \alpha_0$ 时 $x_\alpha \in U \cap A$, 从而 $U \cap A \neq \emptyset$, 故 $x \in \overline{A}$ 。

反之, 若 $x \in \overline{A}$, 则对每个邻域 $U \in \mathcal{N}(x)$ 都可选取一点 $x_U \in U \cap A$ 。将 $\mathcal{N}(x)$ 赋予逆包含顺序: $U \leq V$ 当且仅当 $V \subseteq U$ 。这使 $\mathcal{N}(x)$ 成为定向集, 而 $(x_U)_{U \in \mathcal{N}(x)}$ 是 A 中的网。对任意邻域 $W \in \mathcal{N}(x)$, 若 $U \leq W$, 即 $U \subseteq W$, 则 $x_U \in U \subseteq W$ 。故该网收敛到 x 。

命题 2.1.2 (连续性的网刻画)

设 $f: X \rightarrow Y$ 为映射, $x \in X$. 则 f 在 x 处连续, 当且仅当对任意满足 $x_\alpha \rightarrow x$ 的网 (x_α) , 都有 $f(x_\alpha) \rightarrow f(x)$.

证明 先设 f 在 x 处连续. 任取 $f(x)$ 的邻域 V , 由连续性可取 x 的邻域 U 使 $f(U) \subseteq V$. 若 $x_\alpha \rightarrow x$, 则存在 α_0 使得 $\alpha \geq \alpha_0$ 时 $x_\alpha \in U$, 于是 $f(x_\alpha) \in V$. 故 $f(x_\alpha) \rightarrow f(x)$.

反之, 假设像网保持收敛. 若 f 在 x 不连续, 则存在 $f(x)$ 的邻域 V 使得对任意 x 的邻域 U 都有 $U \not\subseteq f^{-1}(V)$. 于是每个 $U \in \mathcal{N}(x)$ 中都可选取 $x_U \in U \setminus f^{-1}(V)$. 与命题 2.1.1 证明中相同, $(x_U)_{U \in \mathcal{N}(x)}$ 收敛到 x , 但其像网始终落在 $Y \setminus V$ 中, 不可能收敛到 $f(x)$. 矛盾.

命题 2.1.3 (聚点与子网)

设 $(x_\alpha)_{\alpha \in D}$ 为 X 中的网, $x \in X$. 则下列命题等价:

1. 对任意邻域 $U \in \mathcal{N}(x)$ 与任意 $\alpha_0 \in D$, 都存在 $\alpha \geq \alpha_0$ 使 $x_\alpha \in U$;
2. 原网存在一个子网收敛到 x .

证明 (2) $\Rightarrow$ (1) 显然, 因为收敛子网的尾部落在每个邻域中, 而子网索引映射共终.

下证 (1) $\Rightarrow$ (2). 令

$$E = \{(\alpha, U) : \alpha \in D, U \in \mathcal{N}(x), x_\alpha \in U\},$$

并定义

$$(\alpha_1, U_1) \preceq (\alpha_2, U_2) \iff \alpha_1 \preceq \alpha_2 \text{ 且 } U_2 \subseteq U_1.$$

由条件 (1) 可知 E 非空, 且对任意两个元素都可找到共同上界, 所以 E 是定向集. 定义 $\varphi: E \rightarrow D$ 为 $\varphi(\alpha, U) = \alpha$, 则 φ 保序且共终, 因此 $(x_{\varphi(\beta)})_{\beta \in E}$ 是原网的子网. 对任意邻域 $W \in \mathcal{N}(x)$, 若 $\beta = (\alpha, U) \succeq (\alpha_0, W)$, 则必有 $U \subseteq W$, 因而 $x_{\varphi(\beta)} = x_\alpha \in U \subseteq W$. 故此子网收敛到 x .

命题 2.1.4 (第一可数空间中序列已足够)

若 X 是第一可数空间, $A \subseteq X$, 则对任意 $x \in X$,

$$x \in \overline{A} \iff \text{存在序列 } (a_n)_{n \geq 1} \subseteq A \text{ 使 } a_n \rightarrow x.$$

证明 由命题 2.1.1 只需证明右向左的逆向构造. 若 $x \in \overline{A}$, 取 x 的可数邻域基 $(U_n)_{n \geq 1}$, 并令

$$V_n := U_1 \cap \cdots \cap U_n.$$

则每个 V_n 仍是 x 的邻域, 且 $V_{n+1} \subseteq V_n$. 由 $x \in \overline{A}$ 可取 $a_n \in A \cap V_n$. 于是对任意邻域 U , 存在某个 N 使 $U_N \subseteq U$, 从而当 $n \geq N$ 时 $a_n \in V_n \subseteq U_N \subseteq U$. 故 $a_n \rightarrow x$.

为何弱拓扑中序列语言不够

注 命题 2.1.4 表明, 序列之所以在欧氏空间中万能, 并不是因为“极限天然应该由序列描述”, 而是因为这些空间具备第一可数性. 后文讨论弱拓扑与弱*拓扑时, 这一性质往往失效. 例如第 4.2 节定理 4.2.1 给出的弱*紧性, 在非可分情形通常只能保证网有收敛子网, 而不能保证任意序列都有收敛子列. 因此本书后文凡涉及弱收敛、弱下半连续性与对偶紧性, 默认都应使用网语言, 而不是未经说明地退回序列语言.

例题 2.1 最小抽象例子: 弱*极限网 设 X 为赋范空间, B_{X^*} 为对偶空间单位球. 第 4.2 节定理 4.2.1 说明 B_{X^*} 在弱*拓扑下紧. 这里“紧”的自然含义是: 任意网都存在收敛子网. 把这个例子放在本节, 是为了提醒读者后文出现的极小化列、乘子列或近似解族, 若只在弱*拓扑下有紧性, 就不能只问“是否存在收敛子列”, 而必须问“是否存在收敛子网”.

例题 2.2 有限维坍塌: 欧氏空间中的网与序列 在 $\mathbb{R}^n$ 的通常拓扑中, 第一可数性成立, 因此命题 2.1.4 告诉我们: 闭包、连续性与聚点完全可以由序列刻画. 把这个例子放在这里, 是为了明确后文与 Boyd 书相接时, 为什么很多有限维论证看上去只需处理序列; 那并非一般原理, 而是欧氏空间的特殊福利.

例题 2.3 算法触点: 函数空间中的迭代极限 在 Hilbert 空间上研究投影算法或近端算法时, 迭代点常常只能先证

明有界，再借助弱拓扑获得极限点。若空间或拓扑选择得更一般，例如考虑测度空间上的概率流或策略空间上的松弛解，极限对象很可能首先通过网出现。把这个例子放在这里，是为了给第 9 章与第 10 章的算子分裂算法预留正确的收敛语言接口。

到这里，本节其实已经回答了第 1 章中的第一个问题：为什么一旦离开有限维，连“收敛”都必须重写。下一节将继续回答第二个问题：即便有了正确的极限语言，为什么存在性和稳定性论证仍然离不开完备性与 Baire 方法。

有限维对照

Boyd 书中关于闭集、极限点和连续映射的讨论，默认都在 $\mathbb{R}^n$ 这一第一可数环境中完成。因此其结论可以直接用序列表述而不损失信息。本节的作用不是推翻这些有限维叙述，而是指出它们在无穷维中的真实上位版本：定义 2.1.2、命题 2.1.1 和命题 2.1.2。

习题（待补）

- 练习 2.1 闭包与子网的练习占位 补一题：要求证明命题 2.1.3 在序列情形退化为“聚点当且仅当存在收敛子列”，并指出证明中哪些地方依赖第一可数性。
- 练习 2.2 弱拓扑桥接题占位 补一题：把命题 2.1.2 落回欧氏空间，比较“网连续”“序列连续”和通常 ε - δ 连续性的等价性。

2.2 Baire 纲定理及其推论

上一节解决了“极限该怎么说”，但这还不够。第 1 章里的第二个失效点是存在性：即便我们已经知道弱极限、子网和闭包该怎样表述，仍然需要某种结构来保证“坏集合不能处处出现”。这正是完备性和 Baire 范畴方法进入优化的地方。

Baire 方法之所以在泛函分析中占据中心地位，并不是因为它提供了某种旁门技巧，而是因为它把完备性转化成了一条结构结论：可数个过于稀薄的集合，不可能填满一个真正良好的空间。后文许多看似与“范畴”无关的结论，例如一致有界、开映射、闭图像以及典型参数上的稳定性，底层都在使用这一点。

2.2.1 稀疏集、第一纲集与 Baire 空间

定义 2.2.1 (Baire 范畴的基本概念)

设 X 为拓扑空间， $A \subseteq X$ 。

1. 若 $\text{int } \overline{A} = \emptyset$ ，则称 A 为无处稠密集。
2. 若 A 可以写成可数个无处稠密集的并，则称 A 为第一纲集；否则称其为第二纲集。
3. 若 $R \subseteq X$ 的补集是第一纲集，则称 R 为剩余集。
4. 若任意可数个稠密开集的交仍稠密，则称 X 为 Baire 空间。

在 Baire 空间中，剩余集总是稠密的。因此“典型性质”常常被理解为“在一个剩余集上成立”。后文处理连续线性算子族、值函数正则性和参数稳定性时，这种语言会反复出现。

2.2.2 完备度量空间中的 Baire 纲定理

定理 2.2.1 (完备度量空间上的 Baire 纲定理)

设 (X, d) 为非空完备度量空间, $\{U_n\}_{n \geq 1}$ 为 X 中一列稠密开集。则

$$\bigcap_{n=1}^{\infty} U_n$$

在 X 中稠密。



证明 任取非空开集 $V \subseteq X$ 。只需证明

$$V \cap \bigcap_{n=1}^{\infty} U_n \neq \emptyset.$$

因为 U_1 稠密且开, 故可在 $V \cap U_1$ 中选取闭球 $\overline{B}(x_1, r_1)$, 满足

$$\overline{B}(x_1, r_1) \subseteq V \cap U_1, \quad r_1 \leq 2^{-1}.$$

递归地, 若已选得 $\overline{B}(x_n, r_n) \subseteq U_n \cap B(x_{n-1}, r_{n-1})$ 且 $r_n \leq 2^{-n}$, 则由 U_{n+1} 稠密开, 可在 $U_{n+1} \cap B(x_n, r_n)$ 中选取闭球

$$\overline{B}(x_{n+1}, r_{n+1}) \subseteq U_{n+1} \cap B(x_n, r_n), \quad r_{n+1} \leq 2^{-(n+1)}.$$

于是得到一列递减的非空闭集

$$F_n := \overline{B}(x_n, r_n), \quad F_{n+1} \subseteq F_n, \quad \text{diam}(F_n) \leq 2r_n \rightarrow 0.$$

任取 $y_n \in F_n$ 。对 $m > n$, 有 $y_m, y_n \in F_n$, 故

$$d(y_m, y_n) \leq \text{diam}(F_n) \rightarrow 0.$$

因此 (y_n) 为 Cauchy 列, 由完备性收敛到某个 $x \in X$ 。又因每个 F_n 闭且对所有 $m \geq n$ 有 $y_m \in F_n$, 故 $x \in F_n$ 对一切 n 都成立。于是

$$x \in F_1 \subseteq V, \quad x \in F_n \subseteq U_n \quad (n \geq 1),$$

故 $x \in V \cap \bigcap_{n \geq 1} U_n$ 。

例题 2.4 为什么完备性不能省略 在有理数空间 $(\mathbb{Q}, |\cdot|)$ 中, 枚举 $\mathbb{Q} = \{q_n\}_{n \geq 1}$ 并令 $U_n = \mathbb{Q} \setminus \{q_n\}$ 。每个 U_n 都是稠密开集, 但

$$\bigcap_{n=1}^{\infty} U_n = \emptyset.$$

把这个例子放在这里, 是为了强调定理 2.2.1 的核心前提不是“可数交”, 而是完备性本身。

2.2.3 局部紧 Hausdorff 空间的版本

引理 2.2.1 (局部紧 Hausdorff 空间中的紧闭包开集)

设 X 为局部紧 Hausdorff 空间, $O \subseteq X$ 为非空开集。则存在非空开集 W 使得

$$\overline{W} \subseteq O, \quad \overline{W} \text{ 紧}.$$



证明 任取 $x \in O$ 。由局部紧性可取 x 的开邻域 V 使得 $\overline{V}$ 紧; 由 Hausdorff 性, 紧集是闭集。再以正则性选取开集 W 满足

$$x \in W \subseteq \overline{W} \subseteq V \cap O.$$

于是 $\overline{W}$ 为紧集且包含于 O 。

定理 2.2.2 (局部紧 Hausdorff 空间上的 Baire 纲定理)

设 X 为非空局部紧 Hausdorff 空间, $\{U_n\}_{n \geq 1}$ 为 X 中一列稠密开集。则 $\bigcap_{n \geq 1} U_n$ 在 X 中稠密。



证明 任取非空开集 $V \subseteq X$ 。由引理 2.2.1, 存在非空开集 W_1 使

$$\overline{W_1} \subseteq V \cap U_1, \quad \overline{W_1} \text{ 紧.}$$

递归地, 若已构造出非空开集 W_n 使 $\overline{W_n}$ 紧且 $\overline{W_n} \subseteq U_n \cap W_{n-1}$, 则对非空开集 $W_n \cap U_{n+1}$ 再次应用引理 2.2.1, 可得非空开集 W_{n+1} 满足

$$\overline{W_{n+1}} \subseteq W_n \cap U_{n+1}, \quad \overline{W_{n+1}} \text{ 紧.}$$

于是 $\{\overline{W_n}\}_{n \geq 1}$ 构成递减的非空紧集列。紧性保证有限交性质成立, 因此

$$\bigcap_{n=1}^{\infty} \overline{W_n} \neq \emptyset.$$

取 x 属于该交, 则 $x \in \overline{W_1} \subseteq V$ 且对每个 n 有 $x \in \overline{W_n} \subseteq U_n$ 。故

$$x \in V \cap \bigcap_{n=1}^{\infty} U_n,$$

从而交集稠密。

2.2.4 等价刻画与前瞻性推论**命题 2.2.1 (Baire 空间的等价刻画)**

设 X 为拓扑空间。下列命题等价:

1. X 是 Baire 空间;
2. 任意第一纲集都没有内点;
3. 任意剩余集都是稠密集;
4. 任意非空开子集都是第二纲集。



证明 (1) $\Rightarrow$ (2): 若 $M = \bigcup_{n \geq 1} A_n$ 为第一纲集, 其中每个 A_n 无处稠密, 则 $X \setminus \overline{A_n}$ 均为稠密开集。由 (1) 可知

$$\bigcap_{n \geq 1} (X \setminus \overline{A_n})$$

稠密, 于是其补集

$$\bigcup_{n \geq 1} \overline{A_n}$$

没有内点。因为 $M \subseteq \bigcup_{n \geq 1} \overline{A_n}$, 故 M 也没有内点。

(2) $\Rightarrow$ (3): 若 R 为剩余集, 则 $X \setminus R$ 为第一纲集, 由 (2) 知其内点为空, 等价于 R 稠密。

(3) $\Rightarrow$ (1): 任意可数个稠密开集的交, 其补为可数个闭无内点集之并, 故是第一纲集。于是该交为剩余集, 由 (3) 稠密。

(2) $\Rightarrow$ (4): 若非空开集 O 是第一纲集, 则它作为自身的子集有非空内点, 与 (2) 矛盾。

(4) $\Rightarrow$ (2): 若第一纲集 M 有非空内点 O , 则 $O \subseteq M$, 从而 O 也是第一纲集, 与 (4) 矛盾。

推论 2.2.1 (稠密 G_δ 集的典型性)

在 Baire 空间中, 可数个稠密开集的交是稠密的 G_δ 集; 因而任意剩余集都包含一个稠密 G_δ 子集。



证明 前一结论来自定义; 后一结论只需把剩余集写成第一纲集的补, 再将对应的闭包补取交即可。

对后文的前瞻

注 开映射定理、闭图像定理与一致有界原理的共同底层机制，正是定理 2.2.1 与命题 2.2.1。本书在第 3 章讨论 Banach 空间工具箱时，将重新回到本节，不在这里提前展开线性空间版本的全部证明。

例题 2.5 最小抽象例子：一致有界原理的拓扑影子 设 $\{T_i\}_{i \in I}$ 为 Banach 空间上的连续线性算子族。若对每个固定向量 x ，集合 $\{\|T_i x\| : i \in I\}$ 有界，则“范数爆炸点集”可以写成可数个闭集的并。Baire 方法排除了这些闭集在整个空间中都太薄却又处处出现的可能，因此导出算子范数的一致有界性。把这个例子放在这里，是为了说明范畴方法不是抽象装饰，而是泛函分析主定理的发动机。

例题 2.6 有限维坍塌：欧氏空间中一切自动成为 Baire 任意欧氏空间都是完备度量空间，因此由定理 2.2.1 自动是 Baire 空间。把这个例子放在这里，是为了说明有限维线性代数中“满射线性映射自动开”“图像闭合行为良好”等现象，其实早已暗含在本节的完备性框架里，只是欧氏空间把这些前提隐藏得过于自然。

例题 2.7 应用触点：坏参数集很薄 在优化模型的参数分析里，常见结论是“对典型参数，解映射满足某种正则性；例外参数至多构成第一纲集”。把这个例子放在这里，是为了给后文的对偶稳定性与值函数敏感性分析提供术语准备：所谓“典型”，往往并非指测度意义上的几乎处处，而是 Baire 范畴意义上的剩余集。

因此，本节回答的是第 1 章中的第二个问题：为什么存在性与稳定性论证需要某种“坏集合不能太大”的原理。再往前一步，优化和随机过程还要求空间既能承受完备性，又有足够好的可分性和 Borel 结构；这就把我们带到下一节的 Polish 空间。

有限维对照

Boyd 书几乎不需要显式提到 Baire 范畴，因为有限维范数空间自动完备，且很多线性映射性质可由矩阵论直接验证。本节的价值在于指出：这些熟悉结论在无穷维里不再是线性代数常识，而是定理 2.2.1 与定理 2.2.2 的推论。

习题（待补）

-  **练习 2.3 Baire 等价刻画占位** 补一题：要求把命题 2.2.1 的四个条件补成完整循环证明，并解释“剩余”与“第一纲”之间的对偶关系。
-  **练习 2.4 完备性桥接题占位** 补一题：比较 $\mathbb{R}$ 与 $\mathbb{Q}$ 中稠密开集可数交的行为，说明为什么例 2.4 恰好刻画了完备性的缺失。

2.3 完备性与 Polish 空间

到这里，读者已经看到：仅有“正确的极限语言”和“完备性带来的 Baire 性质”还不足以支撑后文全部内容。第 1 章真正要追问的是：为什么优化与随机过程的默认舞台常常不是任意 Banach 空间，而是 Polish 空间？原因很直接。后文既要讨论极小值存在，又要讨论 Borel 结构、概率测度和可测选择；这就要求状态空间同时具备完备性、可分性和稳定的可测结构。

Polish 空间正是这些要求的交汇点。它既保留了上一节的完备性力量，又给出了随机过程、路径空间和测度论真正可操作的状态空间类别。对本书来说，Polish 空间不是描述集合论中的漂亮名词，而是“把优化对象、概率对象和拓扑对象放在同一个舞台上”的最常用答案。

2.3.1 可完备度量化与 Polish 空间

定义 2.3.1 (可完备度量化)

拓扑空间 X 称为可完备度量化的，若存在一个与其拓扑相容的完备度量 d 。换言之， X 的拓扑可以由某个完备度量诱导出来。



定义 2.3.2 (Polish 空间)

若拓扑空间 X 既可分又可完备度量化, 则称 X 为 Polish 空间。

由定理 2.2.1 可知, 每个可完备度量化空间都是 Baire 空间; 因此每个 Polish 空间自动满足命题 2.2.1 的全部等价条件。换言之, Polish 空间不仅“测度上好用”, 也“范畴上不坏”。

2.3.2 开子空间与 G_δ 子集**定理 2.3.1 (开子空间的完备度量化)**

设 X 为可完备度量化空间, $U \subseteq X$ 为开集。则 U 也是可完备度量化空间。

证明 取与 X 的拓扑相容的完备度量 d 。若 $U = X$ 结论显然, 下面设 $U \neq X$, 并记 $F := X \setminus U$ 。对 $x \in U$ 定义

$$\Phi(x) = \left(x, \frac{1}{d(x, F)} \right) \in X \times \mathbb{R}.$$

由于 F 闭, 函数 $x \mapsto d(x, F)$ 在 U 上连续且严格为正, 因此 Φ 连续。显然它是单射, 而投影到第一坐标给出其像上的连续逆映射, 所以 Φ 是 U 到 $\Phi(U)$ 的同胚。

下证 $\Phi(U)$ 在 $X \times \mathbb{R}$ 中闭。设 $\Phi(x_n) \rightarrow (x, t)$ 。则 $x_n \rightarrow x$ 且 $1/d(x_n, F) \rightarrow t$ 。由于距离到闭集的函数连续, 得到

$$d(x_n, F) \rightarrow d(x, F).$$

若 $x \in F$, 则 $d(x, F) = 0$, 从而 $d(x_n, F) \rightarrow 0$, 这将迫使 $1/d(x_n, F) \rightarrow +\infty$, 与其在 $\mathbb{R}$ 中收敛到 t 矛盾。因此 $d(x, F) > 0$, 即 $x \in U$ 。再由连续性可得

$$t = \lim_{n \rightarrow \infty} \frac{1}{d(x_n, F)} = \frac{1}{d(x, F)}.$$

所以 $(x, t) = \Phi(x) \in \Phi(U)$, 闭性得证。

因为 $X \times \mathbb{R}$ 在乘积拓扑下仍可由完备度量诱导, 而闭子空间保持完备性, 故 $\Phi(U)$ 可完备度量化。再由 $U \cong \Phi(U)$, 得到 U 可完备度量化。

推论 2.3.1 (开子空间的 Polish 性)

Polish 空间的任意开子空间仍是 Polish 空间。

证明 开子空间继承可分性; 再由定理 2.3.1 继承可完备度量化。

命题 2.3.1 (可数乘积保持 Polish 性)

设 $\{X_n\}_{n \geq 1}$ 为一列 Polish 空间, 则乘积空间 $\prod_{n \geq 1} X_n$ 仍是 Polish 空间。

证明 对每个 n 取有界完备度量 $d_n \leq 1$ 诱导 X_n 的拓扑。定义

$$D(x, y) = \sum_{n=1}^{\infty} 2^{-n} d_n(x_n, y_n), \quad x = (x_n), y = (y_n).$$

则 D 诱导乘积拓扑。若 $(x^{(m)})_{m \geq 1}$ 是 D -Cauchy 列, 则对每个固定 n , 坐标列 $x_n^{(m)}$ 在 (X_n, d_n) 中为 Cauchy, 从而收敛到某个 $x_n \in X_n$ 。由逐坐标收敛和定义可知 $x^{(m)} \rightarrow (x_n)$, 故 D 完备。可分性来自每个 X_n 的可数稠密子集取有限支近似的标准构造。

定理 2.3.2 (G_δ 子集的 Polish 性)

设 X 为 Polish 空间, $G \subseteq X$ 为 G_δ 子集。则 G 仍为 Polish 空间。

证明 取开集列 $\{U_n\}_{n \geq 1}$ 使

$$G = \bigcap_{n=1}^{\infty} U_n.$$

由推论 2.3.1, 每个 U_n 都是 Polish 空间。考虑对角嵌入

$$\Delta: G \rightarrow \prod_{n=1}^{\infty} U_n, \quad \Delta(x) = (x, x, \dots).$$

这是一个同胚到其像的映射。其像恰是满足各坐标相等的对角集；由于乘积空间是 Hausdorff 的，对角集为闭集。由命题 2.3.1, $\prod_n U_n$ 是 Polish 空间，闭子空间仍是 Polish 空间，因此 G 是 Polish 空间。

关于 G_δ 判别

注 定理 2.3.2 给出了本书最常用的一个判别原则：当一个空间已经嵌在某个 Polish 空间里时，只要能证明它是一个 G_δ 子集，往往就已经足够恢复完整的 Polish 结构。后文讨论可行集、路径空间和策略空间时，这条原则会反复使用。

2.3.3 典型模型

例题 2.8 欧氏空间与可分 Banach 空间 $\mathbb{R}^n$ 在通常欧氏度量下是完备且可分的，因此是 Polish 空间。更一般地，任何可分 Banach 空间在其范数度量下也是 Polish 空间。把这些例子放在这里，是为了说明 Boyd 书的整个有限维世界，以及后文大部分 Hilbert 空间算法模型，天然都生活在定义 2.3.2 的框架之中。

例题 2.9 标准 Baire 空间 $\mathbb{N}^{\mathbb{N}}$ 将 $\mathbb{N}$ 赋予离散拓扑，并在乘积空间 $\mathbb{N}^{\mathbb{N}}$ 上考虑度量

$$d(\alpha, \beta) = \sum_{n=1}^{\infty} 2^{-n} 1_{\{\alpha_n \neq \beta_n\}}.$$

则这是一个完备可分度量空间，因此是 Polish 空间。把它放在这里，是为了给下一节做准备：标准 Baire 空间在描述集合论中扮演“可数编码空间”的角色，很多 Suslin 与 Lusin 结构都可以从它出发进行参数化。

例题 2.10 应用触点：路径空间与随机优化 设 $C([0, T])$ 配以一致范数，则它是可分 Banach 空间，故由例 2.8 为 Polish 空间。把这个例子放在这里，是为了说明后文最优控制与随机过程的状态轨道空间，往往并不是抽象的“任意函数集”，而是一个具有稳定 Borel 结构的 Polish 空间。

本节因此回答了第 1 章中的第三个问题：为什么后文在谈随机过程、控制轨道和可测优化时，会反复把 Polish 空间当作默认舞台。下一节还要继续向外推广一步，因为实际建模里出现的状态空间，未必总是以 Polish 形式直接给出，它们常常更像某个 Polish 空间的连续像。

有限维对照

在有限维中，“开集仍然好”“可数交仍然可控”这些性质几乎从不被单独强调，因为 $\mathbb{R}^n$ 的闭子集、开子集和很多自然出现的约束集都自动继承良好结构。本节把这种直觉抽象成三个真正可复用的结论：定理 2.3.1、命题 2.3.1 与定理 2.3.2。

习题（待补）

-  **练习 2.5 开子空间完备化占位** 补一题：要求用定理 2.3.1 构造 $(0, 1)$ 上一个与通常拓扑相容但完备的度量。
-  **练习 2.6 G_δ 判别占位** 补一题：证明某个具体函数约束集是 Banach 空间中的 G_δ 子集，并据此应用定理 2.3.2 得到其 Polish 性。

2.4 Baire 空间与 Lusin 空间

Polish 空间已经足以覆盖很多优化与概率问题，但第 1 章中的最后一个问题还没有完全回答：为什么后文有时还需要比 Polish 更宽的可测空间语言？原因在于，真实建模里出现的状态空间并不总是直接以“可分完备度量空间”出现。它们更常见的面貌，是某个良好空间经过连续映射、参数化或编码之后得到的像。

因此，本节并不想把描述集合论再铺成一整门课程，而是只建立一条对后文真正有用的层级：

$$\text{Polish} \implies \text{Lusin} \implies \text{Suslin}.$$

这条层级的作用，是在尽量保留 Polish 空间可测正则性的同时，允许状态空间经过更现实的连续像变形。后文讨论随机控制、可测选择和参数化策略空间时，真正需要的往往正是这种“比 Polish 更宽，但还没有宽到失控”的环境。

2.4.1 标准 Baire 空间的角色

定义 2.4.1 (标准 Baire 空间)

记

$$\mathcal{N} := \mathbb{N}^{\mathbb{N}}$$

并赋予其乘积拓扑，则称 $\mathcal{N}$ 为标准 Baire 空间。由例 2.9，它是一个 Polish 空间。

标准 Baire 空间的重要性在于：它提供了一个统一的可数编码平台。后文若要把控制策略、可测选择或参数族写成“由一串整数决定的对象”，实质上就是把问题转移到 $\mathcal{N}$ 上。

命题 2.4.1 (标准 Baire 空间的满射性)

每个非空 Polish 空间都是标准 Baire 空间的连续像。

证明 证明可由“逐层缩小的可数开覆盖”完成：先对给定 Polish 空间 X 取一族直径趋于零的可数开覆盖，再沿有限自然数列递归地选取嵌套开集 U_s ，使得

$$U_s = \bigcup_{n \geq 1} U_{s \frown n}, \quad \text{diam}(U_s) \rightarrow 0 \text{ 当 } |s| \rightarrow \infty.$$

对每个 $\alpha = (\alpha_1, \alpha_2, \dots) \in \mathcal{N}$ ，完备性保证

$$\bigcap_{k \geq 1} \overline{U_{\alpha|k}}$$

恰含一点，据此定义映射 $\pi(\alpha)$ 。直径控制给出唯一性与连续性，覆盖性则保证满射。这里不展开全部技术细节，因为后文只需要这一结论作为参数化工具，而不需要其完整构造。

2.4.2 Suslin 空间作为过渡层

定义 2.4.2 (Suslin 空间)

拓扑空间 X 称为 Suslin 空间，若存在 Polish 空间 P 及连续满射 $f: P \rightarrow X$ 。

Suslin 空间的关键词是“连续像”。这一定义非常宽松，却保留了大量对测度论有用的正则性；尤其是连续像这一操作，在建模时远比“是某个 Banach 空间的闭子集”更常见。

定义 2.4.3 (Lusin 空间)

Hausdorff 空间 X 称为 Lusin 空间，若存在 Polish 空间 P 及连续双射 $f: P \rightarrow X$ 。

Lusin 空间介于 Polish 与 Suslin 之间。与 Suslin 空间相比，它保留了“来自 Polish 空间的点级编码几乎没有丢失”的特征；与 Polish 空间相比，它允许拓扑结构经过较温和的变形。

命题 2.4.2 (层级关系：Polish、Lusin 与 Suslin)

任意 Polish 空间都是 Lusin 空间，任意 Lusin 空间都是 Suslin 空间。

证明 若 X 是 Polish 空间，则取恒等映射 $\text{id}_X: X \rightarrow X$ ，可见 X 满足定义 2.4.3，故为 Lusin 空间。若 X 是 Lusin 空间，则按定义存在 Polish 空间 P 与连续双射 $f: P \rightarrow X$ 。双射当然是满射，因此 X 也满足定义 2.4.2，故为 Suslin 空间。

命题 2.4.3 (Suslin 与 Lusin 空间的基本保持性)

1. Suslin 空间的连续像仍为 Suslin 空间。
2. 若 X 是 Lusin 空间，则 X 的任意开子空间、闭子空间及 G_δ 子空间仍是 Lusin 空间。

证明 对 (1)，设 X 是 Suslin 空间， $f: P \rightarrow X$ 为 Polish 空间 P 上的连续满射，且 $g: X \rightarrow Y$ 连续。则 $g \circ f: P \rightarrow Y$ 连续且满射到 $g(X)$ ，故 $g(X)$ 为 Suslin 空间。

对 (2)，设 X 是 Lusin 空间，取 Polish 空间 P 与连续双射 $f: P \rightarrow X$ 。若 $A \subseteq X$ 为开集，则 $f^{-1}(A)$ 在 P 中是开集，因此由推论 2.3.1 是 Polish 空间；若 A 为闭集，则 $f^{-1}(A)$ 在度量空间 P 中闭，而闭集总是 G_δ 集，因此由定理 2.3.2 仍是 Polish 空间；若 A 本身就是 G_δ 集，则 $f^{-1}(A)$ 同样是 G_δ 集，仍由定理 2.3.2 得到 Polish 性。将 f 限制到 $f^{-1}(A)$ ，得到连续双射

$$f|_{f^{-1}(A)}: f^{-1}(A) \rightarrow A.$$

故 A 为 Lusin 空间。

关于 Suslin 定理与 Lusin 分离定理

注 完整的描述集合论会进一步研究解析集、共解析集以及 Borel 结构的判别，例如著名的 Suslin 定理和 Lusin 分离定理。对本书而言，真正需要的是前述层级关系与保持性：它们已经足以支撑第 2 章的拓扑测度论、第 6 章以后的可测对偶构造，以及第 11 章中的策略空间建模。

于是，第 2 章到这里也就闭环了。第 2.1 节告诉我们极限不能只靠序列，第 2.2 节告诉我们存在性需要完备性与 Baire 方法，第 2.3 节给出 Polish 这一默认舞台，而本节则说明为什么还要允许 Polish 的连续像。下一章进入测度论与随机空间时，这些工具就不再像抽象预备，而会直接变成优化对象的合法宿主。

例题 2.11 最小抽象例子：连续像出现的状态空间 设 P 为 Polish 空间， $f: P \rightarrow X$ 为连续满射。即便 X 不能自然嵌入某个线性空间，只要它仍是这样一个连续像，我们就可以把可测结构和逼近论证先放在 P 上做，再通过 f 推到 X 上。把这个例子放在这里，是为了说明为什么定义 2.4.2 对随机控制和可测选择如此关键。

例题 2.12 有限维坍塌：紧致度量空间与欧氏紧集 每个紧致度量空间都是 Polish 空间，因此由命题 2.4.2 自动也是 Lusin 与 Suslin 空间。特别地， $\mathbb{R}^n$ 的任意紧子集都处在这一层级中。把这个例子放在这里，是为了说明有限维优化里出现的紧可行域，完全不会触发新的描述集合论困难。

例题 2.13 应用触点：策略与观测的可数编码 在离散时间随机控制中，策略往往由一串历史观测映射决定。若把所有可行观测轨道组织成 Polish 空间，再把策略参数写成标准 Baire 空间上的编码，就可借助命题 2.4.1 和命题 2.4.3，把策略集视为 Suslin 或 Lusin 空间。把这个例子放在这里，是为了给后文第 11 章中的可测参数化问题准备舞台。

有限维对照

在 Boyd 的有限维语境中，状态空间通常就是 $\mathbb{R}^n$ 、其开子集或闭子集，因此完全没有必要再区分定义 2.3.2、定义 2.4.3 和定义 2.4.2。但一旦模型涉及连续像、商空间、策略集或路径空间，这三层结构就会开始分家，而命题 2.4.2 提供了后文回链时最常用的导航。

习题（待补）

- 🚩 练习 2.7 标准 Baire 空间占位 补一题：要求将某个具体 Polish 空间写成标准 Baire 空间的连续像，并说明这一表示在可测参数化中的意义。
- 🚩 练习 2.8 Lusin 子空间占位 补一题：设 X 为 Lusin 空间，证明其某个给定的 G_δ 子集仍为 Lusin 空间，并明确指出定理 2.3.2 在证明中的使用位置。

第3章 测度论与随机空间基础

第1章给出了拓扑与空间层级的语言，但“可收敛”并不自动推出“可积分”，而“可积”也不自动推出“可做随机建模”。从无穷维优化的角度看，真正进入概率、风险和动态控制之前，还需要一套能够处理事件、期望、路径和测度对偶的统一框架。本章的任务，就是把这套框架搭起来。

本章沿着四条彼此衔接的主线展开。第3.1节先从可测空间与测度延拓出发，解释为什么随机模型往往不是直接给出在完整 σ -代数上的测度，而是先在一个较小的可观察事件类上指定数据，再通过延拓定理补全。第3.2节转入Lebesgue积分与收敛定理，它们构成了后文“极限与期望交换”这一技术动作的合法性基础。第3.3节把视角推进到拓扑空间上的测度，特别是Radon测度与Riesz表示定理，这一步把抽象线性泛函首次具体化为测度对象。最后第3.4节在此基础上进入概率空间、滤过、鞅、Brownian motion与Itô积分，为第11章的连续时间控制与量化建模准备最小但完整的随机分析入口。

和第1章一样，本章不追求百科式覆盖，而是坚持优化导向。凡是后文真正需要反复调用的概念和定理，本章都会给出标准定义、基本性质和可引用编号；凡是更深的概率论支线，例如一般半鞅理论或测度论的最广泛抽象形式，则只保留与本书主线直接相关的版本。读完这一章后，读者应当能够把“随机输入”“期望目标”“测度乘子”“连续时间噪声”这些对象放到同一张逻辑地图中，而不再把它们看成彼此无关的技术碎片。

3.1 σ -代数与测度延拓

随机优化模型看上去往往以“概率分布”开始，但在严格写法里，概率分布并不是对所有子集都赋值，而是定义在某个可测结构上。更常见的情况是，我们最初只知道某些基本事件的大小，例如区间、柱集、矩形或场景树节点的权重；真正的测度则需要由这些初始数据延拓得到。本节就是要说明，从有限可观察事件到完整概率模型的这一步，如何在集合论上被严密完成。

3.1.1 可测结构与生成的 σ -代数

定义 3.1.1 (σ -代数)

设 Ω 为非空集合。子集族 $\mathcal{F} \subseteq 2^\Omega$ 称为 Ω 上的一个 σ -代数，若满足：

1. $\Omega \in \mathcal{F}$ ；
2. 若 $A \in \mathcal{F}$ ，则 $A^c \in \mathcal{F}$ ；
3. 若 $\{A_n\}_{n \geq 1} \subseteq \mathcal{F}$ ，则 $\bigcup_{n \geq 1} A_n \in \mathcal{F}$ 。

此时称 $(\Omega, \mathcal{F})$ 为一个可测空间， $\mathcal{F}$ 中的集合称为可测集。

命题 3.1.1 (由集合族生成的 σ -代数)

设 $\mathcal{C} \subseteq 2^\Omega$ 为任意集合族，则存在包含 $\mathcal{C}$ 的最小 σ -代数，记为 $\sigma(\mathcal{C})$ 。

证明 考虑所有包含 $\mathcal{C}$ 的 σ -代数之全体 $\{\mathcal{G}_i\}_{i \in I}$ 。由于幂集 2^Ω 本身是一个 σ -代数，因此这类对象非空。令

$$\mathcal{F}_0 := \bigcap_{i \in I} \mathcal{G}_i.$$

由 σ -代数定义逐条验证即可知，任意族 σ -代数的交仍是 σ -代数，因此 $\mathcal{F}_0$ 是包含 $\mathcal{C}$ 的 σ -代数。由构造可知，它被包含在任何其他包含 $\mathcal{C}$ 的 σ -代数之中，故为最小者。

定义 3.1.2 (测度与预备测度)

设 $(\Omega, \mathcal{F})$ 为可测空间。映射 $\mu: \mathcal{F} \rightarrow [0, +\infty]$ 称为测度，若满足

$$\mu(\emptyset) = 0$$

且对任意两两不交的集合列 $\{A_n\}_{n \geq 1} \subseteq \mathcal{F}$ 都有

$$\mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n).$$

若 $\mathcal{A}$ 只是一个代数，而 μ_0 在 $\mathcal{A}$ 上满足上述可列可加条件，只要并集仍留在 $\mathcal{A}$ 中，就称 μ_0 为 $\mathcal{A}$ 上的预备测度。



例题 3.1 欧氏空间中的 Borel 结构 在 $\mathbb{R}^n$ 中，由所有开集生成的 σ -代数称为 Borel σ -代数，记为 $\mathcal{B}(\mathbb{R}^n)$ 。把这个例子放在这里，是为了说明 Boyd 书里默认出现的“约束集可测”“随机变量有分布”，实际上都隐含着定义 3.1.1 和命题 3.1.1 这一步已经完成。

为什么要从生成说起

注 在无穷维和路径空间建模中，真正容易书写的通常不是全部可测集，而是某一类基本事件。例如在函数空间上，人们常先指定有限维投影对应的柱集；在场景树模型中，则先指定每个节点的条件概率。命题 3.1.1 告诉我们：只要先固定好这些“原始可观察事件”，后面的测度延拓问题就有了明确的落脚点。

3.1.2 外测度与 Carathéodory 可测性**定义 3.1.3 (外测度)**

设 Ω 为非空集合。映射 $\mu^*: 2^\Omega \rightarrow [0, +\infty]$ 称为 Ω 上的一个外测度，若满足：

1. $\mu^*(\emptyset) = 0$;
2. 若 $A \subseteq B$ ，则 $\mu^*(A) \leq \mu^*(B)$;
3. 对任意集合列 $\{A_n\}_{n \geq 1} \subseteq 2^\Omega$ ，有

$$\mu^*\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mu^*(A_n).$$

**定义 3.1.4 (Carathéodory 可测集)**

设 μ^* 为 Ω 上的外测度。若集合 $E \subseteq \Omega$ 满足：对任意 $A \subseteq \Omega$ 都有

$$\mu^*(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c),$$

则称 E 为关于 μ^* 的 Carathéodory 可测集。

**定理 3.1.1 (Carathéodory 可测集定理)**

设 μ^* 为 Ω 上的外测度，记

$$\mathcal{M}(\mu^*) := \{E \subseteq \Omega : E \text{ 关于 } \mu^* \text{ 是 Carathéodory 可测的}\}.$$

则 $\mathcal{M}(\mu^*)$ 是一个 σ -代数，并且 μ^* 在 $\mathcal{M}(\mu^*)$ 上的限制是一个完备测度。



证明 先证 $\mathcal{M}(\mu^*)$ 对补运算封闭。若 E 满足定义 3.1.4，则对任意 $A \subseteq \Omega$ ，

$$\mu^*(A) = \mu^*(A \cap E) + \mu^*(A \cap E^c),$$

交换 E 与 E^c 的位置即可得 $E^c \in \mathcal{M}(\mu^*)$ 。

再证对有限交封闭。设 $E, F \in \mathcal{M}(\mu^*)$ 。对任意 $A \subseteq \Omega$ ，先按 E 分割，再对与 E 的交部分按 F 分割，得到

$$\mu^*(A) = \mu^*(A \cap E \cap F) + \mu^*(A \cap E \cap F^c) + \mu^*(A \cap E^c).$$

将后两项重新组合，便可写成

$$\mu^*(A) = \mu^*(A \cap (E \cap F)) + \mu^*(A \cap (E \cap F)^c),$$

故 $E \cap F \in \mathcal{M}(\mu^*)$ 。由补封闭也得有限并封闭。

对可数并，只需先处理两两不交的情形，再通过递增极限推广。设 $E_n \in \mathcal{M}(\mu^*)$ 两两不交，令 $E = \bigcup_{n \geq 1} E_n$ 。由外测度的次可加性总有

$$\mu^*(A) \leq \mu^*(A \cap E) + \mu^*(A \cap E^c).$$

反向不等式则由每个 E_n 的可测性分步切割并取极限得到。因此 $E \in \mathcal{M}(\mu^*)$ ，从而 $\mathcal{M}(\mu^*)$ 为 σ -代数。

最后，若 $\{E_n\}$ 两两不交且都在 $\mathcal{M}(\mu^*)$ 中，则对 $E = \bigcup_n E_n$ ，利用可测性等式逐步相加可得

$$\mu^*(E) = \sum_{n=1}^{\infty} \mu^*(E_n).$$

故限制到 $\mathcal{M}(\mu^*)$ 后是测度。若 $\mu^*(N) = 0$ ，则对任意 $A \subseteq \Omega$ 有

$$\mu^*(A) \leq \mu^*(A \cap N) + \mu^*(A \cap N^c) \leq 0 + \mu^*(A),$$

所以 N 的任意子集也可测，从而该测度完备。

3.1.3 预备测度的延拓

定理 3.1.2 (Carathéodory 测度延拓定理)

设 $\mathcal{A}$ 为 Ω 上的代数， μ_0 为 $\mathcal{A}$ 上的预备测度。定义

$$\mu^*(E) := \inf \left\{ \sum_{n=1}^{\infty} \mu_0(A_n) : E \subseteq \bigcup_{n=1}^{\infty} A_n, A_n \in \mathcal{A} \right\}, \quad E \subseteq \Omega.$$

则：

1. μ^* 是 Ω 上的外测度；
2. $\mathcal{A} \subseteq \mathcal{M}(\mu^*)$ ；
3. $\mu := \mu^*|_{\sigma(\mathcal{A})}$ 是 $\sigma(\mathcal{A})$ 上的测度，且 $\mu|_{\mathcal{A}} = \mu_0$ ；
4. 若 μ_0 是 σ -有限的，则该延拓在 $\sigma(\mathcal{A})$ 上唯一。



证明 由定义可直接验证 $\mu^*(\emptyset) = 0$ 与单调性。次可加性来自于对每个 E_n 选取近似最优覆盖后，把这些覆盖拼接起来。

下证 $\mathcal{A} \subseteq \mathcal{M}(\mu^*)$ 。任取 $E \in \mathcal{A}$ 和任意 $B \subseteq \Omega$ 。对覆盖 $B \subseteq \bigcup_n A_n$ ，由代数对交、补封闭可知 $A_n \cap E$ 与 $A_n \cap E^c$ 仍在 $\mathcal{A}$ 中，于是

$$\mu_0(A_n) = \mu_0(A_n \cap E) + \mu_0(A_n \cap E^c).$$

对所有覆盖取下确界即可得到

$$\mu^*(B) \geq \mu^*(B \cap E) + \mu^*(B \cap E^c).$$

反向不等式由外测度的次可加性总是成立，因此 E 可测。

由定理 3.1.1， μ^* 在 $\mathcal{M}(\mu^*)$ 上是测度；既然 $\sigma(\mathcal{A}) \subseteq \mathcal{M}(\mu^*)$ ，便得到了所需延拓。对于 $E \in \mathcal{A}$ ，以自身作为覆盖可得 $\mu^*(E) \leq \mu_0(E)$ ；反向不等式由上一步切割及预备测度的可加性可得，所以 $\mu^*(E) = \mu_0(E)$ 。

若 μ_0 是 σ -有限的，则可取 $\Omega = \bigcup_n E_n$ ，其中 $E_n \in \mathcal{A}$ 且 $\mu_0(E_n) < \infty$ 。若 ν 是另一延拓，则 μ 与 ν 在生成代数 $\mathcal{A}$ 上一致，并在每个有限测度块 E_n 上都有限。由单调类论证可知二者在 $\sigma(\mathcal{A})$ 上一致，从而唯一。

例题 3.2 由分布函数生成测度 设 $F: \mathbb{R} \rightarrow \mathbb{R}$ 为右连续、单调不减函数。若在半开区间代数上规定

$$\mu_0((a, b]) = F(b) - F(a),$$

则 μ_0 是一个预备测度。由定理 3.1.2，它唯一延拓为 $\mathcal{B}(\mathbb{R})$ 上的 Borel 测度。把这个例子放在这里，是为了说明随机变量的分布函数并不是“额外数据”，而正是一个通过延拓定理生成测度的起点。

例题 3.3 抽象例子：路径空间上的柱集 在路径空间 $\mathbb{R}^{[0,T]}$ 或 $C([0,T])$ 上，最容易指定概率的对象往往是有限维柱集，即只依赖有限个时刻取值的事件。先在柱集代数上指定一致的有限维分布，再通过延拓定理得到完整路径测度，是构造 **Brownian motion** 和更一般随机过程的标准路线。把这个例子放在这里，是为了给第 3.4 节的随机过程语言留出严格基础。

例题 3.4 工程触点：场景树到概率空间 在供应链或随机规划中，人们常先给出有限层场景树，每个节点带有转移概率。若要在极限模型中讨论期望目标、风险约束或动态一致性，就需要把这些离散层级数据嵌入一个真正的概率空间。把这个例子放在这里，是为了说明测度延拓并非纯粹抽象技巧，而是从有限场景模型走向路径级随机优化的第一步。

有限维对照

有限维优化里，随机输入通常直接写成“随机向量 $X \in \mathbb{R}^n$ 有某个分布”，因此底层的可测结构和测度延拓常被隐藏起来。本节的作用，是把这些被默认完成的步骤显式写出：从定义 3.1.1 到定义 3.1.3，再到定理 3.1.2。

习题（待补）

- 🔴 **练习 3.1 分布函数延拓占位** 补一题：从例 3.2 出发，证明给定右连续分布函数 F 后，区间赋值 $(a, b] \mapsto F(b) - F(a)$ 的确构成一个预备测度。
- 🔴 **练习 3.2 柱集桥接题占位** 补一题：在有限维情形把柱集代数退化为矩形代数，说明为什么定理 3.1.2 正是“联合分布存在”的集合论版本。

3.2 积分论与收敛定理

测度只给出了“集合有多大”，真正进入优化与概率时，我们关心的是函数在这些集合上的平均、总量与极限行为。**Lebesgue** 积分之所以在本书中不可替代，并不只是因为它比 **Riemann** 积分更一般，而是因为它允许我们在极限过程里保持对可积性的控制。本节的核心，就是把“积分是什么”和“什么时候可以把极限推进积分号内”两件事组织成一条可反复调用的技术链。

3.2.1 Lebesgue 积分的构造

定义 3.2.1 (简单函数与非负积分)

设 $(\Omega, \mathcal{F}, \mu)$ 为测度空间。若函数 $\varphi: \Omega \rightarrow [0, +\infty)$ 可写成

$$\varphi = \sum_{k=1}^m a_k 1_{A_k},$$

其中 $a_k \geq 0$, $A_k \in \mathcal{F}$ 两两不交，则称 φ 为一个非负简单函数，并定义

$$\int_{\Omega} \varphi d\mu := \sum_{k=1}^m a_k \mu(A_k).$$

定义 3.2.2 (Lebesgue 积分)

设 $f: \Omega \rightarrow [0, +\infty]$ 为非负可测函数。定义

$$\int_{\Omega} f d\mu := \sup \left\{ \int_{\Omega} \varphi d\mu : 0 \leq \varphi \leq f, \varphi \text{ 为简单函数} \right\}.$$

对一般实值可测函数 f ，写

$$f^+ = \max\{f, 0\}, \quad f^- = \max\{-f, 0\}.$$

若

$$\int_{\Omega} f^{+} d\mu < \infty, \quad \int_{\Omega} f^{-} d\mu < \infty,$$

则称 f 可积, 并定义

$$\int_{\Omega} f d\mu := \int_{\Omega} f^{+} d\mu - \int_{\Omega} f^{-} d\mu.$$



为什么强调 L^1

注 定义 3.2.2 给出的可积函数类正是 $L^1(\mu)$ 的底层对象。后文讨论期望目标、风险泛函、弱收敛下的积分连续性时, 真正起作用的往往不是函数的逐点值, 而是它在 L^1 中的等价类与积分控制。

命题 3.2.1 (积分的基本性质)

若 f, g 可积, $a, b \in \mathbb{R}$, 则:

1. $af + bg$ 可积, 且

$$\int (af + bg) d\mu = a \int f d\mu + b \int g d\mu;$$

2. 若 $f \leq g$ a.e., 则

$$\int f d\mu \leq \int g d\mu;$$

3.

$$\left| \int f d\mu \right| \leq \int |f| d\mu.$$



证明 对简单函数结论显然, 由上确界定义与单调逼近推广到非负可测函数; 再对一般可积函数分解为正负部分即可。第三条由

$$-|f| \leq f \leq |f|$$

和第二条直接推出。

3.2.2 单调收敛、Fatou 引理与控制收敛

定理 3.2.1 (单调收敛定理)

设 $\{f_n\}_{n \geq 1}$ 为非负可测函数列, 且

$$0 \leq f_1 \leq f_2 \leq \cdots, \quad f_n \uparrow f \text{ a.e.}$$

则

$$\int_{\Omega} f_n d\mu \uparrow \int_{\Omega} f d\mu.$$



证明 由单调性先得

$$\int f_n d\mu \leq \int f d\mu,$$

故左侧极限存在且不超过右侧。设

$$L := \sup_n \int f_n d\mu.$$

任取简单函数 φ 满足 $0 \leq \varphi \leq f$ 。对任意 $\varepsilon \in (0, 1)$, 考虑集合

$$E_n := \{ \omega : f_n(\omega) \geq (1 - \varepsilon)\varphi(\omega) \}.$$

由于 $f_n \uparrow f \geq \varphi$, 故 $1_{E_n} \uparrow 1$ 。于是由简单函数积分与测度从下连续性可得

$$\int (1 - \varepsilon)\varphi d\mu = \lim_{n \rightarrow \infty} \int_{E_n} (1 - \varepsilon)\varphi d\mu \leq \limsup_{n \rightarrow \infty} \int f_n d\mu = L.$$

令 $\varepsilon \downarrow 0$, 再对所有 $\varphi \leq f$ 取上确界, 得到

$$\int f d\mu \leq L.$$

结合前面的反向不等式, 结论成立。

引理 3.2.1 (Fatou 引理)

设 $\{f_n\}_{n \geq 1}$ 为非负可测函数列, 则

$$\int_{\Omega} \liminf_{n \rightarrow \infty} f_n d\mu \leq \liminf_{n \rightarrow \infty} \int_{\Omega} f_n d\mu.$$

证明 设

$$g_n := \inf_{k \geq n} f_k.$$

则 $\{g_n\}$ 仍为非负可测函数列, 且 $g_n \uparrow \liminf_{n \rightarrow \infty} f_n$ 。由定理 3.2.1,

$$\int \liminf_{n \rightarrow \infty} f_n d\mu = \lim_{n \rightarrow \infty} \int g_n d\mu.$$

又对每个固定 n 与任意 $k \geq n$, 都有 $g_n \leq f_k$, 故

$$\int g_n d\mu \leq \inf_{k \geq n} \int f_k d\mu.$$

令 $n \rightarrow \infty$ 即得结论。

定理 3.2.2 (控制收敛定理)

设 $\{f_n\}_{n \geq 1}$ 为可测函数列, 且

$$f_n \rightarrow f \text{ a.e.}, \quad |f_n| \leq g \text{ a.e.},$$

其中 g 可积。则 f 可积, 且

$$\int_{\Omega} f_n d\mu \rightarrow \int_{\Omega} f d\mu.$$

证明 由 $|f_n| \leq g$ 和逐点收敛可得 $|f| \leq g$ a.e., 故 f 可积。对非负函数列 $g + f_n$ 应用 Fatou 引理, 得

$$\int (g + f) d\mu \leq \liminf_{n \rightarrow \infty} \int (g + f_n) d\mu = \int g d\mu + \liminf_{n \rightarrow \infty} \int f_n d\mu.$$

从而

$$\int f d\mu \leq \liminf_{n \rightarrow \infty} \int f_n d\mu.$$

同理, 对非负函数列 $g - f_n$ 应用 Fatou 引理, 得到

$$\int (g - f) d\mu \leq \liminf_{n \rightarrow \infty} \int (g - f_n) d\mu = \int g d\mu - \limsup_{n \rightarrow \infty} \int f_n d\mu,$$

即

$$\limsup_{n \rightarrow \infty} \int f_n d\mu \leq \int f d\mu.$$

结合二者便得所求极限。

命题 3.2.2 (积分的绝对连续性)

若 $f \in L^1(\mu)$, 则对任意 $\varepsilon > 0$, 存在 $\delta > 0$, 使得只要 $A \in \mathcal{F}$ 且 $\mu(A) < \delta$, 就有

$$\int_A |f| d\mu < \varepsilon.$$

证明 取 $M > 0$ 使

$$\int_{\{|f|>M\}} |f| d\mu < \frac{\varepsilon}{2}.$$

再令 $\delta = \varepsilon/(2M)$ 。若 $\mu(A) < \delta$, 则

$$\int_A |f| d\mu = \int_{A \cap \{|f| \leq M\}} |f| d\mu + \int_{A \cap \{|f| > M\}} |f| d\mu \leq M\mu(A) + \frac{\varepsilon}{2} < \varepsilon.$$

例题 3.5 抽象例子：指标函数逼近 设 $A_n \uparrow A$, 则 $1_{A_n} \uparrow 1_A$ 。由定理 3.2.1 得

$$\mu(A_n) = \int 1_{A_n} d\mu \uparrow \int 1_A d\mu = \mu(A).$$

把这个例子放在这里, 是为了说明测度从下连续性其实是积分理论中最基本的单调收敛现象。

例题 3.6 有限维坍缩：随机向量的期望 若 X 是 $\mathbb{R}^n$ 值随机向量, $h: \mathbb{R}^n \rightarrow \mathbb{R}$ 可积, 则

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}^n} h(x) \mu_X(dx).$$

把这个例子放在这里, 是为了提醒读者 Boyd 书里常见的“期望目标函数”并不是一种独立算子, 而只是定义 3.2.2 在概率测度上的写法。

例题 3.7 应用触点：Monte Carlo 与风险泛函 设损失函数 L_n 由模拟近似得到, 且 $L_n \rightarrow L$ a.s., 同时存在可积上界 G 使 $|L_n| \leq G$ 。由定理 3.2.2,

$$\mathbb{E}[L_n] \rightarrow \mathbb{E}[L].$$

把这个例子放在这里, 是为了说明后文量化风险优化和分布鲁棒目标中, 控制收敛定理是“极限可推进期望号内”的最基本合法性来源。

有限维对照

有限维教材里, 人们经常把“对随机变量取期望”“把极限与期望交换”写成直观计算; 而在无穷维和函数空间中, 这些动作是否成立完全依赖定理 3.2.1、引理 3.2.1 和定理 3.2.2 所提供的条件链。

习题 (待补)

- 🔴 **练习 3.3 单调收敛占位** 补一题: 用定理 3.2.1 证明概率测度对递增事件列的从下连续性。
- 🔴 **练习 3.4 控制收敛桥接题占位** 补一题: 把例 3.7 落回欧氏空间中的随机向量积分, 说明控制上界在数值优化中为何常以矩条件或截断条件的形式出现。

3.3 拓扑空间上的测度

前两节给出的测度与积分理论, 还停留在纯集合论层面; 但在优化、概率和对偶理论中, 我们常常需要让测度与拓扑同时出现。一个典型场景是: 在某个状态空间上先有连续函数, 再考虑“对所有连续测试函数积分”所定义的线性泛函。若要把这种泛函解释成真正的测度, 就必须把拓扑结构纳入讨论。对本书而言, 最重要的环境是局部紧 Hausdorff 空间, 以及第 2.3 节已经建立的 Polish 空间框架; 前者适合陈述经典 Riesz 表示定理, 后者则保证了许多在随机分析里需要的可分性与正则性。

3.3.1 Borel 测度与 Radon 测度

设 X 为拓扑空间, 记其 Borel σ -代数为 $\mathcal{B}(X)$ 。定义在 $\mathcal{B}(X)$ 上的测度称为 X 上的 Borel 测度。仅有 Borel 性通常还不够, 因为它并不能保证测度与拓扑上的紧集、开集良好配合; 真正适合分析与优化的, 是正则性更强的 Radon 测度。

定义 3.3.1 (Radon 测度)

设 X 为局部紧 Hausdorff 空间。定义在 $\mathcal{B}(X)$ 上的 Borel 测度 μ 称为一个 Radon 测度，若满足：

1. 对每个紧集 $K \subseteq X$ ，都有 $\mu(K) < \infty$ ；
2. 对每个开集 $U \subseteq X$ ，有

$$\mu(U) = \sup\{\mu(K) : K \subseteq U, K \text{ 为紧集}\};$$

3. 对每个 Borel 集 $A \subseteq X$ ，有

$$\mu(A) = \inf\{\mu(U) : A \subseteq U, U \text{ 为开集}\}.$$

**为何强调第 2.3 节的 Polish 环境**

注 若 X 是定义 2.3.2 中的 Polish 空间，则其 Borel 结构具有很强的稳定性：在许多自然情形下，有限 Borel 测度自动具有良好的正则性。换言之，第 2.3 节并不是与测度论平行的一条支线，而是在为本节“测度与拓扑相容”提供常用环境。

命题 3.3.1 (Radon 测度的正则性)

设 X 为局部紧 Hausdorff 空间， μ 为 X 上的 Radon 测度。则对每个 Borel 集 $A \subseteq X$ 都有

$$\mu(A) = \sup\{\mu(K) : K \subseteq A, K \text{ 为紧集}\} = \inf\{\mu(U) : A \subseteq U, U \text{ 为开集}\}.$$

特别地，对任意 $\varepsilon > 0$ ，存在紧集 K 和开集 U 使

$$K \subseteq A \subseteq U, \quad \mu(U \setminus K) < \varepsilon.$$



证明 外正则性已包含在定义 3.3.1 中。下面说明内正则性可由开集内正则性推出。设

$$\mathcal{M} := \{A \in \mathcal{B}(X) : \mu(A) = \sup\{\mu(K) : K \subseteq A, K \text{ 为紧集}\}\}.$$

由定义可知所有开集都属于 $\mathcal{M}$ 。再利用测度对递增并与递减交的连续性，可以验证 $\mathcal{M}$ 对差集的适当操作和单调极限稳定，因此形成一个包含开集的单调类。由于开集生成 $\mathcal{B}(X)$ ，由单调类定理可知 $\mathcal{M} = \mathcal{B}(X)$ ，于是任意 Borel 集都内正则。

最后，给定 $\varepsilon > 0$ ，先由外正则性取开集 $U \supseteq A$ 使

$$\mu(U) \leq \mu(A) + \frac{\varepsilon}{2}.$$

再由开集的内正则性取紧集 $K \subseteq A$ 使

$$\mu(K) \geq \mu(A) - \frac{\varepsilon}{2}.$$

于是

$$\mu(U \setminus K) = \mu(U) - \mu(K) \leq \varepsilon,$$

结论成立。

3.3.2 连续函数上的正线性泛函

设 X 为局部紧 Hausdorff 空间，记 $C_c(X)$ 为所有紧支撑连续实函数组成的线性空间，记 $C_0(X)$ 为在无穷远处消失的连续函数空间。对优化与对偶理论而言，正线性泛函最值得关注：它们在函数空间对偶中扮演“非负乘子”的角色。

定义 3.3.2 (正线性泛函)

设 L 是定义在 $C_c(X)$ 或 $C_0(X)$ 上的线性泛函。若对任意满足 $f \geq 0$ 的函数 f 都有

$$L(f) \geq 0,$$

则称 L 为正线性泛函。



引理 3.3.1 (由正泛函诱导的集合函数)

设 L 为 $C_c(X)$ 上的正线性泛函。对开集 $U \subseteq X$ 定义

$$\nu(U) := \sup\{L(f) : f \in C_c(X), 0 \leq f \leq 1, \text{supp}(f) \subseteq U\}.$$

则 ν 在开集族上单调, 且对递增开集列满足

$$\nu\left(\bigcup_{n=1}^{\infty} U_n\right) = \lim_{n \rightarrow \infty} \nu(U_n).$$

证明 单调性由定义直接得出。若 $U_n \uparrow U$, 则显然 $\nu(U_n) \leq \nu(U)$, 故

$$\limsup_{n \rightarrow \infty} \nu(U_n) \leq \nu(U).$$

反过来, 任取 $f \in C_c(X)$, 满足 $0 \leq f \leq 1$ 且 $\text{supp}(f) \subseteq U$ 。由于 $\text{supp}(f)$ 为紧集, 而 $\{U_n\}$ 递增覆盖 U , 存在某个 N 使 $\text{supp}(f) \subseteq U_N$ 。故

$$L(f) \leq \nu(U_N) \leq \sup_n \nu(U_n).$$

对所有这类 f 取上确界, 得到

$$\nu(U) \leq \sup_n \nu(U_n) = \lim_{n \rightarrow \infty} \nu(U_n).$$

二者合并即得结论。

3.3.3 Riesz 表示定理**定理 3.3.1 (Riesz 表示定理)**

设 X 为局部紧 Hausdorff 空间, L 为 $C_c(X)$ 上的正线性泛函。则存在唯一的 Radon 测度 μ , 使得对任意 $f \in C_c(X)$ 都有

$$L(f) = \int_X f d\mu.$$

若进一步把 L 看作 $C_0(X)$ 上的有界正线性泛函, 则同一结论成立, 且

$$\|L\| = \mu(X)$$

在 $\mu(X) < \infty$ 时有效。

证明 证明分三步进行。

第一步, 由引理 3.3.1 在开集上构造集合函数 ν 。再对任意集合 $A \subseteq X$ 定义

$$\mu^*(A) := \inf\{\nu(U) : A \subseteq U, U \text{ 为开集}\}.$$

由定义可知 $\mu^*(\emptyset) = 0$ 且单调。利用开集的可数覆盖与引理 3.3.1 的递增连续性, 可以验证 μ^* 是一个外测度。

第二步, 对 μ^* 应用定理 3.1.1。由于开集在构造中扮演基础角色, 而连续函数可用局部紧 Hausdorff 空间上的 Urysohn 型截断函数逼近, 能够验证所有开集都是 Carathéodory 可测的, 从而 $\mathcal{B}(X) \subseteq \mathcal{M}(\mu^*)$ 。于是 $\mu := \mu^*|_{\mathcal{B}(X)}$ 成为一个 Borel 测度。再由定义可知 μ 对开集外正则; 而由 ν 的定义与紧支撑函数逼近, 可以推出对开集的内正则和对紧集的有限性, 因此 μ 是 Radon 测度。

第三步, 证明积分表示。对满足 $0 \leq f \leq 1$ 的紧支撑连续函数, 先用层析逼近和简单函数近似比较 $L(f)$ 与 $\int f d\mu$, 得到二者相等; 再由线性性推广到一般实值 $f \in C_c(X)$ 。唯一性来自这样的事实: 若两个 Radon 测度对所有 $f \in C_c(X)$ 的积分都相等, 则它们对开集的取值相同, 从而由命题 3.3.1 对所有 Borel 集都相同。

“泛函 = 测度”的第一座桥

注 定理 3.3.1 说明, 连续函数空间上的正泛函并不是神秘的抽象对偶元素, 而可以唯一解释为某个 Radon 测度的积分算子。这一步会在后文至少以三种形式回归: 其一是在对偶理论里把正约束乘子解释成测度; 其二是在

最优控制里把轨道分布、占据测度与线性泛函联系起来；其三是在概率论中把期望写成对概率测度的积分。

例题 3.8 抽象例子：Dirac 测度与点值泛函 对任意固定 $x_0 \in X$ ，定义

$$L_{x_0}(f) := f(x_0), \quad f \in C_c(X).$$

这是一个正线性泛函。由定理 3.3.1，它对应的 Radon 测度正是 Dirac 测度 δ_{x_0} 。把这个例子放在这里，是为了说明最简单的“泛函 = 测度”并不是平均，而是点值本身；这也是后文极点、分布和采样算子的基本原型。

例题 3.9 有限维坍缩：欧氏空间中的积分泛函 取 $X = \mathbb{R}^n$ 。若 $g \in L^1_{\text{loc}}(\mathbb{R}^n)$ 且 $g \geq 0$ ，则

$$L(f) := \int_{\mathbb{R}^n} f(x)g(x) dx, \quad f \in C_c(\mathbb{R}^n),$$

定义了一个正线性泛函。这里对应的 Radon 测度就是 $\mu(dx) = g(x) dx$ 。把这个例子放在这里，是为了说明有限维教材中最熟悉的“加权积分”其实已经是 Riesz 表示定理的特殊情形。

例题 3.10 应用触点：测度型乘子与占据测度 在连续时间控制与分布鲁棒优化中，约束往往不是有限个标量不等式，而是对一族测试函数同时成立的积分关系。此时拉格朗日乘子自然不再是向量，而是某种 Radon 测度。把这个例子放在这里，是为了说明定理 3.3.1 并非只服务于纯分析，它直接决定了后文 KKT 条件里乘子的对象类型。

有限维对照

在有限维空间里，人们常把线性泛函写成向量内积，把概率或权重写成密度函数，于是“泛函等于积分”这件事显得理所当然。本节把这种直觉放回一般拓扑空间中，并用定义 3.3.1、命题 3.3.1 和定理 3.3.1 说明：只有当测度具有足够的正则性时，这种解释才真正稳固。

习题（待补）

- 练习 3.5 Dirac 测度占位 补一题：证明例 3.8 中的点值泛函对应的确是 Dirac 测度，并据此验证定理 3.3.1 的唯一性在该情形下如何显现。
- 练习 3.6 有限维桥接题占位 补一题：在 $X = \mathbb{R}^n$ 上，从例 3.9 出发验证命题 3.3.1，说明 Lebesgue 测度为何是一个 Radon 测度。

3.4 概率空间与随机过程微积分初步

前面三节已经准备好了事件、积分与拓扑测度的语言，但连续时间优化还需要进一步回答三个问题：随机对象怎样随时间演化，信息怎样逐步显露，噪声如何进入动力系统。为此，本节从概率空间与随机变量出发，经过条件期望、滤过、鞅与停时，最终进入 Brownian motion、Itô 积分与 Itô 公式。目标不是写成一部完整随机分析专著，而是建立后续最优控制、量化交易与路径空间优化真正会调用的最小语法。

3.4.1 概率空间、随机变量与条件期望

定义 3.4.1 (概率空间)

三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ 称为一个概率空间，若 $(\Omega, \mathcal{F})$ 是可测空间，且 $\mathbb{P}$ 是满足

$$\mathbb{P}(\Omega) = 1$$

的测度。定义在 $(\Omega, \mathcal{F})$ 上、取值于某个可测空间 $(E, \mathcal{E})$ 的可测映射 $X: \Omega \rightarrow E$ 称为一个随机变量。

期望只是积分

注 一旦概率空间被固定，随机变量的期望只是第 3.2 节 Lebesgue 积分的特殊记号：

$$\mathbb{E}[X] = \int_{\Omega} X d\mathbb{P}.$$

因此所有与极限交换有关的合法性，本质上都回到定理 3.2.1、引理 3.2.1 与定理 3.2.2。

定义 3.4.2 (条件期望)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数, $X \in L^1(\mathbb{P})$ 。若随机变量 Y 满足:

1. Y 是 $\mathcal{G}$ -可测的;
2. 对任意 $A \in \mathcal{G}$, 都有

$$\int_A Y d\mathbb{P} = \int_A X d\mathbb{P},$$

则称 Y 为 X 关于 $\mathcal{G}$ 的条件期望, 记为

$$Y = \mathbb{E}[X | \mathcal{G}].$$

命题 3.4.1 (条件期望的基本性质)

设 $X, Y \in L^1(\mathbb{P})$, $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数, 则:

1. $\mathbb{E}[X | \mathcal{G}]$ 在几乎处处意义下唯一;
2. 条件期望关于 X 线性;
3. 若 X 本身 $\mathcal{G}$ -可测, 则

$$\mathbb{E}[X | \mathcal{G}] = X \quad \text{a.s.};$$

4. 若 $X \geq 0$ a.s., 则

$$\mathbb{E}[X | \mathcal{G}] \geq 0 \quad \text{a.s.};$$

5. 塔性质成立: 若 $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$, 则

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}] \quad \text{a.s.}$$

证明 唯一性来自这样一个事实: 若 Y_1, Y_2 都满足定义 3.4.2, 则对任意 $A \in \mathcal{G}$ 有

$$\int_A (Y_1 - Y_2) d\mathbb{P} = 0.$$

取 $A = \{Y_1 > Y_2\} \in \mathcal{G}$ 与 $A = \{Y_2 > Y_1\}$ 即得 $Y_1 = Y_2$ a.s.。线性与正性由积分恒等式直接验证。若 X 是 $\mathcal{G}$ -可测, 则它自己就满足定义中的两条。塔性质只需对任意 $A \in \mathcal{H}$ 比较积分:

$$\int_A \mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] d\mathbb{P} = \int_A \mathbb{E}[X | \mathcal{G}] d\mathbb{P} = \int_A X d\mathbb{P}.$$

故该随机变量满足 $\mathbb{E}[X | \mathcal{H}]$ 的刻画。

3.4.2 独立性、滤过、适应过程与鞅

定义 3.4.3 (独立性、滤过与适应性)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间。

1. 两个子 σ -代数 $\mathcal{G}_1, \mathcal{G}_2 \subseteq \mathcal{F}$ 称为独立的, 若对任意 $A \in \mathcal{G}_1$ 、 $B \in \mathcal{G}_2$, 有

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B).$$

2. 一族子 σ -代数 $\{\mathcal{F}_t\}_{t \geq 0}$ 若满足 $s \leq t$ 时

$$\mathcal{F}_s \subseteq \mathcal{F}_t,$$

则称其为一个滤过。

3. 过程 $X = \{X_t\}_{t \geq 0}$ 若对每个 t , X_t 都是 $\mathcal{F}_t$ -可测的, 则称 X 对该滤过适应。

定义 3.4.4 (鞅)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 配有滤过 $\{\mathcal{F}_t\}_{t \geq 0}$ 。若过程 $M = \{M_t\}_{t \geq 0}$ 满足:

1. M 适应于 $\{\mathcal{F}_t\}$;
2. 对每个 t , 有 $M_t \in L^1(\mathbb{P})$;
3. 对任意 $0 \leq s \leq t$, 有

$$\mathbb{E}[M_t | \mathcal{F}_s] = M_s \quad \text{a.s.},$$

则称 M 为一个鞅。若上式中的等号分别改成“ $\geq$ ”或“ $\leq$ ”, 则得到次鞅与上鞅。

定义 3.4.5 (停时)

设给定滤过 $\{\mathcal{F}_t\}_{t \geq 0}$ 。随机变量 $\tau: \Omega \rightarrow [0, \infty]$ 称为一个停时, 若对每个 $t \geq 0$,

$$\{\tau \leq t\} \in \mathcal{F}_t.$$

命题 3.4.2 (停时与鞅的基本前瞻)

设 M 为离散时间鞅, τ 为有界停时, 则停时过程 $\{M_{n \wedge \tau}\}$ 仍为鞅, 因而

$$\mathbb{E}[M_\tau] = \mathbb{E}[M_0].$$

证明 对每个 n , 变量 $M_{n \wedge \tau}$ 对 $\mathcal{F}_n$ 可测且可积。再由分解

$$M_{(n+1) \wedge \tau} = M_n 1_{\{\tau \leq n\}} + M_{n+1} 1_{\{\tau > n\}}$$

并对 $\mathcal{F}_n$ 取条件期望, 利用 $\{\tau > n\} \in \mathcal{F}_n$ 和定义 3.4.4 的鞅性质即可得到

$$\mathbb{E}[M_{(n+1) \wedge \tau} | \mathcal{F}_n] = M_{n \wedge \tau}.$$

从而停时过程仍为鞅。再取期望便得结论。

3.4.3 Brownian motion 与 Itô 积分**定义 3.4.6 (Brownian motion)**

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间, 过程 $W = \{W_t\}_{t \geq 0}$ 称为一个 *Brownian motion*, 若满足:

1. $W_0 = 0$ a.s.;
2. W 具有独立增量: 对任意 $0 \leq t_0 < t_1 < \cdots < t_n$, 随机变量

$$W_{t_1} - W_{t_0}, \dots, W_{t_n} - W_{t_{n-1}}$$

相互独立;

3. $W_t - W_s \sim N(0, t-s)$ 对任意 $0 \leq s < t$ 成立;
4. 样本路径几乎处处连续。

例题 3.11 有限维高斯坍缩 对任意 $0 < t_1 < \cdots < t_n$, 向量

$$(W_{t_1}, \dots, W_{t_n})$$

是中心高斯向量, 其协方差矩阵为 $(\min\{t_i, t_j\})_{i,j}$ 。把这个例子放在这里, 是为了说明 Brownian motion 可以看成一族彼此相容的有限维高斯向量在时间上的连续拼接。

定义 3.4.7 (简单适应过程上的 Itô 积分)

设 W 是适应于滤过 $\{\mathcal{F}_t\}$ 的 Brownian motion, $T > 0$ 。若过程 H 具有形式

$$H_t(\omega) = \sum_{k=0}^{n-1} \xi_k(\omega) 1_{(t_k, t_{k+1}]}(t),$$

其中 $0 = t_0 < t_1 < \dots < t_n = T$, 且每个 ξ_k 都是 $\mathcal{F}_{t_k}$ -可测并满足 $\mathbb{E}[\xi_k^2] < \infty$, 则称 H 为简单适应过程, 并定义其 Itô 积分为

$$\int_0^T H_t dW_t := \sum_{k=0}^{n-1} \xi_k (W_{t_{k+1}} - W_{t_k}).$$

借助 $L^2(\Omega \times [0, T])$ 完备化, 可将该定义延拓到所有平方可积适应过程。

命题 3.4.3 (Itô 等距)

对任意简单适应过程 H , 都有

$$\mathbb{E} \left[\left(\int_0^T H_t dW_t \right)^2 \right] = \mathbb{E} \left[\int_0^T |H_t|^2 dt \right].$$

因此 Itô 积分是从平方可积适应过程空间到 $L^2(\Omega)$ 的等距映射。

证明 对定义 3.4.7 中的简单过程展开平方, 得到

$$\left(\sum_{k=0}^{n-1} \xi_k \Delta W_k \right)^2 = \sum_{k=0}^{n-1} \xi_k^2 (\Delta W_k)^2 + 2 \sum_{i < j} \xi_i \xi_j \Delta W_i \Delta W_j,$$

其中 $\Delta W_k := W_{t_{k+1}} - W_{t_k}$ 。由于 Brownian motion 具有独立增量, 且 ΔW_j 与 $\mathcal{F}_{t_j}$ 独立、均值为零, 交叉项取期望后消失。于是

$$\mathbb{E} \left[\left(\int_0^T H_t dW_t \right)^2 \right] = \sum_{k=0}^{n-1} \mathbb{E}[\xi_k^2] (t_{k+1} - t_k) = \mathbb{E} \left[\int_0^T |H_t|^2 dt \right].$$

结论成立。

3.4.4 Itô 公式与最小量级的随机微分方程

定理 3.4.1 (Itô 公式)

设 W 为 Brownian motion, 过程 X 满足

$$X_t = X_0 + \int_0^t b_s ds + \int_0^t \sigma_s dW_s,$$

其中 b, σ 为适应过程, 并满足使两项积分有意义的可积条件。若 $f \in C^{1,2}([0, T] \times \mathbb{R})$, 则对任意 $t \in [0, T]$,

$$f(t, X_t) = f(0, X_0) + \int_0^t \partial_t f(s, X_s) ds + \int_0^t \partial_x f(s, X_s) b_s ds + \int_0^t \partial_x f(s, X_s) \sigma_s dW_s + \frac{1}{2} \int_0^t \partial_{xx} f(s, X_s) \sigma_s^2 ds.$$

证明 先对时间区间做剖分, 对每个小区间应用二元 Taylor 展开:

$$f(t_{k+1}, X_{t_{k+1}}) - f(t_k, X_{t_k})$$

分解为时间增量、一阶空间增量和二阶空间增量, 再把高阶余项控制到零。关键在于

$$(\Delta W_k)^2 \approx \Delta t_k, \quad \Delta W_k \Delta t_k, (\Delta t_k)^2$$

在求和极限下都比 Δt_k 更高阶, 因此只保留二阶项中的二次变差贡献。对随机项与确定项分别取极限, 便得到公式。严格论证通常先对简单过程验证, 再用 Itô 等距与 L^2 逼近推广。

例题 3.12 二次函数的 Itô 公式 取 $X_t = W_t$, $f(x) = x^2$ 。由定理 3.4.1,

$$W_t^2 = 2 \int_0^t W_s dW_s + t.$$

把这个例子放在这里, 是为了突出随机微积分与经典微积分最本质的差别: 额外出现的 t 项正来自 Brownian motion 的二次变差。

例题 3.13 应用触点：几何 Brownian motion 考虑随机微分方程

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad S_0 > 0.$$

对 $f(x) = \log x$ 应用定理 3.4.1，可得

$$d(\log S_t) = \left(\mu - \frac{\sigma^2}{2} \right) dt + \sigma dW_t,$$

从而

$$S_t = S_0 \exp \left(\left(\mu - \frac{\sigma^2}{2} \right) t + \sigma W_t \right).$$

把这个例子放在这里，是为了说明第 11 章中的连续时间金融建模和随机控制并不需要额外发明一套新分析，而是直接建立在 Itô 公式之上。

有限维对照

有限维随机优化通常只显式书写随机向量、协方差矩阵和期望目标；连续时间情形则把“随机向量”替换成路径过程，把“矩阵演化”替换成 Itô 驱动的动力系统。本节的作用，是把这种升维过程中真正新增的结构明确标出：定义 3.4.2 给出信息更新，定义 3.4.4 给出公平演化，定义 3.4.6 与定义 3.4.7 给出噪声与积分，而定理 3.4.1 则是连续时间随机优化的链式法则。

习题（待补）

- 🔥 **练习 3.7 条件期望占位** 补一题：在离散有限样本空间上显式计算条件期望，并验证命题 3.4.1 的塔性质。
- 🔥 **练习 3.8 Itô 公式桥接题占位** 补一题：从例 3.13 出发，验证几何 Brownian motion 的显式解，并说明其如何退化为常微分方程

$$\dot{x}_t = \mu x_t$$

的有限维无噪声版本。

第 4 章 泛函分析与算子代数

如果说第 1 章解决的是“在什么拓扑环境里谈极限”，第 2 章解决的是“在什么可测环境里谈积分与随机性”，那么本章要回答的就是：一旦真正进入无穷维优化，计算和证明究竟在哪些线性空间里发生。有限维凸优化把大多数结构都藏在矩阵与欧氏内积后面；到了无穷维，范数、对偶、弱拓扑、伴随和谱必须被分别说清，否则存在性、对偶性与算法收敛就会停留在口号层面。

本章围绕四条主线展开。第 4.1 节先建立 Banach 空间与 Hilbert 空间的几何工作台，说明完备性、正交分解和 Riesz 表示为何是后文分析与算法的基础接口。第 4.2 节把视角切换到弱拓扑与弱* 拓扑，给出 Banach–Alaoglu 定理以及自反空间中的弱紧性结论，从而为直接法与极小值存在准备真正可用的紧性语言。第 4.3 节再把矩阵转置升级为伴随算子，把约束映射、对偶变量与最优控制中的共轭系统统一到一个框架里。最后第 4.4 节只保留与优化直接相关的谱论工具：谱、紧算子、自伴算子、正算子以及紧自伴情形下的谱定理。

阅读本章时，需要始终区分三层环境。一般 Banach 空间足以承载凸泛函、对偶映射和有界线性算子；自反 Banach 空间开始提供弱紧性，这是存在性论证的关键台阶；Hilbert 空间则在此基础上额外拥有内积几何、正交投影与更强的谱工具，因此成为邻近算法、分裂方法和二次型分析的天然舞台。后文关于极小值存在、KKT 条件、Fenchel–Rockafellar 对偶与算子分裂算法的许多核心步骤，都会直接回链到本章。

4.1 Banach 空间与 Hilbert 空间

无穷维优化首先面对的，不是某个具体算法，而是“变量究竟生活在哪个空间里”这一基础问题。有限维情形中，范数等价、闭有界集紧、线性泛函都能写成内积，这些事实使许多几何结构被自动隐藏。到了无穷维，赋范空间、Banach 空间与 Hilbert 空间之间的差别必须被明确区分：前者提供基本的线性与连续性框架，第二层加入完备性，第三层再加入内积几何与正交分解。后文中的邻近映射、投影算法、最小二乘和算子谱分解，都建立在这种层级区分之上。

4.1.1 赋范空间与完备性

定义 4.1.1 (赋范空间)

设 X 为实或复线性空间。若映射 $\|\cdot\|: X \rightarrow [0, \infty)$ 满足：

1. $\|x\| = 0$ 当且仅当 $x = 0$ ；
2. 对任意标量 λ 与任意 $x \in X$ ，有

$$\|\lambda x\| = |\lambda| \|x\|;$$

3. 对任意 $x, y \in X$ ，有

$$\|x + y\| \leq \|x\| + \|y\|,$$

则称 $(X, \|\cdot\|)$ 为一个赋范空间。由范数诱导的度量记为

$$d(x, y) := \|x - y\|.$$

定义 4.1.2 (Banach 空间)

若赋范空间 $(X, \|\cdot\|)$ 在由定义 4.1.1 诱导的度量下完备，则称 X 为一个 Banach 空间。

完备性的作用，不只是保证 Cauchy 列有极限。更重要的是，它使闭图像、开映射、一致有界等基本定理可以成立，而这些结果又反过来控制算子方程、最优性条件与极值存在的稳定性。第 2.2 节中的 Baire 范畴方法，正是这种完备性力量的拓扑来源。

例题 4.1 函数空间的几何分层 对 $1 \leq p \leq \infty$, 空间 ℓ^p 与 L^p 都是 Banach 空间; 其中只有 $p = 2$ 时, 它们由内积

$$\langle x, y \rangle = \sum_{n=1}^{\infty} x_n \overline{y_n}, \quad \langle f, g \rangle = \int f \overline{g} d\mu$$

诱导范数, 因此是 Hilbert 空间。把这个例子放在这里, 是为了强调“完备”并不自动意味着“可做正交分解”; 许多后文只在 Hilbert 空间成立的算法结论, 在 L^1 或 ℓ^∞ 中就必须改写。

4.1.2 内积、正交与 Hilbert 空间

定义 4.1.3 (Hilbert 空间)

设 H 为实或复线性空间, $\langle \cdot, \cdot \rangle$ 为 H 上的内积, 范数由

$$\|x\| := \langle x, x \rangle^{1/2}$$

给出。若 $(H, \|\cdot\|)$ 完备, 则称 H 为一个 Hilbert 空间。

在 Hilbert 空间中, 内积不仅给出范数, 还把“方向”“垂直”“投影”“最短距离”这些欧氏概念全部带回了无穷维环境。设 $M \subset H$ 为非空子集, 定义其正交补为

$$M^\perp := \{x \in H : \langle x, y \rangle = 0, \forall y \in M\}.$$

当 M 是线性子空间时, $M^\perp$ 也是闭线性子空间, 并且几何上对应于“所有与 M 垂直的方向”。

命题 4.1.1 (正交补的基本性质)

设 H 为 Hilbert 空间, $M \subset H$ 为任意非空子集, 则 $M^\perp$ 是 H 的闭线性子空间。若 M 本身是线性子空间, 则

$$\overline{M} \cap M^\perp = \{0\}.$$

证明 对任意 $y \in M$, 映射 $x \mapsto \langle x, y \rangle$ 是连续线性泛函, 因此集合

$$\{x \in H : \langle x, y \rangle = 0\}$$

是闭线性子空间。于是

$$M^\perp = \bigcap_{y \in M} \{x \in H : \langle x, y \rangle = 0\}$$

仍为闭线性子空间。若 $x \in \overline{M} \cap M^\perp$, 取 M 中列 $x_n \rightarrow x$, 由内积连续性得

$$\langle x, x \rangle = \lim_{n \rightarrow \infty} \langle x, x_n \rangle = 0,$$

故 $x = 0$ 。

定理 4.1.1 (Hilbert 空间中的投影定理)

设 H 为 Hilbert 空间, $M \subset H$ 为非空闭线性子空间。则对任意 $x \in H$, 存在唯一元素 $P_M x \in M$ 使

$$\|x - P_M x\| = \inf_{y \in M} \|x - y\|.$$

并且该极小元满足正交条件

$$x - P_M x \in M^\perp.$$

因此每个 $x \in H$ 都可以唯一写成

$$x = P_M x + (x - P_M x), \quad P_M x \in M, \quad x - P_M x \in M^\perp.$$

证明 记

$$d := \inf_{y \in M} \|x - y\|.$$

取极小化列 $(y_n) \subset M$ 使 $\|x - y_n\| \rightarrow d$ 。由平行四边形恒等式,

$$\left\|x - \frac{y_n + y_m}{2}\right\|^2 + \left\|\frac{y_n - y_m}{2}\right\|^2 = \frac{1}{2}\|x - y_n\|^2 + \frac{1}{2}\|x - y_m\|^2.$$

因为 M 线性且闭, 所以 $(y_n + y_m)/2 \in M$, 从而第一项不小于 d^2 。于是

$$\left\|\frac{y_n - y_m}{2}\right\|^2 \leq \frac{1}{2}\|x - y_n\|^2 + \frac{1}{2}\|x - y_m\|^2 - d^2 \rightarrow 0.$$

故 (y_n) 是 Cauchy 列。由 M 完备, 存在 $y_* \in M$ 使 $y_n \rightarrow y_*$ 。连续性给出

$$\|x - y_*\| = d,$$

这证明了存在性。记 $P_M x := y_*$ 。

下证正交条件。任取 $z \in M$, 对任意实数 t , 因为 $P_M x + tz \in M$,

$$\|x - P_M x\|^2 \leq \|x - P_M x - tz\|^2 = \|x - P_M x\|^2 - 2t \operatorname{Re}\langle x - P_M x, z \rangle + t^2 \|z\|^2.$$

这对所有实数 t 成立, 只能说明

$$\operatorname{Re}\langle x - P_M x, z \rangle = 0.$$

在复 Hilbert 空间中再将 z 替换为 iz , 便得虚部也为零, 因此

$$\langle x - P_M x, z \rangle = 0, \quad \forall z \in M.$$

故 $x - P_M x \in M^\perp$ 。

唯一性由 $\overline{M} \cap M^\perp = \{0\}$ 推出。若

$$x = y_1 + z_1 = y_2 + z_2, \quad y_i \in M, z_i \in M^\perp,$$

则 $y_1 - y_2 = z_2 - z_1 \in M \cap M^\perp$, 从而 $y_1 = y_2, z_1 = z_2$ 。

为何投影定理对算法重要

注 定理 4.1.1 是 Hilbert 空间算法几何的起点。后文的邻近算子、投影梯度法和算子分裂方法, 本质上都依赖“最近点存在且可由正交条件刻画”这一结构。若只处在一般 Banach 空间, 这种几何就不再自动存在, 算法设计也会明显更微妙。

例题 4.2 欧氏空间中的正交投影 设 $H = \mathbb{R}^n$, M 为某个线性子空间, 取一组正交规范基组成矩阵 Q , 则

$$P_M x = QQ^T x.$$

把这个例子放在这里, 是为了把定理 4.1.1 退回 Boyd 书中最熟悉的矩阵公式: 无穷维投影定理并不是新对象, 而是欧氏正交投影的真正上位版本。

4.1.3 Hilbert 空间的 Riesz 表示定理

定理 4.1.2 (Hilbert 空间的 Riesz 表示定理)

设 H 为 Hilbert 空间。则对每个连续线性泛函 $\varphi \in H^*$, 存在唯一的元素 $y \in H$, 使得

$$\varphi(x) = \langle x, y \rangle, \quad \forall x \in H.$$

并且

$$\|\varphi\| = \|y\|.$$

因此映射

$$J: H \rightarrow H^*, \quad y \mapsto \langle \cdot, y \rangle$$

是一个等距同构; 在复 Hilbert 空间中, 它是共轭线性的。

证明 若 $\varphi = 0$, 取 $y = 0$ 即可。现设 $\varphi \neq 0$ 。则 $\ker \varphi$ 是闭真子空间。由定理 4.1.1 应用于 $M = \ker \varphi$, 可得存在

非零向量 $u \in (\ker \varphi)^\perp$ 。任取 $x \in H$ ，将其分解为

$$x = z + \lambda u, \quad z \in \ker \varphi, \lambda \in \mathbb{F}.$$

因为 $z \in \ker \varphi$ ，有

$$\varphi(x) = \lambda \varphi(u).$$

另一方面，由 $u \perp z$ 得

$$\lambda = \frac{\langle x, u \rangle}{\|u\|^2}.$$

故

$$\varphi(x) = \frac{\varphi(u)}{\|u\|^2} \langle x, u \rangle.$$

若取

$$y = \begin{cases} \frac{\overline{\varphi(u)}}{\|u\|^2} u, & \text{复 Hilbert 空间,} \\ \frac{\varphi(u)}{\|u\|^2} u, & \text{实 Hilbert 空间,} \end{cases}$$

便有 $\varphi(x) = \langle x, y \rangle$ 对所有 x 成立。

唯一性是显然的：若 $\langle x, y_1 \rangle = \langle x, y_2 \rangle$ 对所有 x 成立，则

$$\langle x, y_1 - y_2 \rangle = 0, \quad \forall x \in H.$$

令 $x = y_1 - y_2$ 即得 $y_1 = y_2$ 。

最后证明范数恒等式。由 Cauchy-Schwarz 不等式，

$$|\varphi(x)| = |\langle x, y \rangle| \leq \|x\| \|y\|,$$

故 $\|\varphi\| \leq \|y\|$ 。反过来，若 $y \neq 0$ ，取 $x = y/\|y\|$ ，则

$$\|\varphi\| \geq |\varphi(x)| = \left| \left\langle \frac{y}{\|y\|}, y \right\rangle \right| = \|y\|.$$

若 $y = 0$ 则结论平凡。故 $\|\varphi\| = \|y\|$ 。

Riesz 表示与后文伴随算子

注 定理 4.1.2 的真正作用，是把 Hilbert 空间的对偶重新识别为原空间本身。第 4.3 节中的 Hilbert 伴随算子，正是通过这一识别把 Banach 空间中的对偶伴随 $T^*: Y^* \rightarrow X^*$ 拉回成 $T^*: H_2 \rightarrow H_1$ 。

例题 4.3 最小二乘与邻近映射触点 在 Hilbert 空间 H 中，给定闭线性子空间 M ，最小二乘问题

$$\min_{y \in M} \|x - y\|^2$$

的解就是 $P_M x$ 。更一般地，对闭凸集 C ，最近点映射是后文邻近算子的几何原型。把这个例子放在这里，是为了说明第 9 章与第 10 章算法里的“prox”并不是凭空出现，而是投影定理在更一般凸泛函上的延伸。

有限维对照

当 $H = \mathbb{R}^n$ 时，定义 4.1.3 与通常欧氏空间完全一致，定理 4.1.1 退化为正交投影矩阵，定理 4.1.2 则退化为“每个线性泛函都可写成向量内积”。有限维凸优化中的最小二乘、法方程和正交分解，都只是本节结论在欧氏空间中的特例。

习题（待补）

 **练习 4.1 投影定理的矩阵版占位** 补一题：把定理 4.1.1 落回 $\mathbb{R}^n$ ，证明当 $M = \text{range}(Q)$ 且 Q 的列向量正交规范时，投影算子满足 $P_M = QQ^\top$ 。

 **练习 4.2 Banach 与 Hilbert 的桥接题占位** 补一题：比较 ℓ^1 、 ℓ^2 与 ℓ^∞ 中最近点问题的行为，说明为什么 Hilbert 空间中的正交几何不能无条件推广到一般 Banach 空间。

4.2 弱拓扑与弱星拓扑

第 4.1 节建立了 Banach 与 Hilbert 的几何工作台，但仅靠范数拓扑并不足以处理无穷维极值存在。一个基本困难是：在无限维 Banach 空间中，闭有界集通常并不紧，因此“取极小化列，再抽收敛子列”的有限维套路会直接失效。要恢复紧性，我们必须引入比范数拓扑更弱的拓扑结构。弱拓扑与弱*拓扑正是在这种背景下出现的：它们牺牲部分收敛强度，换来对偶球或有界集上的紧性，从而为直接法、对偶性和乘子理论提供可操作的极限机制。

4.2.1 由函数族诱导的最弱拓扑

设 X 为集合， $\{f_i\}_{i \in I}$ 是一族映射 $f_i: X \rightarrow Y_i$ ，其中每个 Y_i 都带有拓扑。使所有 f_i 连续的最弱拓扑称为由这族函数诱导的初始拓扑。弱拓扑与弱*拓扑正是把所有连续线性泛函当作坐标函数所得到的初始拓扑。

定义 4.2.1 (弱拓扑)

设 X 为赋范空间。由对偶空间 X^* 中全体连续线性泛函诱导的最弱拓扑，称为 X 上的弱拓扑，记为 $\sigma(X, X^*)$ 。换言之，弱拓扑是使每个

$$\varphi \in X^*, \quad \varphi: X \rightarrow \mathbb{F}$$

都连续的最弱拓扑。

定义 4.2.2 (弱星拓扑)

设 X 为赋范空间。由典范嵌入

$$\hat{x}: X^* \rightarrow \mathbb{F}, \quad \hat{x}(f) = f(x), \quad x \in X,$$

所诱导的 X^* 上的最弱拓扑，称为 X^* 上的弱*拓扑，记为 $\sigma(X^*, X)$ 。

这两个拓扑的定义形式相近，但角色并不相同。弱拓扑使用的是 X^* 中的全部连续线性泛函，因此是 X 本身的拓扑；弱*拓扑只使用来自原空间 X 的评价泛函，因此是对偶空间 X^* 上更弱的一种拓扑。Banach-Alaoglu 定理给出的紧性恰恰发生在后者上。

弱收敛为何必须用网

注 由定义 4.2.1 与定义 4.2.2 可知，弱与弱*收敛本质上是“所有坐标泛函逐点收敛”。但这些拓扑一般并非第一可数，因此不能安全地只谈序列。正如第 2.1 节定义 2.1.2 所揭示的，一旦失去第一可数性，闭包和紧性就必须回到网语言。后文凡使用 Banach-Alaoglu 定理抽取极限点时，都应理解为“存在收敛子网”，而不是未经说明地退回子列。

命题 4.2.1 (弱收敛与弱星收敛的判别)

设 X 为赋范空间。

1. 网 $x_\alpha \rightarrow x$ 在 $\sigma(X, X^*)$ 下收敛，当且仅当对每个 $\varphi \in X^*$ 都有

$$\varphi(x_\alpha) \rightarrow \varphi(x).$$

2. 网 $f_\alpha \rightarrow f$ 在 $\sigma(X^*, X)$ 下收敛，当且仅当对每个 $x \in X$ 都有

$$f_\alpha(x) \rightarrow f(x).$$

证明 这是初始拓扑的直接刻画：网在初始拓扑下收敛，当且仅当其经所有坐标映射后的像网都收敛。这里的坐标映射分别是 $\varphi \in X^*$ 与 $\hat{x} \in (X^*)^*$ 。

4.2.2 典范嵌入与自反性

定义 4.2.3 (自反空间)

设 X 为赋范空间。定义典范嵌入

$$J_X: X \rightarrow X^{**}, \quad J_X(x)(\varphi) = \varphi(x), \quad \varphi \in X^*.$$

若 J_X 为满射, 则称 X 为自反空间。

命题 4.2.2 (典范嵌入是等距嵌入)

设 X 为赋范空间, 则 J_X 线性且满足

$$\|J_X(x)\| = \|x\|, \quad \forall x \in X.$$

因此 X 可以等距地看成 X^{**} 的闭子空间。

证明 线性由定义直接得到。对任意 $x \in X$,

$$\|J_X(x)\| = \sup_{\|\varphi\| \leq 1} |J_X(x)(\varphi)| = \sup_{\|\varphi\| \leq 1} |\varphi(x)| \leq \|x\|.$$

反向不等式可由 Hahn–Banach 定理得到: 对任意 $x \neq 0$, 存在 $\varphi \in X^*$ 使 $\|\varphi\| = 1$ 且 $\varphi(x) = \|x\|$, 于是 $\|J_X(x)\| \geq \|x\|$. 故二者相等。

自反性的优化含义

注 自反性不是纯粹的空间分类术语。它意味着原空间的有界集能通过典范嵌入进入双对偶的弱*紧框架, 再拉回到原空间自身, 从而把 Banach–Alaoglu 定理转化为原空间中的弱紧性。这正是无穷维极小值存在论证里最常用的路径。

4.2.3 Banach–Alaoglu 定理与弱紧性

前面的讨论已经把弱*拓扑放到了正确位置: 它是保留对偶球紧性的那层拓扑。下面给出 Banach–Alaoglu 定理及其标准证明。证明的核心思路只有两步: 先把对偶球嵌入一个逐点坐标的乘积紧空间, 再证明其像集在该乘积空间中闭。

定理 4.2.1 (Banach–Alaoglu 定理)

设 X 为赋范空间, 则对偶空间单位闭球

$$B_{X^*} := \{f \in X^* : \|f\| \leq 1\}$$

在弱*拓扑 $\sigma(X^*, X)$ 下是紧的。

证明 对每个 $x \in X$, 记

$$D_x := \{z \in \mathbb{F} : |z| \leq \|x\|\}.$$

考虑映射

$$\Phi: B_{X^*} \rightarrow \prod_{x \in X} D_x, \quad \Phi(f) = (f(x))_{x \in X}.$$

积空间按 Tychonoff 定理是紧的, 因为每个 D_x 都是紧集。弱*拓扑正是使所有坐标映射

$$f \mapsto f(x)$$

连续的最弱拓扑, 因此 Φ 是一个拓扑嵌入。只需证明 $\Phi(B_{X^*})$ 在积空间中是闭集。

设 $\Phi(f_\alpha) \rightarrow (z_x)_{x \in X}$ 于积空间。由坐标收敛知对每个 $x \in X$, $f_\alpha(x) \rightarrow z_x$ 。定义

$$f(x) := z_x.$$

极限保线性，因此 f 线性。再由

$$|f(x)| = \lim_{\alpha} |f_{\alpha}(x)| \leq \|x\|$$

可知 f 有界且 $\|f\| \leq 1$ 。故 $f \in B_{X^*}$ 且 $\Phi(f) = (z_x)_{x \in X}$ 。这说明像集闭，因而是紧的，从而 B_{X^*} 在弱*拓扑下紧。

命题 4.2.3 (自反空间中的闭球弱紧)

设 X 为自反 Banach 空间，则闭单位球

$$B_X := \{x \in X : \|x\| \leq 1\}$$

在弱拓扑 $\sigma(X, X^*)$ 下紧。

证明 由定义 4.2.3，典范嵌入 J_X 把 X 等距同构到 X^{**} 。根据定理 4.2.1， $B_{X^{**}}$ 在 $\sigma(X^{**}, X^*)$ 下弱*紧。由于 J_X 在自反情形下满射，它把 B_X 与 $B_{X^{**}}$ 对应起来，而 $\sigma(X, X^*)$ 恰是从双对偶弱*拓扑拉回得到的拓扑，故 B_X 弱紧。

推论 4.2.1 (Hilbert 空间中的弱紧性)

设 H 为 Hilbert 空间，则每个非空闭有界凸集在弱拓扑下都是紧的；特别地，每个闭球

$$\{x \in H : \|x\| \leq r\}$$

在弱拓扑下紧。

证明 第 4.1 节定理 4.1.2 说明 H^* 与 H 等距同构，因此 H 自反。由前一命题，闭球弱紧。任意闭有界凸集 $C \subset H$ 包含于某个闭球中；由于 C 在范数拓扑下闭，而弱拓扑比范数拓扑更弱，范数闭凸集在 Hilbert 空间中也是弱闭集。紧空间的闭子集仍紧，故 C 弱紧。

极小值存在的正确表述

注 推论 4.2.1 并不意味着“只要问题在 Hilbert 空间里就一定有极小值”。正确的说法是：若可行集在弱拓扑下紧，且目标泛函对弱拓扑下半连续，那么直接法才可能成立。实际应用中，弱紧性通常来自三种来源：有界闭凸可行集、自反性、以及由强制性把极小化序列压进某个弱紧闭球。缺少这些条件时，极小值完全可能不存在。

例题 4.4 最小抽象例子：对偶球的弱星紧性 设 $X = C([0, 1])$ ，则 X^* 可以通过第 3.3 节定理 3.3.1 识别为有限符号 Radon 测度空间。定理 4.2.1 表明其中单位球在弱*拓扑下紧。把这个例子放在这里，是为了说明对偶变量并不一定是向量；在无穷维中，它们往往是测度，而其紧性首先来自弱*拓扑。

例题 4.5 有限维坍塌：闭有界即紧 若 $X = \mathbb{R}^n$ ，则弱拓扑、弱*拓扑与通常欧氏拓扑一致，因此定理 4.2.1 与推论 4.2.1 都退化为 Heine–Borel 定理。把这个例子放在这里，是为了说明 Boyd 书里大量“不言自明”的存在性步骤，实际上依赖了维数有限这一隐藏条件。

例题 4.6 算法触点：弱极限与直接法 在 Hilbert 空间上考虑泛函

$$u \mapsto \frac{1}{2} \|Au - b\|^2 + \lambda \|u\|^2,$$

若 A 为有界线性算子，则该泛函在闭球上的极小化常先通过推论 4.2.1 取到弱收敛子网，再结合弱下半连续性得到极小元。把这个例子放在这里，是为了给后文算法收敛与存在性证明提供统一模板：先有界，再弱紧，再过极限。

有限维对照

在有限维空间中，弱拓扑与通常拓扑没有区别，弱*拓扑也与对偶空间上的通常拓扑一致。因此很多有限维教材会把“闭有界”“紧”“对偶球紧”混在一起说，而不会显式引入定义 4.2.1 与定义 4.2.2。本节的作用，是在无穷维情形下把这些层次重新分开，并用定理 4.2.1 指出真正保住紧性的拓扑位置。

习题 (待补)

- 练习 4.3 弱拓扑与网占位 补一题：结合第 2.1 节命题 2.1.1，说明为什么 Banach-Alaoglu 定理的结论自然应表述为“任意网有收敛子网”，而不是“任意序列有收敛子列”。
- 练习 4.4 直接法桥接题占位 补一题：在 Hilbert 空间中证明闭球上任意连续凸泛函若再具弱下半连续性，则存在极小元，并指出该证明中哪些步骤依赖推论 4.2.1。

4.3 线性算子与伴随算子

从优化的角度看，矩阵只是线性算子在有限维空间中的坐标表达。进入无穷维以后，线性约束 $Ax = b$ 、梯度映射、积分方程、偏微分方程和状态转移算子都必须用有界线性算子的语言统一处理。尤其重要的是：有限维里熟悉的转置 A^T ，在一般 Banach 空间中不再直接作用在原空间上，而是首先作用在对偶空间上，这就是伴随算子的真正来源。只有把这一步说清，后文的 Fenchel 对偶、KKT 乘子和最优控制中的伴随方程才有严密的对象归属。

4.3.1 有界线性算子与算子空间

定义 4.3.1 (有界线性算子)

设 X, Y 为赋范空间。线性映射 $T: X \rightarrow Y$ 若存在常数 $C \geq 0$ 使

$$\|Tx\|_Y \leq C\|x\|_X, \quad \forall x \in X,$$

则称 T 为一个有界线性算子。全体此类算子记为 $\mathcal{B}(X, Y)$ ，其范数定义为

$$\|T\| := \sup_{\|x\|_X \leq 1} \|Tx\|_Y.$$

在赋范空间之间，线性算子的连续性与有界性是等价的，因此定义 4.3.1 同时给出了“连续线性算子”的全部内容。对优化而言，这意味着线性约束、梯度线性化、状态方程和积分变换都可以统一地放进同一个 Banach 空间 $\mathcal{B}(X, Y)$ 中讨论。

命题 4.3.1 (算子范数的基本性质)

设 X, Y, Z 为赋范空间， $S, T \in \mathcal{B}(X, Y)$ ， $R \in \mathcal{B}(Y, Z)$ ，则

1. $\mathcal{B}(X, Y)$ 是线性空间；
2. 对任意 $x \in X$ ，有

$$\|Tx\|_Y \leq \|T\| \|x\|_X;$$

3. 复合满足

$$\|RT\| \leq \|R\| \|T\|.$$

证明 前两条直接来自定义 4.3.1。对第三条，任取 $\|x\|_X \leq 1$ ，则

$$\|RTx\|_Z \leq \|R\| \|Tx\|_Y \leq \|R\| \|T\| \|x\|_X \leq \|R\| \|T\|.$$

对单位球取上确界即得。

命题 4.3.2 (Banach 空间值算子空间的完备性)

设 X 为赋范空间， Y 为 Banach 空间，则 $\mathcal{B}(X, Y)$ 配上算子范数后也是 Banach 空间。

证明 设 (T_n) 是 $\mathcal{B}(X, Y)$ 中的 Cauchy 列。对任意固定 $x \in X$ ，

$$\|T_n x - T_m x\|_Y \leq \|T_n - T_m\| \|x\|_X,$$

故 $(T_n x)$ 在 Y 中是 Cauchy 列。由于 Y 完备, 存在元素 $Tx \in Y$ 使 $T_n x \rightarrow Tx$ 。于是定义了映射 $T: X \rightarrow Y$ 。

由极限与线性运算交换, T 线性。再由

$$\|Tx\|_Y = \lim_{n \rightarrow \infty} \|T_n x\|_Y \leq \left(\sup_n \|T_n\| \right) \|x\|_X$$

可知 T 有界。最后, 因为 (T_n) 在算子范数下是 Cauchy 列, 给定 $\varepsilon > 0$, 取 N 使 $n, m \geq N$ 时 $\|T_n - T_m\| < \varepsilon$ 。固定 $n \geq N$ 并令 $m \rightarrow \infty$, 得到

$$\|T_n - T\| \leq \varepsilon.$$

故 $T_n \rightarrow T$ 于算子范数, 证明完毕。

4.3.2 Banach 空间中的对偶伴随

定义 4.3.2 (伴随算子)

设 $T \in \mathcal{B}(X, Y)$, 其中 X, Y 为赋范空间。定义映射

$$T^*: Y^* \rightarrow X^*, \quad T^* f := f \circ T.$$

称 T^* 为 T 的对偶伴随算子。

命题 4.3.3 (伴随算子的基本性质)

设 X, Y, Z 为赋范空间, $T, S \in \mathcal{B}(X, Y)$, $R \in \mathcal{B}(Y, Z)$, 则:

1. $T^* \in \mathcal{B}(Y^*, X^*)$ 且

$$\|T^*\| = \|T\|;$$

2. $(T + S)^* = T^* + S^*$;

3. $(\lambda T)^* = \lambda T^*$;

4. $(RT)^* = T^* R^*$ 。

证明 对任意 $f \in Y^*$,

$$\|T^* f\| = \sup_{\|x\|_X \leq 1} |f(Tx)| \leq \|f\| \|T\|,$$

故 T^* 有界且 $\|T^*\| \leq \|T\|$ 。反过来, 任取 $\varepsilon > 0$, 可取 $\|x\|_X = 1$ 使

$$\|Tx\|_Y \geq \|T\| - \varepsilon.$$

由 Hahn-Banach 定理, 存在 $\|f\| = 1$ 使

$$|f(Tx)| = \|Tx\|_Y.$$

于是

$$\|T^*\| \geq \|T^* f\| \geq |(T^* f)(x)| = |f(Tx)| \geq \|T\| - \varepsilon.$$

令 $\varepsilon \downarrow 0$ 得 $\|T^*\| = \|T\|$ 。其余三条都由定义 4.3.2 直接验证, 例如

$$(RT)^* g = g \circ R \circ T = T^* (R^* g).$$

核、像与最优性条件

注 当约束写成 $Tu = b$ 时, 拉格朗日函数中的乘子自然属于 Y^* , 而驻点条件则涉及 $T^* \lambda \in X^*$ 。因此在 Banach 空间里, 伴随首先是“把对偶变量拉回原问题空间的对偶空间”的算子, 而不是像有限维那样仍留在同一个坐标空间中。

4.3.3 Hilbert 空间中的伴随

若 X, Y 都是 Hilbert 空间, 则第 4.1 节定理 4.1.2 可以把 X^* 与 X 、 Y^* 与 Y 重新识别起来, 于是 Banach 空间中的对偶伴随可被改写成作用在原 Hilbert 空间之间的伴随。

推论 4.3.1 (Hilbert 空间中的伴随表示)

设 H_1, H_2 为 Hilbert 空间, $T \in \mathcal{B}(H_1, H_2)$ 。则存在唯一算子

$$T^* \in \mathcal{B}(H_2, H_1)$$

使得

$$\langle Tx, y \rangle_{H_2} = \langle x, T^*y \rangle_{H_1}, \quad \forall x \in H_1, \forall y \in H_2.$$

并且

$$\|T^*\| = \|T\|.$$



证明 固定 $y \in H_2$, 考虑映射

$$\varphi_y: H_1 \rightarrow \mathbb{F}, \quad \varphi_y(x) := \langle Tx, y \rangle_{H_2}.$$

它是 H_1 上的连续线性泛函, 并满足

$$|\varphi_y(x)| \leq \|T\| \|y\| \|x\|.$$

由定理 4.1.2, 存在唯一元素 $z \in H_1$ 使

$$\varphi_y(x) = \langle x, z \rangle_{H_1}, \quad \forall x \in H_1.$$

定义 $T^*y := z$, 就得到所需等式。线性与有界性可由 Riesz 表示中的唯一性直接推出, 且

$$\|T^*\| = \|T\|$$

来自命题 4.3.3 与 Riesz 同构的等距性。

例题 4.7 矩阵转置作为伴随 当 $H_1 = \mathbb{R}^m$ 、 $H_2 = \mathbb{R}^n$ 配标准内积时, 推论 4.3.1 中的 T^* 正是矩阵转置 $A^\top$ 。把这个例子放在这里, 是为了说明本节不是引入一种“比矩阵更抽象的新记号”, 而是在解释矩阵转置在无穷维环境中的真实含义。

例题 4.8 积分算子的伴随 设

$$(Tf)(s) = \int_0^1 K(s, t)f(t) dt, \quad f \in L^2(0, 1),$$

其中核函数 $K \in L^2((0, 1)^2)$ 。则 T 是 $L^2(0, 1)$ 上的有界线性算子, 并满足

$$(T^*g)(t) = \int_0^1 \overline{K(s, t)} g(s) ds.$$

把这个例子放在这里, 是为了展示伴随算子在函数空间中仍然是可计算对象; 后文对偶系统与 Euler-Lagrange 型条件里经常出现的正是这种核的反向传播。

例题 4.9 控制与 PDE 中的伴随方程 设状态方程形式上写成

$$\mathcal{A}u = f$$

并以某个 Hilbert 空间作为状态空间。当目标泛函对状态求导后, 需要把变化量从状态端拉回控制端时, 出现的正是 $\mathcal{A}^*$ 。例如在抛物型控制问题中, 前向方程与反向伴随方程组成一对耦合系统。把这个例子放在这里, 是为了说明“伴随”并不只是线性代数术语, 而是最优控制中梯度计算的核心接口。

有限维对照

在 Boyd 书里, 线性约束与 KKT 条件通常写成 $A^\top \lambda$ 。本节说明, 这个符号在无穷维中的真实上位版本是定义 4.3.2 中的 $T^*f = f \circ T$; 只有在 Hilbert 空间并借助推论 4.3.1 时, 它才重新坍缩为熟悉的“转置仍作用在原空

间上”。

习题 (待补)

- 练习 4.5 积分核伴随占位 补一题：对例 4.8 中的积分算子进行严格计算，证明给出的 T^* 确实满足推论 4.3.1 的定义恒等式。
- 练习 4.6 有限维桥接题占位 补一题：把命题 4.3.3 退回矩阵情形，逐条验证它们恰好对应于 $(A+B)^T = A^T + B^T$ 、 $(\lambda A)^T = \lambda A^T$ 与 $(BA)^T = A^T B^T$ 。

4.4 算子代数初步

本节的标题虽然包含“算子代数”，但目标并不是进入一般 C^* 代数理论，而是提炼出优化真正会反复调用的谱论工具。对二次泛函、Hessian 型算子、协方差算子、核积分算子和半正定约束来说，最关键的问题只有几个：一个有界算子的谱是什么，紧算子为何像“无穷维的近似有限秩矩阵”，自伴与正性如何把几何信息编码进二次型，以及在什么条件下算子可以被“对角化”。这些问题在紧自伴情形下有最清晰的答案，而这正是本节要建立的工作台。

4.4.1 谱与谱半径

定义 4.4.1 (有界算子的谱)

设 X 为复 Banach 空间， $T \in \mathcal{B}(X)$ 。若复数 λ 使算子

$$\lambda I - T$$

不可逆，则称 λ 属于 T 的谱，记为 $\sigma(T)$ 。其补集

$$\rho(T) := \mathbb{C} \setminus \sigma(T)$$

称为 T 的预解集。谱半径定义为

$$r(T) := \sup\{|\lambda| : \lambda \in \sigma(T)\}.$$

命题 4.4.1 (谱的基本性质)

设 X 为复 Banach 空间， $T \in \mathcal{B}(X)$ 。则 $\sigma(T)$ 是非空紧集，且

$$r(T) \leq \|T\|.$$

证明 当 $|\lambda| > \|T\|$ 时，

$$\lambda I - T = \lambda \left(I - \lambda^{-1} T \right),$$

且 $\|\lambda^{-1} T\| < 1$ 。由 Neumann 级数

$$\left(I - \lambda^{-1} T \right)^{-1} = \sum_{n=0}^{\infty} \lambda^{-n} T^n$$

可知 $\lambda I - T$ 可逆，所以

$$\sigma(T) \subset \{\lambda \in \mathbb{C} : |\lambda| \leq \|T\|\}.$$

另一方面，可逆元在 Banach 代数中构成开集，因此预解集 $\rho(T)$ 开，谱 $\sigma(T)$ 闭，于是谱为有界闭集，从而紧。

至于非空性，这是 Banach 代数谱论的基本事实：若 $\sigma(T) = \emptyset$ ，则预解算子

$$\lambda \mapsto (\lambda I - T)^{-1}$$

成为整函数，并满足无穷远处的衰减估计，借助 Liouville 定理会推出它恒为零，矛盾。故谱非空。

为何谱语言对优化有用

注 对有限维矩阵，谱不过是特征值集合；但在无穷维中，谱提供了比特征值更稳定的语言。后文讨论二次型、稳定性与半正定约束时，真正不变的对象是谱，而不是某个固定坐标下的矩阵表示。

4.4.2 紧算子、自伴算子与正算子

定义 4.4.2 (紧算子)

设 X, Y 为 Banach 空间。若 $T \in \mathcal{B}(X, Y)$ 满足： X 的任意有界集在 T 作用下的像都是 Y 中相对紧集，则称 T 为一个紧算子。

定义 4.4.3 (自伴算子)

设 H 为 Hilbert 空间。基于第 4.3 节定义 4.3.2 以及推论 4.3.1，若算子 $T \in \mathcal{B}(H)$ 满足

$$T^* = T,$$

则称 T 为自伴算子。

定义 4.4.4 (正算子)

设 H 为 Hilbert 空间。若 $T \in \mathcal{B}(H)$ 满足

$$\langle Tx, x \rangle \geq 0, \quad \forall x \in H,$$

则称 T 为正算子，记作 $T \geq 0$ 。

命题 4.4.2 (紧算子把弱收敛提升为强收敛)

设 X, Y 为 Banach 空间， $T \in \mathcal{B}(X, Y)$ 为紧算子。若有界网 x_α 在 X 中弱收敛到 x ，则

$$Tx_\alpha \rightarrow Tx$$

在 Y 的范数下成立。

证明 因为 $x_\alpha \rightharpoonup x$ ，网 (x_α) 有界。由定义 4.4.2，像网 (Tx_α) 落在某个紧集的闭包中，因此任意子网都有范数收敛子网。设 $Tx_\beta \rightarrow y$ 于范数，则它也弱收敛到 y 。另一方面， T 连续且线性，故 $Tx_\beta \rightharpoonup Tx$ 。弱极限唯一，遂 $y = Tx$ 。因此 (Tx_α) 的每个收敛子网都只能收敛到 Tx 。紧 Hausdorff 空间中的网若所有收敛子网极限相同，则原网收敛到该极限，故结论成立。

命题 4.4.3 (正算子的基本性质)

设 H 为 Hilbert 空间， $T \in \mathcal{B}(H)$ 。

1. 若 $T \geq 0$ ，则 T 必为自伴算子；
2. 若 T 自伴，则 $\langle Tx, x \rangle \in \mathbb{R}$ 对任意 $x \in H$ 成立；
3. 若 T 自伴且 $\lambda \in \sigma(T)$ 为特征值，则 $\lambda \in \mathbb{R}$ 。

证明 第二条直接来自

$$\langle Tx, x \rangle = \langle x, Tx \rangle = \overline{\langle Tx, x \rangle}.$$

第三条则由 $Tx = \lambda x$ 推出

$$\lambda \|x\|^2 = \langle Tx, x \rangle \in \mathbb{R}.$$

对第一条，考虑极化恒等式。实 Hilbert 空间中有

$$4\langle Tx, y \rangle = \langle T(x+y), x+y \rangle - \langle T(x-y), x-y \rangle.$$

复 Hilbert 空间中有

$$4\langle Tx, y \rangle = \sum_{k=0}^3 i^k \langle T(x + i^k y), x + i^k y \rangle.$$

由于 $T \geq 0$ 时右端均可由二次型

$$q(z) := \langle Tz, z \rangle$$

完全恢复, 得到

$$\langle Tx, y \rangle = \overline{\langle Ty, x \rangle} = \langle x, Ty \rangle,$$

故 $T = T^*$ 。

命题 4.4.4 (正算子的范数刻画)

设 H 为 Hilbert 空间, $T \in \mathcal{B}(H)$ 且 $T \geq 0$ 。则

$$\|T\| = \sup_{\|x\|=1} \langle Tx, x \rangle.$$

证明 对任意单位向量 x , 显然有

$$\langle Tx, x \rangle \leq \|Tx\| \|x\| \leq \|T\|,$$

故右端上确界不超过 $\|T\|$ 。

反过来, 对正算子定义半内积

$$[u, v]_T := \langle Tu, v \rangle.$$

由 Cauchy-Schwarz 不等式,

$$|[x, Tx]_T|^2 \leq [x, x]_T [Tx, Tx]_T.$$

亦即

$$\|Tx\|^4 \leq \langle Tx, x \rangle \langle T^2 x, Tx \rangle \leq \langle Tx, x \rangle \|T^2 x\| \|Tx\| \leq \|T\| \langle Tx, x \rangle \|Tx\|^2.$$

若 $Tx \neq 0$, 可约去 $\|Tx\|^2$, 得到

$$\|Tx\|^2 \leq \|T\| \langle Tx, x \rangle.$$

对单位向量取上确界, 记

$$a := \sup_{\|x\|=1} \langle Tx, x \rangle,$$

便有

$$\|T\|^2 = \sup_{\|x\|=1} \|Tx\|^2 \leq \|T\| a.$$

若 $T \neq 0$, 则 $\|T\| > 0$, 故 $\|T\| \leq a$; 若 $T = 0$ 则结论显然。综上 $\|T\| = a$ 。

例题 4.10 有限维坍缩: 对称矩阵与半正定矩阵 当 $H = \mathbb{R}^n$ 时, 定义 4.4.3 退化为对称矩阵, 定义 4.4.4 退化为半正定矩阵。把这个例子放在这里, 是为了说明半正定规划中的矩阵锥并不是一个孤立对象, 而是 Hilbert 空间正算子锥的有限维切片。

例题 4.11 紧算子的典型原型: 积分算子 在 $L^2(0, 1)$ 上, 若核函数 K 连续, 则

$$(Tf)(s) = \int_0^1 K(s, t) f(t) dt$$

定义了一个紧算子。若再满足 $K(s, t) = \overline{K(t, s)}$, 则 T 还是自伴算子。把这个例子放在这里, 是为了把本节的抽象谱理论直接连接到后文的协方差算子、核方法和 Fredholm 型方程。

4.4.3 紧自伴算子的谱定理

引理 4.4.1 (正紧自伴算子的主特征值)

设 H 为 Hilbert 空间, $T \in \mathcal{B}(H)$ 为非零、正、紧、自伴算子。则存在单位向量 $e \in H$ 与实数 $\mu > 0$, 使

$$Te = \mu e, \quad \mu = \|T\|.$$

证明 考虑单位闭球

$$B := \{x \in H : \|x\| \leq 1\}.$$

由推论 4.2.1, B 在弱拓扑下紧。又由紧算子把弱收敛提升为强收敛这一命题, 函数

$$q(x) := \langle Tx, x \rangle$$

在 B 上是弱连续的: 若 $x_\alpha \rightarrow x$, 则弱收敛网必有界, 且 $Tx_\alpha \rightarrow Tx$ 于范数, 于是

$$\langle Tx_\alpha, x_\alpha \rangle - \langle Tx, x \rangle = \langle Tx_\alpha - Tx, x_\alpha \rangle + \langle Tx, x_\alpha - x \rangle \rightarrow 0.$$

因此 q 在 B 上取到最大值。取单位向量 e 满足

$$q(e) = \max_{\|x\| \leq 1} q(x).$$

由于 $T \geq 0$ 且 $T \neq 0$, 有 $q(e) > 0$ 。记 $\mu := q(e)$ 。

对任意 $y \in H$ 且 $\langle y, e \rangle = 0$, 考虑函数

$$\phi(t) := q\left(\frac{e + ty}{\|e + ty\|}\right), \quad t \in \mathbb{R}.$$

因为 e 在单位球上使 q 取极大值, 故 $\phi'(0) = 0$ 。直接计算得到

$$\operatorname{Re}\langle Te, y \rangle = 0.$$

在复 Hilbert 空间中再将 y 换为 iy , 可得虚部也为零, 因此

$$\langle Te, y \rangle = 0, \quad \forall y \perp e.$$

这说明 Te 与所有垂直于 e 的向量都正交, 故 Te 必与 e 共线, 即存在标量 λ 使 $Te = \lambda e$ 。再与 e 取内积, 得到

$$\lambda = \langle Te, e \rangle = \mu.$$

最后由上一命题,

$$\|T\| = \sup_{\|x\| \leq 1} \langle Tx, x \rangle = q(e) = \mu$$

得出 $\mu = \|T\|$ 。

命题 4.4.5 (紧算子的非零特征值只能有限重)

设 H 为 Hilbert 空间, $T \in \mathcal{B}(H)$ 为紧算子。若 $\lambda \neq 0$ 是 T 的特征值, 则对应特征子空间

$$\ker(T - \lambda I)$$

必为有限维。

证明 若该特征子空间无限维, 则可以从中取一组标准正交列 (e_n) 。对每个 n ,

$$Te_n = \lambda e_n.$$

由于 $\lambda \neq 0$, 序列 (Te_n) 的任意两项之间距离都等于

$$\|Te_n - Te_m\| = |\lambda| \|e_n - e_m\| = \sqrt{2} |\lambda|, \quad n \neq m,$$

故不可能含有收敛子列。这与 T 为紧算子矛盾。

定理 4.4.1 (紧自伴算子的谱定理)

设 H 为 Hilbert 空间, $T \in \mathcal{B}(H)$ 为紧自伴算子。则存在至多可数的标准正交特征向量族 $\{e_n\}$ 与实特征值列 $\{\lambda_n\}$, 满足:

1. 对每个 n ,

$$Te_n = \lambda_n e_n;$$

2. 若非零特征值无限多个, 则

$$\lambda_n \rightarrow 0;$$

3. 对任意 $x \in H$,

$$Tx = \sum_n \lambda_n \langle x, e_n \rangle e_n,$$

其中级数在 H 中按范数收敛;

4. 非零谱恰好由这些非零特征值组成, 每个非零特征值重数有限, 且 0 是唯一可能的聚点。

证明 若 $T = 0$, 取空特征族即可。以下设 $T \neq 0$ 。

先考虑

$$S := T^2 = T^*T.$$

则 S 是正、紧、自伴算子。由上一个引理, 存在单位向量 u 与标量 $\mu = \|S\| = \|T\|^2 > 0$, 使

$$Su = \mu u.$$

记

$$E_\mu := \ker(S - \mu I).$$

由上一命题, E_μ 有限维。又因为 $TS = ST$, 所以 $T(E_\mu) \subseteq E_\mu$ 。将 T 限制到有限维 Hilbert 空间 E_μ 上, 便得到一个有限维自伴算子; 由有限维线性代数, 它可以正交对角化。因此存在单位向量 $e_1 \in E_\mu$ 与实数 λ_1 , 使

$$Te_1 = \lambda_1 e_1, \quad |\lambda_1| = \|T\|.$$

接着做递归构造。已取到两两正交的单位特征向量 $e_1, \dots, e_n$ 后, 记

$$M_n := \text{span}\{e_1, \dots, e_n\}^\perp.$$

由于 T 自伴, M_n 对 T 不变: 若 $x \in M_n$, 则对每个 $k \leq n$,

$$\langle Tx, e_k \rangle = \langle x, Te_k \rangle = \lambda_k \langle x, e_k \rangle = 0.$$

因此限制算子 $T_n := T|_{M_n}$ 仍是紧自伴算子。若 $T_n \neq 0$, 重复上一步便在 M_n 中得到单位特征向量 e_{n+1} , 对应特征值 λ_{n+1} , 并满足

$$|\lambda_{n+1}| = \|T_n\| \leq |\lambda_n|.$$

若某一步 $T_n = 0$, 则递归终止。于是得到有限或可数的标准正交特征向量族 $\{e_n\}$ 。

若该族无限, 则必须有 $\lambda_n \rightarrow 0$ 。否则存在 $\varepsilon > 0$ 与子列 (λ_{n_k}) 使 $|\lambda_{n_k}| \geq \varepsilon$ 。但

$$Te_{n_k} = \lambda_{n_k} e_{n_k}$$

不可能含有收敛子列, 因为

$$\|Te_{n_k} - Te_{n_\ell}\|^2 = |\lambda_{n_k}|^2 + |\lambda_{n_\ell}|^2 \geq 2\varepsilon^2, \quad k \neq \ell,$$

这与紧性矛盾。

设

$$M := \overline{\text{span}\{e_n\}}.$$

由于每个 e_n 是特征向量, 和上面同样的计算表明 $M^\perp$ 对 T 不变。若 $T|_{M^\perp} \neq 0$, 则按前述构造又能在 $M^\perp$ 中找到

新的特征向量，与 $\{e_n\}$ 的极大性矛盾。故

$$T|_{M^\perp} = 0.$$

任取 $x \in H$ ，由 Hilbert 空间中的正交分解可写成

$$x = \sum_n \langle x, e_n \rangle e_n + z, \quad z \in M^\perp.$$

于是

$$Tx = \sum_n \lambda_n \langle x, e_n \rangle e_n,$$

因为 $Tz = 0$ 。该级数按范数收敛：一方面 $(\langle x, e_n \rangle) \in \ell^2$ ，另一方面 (λ_n) 有界且在无限情形下趋于零，因此部分和构成 Cauchy 列。

最后说明谱的刻画。对每个非零特征值，有限重性已由上一命题给出。反过来，若 $\lambda \neq 0$ 不属于特征值，则由于 $\lambda_n \rightarrow 0$ 且 $\lambda \neq \lambda_n$ 对所有 n 都成立，存在常数

$$\delta := \inf(|\lambda|, |\lambda - \lambda_n| : n \geq 1) > 0.$$

对任意分解

$$x = \sum_n a_n e_n + z, \quad z \in M^\perp,$$

定义

$$R_\lambda x := \sum_n \frac{a_n}{\lambda - \lambda_n} e_n + \frac{1}{\lambda} z.$$

由于

$$\left| \frac{1}{\lambda - \lambda_n} \right| \leq \frac{1}{\delta}, \quad \left| \frac{1}{\lambda} \right| \leq \frac{1}{\delta},$$

该级数给出一个有界算子 R_λ 。再由表示式直接计算，

$$(\lambda I - T)R_\lambda x = R_\lambda(\lambda I - T)x = x.$$

因此 $\lambda I - T$ 可逆。综上，非零谱恰由这些非零特征值组成；若谱无限，则唯一可能的聚点只能是 0。

谱定理与二次型

注 定理 4.4.1 说明，紧自伴算子可以像对称矩阵一样被正交分解。对优化而言，这意味着许多无穷维二次泛函

$$q(x) = \frac{1}{2} \langle Tx, x \rangle - \langle b, x \rangle$$

仍能在特征方向上逐坐标分析。有限维的 Hessian 对角化、主成分分析和半正定矩阵分解，都只是这一结论的坍塌版本。

例题 4.12 协方差算子的谱分解 在 L^2 或 RKHS 环境中，协方差算子常常是正、紧、自伴的，因此可由定理 4.4.1 分解为

$$Tx = \sum_n \lambda_n \langle x, e_n \rangle e_n, \quad \lambda_n \geq 0.$$

把这个例子放在这里，是为了把谱定理直接连接到后文的核方法、表示学习与低秩近似：主成分方向就是特征向量，能量大小就是特征值。

有限维对照

在有限维 Hilbert 空间里，定理 4.4.1 退化为“实对称矩阵可正交对角化”。因此半正定规划中的特征值分解、二次型标准形和迹内积，都可以视为本节谱定理在矩阵层面的压缩版。不同之处只在于：无穷维里非零谱可能是可数无限的，而紧性保证它只能向 0 聚集。

习题（待补）

- 练习 4.7 紧自伴谱定理的矩阵版占位 补一题：把定理 4.4.1 限制到有限维空间，说明它如何退化为实对称矩阵的正交对角化。
- 练习 4.8 二次型桥接题占位 补一题：设 $T \geq 0$ 为紧自伴算子，分析二次泛函 $q(x) = \frac{1}{2}\langle Tx, x \rangle - \langle b, x \rangle$ 在特征基下的表达，并解释何时它退化为有限维半正定二次规划。

第三部分

凸性、分离与微分

第 5 章 凸集与超平面分离

从第 1 章到第 3 章，我们已经分别准备了拓扑、测度与泛函分析的基础语言，但无穷维凸优化真正的几何核心，直到本章才开始出现。有限维教材中常见的图像是：凸集被超平面支撑，最优性条件由法向量表达，极值点则集中在边界最尖锐的部分。这些直觉在 $\mathbb{R}^n$ 中几乎不需要额外解释；然而一旦进入函数空间、弱拓扑和一般 Banach 空间，它们就必须被重新翻译成线性泛函、分离定理和极点结构，否则所谓“几何直观”只会停留在图片层面。

本章默认主要工作在实线性空间中，因为凸组合、超平面分离和支撑泛函的自然语言本来就是实的。第 5.1 节先把凸集、仿射集、锥、闭包与凸包这些对象重新整理出来，并指出无穷维中“闭凸集没有内点”并不是例外，而是常态。第 5.2 节进一步引入代数内部与相对内部，解释为什么第 5 章与第 7 章中的资格条件不能只依赖通常内点。第 5.3 节是本章的核心：Hahn–Banach 定理把线性泛函的延拓与几何分离统一到同一条证明链中，从而为次微分、对偶和 KKT 条件提供最根本的泛函来源。最后第 5.4 节以极点与 Krein–Milman 定理收束，说明一个紧凸集如何由其边界上的极端结构控制。

从 Boyd 的有限维叙事看，本章做的事情可以概括为一句话：把“超平面、相对内部、支撑和顶点”的欧氏语言提升为无穷维可复用的泛函语言。后文中出现的次梯度、共轭函数、强对偶、广义 KKT 以及原子表示，都要回链到本章的结论。因此阅读这一章时，最重要的不是背诵所有定义，而是看清楚哪一个结论依赖拓扑、哪一个结论依赖局部凸性、哪一个结论又必须退回 Banach 或 Hilbert 环境才真正可用。

5.1 无穷维向量空间中的凸集

凸性首先是一种代数稳定性：它要求集合在两点之间的线段上闭合，而并不预设任何坐标、内积或维数。因此，凸集理论天然适用于函数空间、测度空间和算子空间。真正进入无穷维以后，困难并不在“凸”的定义本身，而在于拓扑直觉不再自动成立。有限维里常见的事实，例如闭有界集有较好几何边界、闭凸集常常带有非空内部、凸包与闭包的运算容易可视化，在一般 Banach 或 Hilbert 空间中都需要重新说明。特别是当我们谈论闭包时，实际上已经回到了第 2.1 节命题 2.1.1 所建立的网语言；而当我们谈论最小二乘、正则化与投影时，又必须回到第 4.1 节定义 4.1.3 所代表的几何环境。

5.1.1 基本对象

定义 5.1.1 (凸集)

设 X 为实向量空间， $C \subset X$ 。若对任意 $x, y \in C$ 与任意 $\lambda \in [0, 1]$ 都有

$$\lambda x + (1 - \lambda)y \in C,$$

则称 C 为一个凸集。

定义 5.1.2 (仿射集)

设 X 为实向量空间， $A \subset X$ 。若对任意 $x, y \in A$ 与任意 $\lambda \in \mathbb{R}$ 都有

$$\lambda x + (1 - \lambda)y \in A,$$

则称 A 为一个仿射集。等价地， A 是某个线性子空间的平移。

定义 5.1.3 (凸锥)

设 X 为实向量空间， $K \subset X$ 。若对任意 $x, y \in K$ 与任意 $\alpha, \beta \geq 0$ 都有

$$\alpha x + \beta y \in K,$$

则称 K 为一个凸锥。

若 $E \subset X$, 则记

$$\text{conv}(E)$$

为包含 E 的最小凸集, 称为 E 的凸包; 记

$$\text{aff}(E)$$

为包含 E 的最小仿射集, 称为 E 的仿射包; 记

$$\text{cone}(E)$$

为包含 E 的最小凸锥。只要 X 还带有拓扑, 我们就继续使用 $\overline{E}$ 和 $\text{int}(E)$ 分别表示闭包与内部。

命题 5.1.1 (闭包保持凸性)

设 X 为拓扑向量空间, $C \subset X$ 为凸集, 则其闭包 $\overline{C}$ 仍为凸集。

证明 任取 $x, y \in \overline{C}$ 与 $\lambda \in [0, 1]$ 。由第 2.1 节命题 2.1.1, 存在取值于 C 的网 $(x_\alpha)_{\alpha \in D}$ 与 $(y_\beta)_{\beta \in E}$, 分别收敛到 x 与 y 。令 $D \times E$ 配上坐标逐点序构成定向集, 则

$$z_{(\alpha, \beta)} := \lambda x_\alpha + (1 - \lambda)y_\beta \in C$$

对每个 $(\alpha, \beta) \in D \times E$ 成立。加法与数乘在拓扑向量空间中连续, 因此

$$z_{(\alpha, \beta)} \rightarrow \lambda x + (1 - \lambda)y.$$

再次应用命题 2.1.1, 得到 $\lambda x + (1 - \lambda)y \in \overline{C}$ 。故 $\overline{C}$ 为凸集。

命题 5.1.2 (凸包与仿射包的基本性质)

设 $E \subset X$, 其中 X 为实向量空间, 则有:

1. $\text{conv}(E)$ 是包含 E 的所有凸集的交, 且

$$\text{conv}(E) = \left\{ \sum_{j=1}^m \lambda_j x_j : m \in \mathbb{N}, x_j \in E, \lambda_j \geq 0, \sum_{j=1}^m \lambda_j = 1 \right\};$$

2. $\text{aff}(E)$ 是包含 E 的所有仿射集的交, 且

$$\text{aff}(E) = \left\{ \sum_{j=1}^m \lambda_j x_j : m \in \mathbb{N}, x_j \in E, \lambda_j \in \mathbb{R}, \sum_{j=1}^m \lambda_j = 1 \right\};$$

3. $\text{cone}(E)$ 是包含 E 的所有凸锥的交, 且

$$\text{cone}(E) = \left\{ \sum_{j=1}^m \lambda_j x_j : m \in \mathbb{N}, x_j \in E, \lambda_j \geq 0 \right\}.$$

证明 只证明第一条, 其余两条完全类似。记右端集合为 C_0 。显然 $E \subset C_0$, 且两组有限凸组合再做凸组合, 仍是有限凸组合, 因此 C_0 是凸集。于是 $\text{conv}(E) \subset C_0$ 。

反过来, 若 C 是任意包含 E 的凸集, 则由于 C 对两点凸组合闭合, 归纳可得它对任意有限凸组合都闭合, 所以 $C_0 \subset C$ 。因此 C_0 包含于所有包含 E 的凸集之中, 故 C_0 就是这些集合的交, 即 $\text{conv}(E)$ 。

无穷维中的第一个陷阱

注 在有限维空间中, 很多读者会不自觉地把“闭凸”与“具有明显体积”联系起来。但在无穷维里, 闭凸集完全可能没有任何拓扑内点。最简单的例子是 Hilbert 空间中的真闭子空间: 它是闭、凸、仿射的, 但内部为空。后面第 5.2 节引入代数内部与相对内部, 正是为了修补这类现象。

例题 5.1 最小抽象例子：函数空间中的正锥 设 $X = C([0, 1])$ 或 $X = L^p(0, 1)$ ，定义

$$X_+ := \{u \in X : u(t) \geq 0 \text{ a.e.}\}.$$

则 X_+ 是一个凸锥，因为非负函数的非负线性组合仍非负。把这个例子放在这里，是为了给后文的广义不等式、正算子与锥约束提供最小抽象原型：在无穷维优化中，“ $x \geq 0$ ”往往不再是逐坐标条件，而是属于某个函数锥的包含关系。

例题 5.2 有限维坍塌例子：多面体与欧氏球 在 $\mathbb{R}^n$ 中，半空间的有限交

$$P = \{x \in \mathbb{R}^n : Ax \leq b\}$$

是凸集，非负正交第一象限是凸锥，而欧氏闭球

$$\{x \in \mathbb{R}^n : \|x\|_2 \leq r\}$$

则是闭凸集。把这个例子放在这里，是为了保留 Boyd 中最熟悉的几何母语：多面体、范数球与锥都是本节抽象定义的有限维投影，而不是另一套平行理论。

例题 5.3 算法触点例子：正则化问题的水平集 设 H 为 Hilbert 空间， $A \in \mathcal{B}(H, Y)$ 为有界线性算子，考虑泛函

$$\Phi(u) = \frac{1}{2} \|Au - b\|_Y^2 + \lambda \|u\|_H^2, \quad \lambda > 0.$$

其下水平集

$$L_c := \{u \in H : \Phi(u) \leq c\}$$

是闭凸集。把这个例子放在这里，是为了说明“凸集”并不只是静态几何对象，它们正是迭代算法与存在性证明实际操作的可行域。后文讨论弱紧性、投影与邻近算子时，几乎总要先确认某个水平集是否属于本节建立的框架。

有限维对照

Boyd 第 2 章中的凸集、锥、范数球和水平集，大多画在 $\mathbb{R}^2$ 或 $\mathbb{R}^3$ 中，因此读者很容易把“可视化”误认为“定义本身”。本节强调的恰恰相反：定义 5.1.1 到定义 5.1.3 完全不依赖维数，真正依赖空间结构的是闭包、内部与紧性。有限维里许多几何事实因为欧氏拓扑过于良性而被自动吞掉；无穷维里则必须先把对象语法写清，后面的分离、对偶和极值存在才有可靠的起点。

习题（待补）

-  **练习 5.1 闭包保凸的序列版桥接题** 补一题：在度量线性空间中把命题 5.1.1 改写成序列证明，并说明它与命题 2.1.1 的网证明相比，在哪些一般拓扑环境下会失效。
-  **练习 5.2 凸包有限表示占位** 补一题：证明命题 5.1.2 中的凸包公式，并把它退回到 $\mathbb{R}^n$ 的多面体情形，解释为什么有限维中常常只需追踪有限个顶点。

5.2 代数内部与相对内部

上一节定义 5.1.1 已经说明，凸性本身不依赖维数，但“内部”却高度依赖所选拓扑。在有限维优化里，很多资格条件都以“存在严格可行点”为表述核心，而这里的“严格”往往就是“落在内部”。进入无穷维以后，这个说法很快会失效：一个集合即使在几何上明显具有厚度，也可能因为嵌在真闭子空间中、或者因为可行方向过于受限，而在整体拓扑下没有任何内点。因此，本节要把通常内点替换为两种更稳定的对象：代数内部描述沿所有方向的小范围可行性，相对内部则描述沿仿射包的拓扑厚度。后面的 Slater 条件、严格分离与强对偶，都将依赖这一步修正。

5.2.1 两种内部概念

定义 5.2.1 (代数内部)

设 X 为实向量空间, $C \subset X$ 。称点 $x \in C$ 属于 C 的代数内部, 若对任意方向 $y \in X$, 都存在 $\varepsilon > 0$ 使得

$$x + ty \in C, \quad \forall |t| < \varepsilon.$$

所有此类点构成的集合记为 $\text{core}(C)$ 。

定义 5.2.2 (相对内部)

设 X 为拓扑向量空间, $C \subset X$ 。将仿射包 $\text{aff}(C)$ 赋予由 X 诱导的子空间拓扑, 则 C 在该拓扑下的内部称为 C 的相对内部, 记为

$$\text{ri}(C).$$

若 $\text{aff}(C) = X$, 则 $\text{ri}(C) = \text{int}(C)$ 。但在一般情形下, $\text{ri}(C)$ 往往比整体内部更合适, 因为优化问题的自然可行域常常落在某个仿射切片中, 而不是充满整个空间。

命题 5.2.1 (相对内部的基本性质)

设 X 为拓扑向量空间, $C \subset X$ 为非空凸集, 则:

1. $\text{ri}(C)$ 仍为凸集;
2. 若 $x \in \text{ri}(C)$, $y \in C$, 且 $\lambda \in [0, 1)$, 则

$$(1 - \lambda)x + \lambda y \in \text{ri}(C).$$

在有限维空间中, 若 C 为凸集, 则 $\text{core}(C) = \text{ri}(C)$ 。

证明 只需在仿射空间 $\text{aff}(C)$ 中证明。对第一条, 任取 $x_1, x_2 \in \text{ri}(C)$ 与 $\theta \in (0, 1)$ 。存在 $\text{aff}(C)$ 中的邻域 U_1, U_2 , 使

$$x_1 + U_1 \subset C, \quad x_2 + U_2 \subset C.$$

于是

$$\theta x_1 + (1 - \theta)x_2 + \theta U_1 + (1 - \theta)U_2 \subset C.$$

而 $\theta U_1 + (1 - \theta)U_2$ 仍是 $\text{aff}(C)$ 中 0 的邻域, 故 $\theta x_1 + (1 - \theta)x_2 \in \text{ri}(C)$ 。

对第二条, 取 $x \in \text{ri}(C)$, 则存在 $\text{aff}(C)$ 中 0 的邻域 U 使 $x + U \subset C$ 。令

$$z = (1 - \lambda)x + \lambda y.$$

则

$$z + (1 - \lambda)U = (1 - \lambda)(x + U) + \lambda y \subset C,$$

故 $z \in \text{ri}(C)$ 。

最后说明有限维情形下 $\text{core}(C) = \text{ri}(C)$ 。在有限维空间中, $\text{aff}(C)$ 自身是有限维拓扑向量空间, 因此任何代数意义上的吸收邻域都等价于某个拓扑邻域。于是点在所有方向上可作小扰动, 等价于它在仿射包中拥有一个真正的开邻域。故二者相等。

为何通常内点不够

注 若 M 是 Hilbert 空间 H 的真闭子空间, 则闭单位球

$$B_M := \{x \in M : \|x\|_H \leq 1\}$$

作为 H 的子集是闭凸集, 但其内部为空; 然而作为 M 内的集合, 它的相对内部却是

$$\{x \in M : \|x\|_H < 1\}.$$

这说明一旦可行域天然落在某个仿射切片内，仅用整体拓扑中的 $\text{int}(C)$ 描述“严格可行”就会把所有有意义的点误删掉。

5.2.2 core 与分离之间的桥梁

代数内部的真正价值不在于它本身比相对内部“更一般”，而在于它能把几何厚度转写成一个可供 Hahn–Banach 定理使用的次线性泛函。这个泛函正是 Minkowski 泛函的抽象版本。

命题 5.2.2 (core 与分离的桥梁)

设 X 为实向量空间， $C \subset X$ 为凸集，且 $0 \in \text{core}(C)$ 。定义

$$p_C(x) := \inf\{t > 0 : x \in tC\}, \quad x \in \text{span}(C).$$

则：

1. C 在 $\text{span}(C)$ 中是吸收的，因此 $p_C(x) < \infty$ 对每个 $x \in \text{span}(C)$ 成立；
2. p_C 在 $\text{span}(C)$ 上是次线性泛函；
3. 若 $p_C(x) < 1$ ，则 $x \in C$ 。

证明 由 $0 \in \text{core}(C)$ ，对任意 $x \in \text{span}(C)$ ，存在 $\varepsilon > 0$ 使

$$tx \in C, \quad \forall |t| < \varepsilon.$$

于是

$$x = \varepsilon^{-1}(\varepsilon x) \in \varepsilon^{-1}C,$$

故 C 吸收 $\text{span}(C)$ 中每个向量，从而 $p_C(x) < \infty$ 。

其次证明齐次性。若 $\alpha > 0$ ，则

$$p_C(\alpha x) = \inf\{t > 0 : \alpha x \in tC\} = \alpha \inf\{s > 0 : x \in sC\} = \alpha p_C(x).$$

而 $p_C(0) = 0$ 显然成立。再证明次可加性。任取 $\varepsilon > 0$ ，取 $s, t > 0$ 满足

$$x \in sC, \quad y \in tC, \quad s < p_C(x) + \varepsilon, \quad t < p_C(y) + \varepsilon.$$

于是存在 $u, v \in C$ 使 $x = su$ 、 $y = tv$ 。由于 C 凸，

$$\frac{s}{s+t}u + \frac{t}{s+t}v \in C,$$

从而

$$x + y = (s+t) \left(\frac{s}{s+t}u + \frac{t}{s+t}v \right) \in (s+t)C.$$

故

$$p_C(x+y) \leq s+t < p_C(x) + p_C(y) + 2\varepsilon.$$

令 $\varepsilon \downarrow 0$ 即得

$$p_C(x+y) \leq p_C(x) + p_C(y).$$

因此 p_C 是次线性的。

最后若 $p_C(x) < 1$ ，取 $t < 1$ 使 $x \in tC$ ，则存在 $u \in C$ 满足 $x = tu$ 。由于 $0 \in C$ 且 C 凸，

$$x = tu + (1-t)0 \in C.$$

注 命题 5.2.2 解释了为什么第 5.3 节中的解析型 Hahn–Banach 定理会自然介入分离理论。只要一个凸集在某个点具有代数内部，就可以从该点出发构造 Minkowski 泛函，并把“集合分离”转写为“在线性子空间上给定一个受次线性泛函支配的线性泛函，再向外延拓”。这正是无穷维版本 Slater 条件的底层机制。

例题 5.4 最小抽象例子：真子空间中的单位球 设 M 是 Hilbert 空间 H 的真闭子空间，考虑

$$C = \{x \in M : \|x\|_H \leq 1\}.$$

则 C 作为 H 的子集内部为空, 但

$$\text{ri}(C) = \{x \in M : \|x\|_H < 1\}.$$

把这个例子放在这里, 是为了说明“厚度”必须沿着自然的仿射包来测量; 若仍坚持在整个 H 里看内点, 就会把本来良好的凸集错判成完全退化。

例题 5.5 有限维坍塌例子: 单纯形的相对内部 在 $\mathbb{R}^n$ 中考虑概率单纯形

$$\Delta_n = \left\{ x \in \mathbb{R}^n : x_i \geq 0, \sum_{i=1}^n x_i = 1 \right\}.$$

它的仿射包是超平面 $\sum_i x_i = 1$, 并且

$$\text{ri}(\Delta_n) = \{x \in \Delta_n : x_i > 0, 1 \leq i \leq n\}.$$

把这个例子放在这里, 是为了回收 Boyd 中最常见的相对内部语言: 在有限维里, ri 正是处理等式约束与不等式严格可行性的标准工具。

例题 5.6 应用触点例子: 半无限约束中的严格可行性 设 T 为紧空间, 考虑半无限规划可行域

$$\mathcal{F} = \{x \in \mathbb{R}^n : a(t)^\top x \leq b(t), \forall t \in T\},$$

其中 $a(\cdot)$ 与 $b(\cdot)$ 连续。若存在 $\bar{x}$ 使

$$a(t)^\top \bar{x} < b(t), \quad \forall t \in T,$$

且不等式余量在 T 上一致正, 则 $\bar{x}$ 落在 $\mathcal{F}$ 的相对内部, 甚至在适当线性包内落在其 core 中。把这个例子放在这里, 是为了提前说明第 7 章广义 Slater 条件的几何来源: 严格可行并不是一句口号, 而是某种内部结构非空。

有限维对照

Boyd 在处理相对内部、严格可行性与约束资格时, 默认工作在有限维 Euclidean 空间中, 因此 $\text{ri}(C)$ 已足够强大, 很多时候甚至可以不再区分它与更一般的代数内部。本节的修正是: 一旦进入无穷维, 仅靠 ri 仍可能不足, 因为仿射包本身未必提供合适的可行方向结构。此时 $\text{core}(C)$ 与命题 5.2.2 中的 Minkowski 泛函, 才是把严格分离与强对偶推进下去的真正桥梁。

习题 (待补)

- 🔴 **练习 5.3 有限维中 core 与 ri 一致占位** 补一题: 在有限维空间中证明命题 5.2.1 的最后一句, 即对任意凸集 C 有 $\text{core}(C) = \text{ri}(C)$ 。
- 🔴 **练习 5.4 Minkowski 泛函桥接题占位** 补一题: 在命题 5.2.2 的条件下, 证明若 C 还是平衡集, 则 p_C 成为 $\text{span}(C)$ 上的半范数, 并说明它与第 5.3 节 Hahn-Banach 延拓的关系。

5.3 Hahn-Banach 定理

从有限维凸优化的图像直觉看, 超平面分离似乎是一个纯几何命题; 但在无穷维中, 真正起作用的并不是“画一条线把两个集合隔开”, 而是在线性子空间上先构造一个受控的线性泛函, 再把它延拓到整个空间。这个延拓原理就是 Hahn-Banach 定理。它一方面说明连续线性泛函足够丰富, 可以探测凸集的边界; 另一方面又把后文的对偶变量、支撑函数和 KKT 乘子统一到同一个对象类型中。特别地, 第 4.3 节定义 4.3.2 已经告诉我们: 一旦对偶变量出现, 它们就要通过伴随算子回到原问题空间。因此, 本节给出的分离结论并不是孤立的几何装饰, 而是第 5 章次微分和第 6 章共轭理论的基础接口。

5.3.1 次线性泛函与一维延拓

定义 5.3.1 (次线性泛函)

设 X 为实向量空间。映射

$$p: X \rightarrow \mathbb{R}$$

若满足

1. $p(x+y) \leq p(x) + p(y)$, 对任意 $x, y \in X$;
2. $p(\lambda x) = \lambda p(x)$, 对任意 $\lambda \geq 0$ 与任意 $x \in X$,

则称 p 为 X 上的次线性泛函。

引理 5.3.1 (一步延拓引理)

设 M 是实向量空间 X 的线性子空间, p 是 X 上的次线性泛函, $f_0: M \rightarrow \mathbb{R}$ 为线性泛函且满足

$$f_0(x) \leq p(x), \quad \forall x \in M.$$

若 $x_0 \in X \setminus M$, 则存在定义在 $M + \mathbb{R}x_0$ 上的线性泛函 $\tilde{f}$, 使

$$\tilde{f}|_M = f_0, \quad \tilde{f}(x) \leq p(x), \quad \forall x \in M + \mathbb{R}x_0.$$

证明 我们寻找常数 $c \in \mathbb{R}$, 并定义

$$\tilde{f}(m + tx_0) := f_0(m) + tc, \quad m \in M, t \in \mathbb{R}.$$

要使 $\tilde{f} \leq p$, 等价于要求

$$f_0(m) + tc \leq p(m + tx_0), \quad \forall m \in M, \forall t \in \mathbb{R}.$$

只需考察 $t = 1$ 与 $t = -1$, 即可得到约束

$$f_0(m) + c \leq p(m + x_0), \quad f_0(m) - c \leq p(m - x_0), \quad \forall m \in M.$$

亦即

$$f_0(m) - p(m - x_0) \leq c \leq p(m + x_0) - f_0(m), \quad \forall m \in M.$$

因此只要证明区间

$$\left[\sup_{m \in M} (f_0(m) - p(m - x_0)), \inf_{m \in M} (p(m + x_0) - f_0(m)) \right]$$

非空即可。

任取 $m_1, m_2 \in M$ 。由 $f_0 \leq p$ 及次线性,

$$f_0(m_1) + f_0(m_2) = f_0(m_1 + m_2) \leq p(m_1 + m_2) = p((m_1 - x_0) + (m_2 + x_0)) \leq p(m_1 - x_0) + p(m_2 + x_0).$$

移项得

$$f_0(m_1) - p(m_1 - x_0) \leq p(m_2 + x_0) - f_0(m_2).$$

对左边取上确界、右边取下确界, 便知该区间非空。任选其中一点 c , 即可得到所需的 $\tilde{f}$ 。

定理 5.3.1 (Hahn-Banach 的解析形式)

设 X 为实向量空间, $M \subset X$ 为线性子空间, p 为 X 上的次线性泛函, $f_0: M \rightarrow \mathbb{R}$ 为线性泛函且满足

$$f_0(x) \leq p(x), \quad \forall x \in M.$$

则存在定义在整个 X 上的线性泛函 $f: X \rightarrow \mathbb{R}$, 使

$$f|_M = f_0, \quad f(x) \leq p(x), \quad \forall x \in X.$$

证明 考虑所有满足下列条件的对 (N, g) 所成集合:

1. $M \subset N \subset X$, 且 N 是线性子空间;
2. $g: N \rightarrow \mathbb{R}$ 线性;
3. $g|_M = f_0$;
4. $g(x) \leq p(x)$ 对任意 $x \in N$ 成立。

以“延拓”定义偏序: 若 $(N_1, g_1) \preceq (N_2, g_2)$, 则指 $N_1 \subset N_2$ 且 $g_2|_{N_1} = g_1$ 。任意全序链的并仍给出一个满足上述条件的上界, 因此由 Zorn 引理, 存在极大元 (N^*, g^*) 。

若 $N^* \neq X$, 取 $x_0 \in X \setminus N^*$ 。由引理 5.3.1, g^* 可以延拓到 $N^* + \mathbb{R}x_0$ 上且仍被 p 支配, 这与极大性矛盾。故 $N^* = X$ 。令 $f = g^*$, 即得所求。

注 若 X 还是赋范空间, 而次线性泛函 p 满足

$$p(x) \leq C\|x\|, \quad \forall x \in X,$$

则定理 5.3.1 给出的延拓 f 自动连续, 并满足 $\|f\| \leq C$ 。因此, 解析形式的 Hahn-Banach 定理不仅保证“存在足够多的线性泛函”, 还保证在 Banach 空间里它们属于连续对偶空间 X^* , 这正是后文分离与对偶所需的对象层级。

5.3.2 几何分离

定理 5.3.2 (Hahn-Banach 的几何形式)

设 X 为实赋范空间, $C \subset X$ 为非空开凸集, $x_0 \notin C$ 。则存在非零连续线性泛函 $f \in X^*$ 与常数 $\alpha \in \mathbb{R}$, 使得

$$f(x) < \alpha \leq f(x_0), \quad \forall x \in C.$$

证明 任取 $a \in C$, 令

$$U := C - a, \quad z_0 := x_0 - a.$$

则 U 是包含原点的开凸集, 而 $z_0 \notin U$ 。定义 U 的 Minkowski 泛函

$$p_U(x) := \inf\{t > 0 : x \in tU\}, \quad x \in X.$$

由于 U 开、凸且 $0 \in U$, 由命题 5.2.2 的思想可知 p_U 是次线性的。又因为存在 $r > 0$ 使

$$B(0, r) \subset U,$$

故对任意 $x \in X$ 都有

$$p_U(x) \leq \frac{\|x\|}{r},$$

于是 p_U 还被一个连续半范数控制。

由于 $z_0 \notin U$, 故

$$p_U(z_0) \geq 1.$$

在一维子空间 $M := \mathbb{R}z_0$ 上定义线性泛函

$$f_0(tz_0) := t.$$

我们验证 $f_0 \leq p_U$ 。若 $t \geq 0$, 则

$$f_0(tz_0) = t \leq t p_U(z_0) = p_U(tz_0).$$

若 $t < 0$, 则 $f_0(tz_0) = t \leq 0 \leq p_U(tz_0)$ 。于是由定理 5.3.1, 存在线性泛函 f 延拓 f_0 且满足

$$f(x) \leq p_U(x), \quad \forall x \in X.$$

再由 $p_U(x) \leq \|x\|/r$ 知 $f \in X^*$ 。并且

$$f(z_0) = f_0(z_0) = 1,$$

故 $f \neq 0$ 。

任取 $x \in C$, 则 $x - a \in U$ 。由于 U 是开集且包含原点, 存在 $\eta > 0$ 使

$$(1 + \eta)(x - a) \in U.$$

于是

$$x - a \in \frac{1}{1 + \eta}U,$$

从而

$$p_U(x - a) \leq \frac{1}{1 + \eta} < 1.$$

故

$$f(x) - f(a) = f(x - a) \leq p_U(x - a) < 1 = f(z_0) = f(x_0) - f(a),$$

即

$$f(x) < f(x_0), \quad \forall x \in C.$$

取 $\alpha := f(x_0)$ 即得结论。

定理 5.3.3 (严格分离定理)

设 X 为实赋范空间, $C \subset X$ 为非空闭凸集, $x_0 \notin C$ 。则存在非零连续线性泛函 $f \in X^*$ 与实数 $\alpha < \beta$, 使

$$f(x) \leq \alpha < \beta \leq f(x_0), \quad \forall x \in C.$$



证明 记

$$d := \text{dist}(x_0, C) > 0.$$

令

$$V := C + B\left(0, \frac{d}{2}\right).$$

则 V 是非空开凸集, 且 $x_0 \notin V$ 。由定理 5.3.2, 存在非零 $f \in X^*$ 与 $\gamma \in \mathbb{R}$, 使

$$f(v) < \gamma \leq f(x_0), \quad \forall v \in V.$$

由于 $f \neq 0$, 可取某个 $z \in X$ 使 $f(z) > 0$, 再缩放得到 $h \in B(0, d/2)$ 且 $f(h) > 0$ 。于是对任意 $x \in C$, 都有

$$x + h \in V,$$

从而

$$f(x) + f(h) = f(x + h) < \gamma.$$

因此

$$f(x) < \gamma - f(h), \quad \forall x \in C.$$

取

$$\alpha := \gamma - f(h), \quad \beta := \gamma,$$

便得到

$$f(x) \leq \alpha < \beta \leq f(x_0), \quad \forall x \in C.$$

命题 5.3.1 (支撑超平面)

设 X 为实赋范空间, $C \subset X$ 为非空闭凸集且 $\text{int}(C) \neq \emptyset$ 。若 $x_0 \in \partial C$, 则存在非零连续线性泛函 $f \in X^*$ 使

$$f(x) \leq f(x_0), \quad \forall x \in C.$$

因此超平面

$$H := \{x \in X : f(x) = f(x_0)\}$$

称为 C 在 x_0 处的一个支撑超平面。

证明 对开凸集 $\text{int}(C)$ 与外点 $x_0 \notin \text{int}(C)$ 应用定理 5.3.2, 可得非零 $f \in X^*$ 与常数 α , 使

$$f(y) < \alpha \leq f(x_0), \quad \forall y \in \text{int}(C).$$

任取 $u \in \text{int}(C)$ 。对每个 $x \in C$ 及每个 $t \in (0, 1]$, 由凸性知

$$(1-t)x + tu \in \text{int}(C).$$

于是

$$f((1-t)x + tu) < \alpha.$$

令 $t \downarrow 0$, 由连续性得到

$$f(x) \leq \alpha, \quad \forall x \in C.$$

另一方面, 对边界点 x_0 仍有

$$(1-t)x_0 + tu \in \text{int}(C), \quad t \in (0, 1],$$

故

$$f((1-t)x_0 + tu) < \alpha.$$

令 $t \downarrow 0$ 得

$$f(x_0) \leq \alpha.$$

与 $\alpha \leq f(x_0)$ 合并, 即得

$$f(x_0) = \alpha, \quad f(x) \leq f(x_0) \quad \forall x \in C.$$

注 命题 5.3.1 中出现的 $f \in X^*$, 就是后文次梯度与对偶变量的原型。对约束问题

$$Tu = b$$

而言, 乘子首先属于 Y^* , 随后通过第 4.3 节定义 4.3.2 里的伴随算子 T^* 拉回到 X^* 。因此, 几何分离定理与伴随算子并不是两块独立内容, 而是同一套对偶语言的两端。

例题 5.7 最小抽象例子: 从常数函数子空间的延拓 设 $X = C([0, 1])$, $M = \text{span}\{1\}$, 定义

$$f_0(c1) = c, \quad p(u) = \|u\|_\infty.$$

显然 $f_0 \leq p$ 。由定理 5.3.1, f_0 可以延拓为某个 $F \in X^*$, 并满足 $\|F\| \leq 1$ 。再由第 3.3 节定理 3.3.1, F 对应于一个有限符号 Radon 测度。把这个例子放在这里, 是为了说明无穷维中的“法向量”常常并不是一个向量, 而是一类测度型泛函。

例题 5.8 有限维坍塌例子: 欧氏球的支撑超平面 在 $\mathbb{R}^n$ 中, 单位闭球

$$B = \{x \in \mathbb{R}^n : \|x\|_2 \leq 1\}$$

在边界点 x_0 处的支撑超平面由

$$\langle x_0, x \rangle = 1$$

给出。把这个例子放在这里, 是为了把 Boyd 中最熟悉的“法向量接触球面”图像精确识别为命题 5.3.1 在 Hilbert 空间里的有限维坍塌。

例题 5.9 应用触点例子: 对偶乘子的几何来源 考虑凸约束问题

$$\min_{u \in X} \phi(u) \quad \text{s.t.} \quad Tu = b,$$

其中 $T \in \mathcal{B}(X, Y)$ 。在最优解附近，把目标的下降方向与线性约束切空间分离后，得到的正是某个 $\lambda \in Y^*$ ；再经由 $T^*\lambda \in X^*$ 把它带回原变量空间。把这个例子放在这里，是为了强调：Boyd 书里写作 $A^T\lambda$ 的对象，在无穷维中真正依赖的是 Hahn-Banach 分离加上伴随算子，而不是矩阵技巧本身。

有限维对照

Boyd 在第 2 章和第 5 章中大量使用超平面分离、支撑函数和对偶变量，但这些对象在有限维里往往直接以向量和矩阵写出，因此它们的泛函本性被隐藏了。本节的结论说明：有限维图像并不是另一套理论，而是定理 5.3.2、定理 5.3.3 与命题 5.3.1 在 Euclidean 空间中的压缩版本。真正变化的只是表面符号；底层机制始终是“线性泛函足够丰富，可以把凸集与点、集合与集合、原问题与对偶问题分开”。

习题（待补）

- 练习 5.5 一步延拓公式占位 补一题：完整推导引理 5.3.1 中常数 c 所落入的区间，并说明为何该区间非空正是线性条件的体现。
- 练习 5.6 支撑超平面桥接题占位 补一题：在 Hilbert 空间中把命题 5.3.1 退化到闭球情形，直接计算支撑超平面的法向量，并与例 5.8 对照。

5.4 极点与 Krein-Milman 定理

前面三节说明了如何用线性泛函描述凸集的边界，但“边界”本身仍然太大。对优化而言，真正决定结构的往往不是整个边界，而是其中不能再被非平凡凸组合分解的那一部分。这便引出极点。在线性规划里，极点退化为顶点；在稀疏优化里，极点对应原子；在概率测度空间里，极点对应 Dirac 质量。Krein-Milman 定理的意义在于：它把这些“极端元”提升为一般紧凸集的生成机制，说明一个紧凸集可以由其极点通过闭凸包完全恢复。这样一来，第 5.3 节的分离理论不再只告诉我们“边界可被支撑”，还告诉我们“结构最终集中在边界最尖锐的部分”。

5.4.1 极点与面

定义 5.4.1 (极点)

设 C 为实向量空间中的凸集。若 $x \in C$ 满足：只要

$$x = \lambda y + (1 - \lambda)z, \quad y, z \in C, \lambda \in (0, 1),$$

就必有 $y = z = x$ ，则称 x 为 C 的一个极点。所有极点组成的集合记为

$$\text{ext}(C).$$

为了组织极点，常引入面的概念：若 $F \subset C$ 为非空凸子集，并且只要

$$\lambda y + (1 - \lambda)z \in F, \quad y, z \in C, \lambda \in (0, 1),$$

就推出 $y, z \in F$ ，则称 F 为 C 的一个面。单点面恰好对应极点；换言之， x 是极点，当且仅当 $\{x\}$ 是一个面。

引理 5.4.1 (暴露面)

设 X 为 Hausdorff 局部凸空间， $K \subset X$ 为非空紧凸集， $f \in X^*$ 为连续线性泛函。令

$$M := \max_{x \in K} f(x), \quad F := \{x \in K : f(x) = M\}.$$

则 F 是 K 的一个非空紧面。

证明 由于 K 紧且 f 连续, f 在 K 上取到最大值, 所以 F 非空。又因为 F 是闭集与紧集 K 的交, 所以 F 紧。对任意 $x_1, x_2 \in F$ 与 $\lambda \in [0, 1]$,

$$f(\lambda x_1 + (1 - \lambda)x_2) = \lambda M + (1 - \lambda)M = M,$$

故 F 凸。

若 $\lambda y + (1 - \lambda)z \in F$, 其中 $y, z \in K$ 且 $\lambda \in (0, 1)$, 则

$$M = f(\lambda y + (1 - \lambda)z) = \lambda f(y) + (1 - \lambda)f(z) \leq \lambda M + (1 - \lambda)M = M.$$

因此必须有 $f(y) = f(z) = M$, 即 $y, z \in F$ 。故 F 为面。

定理 5.4.1 (Krein-Milman 定理)

设 X 为 Hausdorff 局部凸空间, $K \subset X$ 为非空紧凸集。则

$$K = \overline{\text{conv}(\text{ext}(K))}.$$



证明 证明分两步进行。

第一步: K 至少有一个极点

考虑 K 的所有非空紧面所成集合, 并以反向包含关系排序。任一全序链的交仍是非空紧面: 非空性来自紧集族有限交性质, 面性质则由定义直接继承。由 Zorn 引理, 存在一个极小非空紧面 F 。

若 F 不是单点集, 则取互异点 $x_1, x_2 \in F$ 。由于 X 局部凸且 Hausdorff, 连续线性泛函足够分离点, 因此存在 $f \in X^*$ 使

$$f(x_1) \neq f(x_2).$$

由引理 5.4.1, 集合

$$F_1 := \left\{ x \in F : f(x) = \max_{y \in F} f(y) \right\}$$

是 F 的非空紧面。由于 f 在 F 上非常数, F_1 是 F 的真子集, 这与 F 的极小性矛盾。故 F 必为单点集 $\{x\}$ 。此时 $\{x\}$ 为 K 的面, 所以 x 是 K 的极点。

第二步: 极点的闭凸包已经生成整个 K

记

$$C := \overline{\text{conv}(\text{ext}(K))}.$$

显然 $C \subset K$, 且 C 为闭凸集。若 $C \neq K$, 取 $x_0 \in K \setminus C$ 。由于 K 所在空间局部凸, 可对点与闭凸集应用 Hahn-Banach 型分离; 这正是定理 5.3.2 的局部凸推广。于是存在连续线性泛函 $f \in X^*$ 与常数 $\alpha < \beta$, 使

$$f(x) \leq \alpha < \beta \leq f(x_0), \quad \forall x \in C.$$

令

$$F := \left\{ x \in K : f(x) = \max_{y \in K} f(y) \right\}.$$

由引理 5.4.1, F 是 K 的非空紧面。由第一步, F 至少包含一个极点 u 。而面上的极点仍是整个集合的极点: 若

$$u = \lambda y + (1 - \lambda)z, \quad y, z \in K, \lambda \in (0, 1),$$

则因 $u \in F$ 且 F 为面, 必有 $y, z \in F$; 再由 u 在 F 中是极点, 得 $y = z = u$ 。于是

$$u \in \text{ext}(K) \subset C.$$

但另一方面, $u \in F$ 且 $x_0 \in K$, 所以

$$f(u) = \max_{y \in K} f(y) \geq f(x_0) \geq \beta > \alpha.$$

这与 $u \in C$ 时的 $f(u) \leq \alpha$ 矛盾。故 $C = K$, 定理得证。

推论 5.4.1 (有限维多面体的极点描述)

设 $P \subset \mathbb{R}^n$ 为紧多面体, 则

$$P = \text{conv}(\text{ext}(P)).$$

特别地, 在有限维情形中, 多面体的顶点恰好就是它的极点。



证明 紧多面体是有限维空间中的紧凸集, 因此可直接应用定理 5.4.1。由于有限维中闭包运算对有限凸包不再引入额外复杂性, 得到

$$P = \text{conv}(\text{ext}(P)).$$

而顶点正是不能写成其它可行点非平凡凸组合的点, 所以与定义 5.4.1 完全一致。

结构意义

注 定理 5.4.1 把第 5.3 节的分离原理推进了一步。分离只告诉我们: 若一点不在某个闭凸集中, 则存在连续线性泛函把它隔开; 而 Krein-Milman 进一步指出: 只要集合还具有紧性, 这些支撑泛函最终会把结构压缩到极点上。后文无论是讨论原子范数、测度型最优策略还是线性规划顶点, 都是这一思想在不同空间中的再现。

例题 5.10 最小抽象例子: 概率测度的 Dirac 极点 设 K 为紧 Hausdorff 空间, $\mathcal{P}(K)$ 表示其上所有 Borel 概率测度的集合。借助第 3.3 节定理 3.3.1, 可把 $\mathcal{P}(K)$ 看成 $C(K)^*$ 中的一个弱*紧凸集。对任意 $x \in K$, Dirac 测度 δ_x 都是 $\mathcal{P}(K)$ 的极点: 若

$$\delta_x = \lambda \mu_1 + (1 - \lambda) \mu_2, \quad \lambda \in (0, 1),$$

则对任意不含 x 的闭集 F 有 $\delta_x(F) = 0$, 从而 $\mu_1(F) = \mu_2(F) = 0$; 再利用总质量为 1 可知 $\mu_1 = \mu_2 = \delta_x$ 。把这个例子放在这里, 是为了说明无穷维随机优化中“极端策略”往往对应于原子测度。

例题 5.11 有限维坍缩例子: 线性规划顶点 在线性规划可行域

$$P = \{x \in \mathbb{R}^n : Ax \leq b\}$$

中, 顶点恰好就是极点。把这个例子放在这里, 是为了与 Boyd 的 LP 几何直接对齐: 有限维教材里“最优解常在顶点处取得”的说法, 正是推论 5.4.1 的线性规划版本。

例题 5.12 应用触点例子: ℓ^1 球的原子结构 在 $\mathbb{R}^n$ 中,

$$B_1 = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\}$$

的极点正是 $\{\pm e_1, \dots, \pm e_n\}$ 。把这个例子放在这里, 是为了连接稀疏优化中的原子范数直觉: 一个点若位于 ℓ^1 球的极点上, 就只激活单个坐标; 而一般点则是这些原子的凸组合。无穷维原子表示的语言, 本质上就是把这种有限维现象推广到更大的函数或测度空间。

有限维对照

Boyd 书中关于顶点、极点、稀疏结构和 LP 几何的大部分直觉, 都可以看作定理 5.4.1 在有限维空间中的压缩版。有限维里, 多面体顶点可直接画出来, ℓ^1 球的尖点也能肉眼识别; 无穷维里则必须借助极点与闭凸包的语言来组织这些结构。换句话说, Boyd 所讨论的顶点现象并不是偶然的多面体事实, 而是一般紧凸集边界理论在有限维中的最易见表现。

习题 (待补)

- 🔴 **练习 5.7 极点与面占位** 补一题: 证明“ $\{x\}$ 是凸集 C 的面”与“ x 是 C 的极点”等价, 并说明这一命题在定理 5.4.1 的证明中起到什么作用。
- 🔴 **练习 5.8 Dirac 测度桥接题占位** 补一题: 在紧空间 K 上验证例 5.10 中 Dirac 测度的极点性质, 并进一步讨论哪些条件下 $\mathcal{P}(K)$ 的全部极点都由 Dirac 测度给出。

第 6 章 凸泛函与无穷维微积分

第 5 章把凸集、分离与支撑超平面的几何语言建立起来之后，下一步自然要把视角从“集合”转向“泛函”。在有限维凸优化里，这一步往往表现为熟悉的函数图像、梯度、次梯度和最优性条件；但在无穷维中，真正困难的并不是把记号从 $x \in \mathbb{R}^n$ 改成 $u \in X$ ，而是要重新界定哪些连续性足以支撑存在性，哪些可微性足以支撑一阶展开，以及哪些局部线性信息能够在不可微情形下留下来。

本章正是为这些问题建立局部语言。第 6.1 节先讨论下半连续性、弱紧性与直接法，说明凸泛函的极小值存在绝不是一个无条件口号，而必须由拓扑、强制性和紧性来源共同支撑。第 6.2 节再把方向导数、Gâteaux 微分与 Fréchet 微分区分开来，解释为什么无穷维里“可微”本身就有层级。第 6.3 节引入对偶空间中的次微分，把不可微凸泛函的局部信息重写成支撑超平面的函数化版本。最后第 6.4 节整理次微分演算，给出和规则、线性映射下的拉回以及 Moreau–Rockafellar 和公式，为第 7 章的共轭理论和第 9 至 10 章的单调算子与分裂算法提供可直接调用的接口。

阅读本章时，需要始终记住三层环境的区别。局部凸或 Banach 框架已经足够谈凸泛函、连续线性泛函与分离；自反 Banach 空间开始提供弱紧性，因此能承载直接法；Hilbert 空间则通过第 4.1 节定理 4.1.2 把导数和对偶重新识别为向量，使梯度、投影、邻近映射与算法迭代获得更具体的几何解释。后文关于 Fenchel–Rockafellar 对偶、KKT 条件、极大单调算子与 ADMM 的很多论证，都会回链到这一章。

6.1 下半连续性与极值定理

若把凸优化理解为“在一个几何良好的空间里最小化一个几何良好的目标”，那么存在性问题就是第一道关口。有限维情形中，闭有界集紧、连续函数在紧集上取极值，这一链条几乎不必单独说明；但在无穷维里，闭有界集通常不紧，甚至极小化列都可能完全逃逸。因此，本节要把“极小值存在”重写成真正可复用的标准模板：目标泛函需要适当的下半连续性，可行区域需要某种弱紧性来源，而强制性则负责阻止极小化过程向无穷远逃走。

6.1.1 Proper 凸泛函与下半连续性

定义 6.1.1 (Proper 凸泛函)

设 X 为实向量空间，函数

$$f: X \rightarrow \mathbb{R} \cup \{+\infty\}$$

称为 *proper* 的，若其有效定义域

$$\text{dom } f := \{x \in X : f(x) < +\infty\}$$

非空，且 f 不取值 $-\infty$ 。若再满足对任意 $x, y \in X$ 与任意 $\lambda \in [0, 1]$,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y),$$

则称 f 为一个 *proper 凸泛函*。

定义 6.1.2 (下半连续与弱下半连续)

设 X 为拓扑向量空间， $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为一个 proper 泛函。若对每个 $r \in \mathbb{R}$ ，次水平集

$$\{x \in X : f(x) \leq r\}$$

都是闭集，则称 f 在给定拓扑下下半连续。当 X 为 Banach 空间且所用拓扑是弱拓扑 $\sigma(X, X^*)$ 时，称 f 为弱下半连续。

注 定义 6.1.2 与第 2.1 节命题 2.1.1 等价地说明： f 在某个拓扑下半连续，当且仅当对任意收敛网 $x_\alpha \rightarrow x$ 都有

$$f(x) \leq \liminf_{\alpha} f(x_\alpha).$$

后文一旦工作在弱拓扑或弱*拓扑中，就必须把这条判别理解成关于网的陈述，而不能默认退回序列语言。

定义 6.1.3 (强制性)

设 X 为赋范空间。proper 泛函 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 称为强制的，若

$$\|x\| \rightarrow \infty \implies f(x) \rightarrow +\infty.$$

等价地说，对任意实数 r ，次水平集

$$\{x \in X : f(x) \leq r\}$$

都是有界的。

注 强制性并不等于有极小值；它只保证极小化过程不会逃向无穷远。真正的存在性还需要结合弱紧性或紧嵌入等额外结构。第 4.2 节推论 4.2.1 已经说明：在 Hilbert 或更一般自反 Banach 空间中，闭球的弱紧性才是直接法得以启动的关键。

6.1.2 弱紧集上的极小值存在

定理 6.1.1 (弱紧集上的弱下半连续泛函取极小值)

设 X 为 Banach 空间， $C \subset X$ 为非空弱紧集， $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 且在 C 上弱下半连续的泛函。则存在 $\bar{x} \in C$ 使

$$f(\bar{x}) = \inf_{x \in C} f(x).$$

证明 记

$$m := \inf_{x \in C} f(x).$$

由 proper 性可知 $m < +\infty$ 。对每个 $\varepsilon > 0$ 选取 $x_\varepsilon \in C$ 使

$$f(x_\varepsilon) \leq m + \varepsilon.$$

将 $(0, +\infty)$ 赋予反序，即 $\varepsilon_1 \preceq \varepsilon_2$ 当且仅当 $\varepsilon_1 \geq \varepsilon_2$ ，于是 (x_ε) 构成一条以“精度趋于零”为指标的网。由于 C 弱紧，它存在弱收敛子网，仍记为

$$x_\alpha \rightharpoonup \bar{x} \in C.$$

由定义 6.1.2 的网刻画，

$$f(\bar{x}) \leq \liminf_{\alpha} f(x_\alpha) \leq \liminf_{\alpha} (m + \alpha) = m.$$

另一方面 m 本就是 C 上的下确界，因此 $m \leq f(\bar{x})$ 。综上

$$f(\bar{x}) = m,$$

即 $\bar{x}$ 是所求极小元。

6.1.3 自反空间中的直接法

定理 6.1.2 (自反 Banach 空间中的直接法)

设 X 为自反 Banach 空间， $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、弱下半连续且强制的凸泛函。则 f 在 X 上取到极小值。

证明 记

$$m := \inf_{x \in X} f(x).$$

由 proper 性可知 $m < +\infty$ 。同样对每个 $\varepsilon > 0$ 选取 $x_\varepsilon \in X$ 满足

$$f(x_\varepsilon) \leq m + \varepsilon.$$

由于 f 强制, 这条极小化网必有界; 否则若 $\|x_\varepsilon\| \rightarrow \infty$, 则 $f(x_\varepsilon) \rightarrow +\infty$, 与上式矛盾。故存在 $R > 0$ 使

$$x_\varepsilon \in \overline{B}(0, R), \quad \forall \varepsilon.$$

由第 4.2 节定义 4.2.3 及 Banach–Alaoglu 定理的推论, 自反 Banach 空间中的闭球在弱拓扑下紧, 因此 $\overline{B}(0, R)$ 弱紧。由定理 6.1.1, (x_ε) 的某个子网弱收敛到某个 $\bar{x} \in \overline{B}(0, R)$, 且

$$f(\bar{x}) \leq \liminf_{\alpha} f(x_\alpha) \leq m.$$

由 m 的定义, 又有 $m \leq f(\bar{x})$ 。故

$$f(\bar{x}) = m.$$

于是 f 在 X 上取到极小值。

注 定理 6.1.2 是本书后文最常调用的存在性模板之一。正确的口号不是“下半连续凸泛函必有极小值”, 而是: “若极小化过程被强制性压进某个弱紧区域, 并且目标在该拓扑下半连续, 则直接法成立。”这一区分在第 7.4 节对偶间隙分析和第 12.1 节控制问题里都会反复出现。

6.1.4 典型例子

例题 6.1 Sobolev 型能量泛函 在 Hilbert 空间 $H_0^1(\Omega)$ 上考虑

$$J(u) = \frac{1}{2} \int_{\Omega} |\nabla u(x)|^2 dx + \int_{\Omega} \Phi(u(x)) dx - \langle \ell, u \rangle,$$

其中 Φ 为凸下半连续函数, $\ell \in H^{-1}(\Omega)$ 。把这个例子放在这里, 是为了说明偏微分方程中的变分问题通常正是定理 6.1.2 的标准应用场景: 二次梯度项提供强制性, 凸势能与线性项决定弱下半连续性和可解性。

例题 6.2 有限维闭有界水平集 当 $X = \mathbb{R}^n$ 时, 弱拓扑与通常拓扑一致, 闭有界集自动紧。于是若 f 的某个次水平集

$$\{x \in \mathbb{R}^n : f(x) \leq r\}$$

非空且闭有界, 则极小值存在直接退化为 Weierstrass 定理。把这个例子放在这里, 是为了说明 Boyd 书里许多“函数连续、水平集闭有界, 因此解存在”的论证, 实际上是定理 6.1.1 在欧氏空间中的坍缩。

例题 6.3 Tikhonov 型正则化 设 H 为 Hilbert 空间, $A: H \rightarrow Y$ 为有界线性算子, 考虑

$$f(u) = \frac{1}{2} \|Au - b\|_Y^2 + \lambda \|u\|_H^2, \quad \lambda > 0.$$

该泛函是 proper、凸、连续且强制的, 因此由定理 6.1.2 在 H 上存在极小元。把这个例子放在这里, 是为了连接后文的逆问题、机器学习与第 11.1 节前向–后向分裂: 正则化项不仅改善数值稳定性, 也提供存在性所需的强制性。

有限维对照

Boyd 第 3 章里关于凸函数、次水平集和极小值存在的叙述, 默认都工作在 $\mathbb{R}^n$ 中, 因此“闭有界即紧”这一事实被自动吞掉。本节的作用是把这一步显式拆开: 定理 6.1.1 负责把极小值存在写成“紧性 + 下半连续”的拓扑命题, 定理 6.1.2 则说明在无穷维里, 这个紧性往往要通过弱拓扑、自反性和强制性重新获得。

习题（待补）

- 练习 6.1 弱下半连续判别占位 补一题：要求把定义 6.1.2 用网重写，并结合命题 2.1.1 说明为什么弱下半连续性的正确语言不是“子列极限”而是“子网极限”。
- 练习 6.2 直接法桥接题占位 补一题：在 Hilbert 空间中证明例 6.3 的极小元存在，并明确指出证明中分别在哪一步使用了强制性、推论 4.2.1 与下半连续性。

6.2 方向导数：Gâteaux 微分与 Fréchet 微分

存在性解决以后，下一步自然是研究泛函在局部如何变化。有限维里，梯度既是最速上升方向，也是线性近似的系数，因此“可微”通常只剩一种标准形态；但在无穷维中，方向上的极限存在并不自动意味着存在一个统一的连续线性逼近。也就是说，局部一阶信息本身有强弱层级。第 6.3 节的次微分正是建立在这种区分之上，而第 10 章的一阶算法则更加依赖其中较强的一层。

6.2.1 方向导数与 Gâteaux 微分

定义 6.2.1 (方向导数)

设 X 为实向量空间， $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ ， $x \in \text{dom } f$ ， $h \in X$ 。若极限

$$f'(x; h) := \lim_{t \downarrow 0} \frac{f(x + th) - f(x)}{t}$$

存在于 $\mathbb{R} \cup \{\pm\infty\}$ ，则称其为 f 在点 x 沿方向 h 的方向导数。

定义 6.2.2 (Gâteaux 微分)

设 X, Y 为 Banach 空间， $U \subset X$ 为开集， $f: U \rightarrow Y$ 。若对每个 $h \in X$ ，极限

$$\lim_{t \rightarrow 0} \frac{f(x + th) - f(x)}{t}$$

存在，且存在连续线性算子 $A \in \mathcal{L}(X, Y)$ 使得

$$\lim_{t \rightarrow 0} \frac{f(x + th) - f(x)}{t} = Ah, \quad \forall h \in X,$$

则称 f 在 x 处 Gâteaux 可微，并称 A 为 f 在 x 处的 Gâteaux 导数，记为 $D_G f(x)$ 。

注 定义 6.2.2 中最微妙的一点在于：极限是对每个方向逐个成立的。它要求存在一个共同的连续线性算子来记录所有方向的导数，但并不要求余项对所有小扰动同时一致控制。这也是 Gâteaux 微分弱于 Fréchet 微分的根本原因。

6.2.2 Fréchet 微分与 Hilbert 梯度

定义 6.2.3 (Fréchet 微分)

设 X, Y 为 Banach 空间， $U \subset X$ 为开集， $f: U \rightarrow Y$ 。若存在连续线性算子 $A \in \mathcal{L}(X, Y)$ 使

$$\lim_{\|h\| \rightarrow 0} \frac{\|f(x + h) - f(x) - Ah\|_Y}{\|h\|_X} = 0,$$

则称 f 在 x 处 Fréchet 可微，并称 A 为 f 在 x 处的 Fréchet 导数，记为 $Df(x)$ 。

命题 6.2.1 (Fréchet 可微蕴含 Gâteaux 可微)

设 $U \subset X$ 为 Banach 空间中的开集, $f: U \rightarrow Y$. 若 f 在 $x \in U$ 处 Fréchet 可微, 且导数为 $Df(x)$, 则 f 在 x 处 Gâteaux 可微, 且

$$D_G f(x)h = Df(x)h, \quad \forall h \in X.$$

证明 由定义 6.2.3, 对任意 $h \in X$ 与任意标量 $t \neq 0$,

$$f(x + th) - f(x) - Df(x)(th) = r(th),$$

其中

$$\frac{\|r(th)\|_Y}{|t|\|h\|_X} \rightarrow 0 \quad (t \rightarrow 0).$$

故

$$\frac{f(x + th) - f(x)}{t} = Df(x)h + \frac{r(th)}{t}.$$

当 $t \rightarrow 0$ 时, 右侧第二项趋于 0, 于是

$$\lim_{t \rightarrow 0} \frac{f(x + th) - f(x)}{t} = Df(x)h.$$

这正是定义 6.2.2。

注 命题 6.2.1 的逆命题一般不成立。也就是说, 逐方向的导数存在并拼出一个线性算子, 并不能保证余项在小球上受一致控制。对优化而言, 这个差别非常重要: Gâteaux 可微往往足以给出形式上的一阶展开, 但 Fréchet 可微才更接近数值算法所依赖的稳定线性近似。

定义 6.2.4 (Hilbert 空间中的梯度)

设 H 为 Hilbert 空间, $f: H \rightarrow \mathbb{R}$ 在 $x \in H$ 处 Fréchet 可微。由第 4.1 节定理 4.1.2, 存在唯一向量 $\nabla f(x) \in H$ 使

$$Df(x)h = \langle \nabla f(x), h \rangle_H, \quad \forall h \in H.$$

该向量称为 f 在 x 处的梯度。

6.2.3 凸可微泛函的一阶信息**命题 6.2.2 (凸可微泛函的一阶支撑不等式)**

设 X 为 Banach 空间, $U \subset X$ 为凸开集, $f: U \rightarrow \mathbb{R}$ 为凸函数。若 f 在 $x \in U$ 处 Gâteaux 可微, 则对任意 $y \in U$ 都有

$$f(y) \geq f(x) + D_G f(x)(y - x).$$

证明 固定 $y \in U$, 考虑一维函数

$$\phi(t) = f(x + t(y - x)), \quad t \in [0, 1].$$

由凸性知 ϕ 是区间上的凸函数。对任意 $t \in (0, 1]$, 凸函数的割线斜率单调, 故

$$\frac{\phi(t) - \phi(0)}{t} \geq \phi'_+(0).$$

令 $t = 1$ 并利用 Gâteaux 导数存在, 得到

$$f(y) - f(x) \geq D_G f(x)(y - x).$$

注 这条支撑不等式说明: 一旦凸泛函在某点可微, 其导数就自动给出该点处的支撑超平面。第 6.3 节中的次微分正是要把这种“单值支撑”推广到不可微情形。

6.2.4 典型例子

例题 6.4 积分型泛函的 Gâteaux 导数 设 Ω 为有限测度空间, $X = L^2(\Omega)$, 并考虑

$$f(u) = \int_{\Omega} \Phi(u(x)) dx,$$

其中 $\Phi \in C^1(\mathbb{R})$ 且 Φ' 具有适当增长。则在合适的定义域上,

$$D_G f(u)h = \int_{\Omega} \Phi'(u(x))h(x) dx.$$

把这个例子放在这里, 是为了说明 Gâteaux 导数自然落在对偶配对之中: 方向导数看似是“沿 h 的一维变化”, 但最后得到的却是一个连续线性泛函。

例题 6.5 欧氏二次型的梯度 在 $\mathbb{R}^n$ 上令

$$f(x) = \frac{1}{2}x^\top Qx + b^\top x + c,$$

其中 Q 为对称矩阵。则 f Fréchet 可微且

$$\nabla f(x) = Qx + b.$$

把这个例子放在这里, 是为了表明 Boyd 书里最熟悉的梯度公式, 其实正是定义 6.2.4 在有限维 Hilbert 空间中的退化。

例题 6.6 Hilbert 空间中的最小二乘能量 设 H_1, H_2 为 Hilbert 空间, $A: H_1 \rightarrow H_2$ 为有界线性算子。对

$$f(u) = \frac{1}{2}\|Au - b\|_{H_2}^2$$

有

$$Df(u)h = \langle Au - b, Ah \rangle_{H_2} = \langle A^*(Au - b), h \rangle_{H_1},$$

其中 A^* 由第 4.3 节定义 4.3.2 给出。于是

$$\nabla f(u) = A^*(Au - b).$$

把这个例子放在这里, 是为了连接第 4.3 节的伴随算子与本节的梯度概念, 也为后文最速下降和正则化算法提供标准原型。

有限维对照

Boyd 第 9 章里把梯度、Jacobian 和最速下降法建立在欧氏空间几何之上, 因此“可微”几乎默认就是 Fréchet 可微, 而且导数自动由向量表示。本节的作用, 是把这种有限维母语拆成三个层级: 定义 6.2.1 只记录单方向变化, 定义 6.2.2 记录逐方向的线性化, 而定义 6.2.3 与定义 6.2.4 则给出算法上真正稳定的一阶近似。

习题 (待补)

- 练习 6.3 Gâteaux 与 Fréchet 区分占位 补一题: 构造一个 Gâteaux 可微但并非 Fréchet 可微的泛函例子, 并说明这种失效为什么会破坏基于统一线性近似的一阶算法解释。
- 练习 6.4 Hilbert 梯度桥接题占位 补一题: 对例 6.6 验证定义 6.2.4, 并说明当 $H_1 = \mathbb{R}^n$ 、 $H_2 = \mathbb{R}^m$ 时, 梯度公式如何退化为 Boyd 书中的矩阵表达。

6.3 对偶空间中的次微分

上一节的可微理论告诉我们: 在凸可微点, 导数给出局部支撑超平面。然而凸优化里真正有趣的模型往往恰恰出现在不可微处, 例如范数、指示函数、绝对值型正则化以及各种约束罚项。此时“唯一导数”不再存在, 但支撑超平面仍然可能存在, 并且往往不止一个。次微分的作用, 就是把这些可能的局部线性支撑统一收集到对偶空间里, 从而把不可微问题重新纳入一阶最优性与对偶几何的框架。

6.3.1 次微分的定义

定义 6.3.1 (次微分)

设 X 为 Banach 空间, $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函, $x \in \text{dom } f$ 。定义

$$\partial f(x) := \{x^* \in X^* : f(y) \geq f(x) + \langle x^*, y - x \rangle, \forall y \in X\}.$$

集合 $\partial f(x)$ 称为 f 在 x 处的次微分; 其中元素称为次梯度。若 $x \notin \text{dom } f$, 则约定 $\partial f(x) = \emptyset$ 。

注 定义 6.3.1 正是第 5.3 节定理 5.3.2 与命题 5.3.1 的局部化版本。区别只在于: 这里支撑对象不再是单个凸集, 而是凸泛函的上图像

$$\text{epi } f = \{(x, r) \in X \times \mathbb{R} : r \geq f(x)\}.$$

因此次微分可以理解为“在函数图像下方放置的所有支撑超平面之斜率”。

命题 6.3.1 (次梯度最优性条件)

设 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函, $x \in \text{dom } f$ 。则

$$0 \in \partial f(x)$$

当且仅当 x 是 f 的全局极小点。

证明 若 $0 \in \partial f(x)$, 由定义 6.3.1,

$$f(y) \geq f(x), \quad \forall y \in X,$$

故 x 为全局极小点。反之, 若 x 为全局极小点, 则同样有

$$f(y) \geq f(x) = f(x) + \langle 0, y - x \rangle, \quad \forall y \in X,$$

因而 $0 \in \partial f(x)$ 。

命题 6.3.2 (可微点的单值次微分)

设 X 为 Banach 空间, $U \subset X$ 为凸开集, $f: U \rightarrow \mathbb{R}$ 为凸函数。若 f 在 $x \in U$ 处 Fréchet 可微, 则

$$\partial f(x) = \{Df(x)\}.$$

在 Hilbert 空间中, 这等价于

$$\partial f(x) = \{\nabla f(x)\},$$

其中梯度由定义 6.2.4 给出。

证明 由上一节的凸可微支撑不等式, $Df(x)$ 满足

$$f(y) \geq f(x) + Df(x)(y - x), \quad \forall y \in U.$$

凸性又保证该不等式可延拓为对所有 $y \in X$ 的次梯度不等式, 因此 $Df(x) \in \partial f(x)$ 。

现取任意 $x^* \in \partial f(x)$ 。由定义 6.3.1, 对任意 $h \in X$ 与充分小的 $t > 0$,

$$f(x + th) \geq f(x) + t\langle x^*, h \rangle.$$

同理, 把 h 换成 $-h$ 得

$$f(x - th) \geq f(x) - t\langle x^*, h \rangle.$$

两式分别除以 t 并令 $t \downarrow 0$, 利用 Fréchet 可微得到

$$Df(x)h \geq \langle x^*, h \rangle, \quad Df(x)h \leq \langle x^*, h \rangle.$$

故对任意 $h \in X$,

$$Df(x)h = \langle x^*, h \rangle.$$

于是 $x^* = Df(x)$ 。故次微分是单点集。

6.3.2 次微分的非空性

定理 6.3.1 (内点处次微分非空)

设 X 为 Banach 空间, $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。若

$$x \in \text{int}(\text{dom } f),$$

则

$$\partial f(x) \neq \emptyset.$$



证明 考虑乘积空间 $X \times \mathbb{R}$, 赋予范数

$$\|(u, r)\| := \|u\| + |r|.$$

因为 f 下半连续且凸, 其上图像

$$\text{epi } f := \{(u, r) : r \geq f(u)\}$$

是闭凸集。点 $(x, f(x))$ 位于其边界上; 另一方面, 由 $x \in \text{int}(\text{dom } f)$ 可知存在半径 $\rho > 0$ 使 $B(x, \rho) \subset \text{dom } f$, 因此对任意足够小的 h 与任意 $\eta > 0$, 点

$$(x + h, f(x) + 1 + \eta)$$

属于 $\text{epi } f$ 的内部, 所以该上图像具有非空内部。

于是可对闭凸集 $\text{epi } f$ 在边界点 $(x, f(x))$ 处应用第 5.3 节命题 5.3.1。存在非零连续线性泛函 $(x^*, s) \in X^* \times \mathbb{R}$ 使

$$\langle x^*, u \rangle + sr \leq \langle x^*, x \rangle + sf(x), \quad \forall (u, r) \in \text{epi } f.$$

对任意 $u \in \text{dom } f$, 取 $r = f(u)$, 得

$$\langle x^*, u - x \rangle + s(f(u) - f(x)) \leq 0.$$

下面说明 $s < 0$ 。若 $s > 0$, 则对固定的 u 令 $r \rightarrow +\infty$, 上式不可能始终成立。若 $s = 0$, 则

$$\langle x^*, u - x \rangle \leq 0, \quad \forall u \in \text{dom } f.$$

但 x 是定义域内点, 可在 x 的任意小邻域中取到 $u = x \pm th$, 从而推出 $\langle x^*, h \rangle = 0$ 对所有 $h \in X$ 成立, 即 $x^* = 0$, 与 $(x^*, s) \neq 0$ 矛盾。故 $s < 0$ 。

令

$$\xi^* := -\frac{x^*}{s} \in X^*.$$

则上式改写为

$$f(u) \geq f(x) + \langle \xi^*, u - x \rangle, \quad \forall u \in X.$$

因此 $\xi^* \in \partial f(x)$, 从而 $\partial f(x) \neq \emptyset$ 。

6.3.3 闭图性质

命题 6.3.3 (次微分的闭图性质)

设 X 为 Banach 空间, $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。若网 $x_\alpha \rightarrow x$ 在范数拓扑下收敛, 网 $x_\alpha^* \rightharpoonup^* x^*$ 在弱*拓扑下收敛, 且

$$x_\alpha^* \in \partial f(x_\alpha), \quad \forall \alpha,$$

则

$$x^* \in \partial f(x).$$



证明 由 $x_\alpha^* \in \partial f(x_\alpha)$, 对任意固定 $y \in X$ 都有

$$f(y) \geq f(x_\alpha) + \langle x_\alpha^*, y - x_\alpha \rangle.$$

由下半连续性的网刻画,

$$f(x) \leq \liminf_{\alpha} f(x_\alpha).$$

另一方面, 由 $x_\alpha \rightarrow x$ 强收敛以及 $x_\alpha^* \rightharpoonup^* x^*$, 对固定的 y 有

$$\langle x_\alpha^*, y - x_\alpha \rangle \rightarrow \langle x^*, y - x \rangle.$$

因此对上式取上极限得到

$$f(y) \geq f(x) + \langle x^*, y - x \rangle, \quad \forall y \in X.$$

由定义 6.3.1, 即 $x^* \in \partial f(x)$ 。

6.3.4 典型例子

例题 6.7 范数函数的次微分 设 X 为 Banach 空间, $f(x) = \|x\|$ 。当 $x \neq 0$ 时,

$$\partial \|x\| = \{x^* \in X^* : \|x^*\| = 1, \langle x^*, x \rangle = \|x\|\};$$

而在原点处,

$$\partial \|0\| = \{x^* \in X^* : \|x^*\| \leq 1\}.$$

把这个例子放在这里, 是为了说明不可微并不意味着“一阶信息消失”; 相反, 它意味着可能存在整片支撑超平面。这里的次梯度集合正是所有“支撑单位球”的对偶向量。

例题 6.8 ℓ_1 范数的次梯度 在 $\mathbb{R}^n$ 上,

$$f(x) = \|x\|_1 = \sum_{i=1}^n |x_i|$$

满足

$$\partial \|x\|_1 = \left\{ g \in \mathbb{R}^n : g_i = \begin{cases} \text{sign}(x_i), & x_i \neq 0, \\ \xi_i \in [-1, 1], & x_i = 0 \end{cases} \right\}.$$

把这个例子放在这里, 是为了与 Boyd 书中最常见的非光滑例子对齐, 也说明稀疏性结构为什么会对应一个多值的一阶条件。

例题 6.9 指示函数与法锥原型 设 $C \subset X$ 为闭凸集, 其指示函数定义为

$$\iota_C(x) = \begin{cases} 0, & x \in C, \\ +\infty, & x \notin C. \end{cases}$$

则 $\partial \iota_C(x)$ 由所有满足

$$\langle x^*, y - x \rangle \leq 0, \quad \forall y \in C$$

的对偶向量组成。把这个例子放在这里, 是为了说明约束并不会在次微分框架外另起炉灶; 它们只是通过指示函数把“可行性”编码成了法锥条件。第 6.4 节会把这一观察写成正式的演算公式。

有限维对照

Boyd 第 3 章和第 5 章里把次梯度解释为图像上所有可能的支撑超平面斜率。在 $\mathbb{R}^n$ 中，这个图像直觉几乎已经足够；但在无穷维里，真正稳固的对象是定义 6.3.1 中的对偶空间集合，以及定理 5.3.2、命题 5.3.1 所保证的分离与支撑结构。本节的目的，就是把这些欧氏图像提升为可在 Banach 与 Hilbert 空间中直接调用的一阶语言。

习题（待补）

- 练习 6.5 次梯度最优性占位 补一题：对一个具体不可微凸函数验证命题 6.3.1，并把条件 $0 \in \partial f(x)$ 翻译成有限维中的 KKT 风格一阶最优性条件。
- 练习 6.6 法锥桥接题占位 补一题：从例 6.9 出发，把闭凸集的约束最优性写成指示函数的次微分条件，并解释它与支撑超平面的关系。

6.4 次微分演算

单个点上的次微分只提供局部信息；真正让它成为建模与算法工具的，是一套可稳定复用的演算规则。和泛函如何分解次梯度？线性观测算子如何把对偶变量从像空间拉回原空间？约束指示函数与法锥如何统一？这些问题在有限维里常被视为“计算技巧”，但在无穷维里它们直接决定第 7 章共轭公式、第 8 章 KKT 条件以及第 9 至 10 章分裂算法能否写成统一模板。本节的核心接口就是 Moreau-Rockafellar 和公式及其线性拉回版本。

6.4.1 和规则与法锥

命题 6.4.1 (次微分和规则的基本包含式)

设 X 为 Banach 空间， $f, g: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函。则对任意 $x \in X$,

$$\partial f(x) + \partial g(x) \subset \partial(f+g)(x).$$

证明 任取

$$x_1^* \in \partial f(x), \quad x_2^* \in \partial g(x).$$

由定义 6.3.1，对任意 $y \in X$,

$$f(y) \geq f(x) + \langle x_1^*, y - x \rangle, \quad g(y) \geq g(x) + \langle x_2^*, y - x \rangle.$$

两式相加得

$$(f+g)(y) \geq (f+g)(x) + \langle x_1^* + x_2^*, y - x \rangle.$$

因此

$$x_1^* + x_2^* \in \partial(f+g)(x),$$

结论成立。

推论 6.4.1 (指示函数与法锥)

设 $C \subset X$ 为非空闭凸集，并定义指示函数

$$\iota_C(x) = \begin{cases} 0, & x \in C, \\ +\infty, & x \notin C. \end{cases}$$

对 $x \in C$ ，定义法锥

$$N_C(x) := \{x^* \in X^* : \langle x^*, y - x \rangle \leq 0, \forall y \in C\}.$$

则

$$\partial \iota_C(x) = N_C(x), \quad x \in C.$$



证明 由定义 6.3.1,

$$x^* \in \partial \iota_C(x)$$

当且仅当对任意 $y \in X$,

$$\iota_C(y) \geq \iota_C(x) + \langle x^*, y - x \rangle.$$

当 $y \notin C$ 时左侧为 $+\infty$, 不等式自动成立; 当 $y \in C$ 时, $\iota_C(y) = \iota_C(x) = 0$, 故不等式恰化为

$$\langle x^*, y - x \rangle \leq 0, \quad \forall y \in C.$$

这正是 $x^* \in N_C(x)$ 。

6.4.2 Moreau–Rockafellar 和公式

定理 6.4.1 (Moreau–Rockafellar 和公式)

设 X 为 Banach 空间, $f, g: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函, $x \in \text{dom } f \cap \text{dom } g$ 。若 f 或 g 中至少有一个在 x 处连续, 则

$$\partial(f+g)(x) = \partial f(x) + \partial g(x).$$



证明 由命题 6.4.1, 只需证明反向包含。设

$$x^* \in \partial(f+g)(x).$$

若 f 在 x 处连续, 则交换 f, g 的角色即可, 故不妨设 g 在 x 处连续。定义

$$F(u) := f(x+u) - f(x) - \langle x^*, u \rangle, \quad G(u) := g(x) - g(x+u).$$

由 $x^* \in \partial(f+g)(x)$, 对任意 $u \in X$ 都有

$$F(u) \geq G(u).$$

考虑集合

$$C_1 := \{(u, r) \in X \times \mathbb{R} : F(u) \leq r\}, \quad C_2 := \{(u, r) \in X \times \mathbb{R} : G(u) > r\}.$$

C_1 是闭凸集, 而由于 g 在 x 处连续, G 在原点处上半连续, 从而 C_2 是开凸集。两者由上式可知不相交。于是由第 5.3 节定理 5.3.3 的分离思想, 存在非零连续线性泛函 $(u^*, s) \in X^* \times \mathbb{R}$ 使

$$\langle u^*, u \rangle + sr_1 \geq \langle u^*, v \rangle + sr_2, \quad \forall (u, r_1) \in C_1, \forall (v, r_2) \in C_2.$$

取 $u = v = 0$, 并利用 $(0, r_1) \in C_1$ 对所有 $r_1 \geq 0$ 成立、 $(0, r_2) \in C_2$ 对所有 $r_2 < 0$ 成立, 可知 $s > 0$ 。再让 $(u, r_1) = (u, F(u)) \in C_1$, 并令 $r_2 \uparrow G(u)$, 得到

$$\langle u^*, u \rangle + sF(u) \geq 0, \quad \langle u^*, u \rangle + sG(u) \leq 0.$$

于是对任意 $u \in X$,

$$f(x+u) \geq f(x) + \left\langle x^* - \frac{u^*}{s}, u \right\rangle, \quad g(x+u) \geq g(x) + \left\langle \frac{u^*}{s}, u \right\rangle.$$

因此

$$x^* - \frac{u^*}{s} \in \partial f(x), \quad \frac{u^*}{s} \in \partial g(x),$$

从而

$$x^* \in \partial f(x) + \partial g(x).$$

反向包含得证。

注 定理 6.4.1 中的连续性假设是一种典型资格条件。它的作用不是为了“让证明顺手”，而是为了排除病态分离失败。后文在第 7.4 节 Fenchel–Rockafellar 对偶和第 8.3 节 Slater 条件中，会看到完全相同的逻辑再次出现。

6.4.3 线性映射下的拉回

命题 6.4.2 (线性映射下的拉回与链式法则)

设 X, Y 为 Banach 空间, $A: X \rightarrow Y$ 为有界线性算子, $g: Y \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函。则对任意 $x \in X$,

$$A^* \partial g(Ax) \subset \partial(g \circ A)(x),$$

其中伴随算子 A^* 由第 4.3 节定义 4.3.2 给出。

证明 任取 $y^* \in \partial g(Ax)$ 。则对任意 $z \in X$,

$$g(Az) \geq g(Ax) + \langle y^*, Az - Ax \rangle.$$

利用伴随算子定义,

$$\langle y^*, Az - Ax \rangle = \langle A^* y^*, z - x \rangle.$$

故

$$(g \circ A)(z) \geq (g \circ A)(x) + \langle A^* y^*, z - x \rangle, \quad \forall z \in X.$$

由定义 6.3.1, 这说明

$$A^* y^* \in \partial(g \circ A)(x).$$

注 命题 6.4.2 是本章最常用的链式法则版本。它说明观测空间中的次梯度会先在像空间里计算, 再通过伴随算子拉回原空间。第 8.2 节的算子约束、第 11.1 节的前向-后向分裂, 以及许多正则化问题中的“梯度项加观测项”都依赖这一步。

6.4.4 典型例子

例题 6.10 和泛函 $f + g$ 的次微分解 设 H 为 Hilbert 空间, f 为光滑凸泛函, g 为 proper 下半连续凸泛函。若 g 在某点连续, 则由定理 6.4.1,

$$\partial(f + g)(x) = \{\nabla f(x)\} + \partial g(x).$$

把这个例子放在这里, 是为了直接通向第 11.1 节的前向-后向分裂: 一个部分用梯度处理, 另一个部分用邻近映射处理。

例题 6.11 线性观测下的正则化 设 $A: X \rightarrow Y$ 为有界线性算子, $\varphi: Y \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函, $\psi: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为正则化项。考虑

$$F(x) = \varphi(Ax) + \psi(x).$$

则由命题 6.4.2 与定理 6.4.1,

$$\partial F(x) \supset A^* \partial \varphi(Ax) + \partial \psi(x),$$

在标准资格条件下可取等号。把这个例子放在这里, 是为了统一逆问题、机器学习和约束优化里的“数据项 + 正则项”结构。

例题 6.12 有限维复合凸函数 当 $X = \mathbb{R}^n$ 、 $Y = \mathbb{R}^m$ 且 A 是矩阵时, 命题 6.4.2 退化为

$$\partial(\varphi \circ A)(x) \supset A^\top \partial \varphi(Ax).$$

若 φ 可微, 则进一步得到

$$\nabla(\varphi \circ A)(x) = A^\top \nabla \varphi(Ax).$$

把这个例子放在这里，是为了把 Boyd 中关于复合目标和线性约束的矩阵链式规则放回无穷维的统一框架。

有限维对照

Boyd 第 3 章和第 6 章里关于复合目标、约束消元和拉格朗日处理的许多规则，在欧氏空间里通常写成“把几个梯度和次梯度加起来，再乘一个转置矩阵”。本节说明，这些公式并不是矩阵世界的偶然巧合，而是命题 6.4.1、定理 6.4.1 和命题 6.4.2 在有限维 Hilbert 空间中的坍缩。

习题（待补）

- 🔥 练习 6.7 Moreau–Rockafellar 公式占位 补一题：针对一个具体的“光滑项 + 非光滑项”模型，使用定理 6.4.1 写出其最优性条件，并说明资格条件在哪一步被使用。
- 🔥 练习 6.8 线性拉回桥接题占位 补一题：对例 6.11 验证命题 6.4.2，并把所得结论退回到矩阵情形，与 Boyd 书中的转置矩阵公式逐项对照。

第 7 章 共轭理论与无穷维对偶

第 6 章把下半连续性、可微性与次微分组织成了凸泛函的局部语言，但这些对象仍然主要生活在原空间 X 中。真正的对偶理论则要求把问题整体搬到对偶空间里重新观察：一个泛函如何通过支撑超平面被编码为另一个泛函？原问题的信息在对偶空间中会损失多少？何时对偶问题只给出下界，何时又能完整恢复原问题的最优值与最优性条件？这些问题的统一答案，正是本章要建立的共轭理论框架。

本章沿着一条清晰的链条推进。第 7.1 节首先定义 Fenchel 共轭，并证明 Fenchel–Young 不等式与其次微分取等条件，说明“共轭”本质上是在对偶空间中重新记录支撑信息。第 7.2 节继续引入双共轭，证明 Fenchel–Moreau 定理，并解释为什么对偶法看到的往往是原问题的闭凸正则化版本。第 7.3 节转向下确界卷积，给出它与共轭、Moreau 包络和变量分裂之间的代数联系，为第 9 至 10 章算法准备接口。最后第 7.4 节把这些工具收束成 Fenchel–Rockafellar 对偶框架，用统一的原–对偶模板、资格条件和对偶间隙语言，为第 8 章 KKT 条件、第 9 章有限维坍塌以及后续应用章节提供总入口。

阅读这一章时，需要始终把第 5.3 节的分离定理与第 6.3 节的次微分语言同时放在脑中。没有 Hahn–Banach 分离，便没有支撑超平面的丰富性；没有次微分，便无法把共轭取等条件重写为最优性条件。另一方面，第 6.4 节 Moreau–Rockafellar 和公式已经预示：资格条件不是证明中的装饰，而是决定“原空间与对偶空间能否无损交换信息”的真正门槛。后文关于广义 KKT、极大单调算子、ADMM 与几何规划的许多关键步骤，都会回链到这一章。

7.1 Fenchel 共轭与 Fenchel-Young 不等式

共轭理论的出发点是一个简单但极其深刻的观察：若一个凸泛函由其所有支撑超平面决定，那么与其直接研究函数值本身，不如把这些支撑超平面收集起来，看成活在对偶空间中的新对象。这样得到的对象就是 Fenchel 共轭。它既是第 5.3 节分离理论的函数化版本，又是第 6.3 节次微分理论的对偶表达，因此本节实际上承担着把“支撑超平面语言”升级为“对偶泛函语言”的任务。

7.1.1 Fenchel 共轭的定义

定义 7.1.1 (Fenchel 共轭)

设 X 为 Banach 空间， $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函。其 Fenchel 共轭定义为函数

$$f^*: X^* \rightarrow \mathbb{R} \cup \{+\infty\}, \quad f^*(x^*) := \sup_{x \in X} \{\langle x^*, x \rangle - f(x)\}.$$

这里的上确界允许取值 $+\infty$ 。若 f 为凸泛函，则 f^* 也是凸且下半连续的。

注 定义 7.1.1 说明，共轭并不是把原函数“再写一遍”，而是把所有可能的仿射下界

$$x \mapsto \langle x^*, x \rangle - c$$

压缩成对偶变量 x^* 的函数。换言之， $f^*(x^*)$ 衡量的是斜率为 x^* 的仿射函数要支撑 f ，其截距至少需要抬高多少。

7.1.2 Fenchel-Young 不等式与取等条件

命题 7.1.1 (Fenchel–Young 不等式)

设 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函。则对任意 $x \in X$ 与任意 $x^* \in X^*$ ，都有

$$f(x) + f^*(x^*) \geq \langle x^*, x \rangle.$$

证明 由定义 7.1.1,

$$f^*(x^*) = \sup_{y \in X} \{\langle x^*, y \rangle - f(y)\}.$$

特别地, 把 y 取为当前的 x , 便得到

$$f^*(x^*) \geq \langle x^*, x \rangle - f(x).$$

移项即得

$$f(x) + f^*(x^*) \geq \langle x^*, x \rangle.$$

命题 7.1.2 (Fenchel-Young 取等与次微分)

设 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函, $x \in \text{dom } f$, $x^* \in X^*$ 。则下列命题等价:

1. $x^* \in \partial f(x)$;
- 2.

$$f(x) + f^*(x^*) = \langle x^*, x \rangle;$$

3. $x \in \partial f^*(x^*)$ 。

证明 由定义 6.3.1, $x^* \in \partial f(x)$ 当且仅当对任意 $y \in X$,

$$f(y) \geq f(x) + \langle x^*, y - x \rangle.$$

移项后得

$$\langle x^*, y \rangle - f(y) \leq \langle x^*, x \rangle - f(x), \quad \forall y \in X.$$

对左边取上确界, 得到

$$f^*(x^*) \leq \langle x^*, x \rangle - f(x).$$

再结合命题 7.1.1, 即得

$$f^*(x^*) = \langle x^*, x \rangle - f(x),$$

即 (1) $\Rightarrow$ (2)。

反过来, 若 (2) 成立, 则对任意 $y \in X$,

$$\langle x^*, y \rangle - f(y) \leq f^*(x^*) = \langle x^*, x \rangle - f(x),$$

从而

$$f(y) \geq f(x) + \langle x^*, y - x \rangle.$$

故 $x^* \in \partial f(x)$ 。这给出 (2) $\Rightarrow$ (1)。

把上一段论证应用于对偶空间上的凸泛函 f^* , 并注意共轭再取一次所得到的变量互换, 便得到 (2) 与 (3) 的等价性。

注 命题 7.1.2 是本章最重要的“翻译器”之一: 它把原空间里的次微分条件 $x^* \in \partial f(x)$ 翻译成共轭表达式的取等条件。后文第 7.4 节的对偶定理和第 8.4 节的 KKT 条件, 本质上都在重复使用这一翻译。

7.1.3 典型例子

例题 7.1 指示函数与支撑函数 设 $C \subset X$ 为非空集合, 指示函数定义为

$$\iota_C(x) = \begin{cases} 0, & x \in C, \\ +\infty, & x \notin C. \end{cases}$$

则其共轭为

$$\iota_C^*(x^*) = \sup_{x \in C} \langle x^*, x \rangle =: \sigma_C(x^*),$$

这里 σ_C 称为 C 的支撑函数。把这个例子放在这里，是为了把第 5.3 节的支撑超平面几何直接转写为函数等式：集合的约束信息，在对偶空间中正是由支撑函数承载。

例题 7.2 范数与对偶范数的共轭 设 $\|\cdot\|$ 是 X 上的范数， $\|\cdot\|_*$ 是对偶范数。对任意 $\lambda > 0$ ，令

$$f(x) = \lambda \|x\|.$$

则

$$f^*(x^*) = \begin{cases} 0, & \|x^*\|_* \leq \lambda, \\ +\infty, & \|x^*\|_* > \lambda. \end{cases}$$

把这个例子放在这里，是为了说明范数正则化在对偶空间中对应的是一个对偶球约束；这正是 Boyd 中“范数球与对偶球”图像的无穷维上位版本。

证明 对任意 $x^* \in X^*$ ，

$$f^*(x^*) = \sup_{x \in X} \{\langle x^*, x \rangle - \lambda \|x\|\}.$$

若 $\|x^*\|_* \leq \lambda$ ，则由对偶范数定义

$$\langle x^*, x \rangle - \lambda \|x\| \leq (\|x^*\|_* - \lambda) \|x\| \leq 0,$$

且在 $x = 0$ 处取到 0，故 $f^*(x^*) = 0$ 。反之若 $\|x^*\|_* > \lambda$ ，则由 Hahn–Banach 支撑论证可取单位向量方向 u 使 $\langle x^*, u \rangle > \lambda$ ，于是

$$\langle x^*, tu \rangle - \lambda \|tu\| = t(\langle x^*, u \rangle - \lambda) \rightarrow +\infty \quad (t \rightarrow +\infty).$$

故 $f^*(x^*) = +\infty$ 。

例题 7.3 正则化项的对偶表示 在 Hilbert 空间 H 上考虑

$$f(u) = \frac{1}{2} \|u\|^2.$$

由第 4.1 节定理 4.1.2 可把 H^* 与 H 识别，于是

$$f^*(v) = \frac{1}{2} \|v\|^2.$$

把这个例子放在这里，是为了给后文 Moreau 包络、prox 映射和二次正则化提供最核心的对偶基线。

有限维对照

Boyd 书中关于共轭函数的几何图像，主要依赖于二维或三维里“用斜率看支撑线”的直觉。本节说明，这个直觉在无穷维里依然成立，但真正稳固的形式是定义 7.1.1 与命题 7.1.2。特别是例 7.1 和例 7.2 表明，Boyd 里熟悉的支撑函数、对偶球和范数正则化，都只是同一套对偶编码机制在有限维 Hilbert 空间中的坍塌。

习题（待补）

 **练习 7.1 Fenchel–Young 取等占位** 补一题：对一个具体的凸泛函验证命题 7.1.2，并把取等条件写成第 6.3 节次微分语言中的最优性判断。

 **练习 7.2 支撑函数桥接题占位** 补一题：从例 7.1 出发，计算一个有限维凸体的支撑函数，并说明该结果如何与 Boyd 书中的超平面支撑图像对应。

7.2 双共轭与闭凸包

一旦有了共轭，最自然的问题就是：再共轭一次会发生什么？有限维图像直觉会让人猜测“应该回到原函数”，但无穷维对偶理论告诉我们，真正回来的并不是原问题的全部细节，而是它的闭凸正则化版本。双共轭正是刻画这种“信息损失最小的闭凸修正”的工具。因此，本节的核心不仅是证明 Fenchel–Moreau 定理（下文也写作

Fenchel-Moreau 定理), 更是解释为什么对偶法在某些时候只能看到松弛后的问题, 而看不到原始的非闭、非凸细节。第 6.1 节定义 6.1.2 中的下半连续性, 在这里正被重新识别为“函数能够被双共轭完整恢复”的必要正则性。

7.2.1 双共轭的定义与基本不等式

定义 7.2.1 (双共轭)

设 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函。定义其双共轭为

$$f^{**}(x) := \sup_{x^* \in X^*} \{\langle x^*, x \rangle - f^*(x^*)\}, \quad x \in X.$$

也就是说, f^{**} 是把 f^* 看成定义在对偶空间上的泛函后, 再次对其取 Fenchel 共轭所得到的对象。

命题 7.2.1 (双共轭总在原函数之下)

设 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函。则对任意 $x \in X$,

$$f^{**}(x) \leq f(x).$$

证明 由命题 7.1.1, 对任意 $x \in X$ 与任意 $x^* \in X^*$,

$$f(x) + f^*(x^*) \geq \langle x^*, x \rangle.$$

移项得

$$\langle x^*, x \rangle - f^*(x^*) \leq f(x).$$

对左边关于 x^* 取上确界, 便得到

$$f^{**}(x) \leq f(x).$$

7.2.2 Fenchel-Moreau 定理

定理 7.2.1 (Fenchel-Moreau 定理)

设 X 为 Banach 空间, $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。则

$$f^{**} = f.$$

证明 由命题 7.2.1, 总有

$$f^{**} \leq f.$$

只需证明反向不等式。固定 $x \in X$ 与实数 $r < f(x)$ 。考虑乘积空间 $X \times \mathbb{R}$ 中的点 (x, r) 与上图像

$$\text{epi } f := \{(u, t) \in X \times \mathbb{R} : t \geq f(u)\}.$$

由于 f 凸且下半连续, $\text{epi } f$ 是闭凸集, 而 $(x, r) \notin \text{epi } f$ 。由第 5.3 节定理 5.3.3, 存在非零连续线性泛函 $(p, \lambda) \in X^* \times \mathbb{R}$ 与常数 c , 使

$$\langle p, u \rangle + \lambda t \geq c > \langle p, x \rangle + \lambda r, \quad \forall (u, t) \in \text{epi } f.$$

由于若 $(u, t) \in \text{epi } f$ 则 $(u, t + s) \in \text{epi } f$ 对所有 $s \geq 0$ 仍成立, 故不可能有 $\lambda < 0$; 否则令 $s \rightarrow +\infty$ 将破坏左侧不等式。若 $\lambda = 0$, 则

$$\langle p, u \rangle \geq c > \langle p, x \rangle$$

对所有 $u \in \text{dom } f$ 成立, 这与 f 的凸下半连续结构结合时会把 (x, r) 完全隔离到定义域外; 在当前取定的 $r < f(x)$ 情形下, 我们可直接把 $(x, f(x)) \in \text{epi } f$ 代入, 得到

$$\langle p, x \rangle + \lambda f(x) \geq c > \langle p, x \rangle + \lambda r,$$

从而 $\lambda > 0$ 。

于是对任意 $u \in X$ ，令 $t = f(u)$ ，有

$$\langle p, u \rangle + \lambda f(u) \geq c > \langle p, x \rangle + \lambda r.$$

移项并除以 λ 得

$$r < f(u) + \left\langle \frac{p}{\lambda}, u - x \right\rangle, \quad \forall u \in X.$$

令

$$x^* := -\frac{p}{\lambda},$$

则

$$r < f(u) - \langle x^*, u \rangle + \langle x^*, x \rangle, \quad \forall u \in X.$$

对右边关于 u 取下确界，便得到

$$r \leq \langle x^*, x \rangle - f^*(x^*) \leq f^{**}(x).$$

由于这对每个 $r < f(x)$ 都成立，令 $r \uparrow f(x)$ ，便得

$$f(x) \leq f^{**}(x).$$

综上

$$f(x) = f^{**}(x), \quad \forall x \in X.$$

注 定理 7.2.1 的真正含义，不是“双共轭把函数又变回来”这样一句形式口号，而是：当且仅当原函数已经是 **proper**、闭且凸的，它才会完整地通过对偶支撑信息重建。换言之，对偶法看到的是闭凸正则化后的问题；原问题若不闭或不凸，双共轭只会保留其对偶侧可见的那部分结构。

7.2.3 上图像闭凸包与闭凸正则化

命题 7.2.2 (双共轭的上图像闭凸包表述)

设 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 **proper** 泛函。则 f^{**} 是不超过 f 的最大下半连续凸泛函；等价地，

$$\text{epi}(f^{**}) = \overline{\text{conv}(\text{epi } f)},$$

其中闭包取于 $X \times \mathbb{R}$ 的乘积拓扑。

证明 命题 7.2.1 已说明 $f^{**} \leq f$ ，而由定义 7.2.1 可知 f^{**} 总是凸且下半连续。若 $g \leq f$ 且 g 为下半连续凸泛函，则由共轭定义可得

$$g^* \geq f^*.$$

再取一次共轭，便有

$$g = g^{**} \leq f^{**},$$

其中等号用到了定理 7.2.1 对 g 的应用。因此 f^{**} 的确是最大的下半连续凸 **minorant**。将这一叙述翻译到上图像层面，正得到

$$\text{epi}(f^{**}) = \overline{\text{conv}(\text{epi } f)}.$$

推论 7.2.1 (指示函数、支撑函数与闭凸包)

设 $C \subset X$ 为非空集合，则

$$(\iota_C)^{**} = \iota_{\overline{\text{conv } C}}.$$

特别地，若 C 已经是非空闭凸集，则由例 7.1，

$$\sigma_C^* = \iota_C.$$



证明 由例 7.1, $\iota_C^* = \sigma_C$ 。另一方面， ι_C 的最大下半连续凸 minorant 正是 $\iota_{\text{conv}C}$ ，故由命题 7.2.2 得

$$(\iota_C)^{**} = \iota_{\text{conv}C}.$$

若 C 本身已经闭凸，则右侧就是 ι_C ，从而 $\sigma_C^* = \iota_C$ 。

7.2.4 典型例子

例题 7.4 非闭凸函数的双共轭正则化 设 $X = \mathbb{R}$ ，并定义

$$f(x) = \begin{cases} 0, & x > 0, \\ 1, & x = 0, \\ +\infty, & x < 0. \end{cases}$$

则 f 是凸但在 0 处并不下半连续，其双共轭满足

$$f^{**}(x) = \begin{cases} 0, & x \geq 0, \\ +\infty, & x < 0. \end{cases}$$

把这个例子放在这里，是为了说明双共轭不是“原函数复制器”，而是闭凸修补器：它自动把孤立的非闭性抹平。

例题 7.5 有限维上图像闭凸包 在 $\mathbb{R}^n$ 中，命题 7.2.2 可以直接理解为“对函数上图像先取凸包再闭包”。把这个例子放在这里，是为了把 Boyd 中关于上图像和支撑超平面的几何直觉直接接回到双共轭公式；有限维图像之所以好画，只是因为闭凸包在那里可以被可视化，而不是因为结论只属于有限维。

例题 7.6 替代损失与闭凸正则化 在机器学习中，0-1 损失的闭凸包会导向铰链损失、logistic 损失等 surrogate 目标。把这个例子放在这里，是为了说明“对偶法看到的是闭凸正则化后的问题”并非纯理论现象，而是现代统计学习中每天都在发生的建模动作。

有限维对照

Boyd 书中常把闭凸包与对偶下界放在几何图像里解释，例如通过支撑超平面观察一个非凸对象被其凸包替代。本节把这种几何说法提升为定理 7.2.1 与命题 7.2.2。在有限维里，这些结果看上去像是图像事实；在无穷维里，它们真正依赖的是下半连续性、分离定理和对偶支撑信息的完整性。

习题（待补）

- 练习 7.3 双共轭桥接题占位 补一题：对一个不是下半连续的凸函数显式计算其双共轭，并说明双共轭在哪个点上修补了原函数的非闭性。
- 练习 7.4 闭凸包占位 补一题：从命题 7.2.2 出发，在有限维中把一个具体函数的上图像闭凸包画出来，并与其双共轭函数逐点对应。

7.3 下确界卷积

前两节说明，共轭把“求和难题”部分转化成了对偶空间里的代数运算。但在建模和算法中，我们经常还想做另一件事：把两个泛函组合成一个更平滑或更易分裂的对象。下确界卷积正是这个目的的标准工具。它一方面把两个代价通过“变量拆分后再求最优拼接”的方式组合起来，另一方面又在共轭侧转化为简单的求和，因此既是 Moreau 包络与平滑化的核心来源，也是第 9 至 10 章算法中变量分裂思想的代数前身。

7.3.1 下确界卷积的定义

定义 7.3.1 (下确界卷积)

设 X 为 Banach 空间, $f, g: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函。定义它们的下确界卷积为

$$(f \square g)(x) := \inf_{y \in X} \{f(y) + g(x - y)\}, \quad x \in X.$$

这一运算也常记作 infimal convolution。

命题 7.3.1 (下确界卷积保持凸性)

若 f, g 为 proper 凸泛函, 则 $f \square g$ 仍是凸泛函。若再假设其中一个函数连续并且另一个下半连续, 则 $f \square g$ 在相应点上也是下半连续的。

证明 任取 $x_1, x_2 \in X$ 与 $\lambda \in [0, 1]$ 。对任意 $\varepsilon > 0$, 可选 $y_1, y_2 \in X$ 使

$$f(y_i) + g(x_i - y_i) \leq (f \square g)(x_i) + \varepsilon, \quad i = 1, 2.$$

由凸性,

$$f(\lambda y_1 + (1 - \lambda)y_2) \leq \lambda f(y_1) + (1 - \lambda)f(y_2),$$

且

$$g(\lambda(x_1 - y_1) + (1 - \lambda)(x_2 - y_2)) \leq \lambda g(x_1 - y_1) + (1 - \lambda)g(x_2 - y_2).$$

注意

$$\lambda(x_1 - y_1) + (1 - \lambda)(x_2 - y_2) = (\lambda x_1 + (1 - \lambda)x_2) - (\lambda y_1 + (1 - \lambda)y_2).$$

故

$$(f \square g)(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda(f \square g)(x_1) + (1 - \lambda)(f \square g)(x_2) + \varepsilon.$$

令 $\varepsilon \downarrow 0$ 得凸性。下半连续性部分来自定义中的下确界与第 6.4 节定理 6.4.1 相同的资格条件机制, 这里不再展开一般证明。

7.3.2 共轭与下确界卷积交换

定理 7.3.1 (下确界卷积的共轭交换公式)

设 $f, g: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函, 则对任意 $x^* \in X^*$,

$$(f \square g)^*(x^*) = f^*(x^*) + g^*(x^*).$$

证明 由定义 7.3.1,

$$(f \square g)^*(x^*) = \sup_{x \in X} \left\{ \langle x^*, x \rangle - \inf_{y \in X} [f(y) + g(x - y)] \right\}.$$

交换上确界与下确界后, 可写为

$$(f \square g)^*(x^*) = \sup_{x, y \in X} \{ \langle x^*, x \rangle - f(y) - g(x - y) \}.$$

令 $z = x - y$, 则 $x = y + z$, 因此

$$\langle x^*, x \rangle - f(y) - g(x - y) = \langle x^*, y \rangle - f(y) + \langle x^*, z \rangle - g(z).$$

于是

$$(f \square g)^*(x^*) = \sup_{y \in X} \{ \langle x^*, y \rangle - f(y) \} + \sup_{z \in X} \{ \langle x^*, z \rangle - g(z) \}.$$

右边正是

$$f^*(x^*) + g^*(x^*).$$

注 定理 7.3.1 是本节的代数核心。它说明：原空间里的“先拆变量、再取下确界”在对偶空间里恰好变成简单的求和。第 6.4 节命题 6.4.2 与定理 6.4.1 告诉我们，次微分演算同样依赖这种“在原空间难、在对偶空间易”的交换机制。

7.3.3 Moreau 包络

定义 7.3.2 (Moreau 包络)

设 H 为 Hilbert 空间, $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函, $\lambda > 0$ 。定义

$$e_\lambda f(x) := \inf_{y \in H} \left\{ f(y) + \frac{1}{2\lambda} \|x - y\|^2 \right\}.$$

该函数称为 f 的 Moreau 包络。它正是 f 与二次惩罚项

$$q_\lambda(x) := \frac{1}{2\lambda} \|x\|^2$$

的下确界卷积。

命题 7.3.2 (Moreau 包络的共轭)

设 H 为 Hilbert 空间, $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 泛函。则

$$(e_\lambda f)^*(v) = f^*(v) + \frac{\lambda}{2} \|v\|^2, \quad v \in H.$$

证明 由定义 7.3.2,

$$e_\lambda f = f \square q_\lambda.$$

再由定理 7.3.1,

$$(e_\lambda f)^* = f^* + q_\lambda^*.$$

因此只需计算 q_λ^* 。对任意 $v \in H$,

$$q_\lambda^*(v) = \sup_{x \in H} \left\{ \langle v, x \rangle - \frac{1}{2\lambda} \|x\|^2 \right\}.$$

把右边配方可得

$$\langle v, x \rangle - \frac{1}{2\lambda} \|x\|^2 = -\frac{1}{2\lambda} \|x - \lambda v\|^2 + \frac{\lambda}{2} \|v\|^2.$$

故上确界在 $x = \lambda v$ 处取到, 且

$$q_\lambda^*(v) = \frac{\lambda}{2} \|v\|^2.$$

代回即得

$$(e_\lambda f)^*(v) = f^*(v) + \frac{\lambda}{2} \|v\|^2.$$

7.3.4 典型例子

例题 7.7 两个指标函数与 Minkowski 和 设 $A, B \subset X$ 为非空集合。则

$$(\iota_A \square \iota_B)(x) = \begin{cases} 0, & x \in A + B, \\ +\infty, & x \notin A + B, \end{cases}$$

其中

$$A + B := \{a + b : a \in A, b \in B\}$$

是 Minkowski 和。把这个例子放在这里，是为了说明下确界卷积是集合运算的函数化版本：在指标函数层面，它正对应于集合的加法。

例题 7.8 Huber 平滑与 Moreau 包络 在 $\mathbb{R}$ 上取 $f(t) = |t|$ ，则其 Moreau 包络给出著名的 Huber 型平滑：

$$e_{\lambda}f(x) = \begin{cases} \frac{x^2}{2\lambda}, & |x| \leq \lambda, \\ |x| - \frac{\lambda}{2}, & |x| > \lambda. \end{cases}$$

把这个例子放在这里，是为了给 Boyd 读者一个最熟悉的有限维坍塌对象：不可微绝对值经过下确界卷积后变成了分段光滑的 Huber 损失。

例题 7.9 正则化分裂模型 对

$$F(x) = \varphi(Ax) + \psi(x),$$

第 6.4 节中的次微分演算告诉我们如何写最优性条件，而本节则说明若把某一项替换为 Moreau 包络，就能得到更平滑的近似模型。把这个例子放在这里，是为了直接接通第 9 章 Moreau-Yosida 正则化与第 10 章变量分裂算法。

有限维对照

Boyd 书里对 Huber 损失、平滑近似与变量分裂的讨论，经常以具体矩阵模型和一维图像展开。本节说明，这些对象背后的统一代数恰恰是定义 7.3.1 与定理 7.3.1。有限维里看上去是“技巧”的平滑与分裂，在无穷维里其实是一种由共轭理论控制的结构性变换。

习题（待补）

-  **练习 7.5 下确界卷积占位** 补一题：对两个具体的凸函数计算其下确界卷积，并验证定理 7.3.1 在该例中的公式。
-  **练习 7.6 Moreau 包络桥接题占位** 补一题：从例中的绝对值函数出发计算 Moreau 包络，并解释它为何会自然导向 Huber 平滑和近端算法。

7.4 Fenchel-Rockafellar 对偶框架

前面三节把共轭、双共轭与下确界卷积准备齐全之后，对偶理论终于可以被写成一个真正可复用的模板：给定原问题，如何构造其对偶问题？为何对偶目标总是原问题的下界？何时下界可以提升为精确的最优值表达？这些问题在有限维教材中常以拉格朗日函数与 KKT 条件的形式出现，而在无穷维里，它们的统一上位版本就是 Fenchel-Rockafellar 对偶。第 6.3 节定义 6.3.1 给出的局部最优性语言，以及第 6.4 节定理 6.4.1 中已经出现的资格条件机制，都会在这里被收束为一个原-对偶总模板。第 8.1 节开始的广义不等式与第 8.4 节的无穷维 KKT，都会直接建立在这一节的框架之上。

7.4.1 原问题、对偶问题与弱对偶

定义 7.4.1 (Fenchel 型原-对偶对)

设 X, Y 为 Banach 空间， $A: X \rightarrow Y$ 为有界线性算子， $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 与 $g: Y \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函。定义原问题

$$p^* := \inf_{x \in X} \{f(x) + g(Ax)\},$$

以及对应的对偶问题

$$d^* := \sup_{y^* \in Y^*} \{-f^*(-A^*y^*) - g^*(y^*)\}.$$

数量

$$p^* - d^*$$

称为对偶间隙。

命题 7.4.1 (弱对偶)

对任意 $x \in X$ 与任意 $y^* \in Y^*$, 都有

$$-f^*(-A^*y^*) - g^*(y^*) \leq f(x) + g(Ax).$$

因此

$$d^* \leq p^*.$$

证明 对 f 应用命题 7.1.1, 并令对偶变量取为 $-A^*y^*$, 得

$$f(x) + f^*(-A^*y^*) \geq \langle -A^*y^*, x \rangle = -\langle y^*, Ax \rangle.$$

对 g 应用同一不等式, 得

$$g(Ax) + g^*(y^*) \geq \langle y^*, Ax \rangle.$$

两式相加即得

$$f(x) + g(Ax) + f^*(-A^*y^*) + g^*(y^*) \geq 0,$$

移项得到

$$-f^*(-A^*y^*) - g^*(y^*) \leq f(x) + g(Ax).$$

再对左边取上确界、对右边取下确界, 便得到

$$d^* \leq p^*.$$

注 命题 7.4.1 的意义在于: 对偶问题从来不会给出“过高的承诺”。它所产生的任何值, 都是原问题最优值的合法下界。真正困难的是判断这个下界是否精确, 也即对偶间隙是否为零; 这正是资格条件要解决的问题。

7.4.2 资格条件

定义 7.4.2 (Fenchel 对偶的资格条件)

设 (f, g, A) 如定义 7.4.1。若存在某个 $x_0 \in \text{dom } f$ 使得 $Ax_0 \in \text{dom } g$ 且 g 在 Ax_0 处连续, 则称该三元组满足 Fenchel 型资格条件。

注 定义 7.4.2 是本章采用的 Banach/Hilbert 常用版本。更一般的局部凸空间理论常把资格条件写成

$$0 \in \text{core}(\text{dom } g - A(\text{dom } f)),$$

这里的 **core** 正是第 5.2 节引入的代数内部。为了保持正文主线紧凑, 本节把证明建立在连续性资格条件上, 而把更一般版本留作前瞻备注。

7.4.3 Fenchel–Rockafellar 对偶定理

定理 7.4.1 (Fenchel–Rockafellar 对偶定理)

设 X, Y 为 Banach 空间, $A: X \rightarrow Y$ 为有界线性算子, $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 与 $g: Y \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。若定义 7.4.2 的资格条件成立, 则

$$\inf_{x \in X} \{f(x) + g(Ax)\} = \sup_{y^* \in Y^*} \{-f^*(-A^*y^*) - g^*(y^*)\}.$$

换言之, 在该资格条件下对偶间隙为零, 即发生强对偶。

证明 定义扰动函数

$$F(x, y) := f(x) + g(Ax + y), \quad (x, y) \in X \times Y,$$

以及值函数

$$\varphi(y) := \inf_{x \in X} F(x, y) = \inf_{x \in X} \{f(x) + g(Ax + y)\}.$$

显然

$$\varphi(0) = \inf_{x \in X} \{f(x) + g(Ax)\} = p^*.$$

首先说明 φ 是 proper、凸且下半连续的, 并且在 0 处连续。proper 性来自资格条件中的点 x_0 : 由于 $f(x_0) < +\infty$ 且 g 在 Ax_0 处连续, 故存在 0 的邻域 $U \subset Y$ 使得对所有 $y \in U$,

$$g(Ax_0 + y) < +\infty.$$

于是对所有 $y \in U$,

$$\varphi(y) \leq f(x_0) + g(Ax_0 + y) < +\infty.$$

又因 g 在 Ax_0 处连续, 右侧随 $y \rightarrow 0$ 有界, 从而 φ 在 0 的邻域上有上界。另一方面, 作为一族仿射变换下凸函数的下确界, φ 自身仍为凸。凸函数在内点附近若局部有上界, 则连续, 故 φ 在 0 处连续。由连续性可知 φ 在 0 处当然下半连续。

接着计算 φ^* 。对任意 $y^* \in Y^*$,

$$\varphi^*(y^*) = \sup_{y \in Y} \{\langle y^*, y \rangle - \varphi(y)\} = \sup_{x \in X, y \in Y} \{\langle y^*, y \rangle - f(x) - g(Ax + y)\}.$$

令

$$z := Ax + y,$$

则 $y = z - Ax$, 于是

$$\varphi^*(y^*) = \sup_{x \in X, z \in Y} \{\langle y^*, z - Ax \rangle - f(x) - g(z)\}.$$

整理得

$$\varphi^*(y^*) = \sup_{x \in X} \{-\langle A^*y^*, x \rangle - f(x)\} + \sup_{z \in Y} \{\langle y^*, z \rangle - g(z)\}.$$

因此

$$\varphi^*(y^*) = f^*(-A^*y^*) + g^*(y^*).$$

由于 φ 是 proper、凸且在 0 处连续, 故由第 7.2 节定理 7.2.1,

$$\varphi(0) = \varphi^{**}(0) = \sup_{y^* \in Y^*} \{-\varphi^*(y^*)\}.$$

代入上一步的表达式, 得到

$$p^* = \sup_{y^* \in Y^*} \{-f^*(-A^*y^*) - g^*(y^*)\} = d^*.$$

故强对偶成立。

注 定理 7.4.1 的证明清楚地表明：资格条件的作用，是保证扰动值函数 φ 在原点附近足够正则，从而能够通过定理 7.2.1 被双共轭完全重建。也就是说，强对偶并不是神奇的值相等，而是“扰动问题在原点没有病态缺口”这一事实的结果。

7.4.4 最优性条件与 KKT 接口

推论 7.4.1 (Fenchel 对偶的次微分最优性条件)

在定理 7.4.1 的假设下，设 $\bar{x} \in X$ 与 $\bar{y}^* \in Y^*$ 分别是原问题与对偶问题的最优解。则下列条件等价于原-对偶最优性：

$$-A^* \bar{y}^* \in \partial f(\bar{x}), \quad \bar{y}^* \in \partial g(A\bar{x}).$$

等价地，

$$0 \in \partial f(\bar{x}) + A^* \partial g(A\bar{x}).$$

证明 由最优性与强对偶，

$$f(\bar{x}) + g(A\bar{x}) = -f^*(-A^* \bar{y}^*) - g^*(\bar{y}^*).$$

整理为

$$f(\bar{x}) + f^*(-A^* \bar{y}^*) = -\langle \bar{y}^*, A\bar{x} \rangle, \quad g(A\bar{x}) + g^*(\bar{y}^*) = \langle \bar{y}^*, A\bar{x} \rangle.$$

于是对 f 与 g 分别都在 Fenchel-Young 不等式中取等。由命题 7.1.2，便得到

$$-A^* \bar{y}^* \in \partial f(\bar{x}), \quad \bar{y}^* \in \partial g(A\bar{x}).$$

反过来，若这两条次微分条件成立，则再次应用命题 7.1.2 可知两边分别在 Fenchel-Young 不等式中取等，故原目标值与对偶目标值相等。结合命题 7.4.1，便知两者均为最优。

注 推论 7.4.1 是第 8.1 节广义不等式和第 8.4 节无穷维 KKT 系统的直接前导接口。有限维中常见的拉格朗日乘子、驻点条件与互补松弛，在本书后文都会被重新写回这里的次微分与伴随算子语言。

7.4.5 典型例子

例题 7.10 线性算子复合的原-对偶模板 设 $A: X \rightarrow Y$ 为有界线性算子，原问题

$$\inf_{x \in X} \{f(x) + g(Ax)\}$$

的对偶正是

$$\sup_{y^* \in Y^*} \{-f^*(-A^* y^*) - g^*(y^*)\}.$$

把这个例子放在这里，是为了强调第 8.2 节抽象标准型、第 11.3 节 ADMM 以及大量逆问题模型，其实都只是这一统一模板的具体化。

例题 7.11 有限维拉格朗日对偶 当 $X = \mathbb{R}^n$ 、 $Y = \mathbb{R}^m$ 且 A 是矩阵时，定义 7.4.1 退化为 Boyd 书中最熟悉的有限维对偶模板。把这个例子放在这里，是为了说明 Boyd 第 5 章的拉格朗日对偶并不是另一套平行理论，而是 Fenchel-Rockafellar 对偶在有限维 Hilbert 空间中的坍塌。

例题 7.12 资源约束的价差解释 在管理科学模型里， $g(Ax)$ 常用来编码资源或风险约束。对偶变量 y^* 则可解释为资源影子价格或边际罚率。把这个例子放在这里，是为了强调对偶变量不只是证明中的中介量；在许多应用场景中，它本身就携带了可解释的经济或工程信息。

有限维对照

Boyd 书中关于强对偶、对偶间隙与 KKT 的叙述，往往借助 Slater 条件和拉格朗日函数在 $\mathbb{R}^n$ 中展开。本节说明，这些有限维公式真正依赖的核心结构是：定义 7.4.1 给出的原-对偶模板、命题 7.4.1 给出的下界机制，以

及定理 7.4.1 所控制的资格条件。有限维之所以显得简单，是因为很多正则性在那里自动满足，而不是因为对偶理论只属于矩阵世界。

习题（待补）

- 🚩 练习 7.7 弱对偶占位 补一题：对一个具体的原-对偶对，逐步验证命题 7.4.1，并写出它给出的显式对偶下界。
- 🚩 练习 7.8 Fenchel-Rockafellar 桥接题占位 补一题：在有限维矩阵模型中应用定理 7.4.1，并把推论 7.4.1 翻译成 Boyd 风格的 KKT 条件。

第四部分

Boyd 坍缩

第 8 章 抽象空间中的锥优化与 KKT 理论

第 7 章已经把共轭、双共轭、下确界卷积与 Fenchel–Rockafellar 对偶写成了统一的原–对偶语言，但那一章仍然主要围绕一般复合凸问题展开。进入本章之后，约束的几何角色会被进一步突出：谁被视为“非负对象”，谁就决定了可行方向、乘子的取值空间以及互补松弛的形式。有限维里这类结构常被写成广义不等式、锥约束和 KKT 条件；在无穷维里，它们必须被重新表述为对偶空间、法锥和连续线性算子的命题。

本章按照四个层次推进。第 8.1 节先用闭凸锥定义偏序与广义不等式，并证明锥序可以完全由对偶锥刻画，把锥约束同第 5.3 节的分离原理连接起来。第 8.2 节把抽象锥规划写成统一标准型，给出拉格朗日函数、对偶函数以及与第 7.4 节 Fenchel 模板的对应关系，为第 11.3 节 ADMM 等算法留出统一接口。第 8.3 节讨论广义 Slater 条件，说明严格可行性为何能够消除对偶间隙，并解释当锥的拓扑内部退化时，为什么必须转向第 5.2 节中的相对内部或代数内部。最后第 8.4 节把这些结果收束成无穷维 KKT 系统，把原可行、对偶可行、驻点条件与互补松弛统一为可检验的最优性证据。

这一章的读法有两个重点。其一，必须始终记住乘子不再默认是 Euclidean 向量；它们往往住在对偶空间里，甚至可能是测度或分布。其二，不能把“强对偶成立”和“KKT 成立”当成无条件口号。和第 6.1 节直接法中的极小值存在一样，这里每一个结论都依赖于明确的正则性门槛：闭凸锥、适当的连续性、以及 Slater 型资格条件。第 9 章会看到，这些结构在 $\mathbb{R}^n$ 中几乎全部自动坍缩为 Boyd 读者熟悉的矩阵公式；但这种简化恰恰依赖于本章已经完成的抽象铺垫。

8.1 广义不等式与闭凸锥

无穷维锥规划的第一步，不是写算法，也不是直接写 KKT，而是先回答一个更基础的问题：在一般线性空间里，什么才叫“非负”？在欧氏空间里，我们习惯用坐标逐项非负或半正定矩阵来回答这个问题；一旦进入函数空间、测度空间或算子空间，这些坐标化描述就不再可靠。能够跨环境保留下来的，是闭凸锥所诱导的偏序结构。广义不等式的全部语言，正是建立在这个观察之上。

8.1.1 锥诱导的偏序

定义 8.1.1 (锥诱导偏序与适当锥)

设 Y 为实 Banach 空间， $K \subset Y$ 为非空闭凸锥，即由定义 5.1.3 已知满足

$$\lambda K \subset K, \quad K + K \subset K, \quad \lambda \geq 0.$$

对任意 $u, v \in Y$ ，定义

$$u \preceq_K v \iff v - u \in K.$$

此时称 $\preceq_K$ 为由 K 诱导的广义不等式。若进一步有

$$K \cap (-K) = \{0\},$$

则称 K 为尖锥；在本章里，闭凸且尖的锥将扮演有限维优化中“正正交体”的抽象替身。

定义 8.1.2 (对偶锥)

设 $K \subset Y$ 为闭凸锥。定义其对偶锥为

$$K^* := \{y^* \in Y^* : \langle y^*, y \rangle \geq 0, \forall y \in K\}.$$

因此，对偶锥中的元素就是对 K 上所有“非负方向”都取非负值的连续线性泛函。

命题 8.1.1 (对偶锥仍是闭凸锥)

设 $K \subset Y$ 为闭凸锥, 则 $K^* \subset Y^*$ 是凸锥, 并且在 Y^* 的弱*拓扑下闭。

证明 若 $y_1^*, y_2^* \in K^*$ 且 $\alpha, \beta \geq 0$, 则对任意 $y \in K$,

$$\langle \alpha y_1^* + \beta y_2^*, y \rangle = \alpha \langle y_1^*, y \rangle + \beta \langle y_2^*, y \rangle \geq 0,$$

故 $\alpha y_1^* + \beta y_2^* \in K^*$, 这说明 K^* 是凸锥。

再固定任意 $y \in K$, 集合

$$H_y := \{y^* \in Y^* : \langle y^*, y \rangle \geq 0\}$$

是弱*闭半空间, 因为映射 $y^* \mapsto \langle y^*, y \rangle$ 在弱*拓扑下连续。于是

$$K^* = \bigcap_{y \in K} H_y$$

是弱*闭集。

命题 8.1.2 (锥序的对偶刻画)

设 $K \subset Y$ 为闭凸锥, $u, v \in Y$ 。则下列两条等价:

$$u \preceq_K v;$$

$$\langle y^*, u \rangle \leq \langle y^*, v \rangle, \quad \forall y^* \in K^*.$$

换言之, 闭凸锥上的广义不等式完全可以由对偶锥上的正泛函检验。

证明 若 $u \preceq_K v$, 则 $v - u \in K$ 。任取 $y^* \in K^*$, 由定义 8.1.2,

$$\langle y^*, v - u \rangle \geq 0,$$

即

$$\langle y^*, u \rangle \leq \langle y^*, v \rangle.$$

反之, 设对所有 $y^* \in K^*$ 都有上述不等式, 但 $u \not\preceq_K v$ 。记

$$w := v - u.$$

则 $w \notin K$ 。由于 K 是闭凸集, 而 w 是其外点, 由第 5.3 节定理 5.3.2 的几何分离形式, 存在非零泛函 $y^* \in Y^*$ 与常数 c , 使

$$\langle y^*, w \rangle < c \leq \langle y^*, k \rangle, \quad \forall k \in K.$$

因为 $0 \in K$, 故 $c \leq 0$ 。又因为 $tk \in K$ 对任意 $t \geq 0$ 仍成立, 上式对每个 $t > 0$ 给出

$$c \leq t \langle y^*, k \rangle.$$

令 $t \downarrow 0$ 即得 $\langle y^*, k \rangle \geq 0$, 故 $y^* \in K^*$ 。于是

$$\langle y^*, v - u \rangle = \langle y^*, w \rangle < c \leq 0,$$

即

$$\langle y^*, v \rangle < \langle y^*, u \rangle,$$

这与假设矛盾。故必有 $u \preceq_K v$ 。

注 命题 8.1.2 是本节的核心接口。它告诉我们: 锥约束不是另一套和对偶理论平行的语言, 而是分离定理在锥环境中的直接应用。后文的锥对偶、互补松弛和广义 KKT, 都会把“可行性”重新翻译为“对偶锥中所有正泛函都看不出违约”。

8.1.2 锥不等式与互补关系

由定义 8.1.1, 约束

$$Ax - b \preceq_K 0$$

等价于

$$b - Ax \in K.$$

因此锥规划中的可行性, 本质上是在判断某个松弛变量是否属于给定的闭凸锥。与之对应, 对偶变量将被要求属于对偶锥 K^* 。这两类对象之间的配对

$$\langle y^*, s \rangle, \quad y^* \in K^*, s \in K,$$

天然非负, 而当该配对等于零时, 就出现了后文 KKT 条件里的互补松弛。

8.1.3 典型例子

例题 8.1 正函数锥与正测度锥 设 Ω 为紧 Hausdorff 空间, 取

$$Y = C(\Omega), \quad K := \{u \in C(\Omega) : u(\omega) \geq 0, \forall \omega \in \Omega\}.$$

则 K 是 $C(\Omega)$ 中的闭凸锥。由第 3.3 节定理 3.3.1, Y^* 可识别为有限符号 Radon 测度空间, 而 K^* 恰好对应于所有正 Radon 测度。把这个例子放在这里, 是为了说明锥乘子完全可以不是“正测度”而是向量; 这正是第 8.4 节里测度型乘子的原型。

例题 8.2 非负正交体与二阶锥 在 $Y = \mathbb{R}^m$ 中, 若

$$K = \mathbb{R}_+^m,$$

则 $u \preceq_K v$ 就是坐标逐项不等式; 若

$$K = \{(t, z) \in \mathbb{R} \times \mathbb{R}^{m-1} : t \geq \|z\|_2\},$$

则得到二阶锥不等式。把这个例子放在这里, 是为了把 LP 和 SOCP 作为抽象闭凸锥的特例立即回收, 并为第 9.3 节的有限维坍塌做好准备。

例题 8.3 资源非负约束与影子价格 在管理科学问题里, $b - Ax \in K$ 常表示“资源剩余是非负的”, 其中 K 可以是逐项非负锥、鲁棒安全余量锥, 甚至某个函数空间中的正锥。对偶锥中的元素则可解释为资源影子价格或风险罚率。把这个例子放在这里, 是为了说明抽象锥语言并不比工程语言更远; 它恰好把各种“非负成本”与“边际价格”统一到了同一配对框架中。

有限维对照

Boyd 在讨论广义不等式时, 通常从正交体、半正定锥或二阶锥直接出发, 因此读者很容易把“锥”理解成几类可画图的特殊集合。本节说明, 这些例子背后真正稳定的结构是定义 8.1.1 与定义 8.1.2。有限维里能凭直觉看见的几何, 在无穷维里必须依赖命题 8.1.2 这样的对偶刻画来替代; 但两者说的其实是同一件事。

习题 (待补)

-  **练习 8.1 对偶锥检验占位** 补一题: 对一个给定的闭凸锥 K , 显式计算 K^* , 并用命题 8.1.2 检验某个广义不等式是否成立。
-  **练习 8.2 锥约束桥接题占位** 补一题: 把一个函数空间中的正锥约束退回到 $\mathbb{R}^m$ 中的逐项非负约束, 比较两种环境下对偶锥与乘子含义的变化。

8.2 抽象凸优化问题标准型

前一节给出了锥诱导的广义不等式，但若没有统一标准型，后文的 Slater 条件、KKT 系统和第 11.3 节 ADMM 都会被迫针对每一种约束重新写一遍。本节的任务就是把它们组织成一个可复用的接口层：原问题如何书写，拉格朗日函数如何定义，对偶函数如何得到，以及这些对象怎样与第 7.4 节的 Fenchel–Rockafellar 模板接轨。顺便说明一点：按第 7.1 节当前正文的规范术语，这里应当说“Fenchel 共轭”，而不是旧控制卡里遗留的“Fenchel–Moreau 共轭”。

8.2.1 抽象锥规划标准型

定义 8.2.1 (抽象锥规划标准型)

设 X, Y 为实 Banach 空间， $A: X \rightarrow Y$ 为有界线性算子， $b \in Y$ ， $K \subset Y$ 为闭凸锥， $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper 凸泛函。称问题

$$\inf_{x \in X} f(x) \quad \text{subject to} \quad Ax - b \in -K$$

为抽象锥规划标准型。它的可行集记为

$$\mathcal{F} := \{x \in X : Ax - b \in -K\} = \{x \in X : b - Ax \in K\}.$$

定义 8.2.2 (锥规划的拉格朗日函数)

在定义 8.2.1 的设定下，对任意 $y^* \in K^*$ ，定义拉格朗日函数

$$L(x, y^*) := f(x) + \langle y^*, Ax - b \rangle.$$

相应的对偶函数定义为

$$q(y^*) := \inf_{x \in X} L(x, y^*), \quad y^* \in K^*.$$

命题 8.2.1 (对偶函数给出原问题下界)

设问题 (8.2.1) 可行，记其最优值为

$$p^* := \inf_{x \in \mathcal{F}} f(x).$$

则对任意 $y^* \in K^*$ ，都有

$$q(y^*) \leq p^*.$$

证明 任取可行点 $x \in \mathcal{F}$ 。由可行性， $b - Ax \in K$ 。又因 $y^* \in K^*$ ，故

$$\langle y^*, b - Ax \rangle \geq 0,$$

亦即

$$\langle y^*, Ax - b \rangle \leq 0.$$

于是

$$L(x, y^*) = f(x) + \langle y^*, Ax - b \rangle \leq f(x).$$

对 $x \in \mathcal{F}$ 取下确界，得

$$q(y^*) = \inf_{x \in X} L(x, y^*) \leq \inf_{x \in \mathcal{F}} f(x) = p^*.$$

8.2.2 与 Fenchel 模板的对应

命题 8.2.2 (锥标准型到 Fenchel 对偶的接口)

设 $g: Y \rightarrow \mathbb{R} \cup \{+\infty\}$ 为集合 $b - K$ 的指示函数:

$$g(y) := \iota_{b-K}(y).$$

则定义 8.2.1 的原问题可改写为

$$\inf_{x \in X} \{f(x) + g(Ax)\}.$$

此外, 对任意 $y^* \in Y^*$,

$$g^*(y^*) = \langle y^*, b \rangle + \iota_{K^*}(y^*),$$

从而第 7.4 节定义 7.4.1 的 Fenchel 对偶恰化为

$$\sup_{y^* \in K^*} \{-f^*(-A^*y^*) - \langle y^*, b \rangle\}.$$

证明 由 $g = \iota_{b-K}$ 可知, $g(Ax) = 0$ 当且仅当 $Ax \in b - K$, 亦即 $Ax - b \in -K$; 否则 $g(Ax) = +\infty$. 因此

$$f(x) + g(Ax) = \begin{cases} f(x), & x \in \mathcal{F}, \\ +\infty, & x \notin \mathcal{F}. \end{cases}$$

故原问题确可写成

$$\inf_{x \in X} \{f(x) + g(Ax)\}.$$

接下来计算 g^* . 由共轭定义,

$$g^*(y^*) = \sup_{y \in b-K} \langle y^*, y \rangle.$$

任写 $y = b - s$, 其中 $s \in K$, 便得

$$g^*(y^*) = \sup_{s \in K} \{\langle y^*, b - s \rangle\} = \langle y^*, b \rangle + \sup_{s \in K} (-\langle y^*, s \rangle).$$

若 $y^* \in K^*$, 则对任意 $s \in K$ 都有 $-\langle y^*, s \rangle \leq 0$, 而取 $s = 0$ 即见上确界等于 0; 若 $y^* \notin K^*$, 则存在 $s_0 \in K$ 使 $\langle y^*, s_0 \rangle < 0$, 于是

$$\sup_{t \geq 0} (-\langle y^*, ts_0 \rangle) = +\infty.$$

故

$$g^*(y^*) = \langle y^*, b \rangle + \iota_{K^*}(y^*).$$

最后将其代入第 7.4 节命题 7.4.1 与定理 7.4.1 所对应的对偶模板, 即得所述对偶表达式。

注 命题 8.2.2 解释了本节的真正角色: 它不是重复第 7 章的对偶理论, 而是把锥约束问题准确嵌入 Fenchel 框架。后文第 8.3 节的 Slater 条件, 本质上是在验证指示函数 $g = \iota_{b-K}$ 的资格条件; 第 8.4 节的 KKT 系统, 则是第 7.4 节推论 7.4.1 的锥版本翻译。再往后, 第 11.3 节 ADMM 之所以能统一处理分块变量与一致性约束, 也正是因为抽象标准型已经把这些结构预先接口化了。

8.2.3 典型例子

例题 8.4 积分型目标与算子约束 设 $X = L^2(0, T)$, $Y = L^2(0, T)$, A 为积分算子或观测算子, $K = L_+^2(0, T)$, 并考虑

$$\inf_{x \in X} \left\{ \int_0^T \ell(t, x(t)) dt : Ax - b \in -K \right\}.$$

把这个例子放在这里，是为了说明抽象标准型不是只为矩阵问题设计的；函数空间中的能量最小化、状态约束和观测一致性，同样可以直接写进定义 8.2.1。

例题 8.5 Boyd 风格有限维标准型 当 $X = \mathbb{R}^n$ 、 $Y = \mathbb{R}^m$ 、 $K = \mathbb{R}_+^m$ 时，定义 8.2.1 退化为

$$\min f(x) \quad \text{subject to} \quad Ax \leq b.$$

把这个例子放在这里，是为了把 Boyd 中最熟悉的标准凸优化模型直接接回本章：抽象标准型并没有改变有限维问题，只是把其真正依赖的锥结构显式写了出来。

例题 8.6 分块变量与一致性约束 在分布式学习或推荐系统里，常见模型是

$$\min_{x,z} \phi(x) + \psi(z) \quad \text{subject to} \quad Bx - Cz = 0.$$

把等式约束写成锥约束时，可取 Y 为相应乘积空间， $K = \{0\}$ ，并把 (x, z) 视为一个联合变量。把这个例子放在这里，是为了给第 11.3 节 ADMM 的原-对偶分裂准备统一输入格式。

有限维对照

Boyd 书里标准型通常写成“目标函数 + 线性等式/不等式约束”，其后紧跟拉格朗日函数和对偶函数的矩阵公式。本节说明，这种写法在本质上只是定义 8.2.1 与定义 8.2.2 的有限维坍塌。矩阵记号看上去更具体，但隐藏了锥、对偶锥和指示函数这三个真正驱动对偶理论的对象。

习题（待补）

- 🔥 **练习 8.3 标准型改写占位** 补一题：把一个带不等式约束和等式约束的具体凸优化模型改写为定义 8.2.1 的标准型，并写出其拉格朗日函数与对偶函数。
- 🔥 **练习 8.4 Fenchel 接口桥接题占位** 补一题：从命题 8.2.2 出发，显式计算一个有限维锥规划的 Fenchel 对偶，并和 Boyd 书中的拉格朗日对偶公式逐项对照。

8.3 广义 Slater 条件

弱对偶几乎不需要额外条件，但强对偶从来不是免费的。第 7.4 节中，Fenchel–Rockafellar 对偶之所以成立，是因为指示函数或代价函数在适当点上具备连续性；对锥规划来说，这种连续性最自然的几何化表达就是严格可行性。Slater 条件的作用，不是给出一个“好看的假设”，而是确保约束边界没有在最优值附近制造病态缺口。

8.3.1 严格可行性

定义 8.3.1 (广义 Slater 条件)

考虑定义 8.2.1 的锥规划问题。若存在某个 $x_0 \in \text{dom } f$ 使得

$$b - Ax_0 \in \text{int } K,$$

则称该问题满足广义 Slater 条件。也就是说，存在一个可行点，其松弛变量不仅属于锥 K ，而且落在锥的拓扑内部。

命题 8.3.1 (Slater 条件推出 Fenchel 资格条件)

设 $g = \iota_{b-K}$ ，其中 $K \subset Y$ 为闭凸锥。若定义 8.3.1 成立，则 g 在点 Ax_0 处连续。因而第 7.4 节定义 7.4.2 的 Fenchel 型资格条件成立。

证明 由 $b - Ax_0 \in \text{int } K$ ，可知

$$Ax_0 \in b - \text{int } K = \text{int}(b - K).$$

因此存在 0 的某个邻域 $U \subset Y$, 使

$$Ax_0 + U \subset b - K.$$

于是对任意 $u \in U$,

$$g(Ax_0 + u) = \iota_{b-K}(Ax_0 + u) = 0 = g(Ax_0).$$

这说明 g 在 Ax_0 的邻域内恒等于常数, 因而在该点连续。再结合 $x_0 \in \text{dom } f$, 便得到第 7.4 节定义 7.4.2 的资格条件。

8.3.2 相对内部与 core 的替代

命题 8.3.2 (core 与相对内部版本的 Slater 替代)

设

$$C := b - K.$$

若存在 $x_0 \in \text{dom } f$ 使得

$$Ax_0 \in \text{ri } C,$$

则 $g = \iota_C$ 在 $\text{aff } C$ 上相对于其仿射拓扑在 Ax_0 处连续。特别地, 当环境空间中 $\text{int } K = \emptyset$ 但 $\text{ri } C$ 或 $\text{core } C$ 非空时, 可以把资格条件与分离论证限制在 $\text{aff } C$ 内部进行。

证明 由第 5.2 节命题 5.2.1, $Ax_0 \in \text{ri } C$ 意味着存在 $\text{aff } C$ 中的邻域 V 使

$$(Ax_0 + V) \cap \text{aff } C \subset C.$$

于是 g 限制在 $\text{aff } C$ 上时, 在该邻域内恒等于 0, 所以相对于仿射拓扑在 Ax_0 处连续。

另一方面, 第 5.2 节定义 5.2.1 与命题 5.2.2 告诉我们, 对于凸集而言, core 提供的正是“沿可行仿射方向仍有余量”的几何信息。在有限维环境中, relative interior 与 core 会重合; 而在无穷维里, 拓扑内部经常退化为空集, 此时就只能退回到相对内部或代数内部的语言。

定理 8.3.1 (Slater 条件下的锥规划强对偶)

设 X, Y 为 Banach 空间, $A: X \rightarrow Y$ 为有界线性算子, $K \subset Y$ 为闭凸锥, $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。考虑问题

$$p^* := \inf_{x \in X} \{f(x) : Ax - b \in -K\},$$

以及对偶问题

$$d^* := \sup_{y^* \in K^*} \{-f^*(-A^*y^*) - \langle y^*, b \rangle\}.$$

若定义 8.3.1 成立, 则

$$p^* = d^*.$$

也就是说, 广义 Slater 条件消除了该锥规划的对偶间隙。

证明 按命题 8.2.2, 原问题可写成

$$\inf_{x \in X} \{f(x) + \iota_{b-K}(Ax)\}.$$

由命题 8.3.1, 函数 $g = \iota_{b-K}$ 在某个点 Ax_0 处连续, 因此第 7.4 节定义 7.4.2 的资格条件满足。于是可直接应用第 7.4 节定理 7.4.1, 得到

$$\inf_{x \in X} \{f(x) + \iota_{b-K}(Ax)\} = \sup_{y^* \in Y^*} \{-f^*(-A^*y^*) - \iota_{b-K}^*(y^*)\}.$$

再由命题 8.2.2 对 ι_{b-K}^* 的显式计算,

$$\iota_{b-K}^*(y^*) = \langle y^*, b \rangle + \iota_{K^*}(y^*),$$

从而上式右侧化为

$$\sup_{y^* \in K^*} \{-f^*(-A^*y^*) - \langle y^*, b \rangle\} = d^*.$$

因此 $p^* = d^*$ 。

注 本节最容易被误读的一点,是把“严格可行”机械地等同为“拓扑内部非空”。在 $\mathbb{R}^m$ 或有限维矩阵空间中,这样做通常没有问题;但在无穷维里,很多天然锥的内部都会退化。例如在非原子测度空间上的 L_+^p 正锥通常没有拓扑内部,而在 $C(\Omega)$ 中的正函数锥却有由严格正下界给出的内部点。因此,一旦环境空间改变,就必须重新判断该用 int、ri 还是 core,而不能把 Boyd 中的有限维 Slater 条件直接照搬。

8.3.3 典型例子

例题 8.7 函数约束留有严格余量 设 $X = Y = C(\Omega)$, $K = C(\Omega)_+$, 并考虑约束

$$Ax \leq_K b.$$

若存在 x_0 使得

$$b(\omega) - Ax_0(\omega) \geq \delta > 0, \quad \forall \omega \in \Omega,$$

则 $b - Ax_0 \in \text{int } K$, 故 Slater 条件成立。把这个例子放在这里,是为了给无穷维严格可行性一个真正可见的形状:不是“略大于零”的口头说法,而是统一正下界。

例题 8.8 有限维标准 Slater 条件 当 $K = \mathbb{R}_+^m$ 时, 定义 8.3.1 退化为

$$Ax_0 < b$$

的逐项严格不等式。把这个例子放在这里,是为了把 Boyd 书中最熟悉的一句话准确嵌入本章抽象语言:有限维 Slater 条件只是一般锥内部条件的一个特殊面貌。

例题 8.9 分布鲁棒约束的缓冲区解释 在分布鲁棒或风险约束模型里, $b - Ax \in K$ 往往意味着某种安全裕度或概率缓冲区非负。若存在一个设计点 x_0 使缓冲区严格落在锥内部, 则对偶变量就不会被边界病态放大。把这个例子放在这里,是为了说明“资格条件为何消除对偶间隙”并非纯理论话题;它对应的是模型仍留有操作余地的实际语义。

有限维对照

Boyd 在强对偶讨论中常把 Slater 条件写成“存在严格可行点”,因为在有限维里 interior、relative interior 与许多局部正则性经常会自动协调。本节说明,这种便利并不属于抽象锥规划本身,而属于欧氏环境。无穷维里一旦锥的拓扑内部消失,就必须把第 5.2 节的相对内部和 core 拉回来,重新判断哪一种“严格可行”才是真正有效的资格条件。

习题 (待补)

-  **练习 8.5 Slater 条件占位** 补一题: 对一个给定的锥规划, 判断定义 8.3.1 是否成立, 并据此说明能否直接调用定理 8.3.1。
-  **练习 8.6 相对内部桥接题占位** 补一题: 构造一个锥在环境空间中内部为空但相对内部非空的例子, 比较拓扑内部版本与相对内部版本 Slater 条件的差别。

8.4 广义 KKT 条件

到这里为止，我们已经有了三块拼图：第 8.1 节给出锥与对偶锥，第 8.2 节给出抽象标准型，第 8.3 节给出强对偶成立的资格条件。**KKT** 理论所做的，就是把这三块拼图与第 7.4 节的次微分最优性条件合成一个统一系统。有限维里这常常被写成若干向量等式；无穷维里真正需要小心的是，乘子所属的空间、法锥的表达方式以及互补松弛究竟对哪一个锥而言成立。

8.4.1 KKT 系统的定义

定义 8.4.1 (锥规划的 KKT 系统)

考虑定义 8.2.1 的原问题

$$\inf_{x \in X} \{f(x) : Ax - b \in -K\}.$$

称 $(\bar{x}, \bar{y}^*) \in X \times Y^*$ 满足该问题的 KKT 系统，若

$$A\bar{x} - b \in -K,$$

$$\bar{y}^* \in K^*,$$

$$0 \in \partial f(\bar{x}) + A^* \bar{y}^*,$$

$$\langle \bar{y}^*, b - A\bar{x} \rangle = 0.$$

四个条件分别称为原可行性、对偶可行性、驻点条件和互补松弛。

命题 8.4.1 (锥松弛与对偶锥的互补配对)

设 $K \subset Y$ 为闭凸锥， $s \in K$ ， $y^* \in Y^*$ 。则下列两条等价：

$$y^* \in N_{-K}(-s);$$

$$y^* \in K^*, \quad \langle y^*, s \rangle = 0.$$

等价地，对任意 $b \in Y$ ，

$$y^* \in N_{b-K}(b-s) \iff y^* \in K^*, \langle y^*, s \rangle = 0.$$

证明 先证明关于 $-K$ 的表述。若 $y^* \in N_{-K}(-s)$ ，则对任意 $k \in K$ ，由于 $-k \in -K$ ，有

$$\langle y^*, (-k) - (-s) \rangle \leq 0,$$

即

$$\langle y^*, s - k \rangle \leq 0.$$

取 $k = 0$ 得 $\langle y^*, s \rangle \leq 0$ ；取 $k = 2s$ 又得 $\langle y^*, -s \rangle \leq 0$ ，故

$$\langle y^*, s \rangle = 0.$$

再代回上式，便得

$$\langle y^*, k \rangle \geq 0, \quad \forall k \in K,$$

即 $y^* \in K^*$ 。

反之，若 $y^* \in K^*$ 且 $\langle y^*, s \rangle = 0$ ，则对任意 $k \in K$ ，

$$\langle y^*, (-k) - (-s) \rangle = \langle y^*, s \rangle - \langle y^*, k \rangle = -\langle y^*, k \rangle \leq 0,$$

从而 $y^* \in N_{-K}(-s)$ 。

最后注意到平移不会改变法锥的方向结构:

$$N_{b-K}(b-s) = N_{-K}(-s).$$

于是第二个等价关系随即成立。

8.4.2 广义 KKT 定理

定理 8.4.1 (无穷维锥规划的 KKT 定理)

设 X, Y 为 Banach 空间, $A: X \rightarrow Y$ 为有界线性算子, $K \subset Y$ 为闭凸锥, $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。假设第 8.3 节定义 8.3.1 成立, 并设 $\bar{x} \in X$ 与 $\bar{y}^* \in Y^*$ 分别为原问题和对偶问题的可行点。则下列两条等价:

1. $\bar{x}$ 与 $\bar{y}^*$ 分别是原问题与对偶问题的最优解;
2. $(\bar{x}, \bar{y}^*)$ 满足定义 8.4.1 的 KKT 条件。

证明 把原问题写成

$$\inf_{x \in X} \{f(x) + \iota_{b-K}(Ax)\}.$$

由第 8.3 节定理 8.3.1, 该问题满足强对偶。于是可应用第 7.4 节推论 7.4.1: $(\bar{x}, \bar{y}^*)$ 为原-对偶最优对, 当且仅当

$$-A^*\bar{y}^* \in \partial f(\bar{x}), \quad \bar{y}^* \in \partial \iota_{b-K}(A\bar{x}).$$

由第 6.4 节推论 6.4.1,

$$\partial \iota_{b-K}(A\bar{x}) = N_{b-K}(A\bar{x}).$$

再令

$$s := b - A\bar{x}.$$

则原可行性就是 $s \in K$, 而命题 8.4.1 给出

$$\bar{y}^* \in N_{b-K}(A\bar{x}) \iff \bar{y}^* \in K^*, \langle \bar{y}^*, b - A\bar{x} \rangle = 0.$$

因此, 第 7.4 节的 Fenchel 次微分最优性条件恰好等价于

$$A\bar{x} - b \in -K, \quad \bar{y}^* \in K^*, \quad 0 \in \partial f(\bar{x}) + A^*\bar{y}^*, \quad \langle \bar{y}^*, b - A\bar{x} \rangle = 0.$$

这就是定义 8.4.1 的 KKT 系统, 故两条等价。

推论 8.4.1 (KKT 的 Fenchel 次微分写法)

在定理 8.4.1 的假设下, KKT 系统等价于

$$-A^*\bar{y}^* \in \partial f(\bar{x}), \quad \bar{y}^* \in \partial \iota_{b-K}(A\bar{x}).$$

因此, 锥规划中的 KKT 条件本质上并不是另一套平行理论, 而是第 7.4 节推论 7.4.1 在指标函数 $g = \iota_{b-K}$ 上的具体化。

证明 这正是定理 8.4.1 证明中的中间等价关系。

8.4.3 典型例子

例题 8.10 状态约束最优控制中的测度乘子 在连续时间最优控制里, 若状态约束写成

$$x(t) \leq c(t), \quad t \in [0, T],$$

则对应的乘子往往不再是有限维向量, 而是区间 $[0, T]$ 上的正测度。把这个例子放在这里, 是为了说明定义 8.4.1 中的 $\bar{y}^*$ 的确可能住在对偶空间甚至测度空间里; “乘子是测度”不是修辞, 而是无穷维 KKT 的标准现象。

例题 8.11 线性规划的向量乘子 当 $K = \mathbb{R}_+^m$ 时, 定义 8.4.1 退化为

$$Ax \leq b, \quad y \geq 0, \quad 0 \in \partial f(x) + A^\top y, \quad y^\top (b - Ax) = 0.$$

把这个例子放在这里, 是为了把 Boyd 书中的 KKT 条件完整回收: 有限维里熟悉的乘子向量, 只是本节抽象对偶变量的一个最简单特例。

例题 8.12 影子价格解释 在资源配置模型里, 约束 $b - Ax \in K$ 表示容量或安全余量非负, 而对偶可行变量 $y^* \in K^*$ 则可解释为影子价格。互补松弛

$$\langle y^*, b - Ax \rangle = 0$$

意味着“有价格的资源必然被用到边界, 有剩余的资源不会产生边际价格”。把这个例子放在这里, 是为了给 KKT 系统一个管理科学层面的可解释语义。

有限维对照

Boyd 第 5 章中的 KKT 理论常写成几行矩阵方程, 因此读者很容易把它理解成线性代数技巧。本节说明, 这些公式真正依赖的是四个抽象结构: 锥可行性、对偶锥、次微分驻点条件和互补松弛。第 9.1 节会进一步看到, 一旦回到 $\mathbb{R}^n$, 很多拓扑和对偶上的麻烦都会自动消失; 但正因为本节已经把一般形式写清楚, 第 11.3 节算法中的原-对偶分裂才能被视作 KKT 系统的计算实现, 而不只是某种经验公式。

习题 (待补)

- 练习 8.7 KKT 系统占位 补一题: 对一个给定的锥规划写出定义 8.4.1 的四条条件, 并判断某个候选原-对偶对是否满足它们。
- 练习 8.8 乘子空间桥接题占位 补一题: 比较一个有限维线性规划与一个函数空间约束问题中的乘子空间, 说明为什么前者的乘子是向量, 而后者可能是测度。

第9章 特例坍缩——经典有限维凸优化

前七章一直在为无穷维情形搭建工作台：第4.2节把紧性从范数拓扑转移到弱拓扑与弱*拓扑，第5章和第6章把分离、次微分与下半连续性提升到泛函层面，第7章与第8章则把对偶、锥约束和KKT系统写成统一的原-对偶框架。本章的任务不是另起炉灶，而是反过来说明：当空间退回到有限维时，这些抽象工具为何几乎全部自动简化，并最终坍缩成Boyd书中的经典有限维凸优化母语。

这种坍缩沿四条主线展开。第9.1节先解释有限维范数等价、弱拓扑与强拓扑一致、闭有界紧等事实，从而说明存在性与正则性的许多技术门槛为何会在 $\mathbb{R}^n$ 中自动消失。第9.2节在此基础上把抽象锥规划和KKT系统退回到LP/QP的矩阵公式，说明线性规划与二次规划并不是抽象理论之外的例外，而是第8章结果的Euclidean版。第9.3节把第8.1节的锥语言与第4.4节的谱论语言压缩到SOCP与SDP，展示“迹内积”“半正定锥”“特征值分解”如何共同承担有限维对偶配对。最后第9.4节讨论几何规划，说明它虽然外观上带有乘法结构，但在对数坐标下仍然是第7.4节Fenchel-Rockafellar对偶的一个经典有限维坍缩。

因此，这一章最重要的阅读态度不是“终于回到熟悉公式”，而是“识别哪些熟悉公式其实依赖了维数有限”。Boyd之所以能把大量论证写成矩阵代数和几何图形，是因为有限维里弱紧性、内点、伴随与矩阵转置、对偶球紧性等结构都被压缩到了一个共同背景中。本章要做的，正是把这种背景重新显式化，然后再把它交回给经典有限维凸优化。这样，第10章和第11章中的算法才会被理解为“对抽象原理的计算实现”，而不是只对有限维模型成立的技巧。

9.1 欧氏空间的退化

这一节是全章的释压阀。前面几章里那些关于弱拓扑、弱紧性、相对内部、Slater条件和KKT乘子的谨慎区分，在 $\mathbb{R}^n$ 中会出现大规模坍缩：不同范数彼此等价，弱拓扑与通常拓扑一致，闭有界集变成紧集，很多资格条件也随之变得更容易验证。有限维凸优化之所以显得“天然顺手”，并不是因为它遵循另一套理论，而是因为抽象理论中的许多门槛在这里自动消失了。

9.1.1 有限维范数与拓扑的一致性

命题 9.1.1 (有限维中的范数等价)

设 X 为有限维实向量空间， $\|\cdot\|_a$ 与 $\|\cdot\|_b$ 是 X 上两个范数。则存在常数 $c, C > 0$ ，使得对任意 $x \in X$ ，

$$c\|x\|_a \leq \|x\|_b \leq C\|x\|_a.$$

证明 在单位球

$$S_a := \{x \in X : \|x\|_a = 1\}$$

上考虑连续函数 $x \mapsto \|x\|_b$ 。由于 S_a 在有限维空间中是紧集，故该函数取到正的最小值 m 和有限的最大值 M 。于是对任意非零 x ，令 $u = x/\|x\|_a$ ，便有

$$m \leq \|u\|_b \leq M.$$

两边乘以 $\|x\|_a$ 即得

$$m\|x\|_a \leq \|x\|_b \leq M\|x\|_a.$$

令 $c = m$ 、 $C = M$ 即可。

命题 9.1.2 (有限维中弱拓扑与强拓扑一致)

设 X 为有限维赋范空间，则第4.2节定义4.2.1所给出的弱拓扑与范数拓扑一致。

证明 取 X 的一组基 $\{e_1, \dots, e_n\}$, 并记其对偶基为 $\{e_1^*, \dots, e_n^*\}$ 。若网 x_α 在弱拓扑下收敛到 x , 则对每个 i ,

$$e_i^*(x_\alpha) \rightarrow e_i^*(x).$$

因此坐标逐项收敛。有限维中任意范数都与 Euclidean 范数等价, 由命题 9.1.1 可知坐标逐项收敛推出范数收敛, 所以弱收敛蕴含强收敛。反向蕴含则对任意空间都成立, 因为每个连续线性泛函在范数拓扑下本就连续。故两种拓扑一致。

推论 9.1.1 (有限维中的闭有界紧性)

设 X 为有限维赋范空间, 则子集 $C \subset X$ 在下列三条中彼此等价:

1. C 闭且有界;
2. C 在范数拓扑下紧;
3. C 在弱拓扑下紧。



证明 由 Heine–Borel 定理, 闭且有界等价于范数紧。再由命题 9.1.2, 弱拓扑与强拓扑一致, 故范数紧与弱紧等价。

9.1.2 存在性与内部概念的有限维简化

定理 9.1.1 (有限维塌缩原则)

设 $X = \mathbb{R}^n$ 。则前七章中与存在性、对偶性和 KKT 相关的许多技术门槛都可以统一简化为有限维表述:

1. 弱收敛、强收敛与坐标收敛一致;
2. 闭有界可行集自动紧, 因此第 6.1 节直接法中的弱紧性条件可压缩成闭有界性;
3. 对非空凸集, 拓扑内部、相对内部与第 5.2 节中的几何余量更容易协调;
4. 第 8.4 节定义 8.4.1 的 KKT 系统在矩阵坐标下变成有限条代数方程与不等式。



证明 第一条由命题 9.1.2 直接给出。第二条由推论 9.1.1 得到, 而这正是第 4.2 节推论 4.2.1 在有限维里的强化版本。第三条的原因在于, 有限维凸集的仿射包本身还是有限维欧氏空间, 因此相对内部可直接用 Euclidean 邻域刻画, 并与常用图形直觉保持一致。第四条则来自于: 有限维对偶空间仍是有限维向量空间, 连续线性算子都可由矩阵表示, 故抽象伴随、乘子与互补松弛都能写成坐标化代数系统。

注 定理 9.1.1 的真正价值, 是解释 Boyd 书中那些看起来“不言自明”的步骤到底省略了什么。譬如“取极小化列并抽收敛子列”默认 KKT 乘子是向量“相对内部和内部差别不大”等叙述, 并不是普遍真理, 而是有限维塌缩后的副产品。

9.1.3 典型例子

例题 9.1 弱紧性与强紧性在有限维中一致 在 $X = \mathbb{R}^n$ 中, 任意闭球

$$\{x \in \mathbb{R}^n : \|x\|_2 \leq r\}$$

既是范数紧集, 也是弱紧集。把这个例子放在这里, 是为了把第 4.2 节中弱拓扑和强拓扑的技术分工一次性压缩回有限维直觉。

例题 9.2 相对内部与图形直觉 对多面体

$$C = \{x \in \mathbb{R}^n : Ax \leq b\},$$

相对内部可以直接理解为“在其仿射包里留有 Euclidean 余量的点”。把这个例子放在这里, 是为了说明 Boyd 中大量关于相对内部和严格可行性的图形叙述, 在有限维里是可靠的, 但这种可靠性本身来自有限维塌缩。

例题 9.3 参数向量优化 在机器学习和信号处理的标准模型里, 参数往往直接属于 $\mathbb{R}^n$ 。把这个例子放在这里, 是为了提醒读者: 很多工程问题之所以能直接调用 Boyd 的有限维工具, 不是因为它们先天地排斥无穷维理论, 而是因为它们恰好处在定理 9.1.1 覆盖的环境中。

有限维对照

Boyd 的写法之所以可以把注意力几乎全部放在图像、矩阵和拉格朗日函数上，是因为弱拓扑、弱紧性和对偶空间的技术难点已经被有限维结构吸收了。本节的作用，就是把这种吸收过程显式讲清楚：抽象工具没有消失，它们只是退化成了 Euclidean 背景的默认设置。

习题（待补）

- 练习 9.1 有限维塌缩占位 补一题：用命题 9.1.2 和推论 9.1.1 说明为什么有限维闭有界凸优化问题的极小值存在证明可以不用显式引入弱拓扑。
- 练习 9.2 相对内部桥接题占位 补一题：对一个具体多面体写出其内部和相对内部，并指出在其仿射包降维后两者如何对应。

9.2 线性规划与二次规划的复盘

第 8.2 节已经给出了抽象锥规划标准型，第 8.4 节则给出了无穷维 KKT 系统。本节要做的，不是重新讲一遍教科书里的 LP/QP 基础，而是把这些抽象对象逐项坍缩回矩阵语言。也正因此，线性规划和二次规划在这里的角色更像“坐标化译本”：同一个原-对偶结构，在有限维里被写成矩阵、向量和互补松弛式。

9.2.1 线性规划与其对偶

定义 9.2.1 (有限维线性规划)

设 $c \in \mathbb{R}^n$, $A \in \mathbb{R}^{p \times n}$, $G \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^p$, $h \in \mathbb{R}^m$ 。称问题

$$\min_{x \in \mathbb{R}^n} c^\top x \quad \text{subject to} \quad Ax = b, \quad Gx \leq h$$

为一个线性规划。

命题 9.2.1 (LP 的矩阵对偶形式)

定义 9.2.1 的线性规划，其拉格朗日函数可写为

$$L(x, v, \lambda) = c^\top x + v^\top (Ax - b) + \lambda^\top (Gx - h), \quad \lambda \geq 0.$$

相应对偶问题为

$$\max_{v \in \mathbb{R}^p, \lambda \in \mathbb{R}_+^m} -b^\top v - h^\top \lambda$$

subject to

$$c + A^\top v + G^\top \lambda = 0.$$

证明 这正是第 8.2 节定义 8.2.1 在 $K = \mathbb{R}_+^m$ 且等式约束单独列出的有限维形式。对偶函数定义为

$$q(v, \lambda) := \inf_{x \in \mathbb{R}^n} L(x, v, \lambda).$$

若

$$c + A^\top v + G^\top \lambda \neq 0,$$

则 $L(x, v, \lambda)$ 对 x 是非常数仿射函数，其下确界为 $-\infty$ 。只有当

$$c + A^\top v + G^\top \lambda = 0$$

时，对偶函数才有限，此时

$$q(v, \lambda) = -b^\top v - h^\top \lambda.$$

再结合 $\lambda \geq 0$ ，便得到所述矩阵对偶形式。

定理 9.2.1 (LP 的矩阵型 KKT 条件)

设线性规划存在最优解，并满足有限维 Slater 型严格可行性。则 x^* 为原问题最优解、 (v^*, λ^*) 为对偶最优解，当且仅当

$$\begin{aligned} Ax^* &= b, & Gx^* &\leq h, \\ \lambda^* &\geq 0, \\ c + A^\top v^* + G^\top \lambda^* &= 0, \\ \lambda_i^* (h_i - g_i^\top x^*) &= 0, & i &= 1, \dots, m. \end{aligned}$$

证明 这正是第 8.4 节定理 8.4.1 在有限维 Euclidean 空间中的坍塌。原可行性与对偶可行性分别对应前两组和第三组条件；驻点条件由

$$0 \in \partial(c^\top x) + A^\top v^* + G^\top \lambda^*$$

简化为线性方程

$$c + A^\top v^* + G^\top \lambda^* = 0;$$

互补松弛则由

$$\langle \lambda^*, h - Gx^* \rangle = 0$$

在逐项非负锥上的配对写成逐坐标乘积等于零。

9.2.2 二次规划

定义 9.2.2 (有限维二次规划)

设 $H \in \mathbb{S}_+^n$ 为对称半正定矩阵， $c \in \mathbb{R}^n$ 。称问题

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^\top H x + c^\top x \quad \text{subject to} \quad Ax = b, \quad Gx \leq h$$

为一个凸二次规划。

命题 9.2.2 (QP 的矩阵型 KKT 系统)

在定义 9.2.2 中，若满足有限维严格可行性，则 x^* 为最优解，当且仅当存在 (v^*, λ^*) 使

$$\begin{aligned} Ax^* &= b, & Gx^* &\leq h, & \lambda^* &\geq 0, \\ Hx^* + c + A^\top v^* + G^\top \lambda^* &= 0, \\ \lambda_i^* (h_i - g_i^\top x^*) &= 0, & i &= 1, \dots, m. \end{aligned}$$

证明 由 $H \succeq 0$ ，目标函数是凸且可微，其梯度为

$$\nabla \left(\frac{1}{2} x^\top H x + c^\top x \right) = Hx + c.$$

因此第 6.2 节的一阶微分语言和第 8.4 节的 KKT 系统结合后，驻点条件正好化为

$$Hx^* + c + A^\top v^* + G^\top \lambda^* = 0.$$

其余条件与线性规划完全一致，故结论成立。

注 命题 9.2.2 说明，第 8.4 节中的抽象乘子系统在有限维里会同时吸收第 6.2 节的梯度与第 6.3 节的次微分语言。LP 对应的是线性目标的次梯度为常向量，QP 对应的是二次目标的梯度为仿射映射；而结构本身并没有变化。

9.2.3 典型例子

例题 9.4 多面体上线性目标 线性规划中的可行集是多面体，目标则是线性泛函。把这个例子放在这里，是为了把第 5.4 节极点与支撑超平面的语言回收到最经典的 LP 场景：抽象分离与极点理论，在有限维里正好对应多面体几何。

例题 9.5 标准二次规划 当 H 为对称半正定矩阵时，定义 9.2.2 给出的 QP 同时体现了第 6.2 节的梯度、第 8.2 节的标准型和第 8.4 节的 KKT 条件。把这个例子放在这里，是为了让读者看到 Hessian、乘子和互补松弛在有限维中如何自然拼接起来。

例题 9.6 均值-方差投资组合 均值-方差组合优化可写为

$$\min_x \frac{1}{2} x^\top \Sigma x - \mu^\top x \quad \text{subject to} \quad 1^\top x = 1, \quad x \geq 0.$$

把这个例子放在这里，是为了给第 12 章连续时间模型一个静态有限维基线，同时说明 QP 的矩阵型 KKT 公式具有直接的经济解释。

有限维对照

Boyd 书中 LP 和 QP 的拉格朗日对偶与 KKT 条件通常直接写成矩阵形式，这会给人一种错觉：似乎这些结论只属于线性代数世界。本节的作用正相反。通过回链定义 8.2.1、定理 8.4.1 与推论 8.4.1，我们看到矩阵公式只是抽象 KKT 在 $\mathbb{R}^n$ 中的坐标表示。

习题（待补）

 **练习 9.3LP 对偶占位** 补一题：从定义 9.2.1 出发，直接计算线性规划的对偶函数并推出命题 9.2.1。

 **练习 9.4QP KKT 桥接题占位** 补一题：对一个带不等式约束的凸二次规划写出命题 9.2.2 的全部条件，并说明哪些部分来自第 8.4 节的抽象 KKT 系统。

9.3 SOCP 与 SDP

如果说上一节把一般锥规划退回到了 LP/QP，那么本节要展示的则是最具代表性的两个有限维锥：二阶锥和半正定锥。它们的重要性不只在应用面广，更在于它们恰好把第 8.1 节的广义不等式语言和第 4.4 节的谱论语言接到了一起。SOCP 强调“锥”的几何自对偶性，SDP 则强调“正性”与“谱分解”的矩阵化。

9.3.1 二阶锥与半正定锥

定义 9.3.1 (二阶锥)

在 $\mathbb{R} \times \mathbb{R}^{m-1}$ 中，定义

$$Q_m := \{(t, z) : t \geq \|z\|_2\}.$$

该集合称为 m 维二阶锥，也称 Lorentz 锥。

定义 9.3.2 (半正定锥)

记 $\mathbb{S}^n$ 为 $n \times n$ 实对称矩阵空间。定义

$$\mathbb{S}_+^n := \{X \in \mathbb{S}^n : x^\top X x \geq 0, \forall x \in \mathbb{R}^n\}.$$

称其为半正定锥。

命题 9.3.1 (二阶锥的自对偶性)

在标准 Euclidean 内积下, 二阶锥满足

$$Q_m^* = Q_m.$$

证明 设 $(s, y) \in Q_m$ 。对任意 $(t, z) \in Q_m$, 由 Cauchy-Schwarz 不等式,

$$st + y^\top z \geq st - \|y\|_2 \|z\|_2 \geq st - \|y\|_2 t = t(s - \|y\|_2) \geq 0,$$

故 $Q_m \subset Q_m^*$ 。

反之, 若 $(s, y) \in Q_m^*$, 则对所有 $(t, z) \in Q_m$ 有

$$st + y^\top z \geq 0.$$

特别取 $t = \|z\|_2$ 且令 $z = -\|z\|_2 y / \|y\|_2$ (当 $y \neq 0$ 时), 便得

$$\|z\|_2(s - \|y\|_2) \geq 0.$$

由 $\|z\|_2 > 0$ 任意, 可知 $s \geq \|y\|_2$, 故 $(s, y) \in Q_m$ 。于是 $Q_m^* = Q_m$ 。

命题 9.3.2 (迹内积与半正定锥的对偶配对)

在 $\mathbb{S}^n$ 上定义迹内积

$$\langle X, Y \rangle := \text{tr}(XY).$$

则对任意 $X, Y \in \mathbb{S}_+^n$,

$$\langle X, Y \rangle \geq 0,$$

并且

$$(\mathbb{S}_+^n)^* = \mathbb{S}_+^n$$

其中对偶是相对于迹内积而言。

证明 若 $X, Y \succeq 0$, 则存在对称平方根 $Y^{1/2}$, 从而

$$\text{tr}(XY) = \text{tr}(Y^{1/2}XY^{1/2}) \geq 0$$

因为矩阵 $Y^{1/2}XY^{1/2}$ 仍半正定, 其特征值非负, 迹自然非负。

反之, 若某个对称矩阵 Z 满足

$$\text{tr}(ZY) \geq 0, \quad \forall Y \succeq 0,$$

则特别对秩一矩阵 $Y = uu^\top \succeq 0$ 有

$$u^\top Zu = \text{tr}(Zuu^\top) \geq 0, \quad \forall u \in \mathbb{R}^n.$$

故 $Z \succeq 0$ 。这就证明了半正定锥对迹内积是自对偶的, 而迹内积正是第 8.1 节定义 8.1.2 在矩阵空间中的具体写法。

9.3.2 谱语言在矩阵上的坍塌**定理 9.3.1 (对称矩阵的谱分解坍塌)**

设 $X \in \mathbb{S}^n$ 。则存在正交矩阵 Q 与实对角矩阵

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$$

使

$$X = Q\Lambda Q^\top.$$

特别地,

$$X \succeq 0 \iff \lambda_i \geq 0, i = 1, \dots, n.$$



证明 这正是第 4.4 节定理 4.4.1 在有限维 Hilbert 空间 $\mathbb{R}^n$ 上的坍塌。有限维下所有线性算子都是紧算子，因此任意自伴算子都可正交对角化。对 $X \in \mathbb{S}^n$ 应用该谱定理，即得

$$X = Q\Lambda Q^\top.$$

再注意到对任意 $u \in \mathbb{R}^n$ ，令 $v = Q^\top u$ ，则

$$u^\top Xu = v^\top \Lambda v = \sum_{i=1}^n \lambda_i v_i^2.$$

因此 $u^\top Xu \geq 0$ 对所有 u 成立，当且仅当每个 $\lambda_i \geq 0$ 。

注 定理 9.3.1 解释了 SDP 为什么同时属于锥优化和谱论两条主线：矩阵正性既可以理解为“落在半正定锥中”，也可以理解为“所有特征值非负”。这两种说法在有限维中完全等价，而在无穷维里则必须借助第 4.4 节的紧自伴谱定理才能恢复。

9.3.3 典型例子

例题 9.7 二阶锥几何 二阶锥约束

$$\|Fx + g\|_2 \leq a^\top x + b$$

可直接写成

$$(a^\top x + b, Fx + g) \in \mathcal{Q}_m.$$

把这个例子放在这里，是为了说明 SOCP 并不是“带范数的不等式技巧”，而是第 8.1 节广义不等式语言在一个自对偶锥上的直接落地。

例题 9.8 对称矩阵特征值分解 对任意 $X \in \mathbb{S}^n$ ，定理 9.3.1 给出的

$$X = Q\Lambda Q^\top$$

就是有限维最熟悉的特征值分解。把这个例子放在这里，是为了把 Boyd 关于 SDP 的几何图像、矩阵迹内积和半正定约束统一到一个谱分解视角中。

例题 9.9 LMI 与协方差估计 鲁棒控制和协方差估计中常见约束是

$$A_0 + \sum_{i=1}^n x_i A_i \succeq 0,$$

这是一类线性矩阵不等式。把这个例子放在这里，是为了给工程读者一个直接触点：LMI 只是半正定锥约束的 affine 切片，因此它们天然属于第 8.1 节的锥规划框架。

有限维对照

Boyd 书中 SOCP 和 SDP 往往被当成“高级有限维模型”单独介绍，但从本书视角看，它们不过是两件事情的交叉：第 8.1 节的锥语言，以及第 4.4 节的谱论语言。有限维之所以让这些模型显得特别整洁，是因为对偶锥、自伴正性和特征值分解都能同时写成矩阵公式。

习题（待补）

- 🔴 **练习 9.5 SOCP 自对偶占位** 补一题：直接验证命题 9.3.1，并把二阶锥约束改写为一个广义不等式。
- 🔴 **练习 9.6 SDP 谱分解桥接题占位** 补一题：利用定理 9.3.1 证明矩阵半正定等价于所有特征值非负，并说明这与命题 9.3.2 的关系。

9.4 几何规划的对偶透视

几何规划表面上似乎离前几章很远，因为它天然带有乘法结构、幂函数和 **posynomial** 目标，而不是线性算子与加法对偶。但这正是它适合放在本章末尾的原因：**GP** 是一个最典型的“特例坍塌”。一旦做对数变换，乘法会变成加法，**monomial** 会变成仿射函数，**posynomial** 会变成 **log-sum-exp**，从而整个问题重新回到凸分析和 Fenchel–Rockafellar 对偶的轨道上。

9.4.1 几何规划的基本形式

定义 9.4.1 (几何规划)

一个标准几何规划通常写成

$$\min_{x \in \mathbb{R}_{++}^n} f_0(x)$$

subject to

$$f_i(x) \leq 1, \quad i = 1, \dots, m,$$

$$g_j(x) = 1, \quad j = 1, \dots, p,$$

其中每个 f_i 是 **posynomial**，每个 g_j 是 **monomial**。这里

$$g(x) = cx_1^{a_1} \cdots x_n^{a_n}, \quad c > 0,$$

称为 **monomial**；若

$$f(x) = \sum_{k=1}^N c_k x_1^{a_{1k}} \cdots x_n^{a_{nk}}, \quad c_k > 0,$$

则称为 **posynomial**。

命题 9.4.1 (对数变换后的凸性)

令

$$y_i = \log x_i, \quad x_i = e^{y_i}.$$

则 **monomial** 的对数变成仿射函数，**posynomial** 的对数变成 **convex** 的 **log-sum-exp** 形式。特别地，几何规划在对数坐标下可转化为凸优化问题。

证明 对 **monomial**,

$$\log g(e^y) = \log c + \sum_{i=1}^n a_i y_i,$$

这是仿射函数。

对 **posynomial**,

$$f(e^y) = \sum_{k=1}^N c_k \exp(a_k^\top y),$$

故

$$\log f(e^y) = \log \left(\sum_{k=1}^N \exp(a_k^\top y + \log c_k) \right).$$

右端正是经典的 **log-sum-exp** 形式。由于指数函数凸且求和保持凸性，而对数作用在正和式上得到的 **log-sum-exp** 仍是凸函数，因此在变量 y 上得到的是凸约束与凸目标。

定义 9.4.2 (GP 中的 log-sum-exp 目标)

若 f 是 posynomial, 则在对数坐标 $y = \log x$ 下定义

$$F(y) := \log f(e^y) = \log \left(\sum_{k=1}^N \exp(a_k^\top y + \beta_k) \right), \quad \beta_k := \log c_k.$$

函数 F 称为 GP 变换后的 *log-sum-exp* 目标或约束函数。

**9.4.2 GP 的对偶透视****定理 9.4.1 (GP 的 Fenchel 对偶表示)**

在对数变量 y 下, 几何规划可写成一个由仿射项与 log-sum-exp 项组成的有限维凸优化问题。因而在满足有限维资格条件时, 其对偶问题可由第 7.4 节定理 7.4.1 给出; 换言之, GP 的经典对偶本质上是 log-sum-exp 共轭与仿射约束共同作用的 Fenchel 对偶。



证明 由命题 9.4.1, 原 GP 在对数变量下化为

$$\min_y F_0(y)$$

subject to

$$F_i(y) \leq 0, \quad i = 1, \dots, m,$$

$$\alpha_j^\top y + \gamma_j = 0, \quad j = 1, \dots, p,$$

其中每个 F_i 都是定义 9.4.2 给出的 log-sum-exp 函数。于是这已经是一个标准有限维凸优化问题。

再把不等式约束写成指示函数, 把等式约束写成仿射子空间的指示函数, 便可将整个问题整理为

$$\inf_y \{ \Phi(y) + \Psi(By) \},$$

其中 Φ 由 log-sum-exp 项组成, Ψ 由约束指示函数组成。此时第 7.1 节定义 7.1.1 的 Fenchel 共轭和第 7.4 节定理 7.4.1 直接适用, 于是得到 GP 的对偶表示。也就是说, GP 并不是对偶理论之外的特例, 而是对数坐标下的有限维对偶坍缩。

注 从本书视角看, GP 最值得强调的不是“它可以变凸”这一口号, 而是“它变凸之后, 所依赖的仍然是同一套共轭与对偶框架”。这就是为什么本节要显式回链第 7.4 节, 而不是把 GP 当作一组孤立技巧。

9.4.3 典型例子

例题 9.10 功率控制的几何规划 无线功率控制中的信噪比约束常可整理为

$$\frac{\sigma_i + \sum_{j \neq i} a_{ij} p_j}{p_i} \leq \frac{1}{\gamma_i}, \quad p_i > 0.$$

在正变量 p_i 上这看起来是分式与乘法混合结构; 经对数变换后, 它会变成 log-sum-exp 约束。把这个例子放在这里, 是为了回收 Boyd 中最经典的 GP 工程模型, 并说明它本质上属于有限维对偶坍缩。

例题 9.11 电路与面积功率折中 集成电路设计里经常出现 monomial 与 posynomial 形式的面积、延迟和功耗模型。把这个例子放在这里, 是为了说明 GP 不是数学上的边角料, 而是对数凸建模在工程中的代表性落点。

例题 9.12 乘法效用资源分配 若效用函数带有乘法结构, 如

$$\prod_{i=1}^n x_i^{\alpha_i},$$

则取对数后会转化为加法目标

$$\sum_{i=1}^n \alpha_i \log x_i.$$

把这个例子放在这里，是为了给管理科学读者一个直观触点：乘法效用模型之所以适合凸优化，不是因为乘法本身“神奇”，而是因为对数坐标把它送回了加法与对偶的世界。

有限维对照

Boyd 书中几何规划往往以对数变换和工程例子同时出现，因此读者容易把它记成一套技巧性很强的特例。本节强调的恰恰是相反的事实：GP 在有限维里之所以漂亮，是因为 $\log$ -sum-exp、Fenchel 共轭和 Fenchel–Rockafellar 对偶都能被完整显式写出。也就是说，GP 不是对凸对偶的例外，而是它最精致的坍塌之一。

习题（待补）

-  **练习 9.7GP 对数变换占位** 补一题：把一个具体的 posynomial 目标和约束问题改写为对数变量下，并验证 $\log$ -sum-exp 函数的出现。
-  **练习 9.8GP 对偶桥接题占位** 补一题：对一个简单的几何规划写出其对数凸化问题，并说明第 7.4 节 Fenchel–Rockafellar 对偶如何给出对应对偶表达。

第五部分

算法

第 10 章 单调算子与预解式

第 6 章把凸泛函的局部最优性写成了次微分条件，第 7 章说明共轭与下确界卷积怎样把这些局部信息重新组织成对偶与平滑，第 8 章则把原-对偶系统放进锥约束与 KKT 语言中统一处理。到这一章，问题已经不再是“如何写出最优性条件”，而是“如何把最优性条件改写成可迭代求解的对象”。单调算子理论正是完成这一步的标准接口。

本章沿四条线索推进。第 10.1 节先在 Banach/Hilbert 的双层背景下定义单调与极大单调，并把次微分、法锥这些熟悉对象提升为极大单调算子的原型。第 10.2 节随后把视角收束到 Hilbert 空间：在这里，借助第 4.1 节定理 4.1.2 的向量化识别，resolvent 可以被具体写成邻近算子，投影、软阈值和 Moreau 分解也都获得清晰的几何意义。第 10.3 节继续讨论 Moreau-Yosida 正则化，说明第 7.3 节中的 Moreau 包络如何从对偶代数对象变成算法中的平滑代理。最后第 10.4 节把最优化、变分不等式和可行性问题统一改写为单调包含

$$0 \in Au,$$

从而把第 11 章的分裂算法全部放到同一个零点框架下。

阅读本章时，最需要记住的是环境分层。对一般 Banach 空间而言，单调算子的自然值域是对偶空间 X^* ；因此“单调”这一概念本身并不依赖 Hilbert 结构。真正把 resolvent、prox、firm nonexpansive 和 Moreau 分解写成最简洁形式的，是 Hilbert 几何。也正因为如此，本章采用双层叙述：第 10.1 节保留 Banach/Hilbert 共通的极大单调主线，第 10.2 节以后则明确回到 Hilbert 主舞台，不把更一般 Banach 版的近端理论塞进正文中心。

如果把第 9 章看成“抽象理论向 Boyd 母语的有限维坍塌”，那么本章恰好走的是相反方向：Boyd 中的 prox、投影、平滑和固定点，在这里被重新解释为极大单调、resolvent、Yosida 正则化和单调包含。这样做的目的不是增加抽象术语，而是为了让第 11 章之后的算法不再停留于经验公式，而能被理解为对统一解析结构的计算实现。

10.1 极大单调算子

第 6.3 节已经告诉我们，不可微凸泛函的局部信息可以写成次微分；第 8.4 节则说明，许多最优性系统最终都能写成某种驻点与互补关系。本节要做的，是把这些静态条件提升为动态对象。所谓“动态”，并不是引入时间，而是把“解满足某个不等式”改写成“某个算子取零点”。一旦这一步完成，后面的 resolvent、prox 与分裂算法就都有了统一母体。

10.1.1 Banach 空间中的单调与极大单调

定义 10.1.1 (单调算子)

设 X 为实 Banach 空间， $A: X \rightrightarrows X^*$ 为一个多值算子，其图像记为

$$\text{gra } A := \{(x, x^*) \in X \times X^* : x^* \in Ax\}.$$

若对任意 $(x, x^*), (y, y^*) \in \text{gra } A$ 都有

$$\langle x^* - y^*, x - y \rangle \geq 0,$$

则称 A 为单调算子。

定义 10.1.2 (极大单调算子)

在定义 10.1.1 的条件下，若 A 的图像在集合包含意义下不能被任何更大的单调图像真扩张，即只要某个单调算子 B 满足

$$\text{gra } A \subset \text{gra } B,$$

就必有 $\text{gra } A = \text{gra } B$, 则称 A 为极大单调算子。

注 单调算子最自然的定义舞台是 $X \times X^*$, 因此它并不需要 Hilbert 结构。真正需要 Hilbert 几何的是 resolvent、邻近算子和 Moreau 分解, 因为这些对象要把“对偶元素”重新识别成“向量”。本章正是按这个分工推进: 定义 10.1.1 与定义 10.1.2 保持 Banach 级别的一般性, 而第 10.2 节以后则显式回到 Hilbert 空间。

命题 10.1.1 (单调图像的基本结构)

设 $A: X \rightrightarrows X^*$ 为单调算子, 则对每个 $x \in X$, 集合 Ax 是凸集。若 A 还是极大单调的, 则其图像在积拓扑下闭。

证明 先证凸值性。若 $x_1^*, x_2^* \in Ax$, 取任意 $\theta \in [0, 1]$ 并令

$$x_\theta^* := \theta x_1^* + (1 - \theta)x_2^*.$$

对任意 $(y, y^*) \in \text{gra } A$, 由单调性分别有

$$\langle x_i^* - y^*, x - y \rangle \geq 0, \quad i = 1, 2.$$

将两式作凸组合即得

$$\langle x_\theta^* - y^*, x - y \rangle \geq 0.$$

若 A 极大单调, 则点 (x, x_θ^*) 与整张图像仍保持单调关系。由极大性, 必有 $(x, x_\theta^*) \in \text{gra } A$, 故 Ax 为凸集。

再证图像闭性。设 $(x_n, x_n^*) \in \text{gra } A$ 且 $(x_n, x_n^*) \rightarrow (x, x^*)$ 。对任意 $(y, y^*) \in \text{gra } A$, 单调性给出

$$\langle x_n^* - y^*, x_n - y \rangle \geq 0.$$

令 $n \rightarrow \infty$ 得

$$\langle x^* - y^*, x - y \rangle \geq 0.$$

于是 (x, x^*) 与图像中的每个点都保持单调关系。由定义 10.1.2 的极大性, $(x, x^*) \in \text{gra } A$ 。

10.1.2 Hilbert 识别与 resolvent

定义 10.1.3 (单调算子的 resolvent)

设 H 为实 Hilbert 空间, $A: H \rightrightarrows H$ 为单调算子, $\lambda > 0$ 。称多值映射

$$J_{\lambda A} := (I + \lambda A)^{-1}$$

为 A 的 resolvent。也就是说,

$$u = J_{\lambda A}(x) \iff x - u \in \lambda Au.$$

定理 10.1.1 (Minty 满射定理)

设 H 为 Hilbert 空间, $A: H \rightrightarrows H$ 为单调算子, $\lambda > 0$ 。则在 $\text{ran}(I + \lambda A)$ 上, resolvent $J_{\lambda A}$ 是单值的, 并满足参数化公式

$$\text{gra } A = \left\{ \left(J_{\lambda A}(x), \frac{x - J_{\lambda A}(x)}{\lambda} \right) : x \in \text{ran}(I + \lambda A) \right\}.$$

进一步, A 为极大单调算子, 当且仅当

$$\text{ran}(I + \lambda A) = H.$$

证明 先证单值性。若 $u_1, u_2 \in J_{\lambda A}(x)$, 则存在 $a_i \in Au_i$ 使

$$x = u_i + \lambda a_i, \quad i = 1, 2.$$

两式相减得

$$u_1 - u_2 = -\lambda(a_1 - a_2).$$

再与 $a_1 - a_2$ 作内积并用单调性,

$$\|u_1 - u_2\|^2 = -\lambda \langle a_1 - a_2, u_1 - u_2 \rangle \leq 0.$$

故 $u_1 = u_2$, 于是 $J_{\lambda A}$ 在其定义域上单值。

参数化公式只是定义 10.1.3 的改写。若 $(u, a) \in \text{gra } A$, 取

$$x := u + \lambda a,$$

则 $u = J_{\lambda A}(x)$ 且 $a = (x - u)/\lambda$ 。反过来, 若 $x \in \text{ran}(I + \lambda A)$, 令 $u = J_{\lambda A}(x)$, 则由 resolvent 的定义,

$$\frac{x - u}{\lambda} \in Au,$$

故参数化成立。

最后说明极大性与满射性的关系。若 $\text{ran}(I + \lambda A) = H$, 则对每个 $x \in H$, 存在唯一 $u = J_{\lambda A}(x)$ 。若某个点 (z, w) 与 $\text{gra } A$ 的每个点都保持单调关系, 即

$$\langle w - a, z - u \rangle \geq 0, \quad \forall (u, a) \in \text{gra } A,$$

取 $x := z + \lambda w$ 。由满射性可取 $u = J_{\lambda A}(x)$, 并令 $a = (x - u)/\lambda \in Au$ 。于是

$$z - u = x - \lambda w - u = \lambda(a - w).$$

代回单调关系得

$$0 \leq \langle w - a, z - u \rangle = -\lambda \|w - a\|^2,$$

故 $w = a$, 继而 $z = u$, 从而 $(z, w) \in \text{gra } A$, 即 A 极大。

反之, 若 A 极大单调, 则可对图像施加标准的 Minty 变换

$$(u, a) \mapsto (u + \lambda a, u - \lambda a).$$

单调性恰好保证该变换后的第一坐标决定第二坐标, 而极大性保证其第一坐标像不能遗漏任何点, 否则可用 Hahn-Banach 分离构造出对图像的真单调扩张, 违背定义 10.1.2。因此

$$\text{ran}(I + \lambda A) = H.$$

这就是 Minty 满射定理。

10.1.3 次微分作为极大单调算子的原型

定理 10.1.2 (次微分的极大单调性)

设 H 为 Hilbert 空间, $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。则其次微分算子

$$\partial f: H \rightrightarrows H$$

是极大单调算子。

证明 由定义 6.3.1, 若 $u^* \in \partial f(u)$, $v^* \in \partial f(v)$, 则

$$f(v) \geq f(u) + \langle u^*, v - u \rangle,$$

$$f(u) \geq f(v) + \langle v^*, u - v \rangle.$$

两式相加即得

$$\langle u^* - v^*, u - v \rangle \geq 0,$$

故 ∂f 单调。

为证极大性，由定理 10.1.1 只需证明

$$\text{ran}(I + \partial f) = H.$$

任取 $y \in H$ ，考虑泛函

$$\Phi_y(x) := f(x) + \frac{1}{2}\|x - y\|^2.$$

由第 6.1 节定义 6.1.2， Φ_y 仍下半连续；二次项提供强制性，因此第 6.1 节定理 6.1.1 保证 Φ_y 有极小点 $\bar{x}$ 。对该极小点，命题 6.3.1 给出

$$0 \in \partial \Phi_y(\bar{x}).$$

再由第 6.4 节定理 6.4.1，

$$\partial \Phi_y(\bar{x}) = \partial f(\bar{x}) + \bar{x} - y.$$

于是

$$y - \bar{x} \in \partial f(\bar{x}),$$

等价于

$$y \in \bar{x} + \partial f(\bar{x}).$$

这说明每个 $y \in H$ 都属于 $\text{ran}(I + \partial f)$ ，故由定理 10.1.1， ∂f 极大单调。

注 定理 10.1.2 是本章与前几章的真正汇合点。第 6.3 节的次微分把不可微凸分析写成局部支撑超平面语言，第 5.3 节定理 5.3.2 解释了这些支撑超平面的来源，而第 7.4 节定理 7.4.1 又告诉我们它们怎样进入原-对偶系统。到了这里，同一个对象被重新理解为极大单调算子，从而获得了迭代求解的接口。

10.1.4 典型例子

例题 10.1 闭真凸下半连续泛函的次微分 定理 10.1.2 表明，对任何 proper、凸且下半连续的泛函 f ，算子 ∂f 都是极大单调的。把这个例子放在这里，是为了让读者看到：本章并不是另起炉灶，而是在第 6.3 节对象上增加了“可做 resolvent 和求零点”的新结构。

例题 10.2 闭凸集的法锥 若 $C \subset H$ 为非空闭凸集，则第 6.4 节推论 6.4.1 说明

$$N_C(x) = \partial \iota_C(x).$$

因此法锥也是极大单调算子。把这个例子放在这里，是为了说明约束集并不只贡献可行域，它们还会在后文分裂算法中以算子形式重新出现。

例题 10.3 正半定矩阵诱导的线性单调算子 在 $\mathbb{R}^n$ 中，设 $Q \succeq 0$ 为对称正半定矩阵，并定义 $Ax := Qx$ 。则

$$\langle Qx - Qy, x - y \rangle = (x - y)^\top Q(x - y) \geq 0,$$

所以 A 单调。把这个例子放在这里，是为了给 Boyd 读者一个最直接的有限维坍缩对象：矩阵正半定性在本章恰好对应线性算子的单调性。

有限维对照

Boyd 书里常把一阶最优性条件、投影和 prox 更新直接写成 Euclidean 公式；从本节角度看，这些对象其实都源于极大单调算子。有限维里，由于 $\mathbb{R}^n$ 与其对偶空间天然等同，且矩阵正半定性可直接检查，单调结构会被压缩成非常熟悉的线性代数语句。无穷维里则必须先经过定义 10.1.1、定义 10.1.2 与定理 10.1.1 的整理，后面的 resolvent 和 prox 才有稳定落脚点。

习题 (待补)

- 练习 10.1Minty 参数化占位 补一题：从定义 10.1.3 出发，证明单调算子的 resolvent 在其定义域上单值，并写出定理 10.1.1 中的图像参数化公式。
- 练习 10.2 法锥与极大单调桥接题占位 补一题：取一个非空闭凸集 C ，证明 $N_C = \partial \iota_C$ ，并据此解释为什么约束集合也能被视作极大单调算子的来源。

10.2 邻近算子

上一节已经把极大单调算子确立为统一母语；本节要做的，是把这门语言翻译成 Hilbert 几何。翻译的关键是：在 Hilbert 空间里，resolvent 不只是一个抽象逆映射，它还等价于“在原目标上加一个二次正则项后求极小值”的操作。邻近算子因此既是解析对象，也是算法模块。第 11 章的几乎所有分裂算法，都可以看成在不同位置调用本节定义的 prox。

10.2.1 prox 的定义与 resolvent 解释

定义 10.2.1 (邻近算子)

设 H 为 Hilbert 空间， $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函， $\lambda > 0$ 。定义

$$\text{prox}_{\lambda f}(x) := \arg \min_{u \in H} \left\{ f(u) + \frac{1}{2\lambda} \|u - x\|^2 \right\}, \quad x \in H.$$

该映射称为 f 的邻近算子。

命题 10.2.1 (prox 是次微分 resolvent)

在定义 10.2.1 的条件下，

$$\text{prox}_{\lambda f} = (I + \lambda \partial f)^{-1} = J_{\lambda \partial f}.$$

特别地，邻近算子是第 10.1 节定义 10.1.3 的 resolvent 在次微分算子上的具体化。

证明 固定 $x \in H$ ，考虑泛函

$$\Phi_x(u) := f(u) + \frac{1}{2\lambda} \|u - x\|^2.$$

二次项连续且严格凸，故由定义 10.2.1 可知 Φ_x 的极小点唯一。设其为 u 。由命题 6.3.1，

$$0 \in \partial \Phi_x(u).$$

再由第 6.4 节定理 6.4.1，

$$\partial \Phi_x(u) = \partial f(u) + \frac{1}{\lambda}(u - x).$$

因此

$$0 \in \partial f(u) + \frac{1}{\lambda}(u - x) \iff x - u \in \lambda \partial f(u).$$

这正等价于

$$u \in (I + \lambda \partial f)^{-1}(x).$$

由唯一性， $u = \text{prox}_{\lambda f}(x)$ ，故结论成立。

命题 10.2.2 (prox 的最优性条件)

设 $u = \text{prox}_{\lambda f}(x)$ 。则下列两条等价：

$$u = \text{prox}_{\lambda f}(x);$$

$$0 \in \partial f(u) + \frac{1}{\lambda}(u - x).$$

等价地,

$$\frac{x - u}{\lambda} \in \partial f(u).$$

▲

证明 这只是命题 10.2.1 证明中的最优性条件重写。由于

$$u = \text{prox}_{\lambda f}(x) \iff x - u \in \lambda \partial f(u),$$

将后式两边同时除以 λ 即得所述等价关系。

10.2.2 非扩张性与 Moreau 分解

命题 10.2.3 (prox 的 firm nonexpansive 性)

设 $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函, $\lambda > 0$ 。则对任意 $x, y \in H$,

$$\|\text{prox}_{\lambda f}(x) - \text{prox}_{\lambda f}(y)\|^2 \leq \langle \text{prox}_{\lambda f}(x) - \text{prox}_{\lambda f}(y), x - y \rangle.$$

因此 $\text{prox}_{\lambda f}$ 尤其是 1-Lipschitz 的。

▲

证明 记

$$u = \text{prox}_{\lambda f}(x), \quad v = \text{prox}_{\lambda f}(y).$$

由命题 10.2.2,

$$\frac{x - u}{\lambda} \in \partial f(u), \quad \frac{y - v}{\lambda} \in \partial f(v).$$

再由第 10.1 节定理 10.1.2 所给出的单调性,

$$\left\langle \frac{x - u}{\lambda} - \frac{y - v}{\lambda}, u - v \right\rangle \geq 0.$$

乘以 λ 得

$$\langle x - y, u - v \rangle - \|u - v\|^2 \geq 0,$$

即

$$\|u - v\|^2 \leq \langle u - v, x - y \rangle.$$

再由 Cauchy-Schwarz 不等式,

$$\|u - v\|^2 \leq \|u - v\| \|x - y\|,$$

从而 $\|u - v\| \leq \|x - y\|$ 。

命题 10.2.4 (Moreau 分解)

设 $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函, $\lambda > 0$ 。则对任意 $x \in H$,

$$x = \text{prox}_{\lambda f}(x) + \lambda \text{prox}_{\lambda^{-1} f^*}(x/\lambda).$$

▲

证明 记

$$u := \text{prox}_{\lambda f}(x).$$

由命题 10.2.2,

$$\frac{x - u}{\lambda} \in \partial f(u).$$

由第 7.1 节命题 7.1.2, 这等价于

$$u \in \partial f^*\left(\frac{x-u}{\lambda}\right).$$

将其改写为

$$0 \in \partial f^*\left(\frac{x-u}{\lambda}\right) + \lambda \left(\frac{x-u}{\lambda} - \frac{x}{\lambda}\right).$$

这正是命题 10.2.2 对泛函 $\lambda^{-1}f^*$ 和点 x/λ 的应用, 因此

$$\frac{x-u}{\lambda} = \text{prox}_{\lambda^{-1}f^*}(x/\lambda).$$

整理即可得到 Moreau 分解。

注 命题 10.2.4 是第 7.1 节 Fenchel 共轭与第 10.1 节 resolvent 语言在 Hilbert 空间中的一次精确握手。它说明 prox 从来不只是“解一个带二次项的小问题”, 而是原空间与对偶空间之间的一种显式分解。

10.2.3 典型例子

例题 10.4 闭凸集投影 取 $f = \iota_C$, 其中 $C \subset H$ 为非空闭凸集。则

$$\text{prox}_{\iota_C}(x) = \arg \min_{u \in C} \frac{1}{2\lambda} \|u - x\|^2 = P_C x.$$

把这个例子放在这里, 是为了直接把第 4.1 节定理 4.1.1 回收到算法主线: 投影就是最基本的 prox 。

例题 10.5 ℓ^1 软阈值 在 $\mathbb{R}^n$ 上取

$$f(x) = \|x\|_1.$$

则 $\text{prox}_{\lambda f}$ 逐坐标写成软阈值

$$(\text{prox}_{\lambda \|\cdot\|_1}(x))_i = \text{sign}(x_i) \max\{|x_i| - \lambda, 0\}.$$

把这个例子放在这里, 是为了把 Boyd 书中最熟悉的非光滑更新直接识别为 resolvent 的 Euclidean 坍塌。

例题 10.6 核范数与奇异值阈值 在矩阵空间上取

$$f(X) = \|X\|_*.$$

则 $\text{prox}_{\lambda f}$ 对应于对奇异值做软阈值。把这个例子放在这里, 是为了说明 prox 并不只适用于向量稀疏化; 在矩阵补全、低秩恢复和 TV 型模型中, 它同样是核心更新模块。

有限维对照

Boyd 常把 prox 解释成“加一个二次项后求极小值”, 并配以投影和软阈值图形。本节说明, 这种解释完全正确, 但它在有限维里之所以显得自然, 是因为第 4.1 节定理 4.1.2 允许我们把对偶元素直接看成向量, 于是第 10.1 节的 resolvent 便被压缩成一个 Euclidean 映射。真正的结构核心不是坐标公式, 而是命题 10.2.1、命题 10.2.3 与命题 10.2.4。

习题 (待补)

- 🔴 **练习 10.3 投影即 prox 占位** 补一题: 对非空闭凸集 C , 证明 $\text{prox}_{\iota_C} = P_C$, 并说明命题 10.2.3 如何退化为投影的非扩张性。
- 🔴 **练习 10.4 软阈值桥接题占位** 补一题: 直接计算 $\text{prox}_{\lambda \|\cdot\|_1}$, 并利用命题 10.2.4 写出相应的对偶分解。

10.3 Moreau 包络

第 7.3 节已经从共轭与下确界卷积的角度引入了 Moreau 包络, 但在那里, 重点还是代数结构和对偶交换。本节要把同一个对象重新放回算法语境: 一方面, Moreau-Yosida 正则化提供了“把不可微目标平滑化而不改写极

小值集合”的手段；另一方面，它又通过 Yosida 近似把极大单调算子变成单值 Lipschitz 映射，为第 11 章的连续和离散迭代提供统一接口。

10.3.1 Yosida 近似

定义 10.3.1 (Yosida 近似)

设 H 为 Hilbert 空间, $A: H \rightrightarrows H$ 为极大单调算子, $\lambda > 0$. 定义

$$A_\lambda := \frac{1}{\lambda}(I - J_{\lambda A}),$$

称其为 A 的 Yosida 近似. 当 $A = \partial f$ 时, A_λ 也称为 f 的 Moreau–Yosida 正则化梯度.

命题 10.3.1 (Moreau 包络的梯度公式)

设 $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函, $\lambda > 0$. 则第 7.3 节定义 7.3.2 中的 Moreau 包络

$$e_\lambda f(x) = \inf_{u \in H} \left\{ f(u) + \frac{1}{2\lambda} \|u - x\|^2 \right\}$$

在 H 上 Fréchet 可微, 且

$$\nabla e_\lambda f(x) = \frac{1}{\lambda}(x - \text{prox}_{\lambda f}(x)) = (\partial f)_\lambda(x).$$

证明 设

$$p(x) := \text{prox}_{\lambda f}(x).$$

由命题 10.2.2,

$$\frac{x - p(x)}{\lambda} \in \partial f(p(x)).$$

因此, 依据第 7.1 节 Fenchel–Young 取等条件,

$$f(p(x)) + f^*\left(\frac{x - p(x)}{\lambda}\right) = \left\langle \frac{x - p(x)}{\lambda}, p(x) \right\rangle.$$

另一方面, 对任意 $h \in H$, 由 $p(x)$ 对 $e_\lambda f(x)$ 的最优性,

$$e_\lambda f(x + h) \leq f(p(x)) + \frac{1}{2\lambda} \|p(x) - x - h\|^2.$$

减去

$$e_\lambda f(x) = f(p(x)) + \frac{1}{2\lambda} \|p(x) - x\|^2$$

得

$$e_\lambda f(x + h) - e_\lambda f(x) \leq \left\langle \frac{x - p(x)}{\lambda}, h \right\rangle + \frac{1}{2\lambda} \|h\|^2.$$

同理, 以 $p(x + h)$ 作为 $e_\lambda f(x)$ 的竞争点, 可得反向估计

$$e_\lambda f(x + h) - e_\lambda f(x) \geq \left\langle \frac{x - p(x + h)}{\lambda}, h \right\rangle - \frac{1}{2\lambda} \|h\|^2.$$

由命题 10.2.3, p 连续, 从而

$$\frac{x - p(x + h)}{\lambda} \rightarrow \frac{x - p(x)}{\lambda} \quad (h \rightarrow 0).$$

夹逼后得到

$$e_\lambda f(x + h) - e_\lambda f(x) - \left\langle \frac{x - p(x)}{\lambda}, h \right\rangle = o(\|h\|),$$

故 $e_\lambda f$ Fréchet 可微, 且梯度正是所述表达式. 根据定义 10.3.1, 该梯度也就是 $(\partial f)_\lambda$.

命题 10.3.2 (Yosida 近似的 Lipschitz 性)

设 $A: H \rightrightarrows H$ 为极大单调算子, $\lambda > 0$ 。则 A_λ 是单值映射, 并满足

$$\|A_\lambda x - A_\lambda y\| \leq \frac{1}{\lambda} \|x - y\|, \quad \forall x, y \in H.$$

证明 由定理 10.1.1, $J_{\lambda A}$ 在整个 H 上单值, 因此定义 10.3.1 立即说明 A_λ 单值。再由定义,

$$A_\lambda x - A_\lambda y = \frac{1}{\lambda} ((x - y) - (J_{\lambda A} x - J_{\lambda A} y)).$$

对极大单调算子, 其 resolvent 是 firm nonexpansive; 这可由定理 10.1.1 与命题 10.2.3 在一般 A 上的同样证明得到。于是

$$\|J_{\lambda A} x - J_{\lambda A} y\|^2 \leq \langle J_{\lambda A} x - J_{\lambda A} y, x - y \rangle.$$

因此

$$\begin{aligned} \|A_\lambda x - A_\lambda y\|^2 &= \frac{1}{\lambda^2} \|(x - y) - (J_{\lambda A} x - J_{\lambda A} y)\|^2 \\ &= \frac{1}{\lambda^2} (\|x - y\|^2 + \|J_{\lambda A} x - J_{\lambda A} y\|^2 - 2\langle x - y, J_{\lambda A} x - J_{\lambda A} y \rangle) \\ &\leq \frac{1}{\lambda^2} (\|x - y\|^2 - \|J_{\lambda A} x - J_{\lambda A} y\|^2) \leq \frac{1}{\lambda^2} \|x - y\|^2. \end{aligned}$$

取平方根即得结论。

10.3.2 Moreau–Yosida 正则化**定理 10.3.1 (Moreau–Yosida 正则化)**

设 $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函, $\lambda > 0$ 。则 $e_\lambda f$ 具有以下性质:

1. $e_\lambda f$ 为凸且处处有限的连续函数;
2. $e_\lambda f$ Fréchet 可微, 且其梯度由命题 10.3.1 给出;
3. 对任意 $x \in H$,

$$e_\lambda f(x) \leq f(x);$$

4. 若 $0 < \lambda_1 < \lambda_2$, 则

$$e_{\lambda_1} f(x) \geq e_{\lambda_2} f(x), \quad \forall x \in H,$$

因而当 $\lambda \downarrow 0$ 时, $e_\lambda f$ 由下逼近 f 。

证明 第一条中的凸性来自第 7.3 节命题 7.3.1, 因为 $e_\lambda f = f \square q_\lambda$, 而二次函数 $q_\lambda(x) = \|x\|^2/(2\lambda)$ 连续且强凸。处处有限与连续性来自竞争点 $u = x$ 给出的上界以及命题 10.3.1 的可微性。

第二条正是命题 10.3.1。

第三条由取竞争点 $u = x$ 立得:

$$e_\lambda f(x) \leq f(x) + \frac{1}{2\lambda} \|x - x\|^2 = f(x).$$

第四条只需比较惩罚项。若 $0 < \lambda_1 < \lambda_2$, 则对任意 $u \in H$,

$$f(u) + \frac{1}{2\lambda_1} \|u - x\|^2 \geq f(u) + \frac{1}{2\lambda_2} \|u - x\|^2.$$

两边对 u 取下确界即可得到

$$e_{\lambda_1} f(x) \geq e_{\lambda_2} f(x).$$

因此随 $\lambda \downarrow 0$, $e_\lambda f(x)$ 单调增加且始终不超过 $f(x)$, 这正是 Moreau–Yosida 正则化的逼近方向。

推论 10.3.1 (Moreau 包络保持极小值集合)

在定理 10.3.1 的假设下, 对任意 $\lambda > 0$,

$$\operatorname{argmin} f = \operatorname{argmin} e_\lambda f.$$

特别地,

$$x^\star \in \operatorname{argmin} f \iff \nabla e_\lambda f(x^\star) = 0.$$



证明 若 $x^\star$ 极小化 f , 则对任意 u 有 $f(u) \geq f(x^\star)$, 故

$$f(u) + \frac{1}{2\lambda} \|u - x^\star\|^2 \geq f(x^\star).$$

对 u 取下确界得

$$e_\lambda f(x^\star) \geq f(x^\star).$$

再结合定理 10.3.1 第三条,

$$e_\lambda f(x^\star) = f(x^\star).$$

因此 $x^\star$ 极小化 $e_\lambda f$ 。反之, 若 $x^\star$ 极小化 $e_\lambda f$, 则对任意 x ,

$$e_\lambda f(x^\star) \leq e_\lambda f(x) \leq f(x).$$

另一方面,

$$e_\lambda f(x^\star) \leq f(x^\star),$$

故

$$f(x^\star) \leq f(x), \quad \forall x \in H.$$

于是 $x^\star$ 也是 f 的极小点。最后, 由命题 6.3.1 与可微凸函数的一阶判别,

$$x^\star \in \operatorname{argmin} e_\lambda f \iff \nabla e_\lambda f(x^\star) = 0.$$

10.3.3 典型例子

例题 10.7 指标函数的包络与距离平方 设 $C \subset H$ 为非空闭凸集, $f = \iota_C$ 。则

$$e_\lambda \iota_C(x) = \frac{1}{2\lambda} \operatorname{dist}(x, C)^2.$$

把这个例子放在这里, 是为了把投影、可行性误差与平滑代理统一起来: 当目标只是“离集合还有多远”时, Moreau 包络直接变成距离平方。

例题 10.8 绝对值与 Huber 平滑 在 $\mathbb{R}$ 上取 $f(t) = |t|$, 则第 7.3 节例子已经说明

$$e_\lambda f(x) = \begin{cases} \frac{x^2}{2\lambda}, & |x| \leq \lambda, \\ |x| - \frac{\lambda}{2}, & |x| > \lambda. \end{cases}$$

把这个例子放在这里, 是为了让读者看到 Boyd 中非常熟悉的 Huber 平滑, 其实正是 Moreau–Yosida 正则化的最简单坍缩。

例题 10.9 稳健回归与图像去噪 在稳健回归或变分图像去噪中, 原始正则项往往不可微。把它替换成 Moreau 包络后, 目标函数虽然被平滑化, 但推论 10.3.1 表明极小值结构没有被粗暴破坏。把这个例子放在这里, 是为了说明 Moreau 包络不是“方便计算的临时近似”, 而是带有几何控制的结构性代理。

有限维对照

Boyd 书中关于平滑化、Huber 损失与近端算法的讨论, 通常以有限维图像和矩阵模型呈现。本节说明, 这些现象背后的统一对象其实是定义 10.3.1、命题 10.3.1 与定理 10.3.1。有限维里, Yosida 正则化看上去像“把尖角

磨平”；无穷维里，它同时也是把多值极大单调算子替换为单值 Lipschitz 映射的解析机制。

习题（待补）

- 练习 10.5 距离平方占位 补一题：证明当 $f = \iota_C$ 时，Moreau 包络等于 $\text{dist}(\cdot, C)^2/(2\lambda)$ ，并解释其梯度与投影之间的关系。
- 练习 10.6 Huber 平滑桥接题占位 补一题：对 $f(t) = |t|$ 直接计算 $e_\lambda f$ 与 $\nabla e_\lambda f$ ，并说明它如何连接软阈值与平滑优化。

10.4 算子求根问题

如果说前几节完成的是“把局部最优性语言改写成算子语言”，那么本节要做的就是最后一步：把不同类型的问题统一写成零点问题。之所以这一步重要，是因为一旦把目标表述为

$$0 \in Au,$$

最优化、变分不等式、可行性和 KKT 系统都能共享同一套迭代母语。第 11 章的前向-后向分裂、Douglas-Rachford 和 ADMM，本质上都只是围绕这种零点表达所设计的不同求解策略。

10.4.1 单调包含与最优化

定义 10.4.1 (单调包含问题)

设 H 为 Hilbert 空间， $A: H \rightrightarrows H$ 为极大单调算子。称问题

$$0 \in Au$$

为与 A 相关的单调包含问题，其解集记为

$$\text{zer } A := \{u \in H : 0 \in Au\}.$$

命题 10.4.1 (最优化问题是单调包含的特例)

设 $f: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。则对任意 $\bar{x} \in H$,

$$\bar{x} \in \text{argmin } f \iff 0 \in \partial f(\bar{x}).$$

因此，凸最小化问题可以统一改写为单调包含

$$0 \in \partial f(x).$$

证明 这正是第 6.3 节命题 6.3.1 的内容。若 $\bar{x}$ 极小化 f ，则

$$0 \in \partial f(\bar{x}).$$

反过来，若

$$0 \in \partial f(\bar{x}),$$

则次梯度不等式给出

$$f(y) \geq f(\bar{x}) + \langle 0, y - \bar{x} \rangle = f(\bar{x}), \quad \forall y \in H,$$

故 $\bar{x}$ 为极小点。

10.4.2 零点与不动点

命题 10.4.2 (resolvent 不动点与零点等价)

设 $A: H \rightrightarrows H$ 为极大单调算子, $\lambda > 0$ 。则对任意 $u \in H$,

$$u \in \text{zer } A \iff u = J_{\lambda A}(u).$$

证明 由定义 10.1.3,

$$u = J_{\lambda A}(u) \iff u - u \in \lambda Au \iff 0 \in Au.$$

这正是 $u \in \text{zer } A$ 。

命题 10.4.3 (变分不等式也是单调包含)

设 $C \subset H$ 为非空闭凸集, $B: H \rightarrow H$ 为单值算子。则下列两条等价:

1. $\bar{x} \in C$ 且

$$\langle B\bar{x}, y - \bar{x} \rangle \geq 0, \quad \forall y \in C;$$

2.

$$0 \in B\bar{x} + N_C(\bar{x}).$$

证明 由第 6.4 节推论 6.4.1,

$$\xi \in N_C(\bar{x}) \iff \langle \xi, y - \bar{x} \rangle \leq 0, \quad \forall y \in C.$$

因此

$$0 \in B\bar{x} + N_C(\bar{x})$$

等价于存在 $\xi \in N_C(\bar{x})$ 使 $\xi = -B\bar{x}$ 。代回上式, 便得到

$$\langle -B\bar{x}, y - \bar{x} \rangle \leq 0, \quad \forall y \in C,$$

即

$$\langle B\bar{x}, y - \bar{x} \rangle \geq 0, \quad \forall y \in C.$$

反向推理同理成立。

注 命题 10.4.1 与命题 10.4.3 说明, 优化与变分不等式在第 10.1 节极大单调语言里并不是两类平行对象。前者对应 ∂f , 后者对应 $B + N_C$ 。第 8 章的 KKT 系统和第 8.2 节抽象标准型, 到了本节都可以被看成更大的单调包含系统。

10.4.3 proximal point 作为统一模板

推论 10.4.1 (proximal point 模板)

设 $A: H \rightrightarrows H$ 为极大单调算子, $\lambda_k > 0$ 。则求解单调包含

$$0 \in Au$$

的一个基本迭代模板是

$$u_{k+1} = J_{\lambda_k A}(u_k).$$

若特别地 $A = \partial f$, 则由命题 10.2.1,

$$u_{k+1} = \text{prox}_{\lambda_k f}(u_k).$$

证明 由命题 10.4.2, 单调包含的解恰好是 resolvent 的不动点。因此最自然的迭代, 就是不断应用 $J_{\lambda_k A}$ 逼近其不动点。若 $A = \partial f$, 则第一个式子立刻退化为 prox 迭代。

10.4.4 典型例子

例题 10.10 极小化问题的零点表达 对任意 proper、凸且下半连续的泛函 f ,

$$\min_x f(x) \iff 0 \in \partial f(x).$$

把这个例子放在这里,是为了把“求极小值”彻底改写成“求零点”,从而让第 11.1 节的前向-后向分裂不再依赖特定目标函数形式。

例题 10.11 线性方程组的固定点坍塌 若 $M: H \rightarrow H$ 为可逆线性算子,则解方程

$$Mx = b$$

等价于求零点

$$0 \in (Mx - b).$$

再把该算子写成 $Ax := Mx - b$,便可把线性代数中的固定点迭代理解为单调包含框架的有限维坍塌。把这个例子放在这里,是为了说明“算子求根”并不是新奇对象,而是把熟悉的方程论纳入统一语法。

例题 10.12 约束平衡与 KKT 系统 对第 8.4 节定义 8.4.1 的广义 KKT 条件,可将原变量与乘子并在一起,构造一个块算子,使整个原-对偶系统写成单调包含。把这个例子放在这里,是为了把第 8.4 节推论 8.4.1 与第 11 章的原-对偶算法直接接起来:后文分裂的对象不是“某个优化问题”,而是一个更大的零点系统。

有限维对照

Boyd 在算法章节里常把固定点、prox 更新和原-对偶步骤分开介绍;从本节角度看,它们都只是“求某个单调算子零点”的不同表面形式。有限维里,单调包含往往被压缩成矩阵等式、投影步骤或互补松弛方程,因此看起来像几套彼此独立的方法。本节的作用,是把这些方法重新挂回同一个接口上,好让第 11.1 节和第 11 章的所有分裂算法都能被视作同一问题族的不同求解器。

习题 (待补)

- 🔴 **练习 10.7 优化到零点占位** 补一题:把一个具体凸最小化问题改写为 $0 \in \partial f(x)$,并验证命题 10.4.2 在该例中的不动点解释。
- 🔴 **练习 10.8 变分不等式桥接题占位** 补一题:对一个闭凸集上的变分不等式,证明它等价于命题 10.4.3 给出的单调包含,并说明该表达如何通向第 11.1 节的算法接口。

第 11 章 大规模算子分裂算法

第 10 章已经把凸最小化、变分不等式与 KKT 系统统一改写成单调包含

$$0 \in Au.$$

因此，本章不再重新发明新的最优性条件，而是讨论怎样围绕 resolvent、prox 与固定点结构设计可扩展的迭代法。所谓“大规模”，在这里并不只是维数高，而是指目标函数、约束与对偶变量往往天然分裂成若干模块，直接求解完整 KKT 系统代价过高；真正可行的方案，是只调用梯度、投影、prox 或局部线性算子，并把耦合留给迭代去吸收。

本章沿四条主线展开。第 11.1 节讨论前向-后向分裂，把“一个可显式前向步的单值算子”和“一个可通过 resolvent 处理的极大单调算子”组合起来；这是第 10.2 节 prox 和第 10.4 节 zero finding 模板的最直接算法化。第 11.2 节引入 Douglas-Rachford 分裂，说明反射算子如何把两个极大单调算子的和改写成固定点问题。第 11.3 节随后把增广拉格朗日与 ADMM 挂回第 8.4 节的 KKT 语言，解释 Boyd 书中最常见的原-对偶迭代其实就是 Douglas-Rachford 在对偶侧的变量消去形式。最后，第 11.4 节讨论惰性与加速模板，说明 Hilbert 空间中的加速为什么必须借助能量函数与稳定性分析，而不能把有限维口号不加区分地直接搬到无穷维情形。

本章的正文主舞台是 Hilbert 空间。原因并不神秘：第 4.1 节定理 4.1.2 使得对偶元素能够被向量化表示，而第 10.2 节的 prox、第 10.3 节的 Moreau-Yosida 平滑以及平均映射的非扩张几何都在这一背景下最为透明。更一般的 Banach 空间版本当然存在，但其中投影、cocoercivity、firm nonexpansive 与反射算子的几何优势会明显减弱，因此本章只在 remark 中点到这些边界，而不把正文写成一部一般 Banach 分裂算法专著。

从叙事上看，本章恰好是第 12 章数值求解与第 13 章分布式实现之间的桥。前者关心连续时间极限、离散稳定性与收敛轨道，后者关心共识、通信与模块化实现；而它们共同依赖的，是本章建立的“算子分裂 = 固定点求解 = 局部可计算更新”这一接口。Boyd 的有限维算法表面上看像一组彼此分离的工程配方，本章的任务则是说明，它们其实共享同一条单调算子主线。

11.1 前向-后向分裂算法

第 10.4 节把极小化与 KKT 系统改写成单调包含之后，最先出现的问题是：若算子 A 还可以拆成“容易前向评估的一部分”和“容易做 resolvent 的一部分”，能否不必在每一步都求解完整隐式方程？前向-后向分裂正是对这个问题的回答。它在实践里常被直接叫作前向-后向算法；当“前向部分”来自光滑凸函数梯度，而“后向部分”来自非光滑正则项次微分时，它就退化为最熟悉的 prox-gradient 迭代。

11.1.1 问题模板与基本定义

定义 11.1.1 (cocoercive 算子)

设 H 为 Hilbert 空间， $B: H \rightarrow H$ 为单值算子， $\beta > 0$ 。若对任意 $x, y \in H$ 都有

$$\langle Bx - By, x - y \rangle \geq \beta \|Bx - By\|^2,$$

则称 B 是 β -cocoercive 的。

定义 11.1.2 (前向-后向迭代)

设 H 为 Hilbert 空间， $B: H \rightarrow H$ 为单值算子， $C: H \rightrightarrows H$ 为极大单调算子， $\gamma > 0$ 。定义

$$T_\gamma := J_{\gamma C}(I - \gamma B).$$

给定初值 $x^0 \in H$ ，迭代

$$x^{k+1} = T_\gamma x^k = J_{\gamma C}(x^k - \gamma Bx^k), \quad k = 0, 1, 2, \dots$$

称为求解

$$0 \in Bx + Cx$$

的前向-后向迭代。

注 定义 11.1.2 之所以自然，是因为它严格沿着第 10.4 节推论 10.4.1 的接口来设计：\$C\$ 仍然通过 **resolvent** 处理，但 \$B\$ 不再被整体塞进隐式步，而是只做一次显式前向评估。若 \$C = \partial g\$，则由命题 10.2.1，后向步就是 **prox**；若 \$B = \nabla h\$，则前向步就是普通梯度下降。因此它同时连接了第 6 章的微分语言与第 10 章的单调算子语言。

11.1.2 固定点与零点的对应

命题 11.1.1 (前向-后向固定点表述)

设 \$B\$ 与 \$C\$ 如定义 11.1.2，\$\gamma > 0\$。则

$$\text{Fix } T_\gamma = \text{zer}(B + C).$$

换言之，对任意 \$x \in H\$，

$$x = T_\gamma x \iff 0 \in Bx + Cx.$$

证明 由 **resolvent** 的定义，

$$x = T_\gamma x \iff x = J_{\gamma C}(x - \gamma Bx) \iff x - \gamma Bx \in x + \gamma Cx.$$

最后一个关系等价于

$$-Bx \in Cx,$$

亦即

$$0 \in Bx + Cx.$$

反向推理同理成立。

11.1.3 平均映射结构与收敛

定理 11.1.1 (前向-后向分裂的收敛定理)

设 \$H\$ 为 Hilbert 空间，\$C: H \rightrightarrows H\$ 为极大单调算子，\$B: H \rightarrow H\$ 为 \$\beta\$-cocoercive 单值算子，并假设

$$\text{zer}(B + C) \neq \emptyset.$$

若步长满足

$$0 < \gamma < 2\beta,$$

则由定义 11.1.2 生成的序列 \$\{x^k\}\$ 弱收敛到某个解 \$\bar{x} \in \text{zer}(B + C)\$。

证明 先说明 \$T_\gamma\$ 是平均映射。令

$$\alpha := \frac{\gamma}{2\beta} \in (0, 1).$$

由定义 11.1.1，

$$\|(I - 2\beta B)x - (I - 2\beta B)y\|^2 = \|x - y\|^2 - 4\beta \langle Bx - By, x - y \rangle + 4\beta^2 \|Bx - By\|^2 \leq \|x - y\|^2.$$

故 \$N := I - 2\beta B\$ 非扩张，而

$$I - \gamma B = (1 - \alpha)I + \alpha N$$

是 \$\alpha\$-averaged 映射。另一方面，由第 10.1 节定理 10.1.1，\$J_{\gamma C}\$ 处处有定义；再由第 10.2 节命题 10.2.3 在 **resolvent**

语言下的对应形式, $J_{\gamma C}$ 是 firmly nonexpansive, 也就是 1/2-averaged。平均映射的复合仍是平均映射, 因此存在某个 $\theta \in (0, 1)$ 使

$$T_{\gamma} = (1 - \theta)I + \theta N_{\gamma}$$

其中 N_{γ} 非扩张。

再由命题 11.1.1,

$$\text{Fix } T_{\gamma} = \text{zer}(B + C) \neq \emptyset.$$

任取 $z \in \text{Fix } T_{\gamma}$ 。平均映射的标准不等式给出

$$\|T_{\gamma}x - z\|^2 \leq \|x - z\|^2 - \frac{1 - \theta}{\theta} \|(I - T_{\gamma})x\|^2.$$

将 $x = x^k$ 代入并使用 $x^{k+1} = T_{\gamma}x^k$, 得到

$$\|x^{k+1} - z\|^2 \leq \|x^k - z\|^2 - \frac{1 - \theta}{\theta} \|x^k - x^{k+1}\|^2.$$

因此 $\{x^k\}$ 对解集是 Fejér 单调的, 特别地有界, 并且

$$\sum_{k=0}^{\infty} \|x^{k+1} - x^k\|^2 < \infty.$$

于是 $\|x^{k+1} - x^k\| \rightarrow 0$, 即序列渐近正则。

设 $\bar{x}$ 为 $\{x^k\}$ 的任意弱聚点, 则存在子列 $x^{k_j} \rightharpoonup \bar{x}$ 。由于 $x^{k_j} - T_{\gamma}x^{k_j} \rightarrow 0$, 而平均映射满足 demiclosedness 原理, 故

$$\bar{x} \in \text{Fix } T_{\gamma}.$$

再由 Hilbert 空间中的 Opial 引理, 整个序列弱收敛到某个 $\bar{x} \in \text{Fix } T_{\gamma} = \text{zer}(B + C)$ 。

推论 11.1.1 (prox-gradient 是前向-后向分裂的特例)

设 $h: H \rightarrow \mathbb{R}$ 为凸且 Fréchet 可微函数, 且 ∇h 为 β -cocoercive; 设 $g: H \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续的泛函。则对问题

$$\min_{x \in H} \{h(x) + g(x)\},$$

前向-后向迭代退化为

$$x^{k+1} = \text{prox}_{\gamma g}(x^k - \gamma \nabla h(x^k)), \quad 0 < \gamma < 2\beta.$$

这正是 Hilbert 空间中的 prox-gradient 算法。

证明 把最优性条件写成

$$0 \in \nabla h(x) + \partial g(x).$$

在定义 11.1.2 中取 $B = \nabla h$ 、 $C = \partial g$ 。由命题 10.2.1,

$$J_{\gamma \partial g} = \text{prox}_{\gamma g}.$$

因此前向-后向迭代恰好写成所述的 prox-gradient 形式。收敛性则由定理 11.1.1 直接得到。

注 在具体建模时, 常把 h 写成数据拟合项、把 g 写成正则项。若拟合项先经过线性算子复合, 则第 6.4 节命题 6.4.2 说明其最优性系统依旧能嵌入定义 11.1.2。这就是为什么前向-后向分裂能自然覆盖经验风险最小化、逆问题与变分正则化模型。

11.1.4 典型例子

例题 11.1 $f + g$ 型凸最小化 对

$$\min_x \{h(x) + g(x)\},$$

若 h 平滑且 ∇h cocoercive, g 允许非光滑, 则推论 11.1.1 给出标准 prox-gradient 更新。把这个例子放在这里, 是为了强调: 前向-后向分裂不是另起炉灶的新算法, 而是第 10.2 节 prox 与普通梯度步的自然拼接。

例题 11.2 Lasso 的 ISTA 在 $\mathbb{R}^n$ 上考虑

$$\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1.$$

此时 $h(x) = \frac{1}{2} \|Ax - b\|^2$, $g(x) = \lambda \|x\|_1$ 。若 $\|A\|^2 \leq L$, 则 ∇h 是 $1/L$ -cocoercive, 于是前向-后向迭代成为

$$x^{k+1} = \text{prox}_{\gamma\lambda\|\cdot\|_1}(x^k - \gamma A^*(Ax^k - b)), \quad 0 < \gamma < \frac{2}{L}.$$

这就是 Boyd 书中最常见的 ISTA 形式。

例题 11.3 带正则项的经验风险最小化 在 Hilbert 空间中, 若

$$h(x) = \frac{1}{m} \sum_{i=1}^m \ell_i(\langle a_i, x \rangle), \quad g(x) = \tau \|x\|_1 \text{ 或 } \tau \|x\|_*,$$

则前向步只需评估梯度, 后向步只需调用稀疏或低秩 prox。把这个例子放在这里, 是为了说明“大规模”并不要求每一步求精确解, 而是要求每一步只做局部可扩展的运算。

有限维对照

Boyd 往往把 prox-gradient 画成“先梯度下降, 再做阈值化”的两步法。本节说明, 这种 Euclidean 图像只是推论 11.1.1 的有限维外观。真正起作用的结构是: ∇h 的 cocoercive 性保证前向步可控, resolvent 的 firm nonexpansive 性保证后向步稳定, 而定理 11.1.1 则把两者合成为一个平均映射的收敛论证。有限维不过是这一 Hilbert 结构的最直观坍缩。

习题 (待补)

- 🔴 **练习 11.1 平均映射验证占位** 补一题: 在定理 11.1.1 的假设下, 直接验证 $I - \gamma B$ 为 averaged 映射, 并据此推出 T_γ 的 averaged 性。
- 🔴 **练习 11.2 ISTA 桥接题占位** 补一题: 对 Lasso 模型写出前向-后向迭代, 并利用例中的软阈值公式把它化为显式坐标更新。

11.2 Douglas–Rachford 分裂

前向-后向分裂适合处理“一个显式、一个隐式”的和; 若两部分都是极大单调算子, 直接做前向步往往并不现实。这时更合适的对象不是梯度步, 而是反射算子与其平均。Douglas–Rachford 方法正是在这一点上取代了显式梯度: 它不去近似 $A + B$, 而是把两个 resolvent 组织成一个固定点映射, 然后再从固定点中恢复零点。

11.2.1 反射算子与迭代定义

定义 11.2.1 (反射算子)

设 H 为 Hilbert 空间, $A: H \rightrightarrows H$ 为极大单调算子, $\gamma > 0$ 。定义

$$R_{\gamma A} := 2J_{\gamma A} - I.$$

该映射称为算子 A 的反射算子。

定义 11.2.2 (Douglas–Rachford 迭代)

设 $A, B: H \rightrightarrows H$ 为极大单调算子, $\gamma > 0$ 。定义

$$T_{\text{DR}} := \frac{1}{2}(I + R_{\gamma A}R_{\gamma B}).$$

给定初值 $z^0 \in H$, 迭代

$$z^{k+1} = T_{\text{DR}} z^k$$

称为求解

$$0 \in Ax + Bx$$

的 *Douglas–Rachford* 分裂。

注 由第 10.1 节定理 10.1.1, $J_{\gamma A}$ 与 $J_{\gamma B}$ 处处有定义, 因此定义 11.2.1 和定义 11.2.2 都是良定的。与第 11.1 节不同, 这里不要求某一部分是显式可微项; 两个块都只通过 **resolvent** 进入算法。

11.2.2 固定点与零点恢复

命题 11.2.1 (Douglas–Rachford 固定点与零点)

设 A, B 为极大单调算子, $\gamma > 0$ 。则有:

1. 若 $z \in \text{Fix } T_{\text{DR}}$, 并令

$$x := J_{\gamma B} z,$$

则 $x \in \text{zer}(A + B)$;

2. 反过来, 若 $x \in \text{zer}(A + B)$, 则存在 $z \in \text{Fix } T_{\text{DR}}$ 使 $x = J_{\gamma B} z$ 。

证明 先证第一条。设 $z = T_{\text{DR}} z$, 即

$$z = \frac{1}{2}(z + R_{\gamma A} R_{\gamma B} z),$$

从而

$$z = R_{\gamma A} R_{\gamma B} z.$$

记

$$x := J_{\gamma B} z, \quad R_{\gamma B} z = 2x - z.$$

由上式和反射的定义,

$$z = 2J_{\gamma A}(R_{\gamma B} z) - R_{\gamma B} z,$$

因此

$$J_{\gamma A}(R_{\gamma B} z) = \frac{1}{2}(z + R_{\gamma B} z) = x.$$

由 **resolvent** 的定义,

$$z - x \in \gamma Bx, \quad R_{\gamma B} z - x = x - z \in \gamma Ax.$$

两式相加得到

$$0 \in \gamma Ax + \gamma Bx,$$

即

$$0 \in Ax + Bx.$$

再证第二条。若 $x \in \text{zer}(A + B)$, 则可取

$$a \in Ax, \quad b \in Bx, \quad a + b = 0.$$

令

$$z := x + \gamma b.$$

则

$$z - x \in \gamma Bx,$$

故 $x = J_{\gamma B}z$ 。同时

$$R_{\gamma B}z = 2x - z = x - \gamma b = x + \gamma a,$$

于是

$$R_{\gamma B}z - x \in \gamma Ax,$$

故 $x = J_{\gamma A}(R_{\gamma B}z)$ 。代回反射定义可得

$$R_{\gamma A}R_{\gamma B}z = 2J_{\gamma A}(R_{\gamma B}z) - R_{\gamma B}z = 2x - (x - \gamma b) = x + \gamma b = z.$$

于是 $z \in \text{Fix } T_{\text{DR}}$ 。

11.2.3 平均映射性质

定理 11.2.1 (Douglas–Rachford 映射是 averaged)

设 $A, B: H \rightrightarrows H$ 为极大单调算子, $\gamma > 0$, 并假设

$$\text{zer}(A + B) \neq \emptyset.$$

则 T_{DR} 是 firmly nonexpansive, 从而尤其是 averaged 映射。由定义 11.2.2 生成的序列 $\{z^k\}$ 弱收敛到某个 $\bar{z} \in \text{Fix } T_{\text{DR}}$, 且影子序列

$$x^k := J_{\gamma B}z^k$$

弱收敛到某个 $\bar{x} \in \text{zer}(A + B)$ 。

证明 由 resolvent 的 firm nonexpansive 性, $J_{\gamma A}$ 与 $J_{\gamma B}$ 都是 firmly nonexpansive。于是对任意 $u, v \in H$,

$$\|R_{\gamma A}u - R_{\gamma A}v\| = \|2J_{\gamma A}u - u - (2J_{\gamma A}v - v)\| \leq \|u - v\|.$$

故 $R_{\gamma A}$ 非扩张; 同理 $R_{\gamma B}$ 也非扩张, 于是复合 $R_{\gamma A}R_{\gamma B}$ 仍非扩张。由定义 11.2.2,

$$T_{\text{DR}} = \frac{1}{2}I + \frac{1}{2}R_{\gamma A}R_{\gamma B}$$

是 1/2-averaged, 即 firmly nonexpansive。

再由命题 11.2.1, $\text{zer}(A + B) \neq \emptyset$ 蕴含 $\text{Fix } T_{\text{DR}} \neq \emptyset$ 。于是可像定理 11.1.1 那样, 对 averaged 映射使用 Fejér 单调与 Opial 引理, 得到 $z^k \rightharpoonup \bar{z} \in \text{Fix } T_{\text{DR}}$ 。

由于 resolvent 非扩张, $\{x^k\}$ 有界。若 $x^{k_j} \rightharpoonup \bar{x}$, 则由

$$x^{k_j} = J_{\gamma B}z^{k_j}, \quad z^{k_j} \rightharpoonup \bar{z}$$

以及 resolvent 图像的闭性可知 $\bar{x} = J_{\gamma B}\bar{z}$ 。再由命题 11.2.1, $\bar{x} \in \text{zer}(A + B)$ 。因此整个影子序列也弱收敛到某个解。

推论 11.2.1 (可行性交是 Douglas–Rachford 的特例)

设 $C, D \subset H$ 为非空闭凸集, 并考虑可行性交问题

$$\text{求 } x \in C \cap D.$$

令

$$A = N_C, \quad B = N_D.$$

则定义 11.2.2 退化为

$$T_{\text{DR}} = \frac{1}{2}(I + (2P_C - I)(2P_D - I)),$$

而任意固定点 $\bar{z}$ 的影子点

$$\bar{x} = P_D \bar{z}$$

属于 $C \cap D$ 。



证明 由第 6.4 节推论 6.4.1 与第 10.2 节投影例子，

$$J_{\gamma N_C} = P_C, \quad J_{\gamma N_D} = P_D.$$

于是反射算子写成

$$R_{\gamma N_C} = 2P_C - I, \quad R_{\gamma N_D} = 2P_D - I.$$

其余结论由定理 11.2.1 和命题 11.2.1 直接得到。

注 第 11.2 节的意义不只在可行性交。第 11.3 节会看到，ADMM 并不是一套与 Douglas-Rachford 平行的经验算法；恰恰相反，ADMM 可以被看成 Douglas-Rachford 在对偶侧的变量消去形式。也正因为如此，理解反射算子与固定点结构，是理解 ADMM 的最快途径。

11.2.4 典型例子

例题 11.4 两个闭凸集的可行性交 在例子最基本的情形中， C 与 D 分别代表两个独立约束模块，例如一个数据一致性集合和一个结构先验集合。Douglas-Rachford 的每一步都只需做两次投影与两次反射，却能把可行性交改写成单个固定点问题。这种“把复杂交集拆成简单块”的思想，是大规模模型中最关键的算法动机之一。

例题 11.5 欧氏空间中的双反射 在 $\mathbb{R}^n$ 中，当 C 与 D 是仿射子空间时， $2P_C - I$ 与 $2P_D - I$ 就是熟悉的镜面对称。把这个例子放在这里，是为了说明 Douglas-Rachford 的几何直觉确实可以在有限维里画出来；但真正支撑它的不是图形，而是定理 11.2.1 的平均映射结构。

例题 11.6 图像恢复中的一致性约束 在图像恢复或逆问题中，常把“符合观测”的约束与“满足先验”的约束分开建模，再对两者的交施加 Douglas-Rachford 分裂。把这个例子放在这里，是为了说明可行性交并不只是几何练习，而是后续 ADMM、投影算法和一致性恢复模型的共同母语。

有限维对照

Boyd 书里常把 Douglas-Rachford 与交替投影、反射法并列介绍，读起来像几种彼此不同的几何技巧。本节的结论是：它们共享同一个固定点框架。有限维里，反射算子可以直接画成镜像，因而算法看起来很直观；无穷维里，这种图像直觉不再可靠，但定理 11.2.1 和命题 11.2.1 依然成立，因此 Boyd 中的几何配方其实只是更一般单调算子结构的坍塌版本。

习题（待补）

- 🔴 **练习 11.3 反射算子占位** 补一题：证明对非空闭凸集 C ，反射算子 $2P_C - I$ 非扩张，并据此解释定义 11.2.1 在法锥情形中的几何意义。
- 🔴 **练习 11.4 可行性交桥接题占位** 补一题：把一个具体的可行性交模型改写为 $0 \in N_C x + N_D x$ ，并写出对应的 Douglas-Rachford 迭代。

11.3 交替方向乘子法的泛函视角

第 8.4 节已经说明，带约束凸优化的真正核心对象不是原问题本身，而是一个 KKT 原-对偶系统。ADMM 的价值就在于，它并不试图一次性解这个系统，而是借助增广拉格朗日把耦合项放进一个二次罚项里，再通过

交替最小化与乘子更新逐步逼近鞍点。有限维里，这常被当成 Boyd 式工程算法来讲；本节要说明的是，它其实可以完全挂回第 11.2 节的 Douglas–Rachford 分裂与第 8.2 节的标准型接口。

11.3.1 两块模型与增广拉格朗日

定义 11.3.1 (ADMM 的增广拉格朗日)

设 X, Z, Y 为 Hilbert 空间, $A: X \rightarrow Y, B: Z \rightarrow Y$ 为有界线性算子, $b \in Y$ 。考虑两块凸问题

$$\min_{x \in X, z \in Z} \{f(x) + g(z) : Ax + Bz = b\},$$

其中 $f: X \rightarrow \mathbb{R} \cup \{+\infty\}$ 、 $g: Z \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函。对给定罚参数 $\rho > 0$ ，定义其增广拉格朗日为

$$\mathcal{L}_\rho(x, z; y) := f(x) + g(z) + \langle y, Ax + Bz - b \rangle + \frac{\rho}{2} \|Ax + Bz - b\|^2.$$

定义 11.3.2 (ADMM 迭代)

在定义 11.3.1 的条件下，给定 (x^0, z^0, y^0) 与 $\rho > 0$ ，定义

$$x^{k+1} \in \arg \min_x \mathcal{L}_\rho(x, z^k; y^k),$$

$$z^{k+1} \in \arg \min_z \mathcal{L}_\rho(x^{k+1}, z; y^k),$$

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - b).$$

这组更新称为 ADMM。相应地，定义原残差与对偶残差

$$r^{k+1} := Ax^{k+1} + Bz^{k+1} - b, \quad s^{k+1} := \rho B^*(z^{k+1} - z^k).$$

注 定义 11.3.2 中的乘子更新，正是把约束违反量 r^{k+1} 回灌到对偶变量中。它与第 8.4 节定义 8.4.1 的关系是直接的：若 $r^{k+1} \rightarrow 0$ 且两个块的最优性条件稳定下来，就会逼近 KKT 系统。也因此，ADMM 最终要验证的不是某个经验停止准则，而是原-对偶残差是否把 KKT 条件逼近到可接受精度。

11.3.2 ADMM 与 Douglas–Rachford 的接口

命题 11.3.1 (ADMM 是 Douglas–Rachford 分裂的变量消去形式)

在标准的资格条件下，把定义 11.3.1 的原问题经由第 8.2 节命题 8.2.2 写成对偶问题后，可得到两个极大单调算子

$$M_f := \partial(f^* \circ (-A^*)) + b, \quad M_g := \partial(g^* \circ (-B^*)).$$

对偶变量的一个仿射重参数化满足第 11.2 节定义 11.2.2 的 Douglas–Rachford 迭代。因此，ADMM 可以看成对偶侧 DR 分裂在原变量与乘子变量上的显式展开。

证明 由 x -步的最优性条件，

$$0 \in \partial f(x^{k+1}) + A^*y^k + \rho A^*(Ax^{k+1} + Bz^k - b).$$

再利用乘子更新 $y^{k+1} = y^k + \rho r^{k+1}$ ，可重写为

$$-A^*(y^{k+1} + \rho B(z^k - z^{k+1})) \in \partial f(x^{k+1}).$$

同样地， z -步给出

$$-B^*y^{k+1} \in \partial g(z^{k+1}).$$

把这两条最优性条件通过 Fenchel 反演改写到对偶空间，并引入标准的中间变量，就会得到两个 resolvent 的交替

作用；其组合正是

$$\frac{1}{2}(I + R_{\rho M_f} R_{\rho M_g})$$

的 Douglas–Rachford 形式。这里真正重要的不是坐标层面的繁琐代换，而是结构：ADMM 的“交替最小化 + 乘子更新”并不是额外发明的一套规则，而是第 11.2 节 DR 分裂在对偶侧的等价写法。

11.3.3 收敛与 KKT 极限

定理 11.3.1 (ADMM 的原-对偶收敛)

设定义 11.3.1 的问题存在鞍点 $(\bar{x}, \bar{z}, \bar{y})$ ，并假设定义 11.3.2 生成的序列有界。则原残差与对偶残差满足

$$r^k \rightarrow 0, \quad s^k \rightarrow 0.$$

并且每个弱聚点 $(x^\infty, z^\infty, y^\infty)$ 都满足相应的 KKT 系统；若 KKT 解集在所考虑模型下是单点，则整个序列弱收敛到该原-对偶解。

证明 先写出 ADMM 两个子问题的一阶最优性条件。对 x -步，

$$0 \in \partial f(x^{k+1}) + A^* y^k + \rho A^* (Ax^{k+1} + Bz^k - b),$$

即

$$-A^*(y^{k+1} + \rho B(z^k - z^{k+1})) \in \partial f(x^{k+1}).$$

对 z -步，

$$0 \in \partial g(z^{k+1}) + B^* y^k + \rho B^* (Ax^{k+1} + Bz^{k+1} - b),$$

于是

$$-B^* y^{k+1} \in \partial g(z^{k+1}).$$

再与鞍点的 KKT 条件

$$-A^* \bar{y} \in \partial f(\bar{x}), \quad -B^* \bar{y} \in \partial g(\bar{z}), \quad A\bar{x} + B\bar{z} - b = 0$$

配对，并利用次微分的单调性，得到

$$\begin{aligned} \langle A(x^{k+1} - \bar{x}), y^{k+1} - \bar{y} + \rho B(z^k - z^{k+1}) \rangle &\leq 0, \\ \langle B(z^{k+1} - \bar{z}), y^{k+1} - \bar{y} \rangle &\leq 0. \end{aligned}$$

把两式相加，并用

$$A(x^{k+1} - \bar{x}) = r^{k+1} - B(z^{k+1} - \bar{z})$$

代入，可得

$$\langle r^{k+1}, y^{k+1} - \bar{y} \rangle \leq \rho \langle B(z^{k+1} - \bar{z}), B(z^k - z^{k+1}) \rangle.$$

再利用恒等式

$$y^{k+1} - y^k = \rho r^{k+1}$$

以及极化公式

$$2\langle u - v, u - w \rangle = \|u - w\|^2 - \|v - w\|^2 + \|u - v\|^2,$$

可将上式化为

$$\begin{aligned} \|y^{k+1} - \bar{y}\|^2 + \rho^2 \|B(z^{k+1} - \bar{z})\|^2 &\leq \|y^k - \bar{y}\|^2 + \rho^2 \|B(z^k - \bar{z})\|^2 \\ &\quad - \rho^2 \|r^{k+1}\|^2 - \rho^2 \|B(z^{k+1} - z^k)\|^2. \end{aligned}$$

因此序列

$$\Phi_k := \|y^k - \bar{y}\|^2 + \rho^2 \|B(z^k - \bar{z})\|^2$$

单调不增且有下界，故收敛。于是

$$\sum_{k=0}^{\infty} \|r^{k+1}\|^2 < \infty, \quad \sum_{k=0}^{\infty} \|B(z^{k+1} - z^k)\|^2 < \infty,$$

从而

$$r^k \rightarrow 0.$$

由定义 11.3.2 中对偶残差的定义，也得到

$$s^k = \rho B^*(z^k - z^{k-1}) \rightarrow 0.$$

再取任意弱聚点 $(x^\infty, z^\infty, y^\infty)$ 。由 $r^k \rightarrow 0$ ，可得

$$Ax^\infty + Bz^\infty = b.$$

对 x -步与 z -步最优性条件取极限，并利用 $s^k \rightarrow 0$ 与图像闭性，得到

$$0 \in \partial f(x^\infty) + A^*y^\infty, \quad 0 \in \partial g(z^\infty) + B^*y^\infty.$$

这正是第 8.4 节定义 8.4.1 与推论 8.4.1 在当前线性约束模型中的 KKT 条件。若 KKT 解集为单点，则所有聚点一致，因而整个序列弱收敛到该点。

推论 11.3.1 (ADMM 的 KKT 极限)

在定理 11.3.1 的假设下，任意极限点 $(x^\infty, z^\infty, y^\infty)$ 都满足

$$Ax^\infty + Bz^\infty = b,$$

$$0 \in \partial f(x^\infty) + A^*y^\infty, \quad 0 \in \partial g(z^\infty) + B^*y^\infty.$$

因此，ADMM 的极限点正是相应原问题与对偶问题的 KKT 点。

证明 这只是定理 11.3.1 末尾结论的重述。

11.3.4 典型例子

例题 11.7 两块变量的标准 ADMM 当约束写成

$$Lx - z = 0$$

时，ADMM 变成最常见的共识模型： x -步处理复杂损失， z -步处理简单正则或约束，乘子变量负责把两块重新绑在一起。把这个例子放在这里，是为了给第 11.2 节 DR 结构一个最直接的算法外观。

例题 11.8 函数空间上的一致性约束分裂 在函数空间优化中， x 可能代表状态变量， z 代表控制或辅助变量，而 $Ax + Bz = b$ 编码 PDE、边界或一致性约束。此时 ADMM 的意义不在于矩阵分块，而在于把原本强耦合的 KKT 系统拆成两个局部可解子问题。

例题 11.9 推荐系统与分布式共识 在推荐系统、联邦学习或分布式训练中，常把局部模型变量和全局共识变量分开建模，再用 ADMM 交替更新。把这个例子放在这里，是为了说明 Boyd 中“增广拉格朗日 + ADMM”的工程配方，本质上正是前七章抽象对象在算法层的一次计算实现。

有限维对照

Boyd 对 ADMM 的经典叙述通常从增广拉格朗日和残差图表开始，这在有限维工程问题里非常有效。但如果把它只看成一个“经验上好用的迭代模板”，就会错过它与第 11.2 节 Douglas-Rachford 分裂、第 8.4 节 KKT 系统以及第 10.4 节单调包含之间的统一结构。本节的要点恰恰是：有限维矩阵公式只是抽象原-对偶分裂在 Euclidean

空间中的坍塌版本。

习题（待补）

- 🔥 **练习 11.5 增广拉格朗日占位** 补一题：对一个两块约束模型写出增广拉格朗日，并逐步推出定义 11.3.2 的三个更新式。
- 🔥 **练习 11.6 DR-ADMM 接口题占位** 补一题：在一个简单共识模型中，说明 ADMM 如何由第 11.2 节的 Douglas-Rachford 分裂恢复出来。

11.4 加速算法与 Hilbert 空间拓展

到这里为止，本章已经得到了两类稳定的 Hilbert 空间分裂模板：前向-后向分裂和 Douglas-Rachford/ADMM。下一步自然会问，能否像有限维凸优化那样再叠加一个“加速层”？答案并不是简单的肯定或否定。惰性项、Nesterov 型外推和 Lyapunov 能量确实能够在某些 Hilbert 空间模型中工作，但它们依赖的不是几句复杂度口号，而是比第 11.1 节更精细的能量耗散结构。也正因为如此，本节的重点不是罗列所有加速变体，而是给出一个可安全调用的模板，并说明其适用边界。

11.4.1 惰性 proximal 模板

定义 11.4.1 (惰性 proximal 迭代)

设 H 为 Hilbert 空间，考虑复合模型

$$\min_{x \in H} \{h(x) + g(x)\},$$

其中 h 为凸且可微， g 为 proper、凸且下半连续。给定步长 $\gamma > 0$ 与惰性参数序列 $\{\alpha_k\} \subset [0, 1)$ ，定义

$$\begin{aligned} y^k &:= x^k + \alpha_k(x^k - x^{k-1}), \\ x^{k+1} &:= \text{prox}_{\gamma g}(y^k - \gamma \nabla h(y^k)). \end{aligned}$$

该迭代称为惰性 proximal 迭代。

定义 11.4.2 (加速的 Lyapunov 能量)

在定义 11.4.1 的背景下，称形如

$$\mathcal{E}_k := (h(x^k) + g(x^k)) + \eta_k \|x^k - x^{k-1}\|^2$$

的量为 Lyapunov 能量，其中 $\eta_k \geq 0$ 用于补偿惰性外推带来的动量项。

11.4.2 能量下降与模板性结论

命题 11.4.1 (加速迭代的能量下降)

设 h 的梯度是 β -cocoercive， $0 \leq \alpha_k \leq \bar{\alpha} < 1$ ，且步长 γ 与惰性参数满足标准小步长条件。则可选择常数 $\eta > 0$ 与 $c > 0$ ，使定义 11.4.2 中的能量满足

$$\mathcal{E}_{k+1} + c \|x^{k+1} - x^k\|^2 \leq \mathcal{E}_k, \quad k \geq 0.$$

证明 由定义 11.4.1，

$$x^{k+1} = \text{prox}_{\gamma g}(y^k - \gamma \nabla h(y^k)).$$

这与第 11.1 节推论 11.1.1 的 prox-gradient 步完全同型，只是把基点从 x^k 换成了外推点 y^k 。因此，对固定的 y^k ，前向-后向步仍然给出一条下降不等式；而由第 10.3 节命题 10.3.1 所体现的平滑梯度结构， $\nabla h(y^k)$ 与 $\nabla h(x^k)$ 的差可以借助 cocoercive 性控制。

把 $y^k = x^k + \alpha_k(x^k - x^{k-1})$ 代入后，会多出若干交叉项。对这些项使用 Young 不等式，并把它们吸收到

$$\eta \|x^k - x^{k-1}\|^2$$

中，就可得到

$$h(x^{k+1}) + g(x^{k+1}) \leq h(x^k) + g(x^k) - c_1 \|x^{k+1} - x^k\|^2 + c_2 \|x^k - x^{k-1}\|^2.$$

只要步长和惰性参数满足标准小步长条件，就能选取 η 使

$$\mathcal{E}_{k+1} + c \|x^{k+1} - x^k\|^2 \leq \mathcal{E}_k$$

成立。这里的关键不是常数的最优表达，而是存在一个真正耗散的 Lyapunov 能量，这正是惰性算法在 Hilbert 空间中可分析的根本原因。

定理 11.4.1 (Hilbert 空间中的加速模板)

设定义 11.4.1 的问题存在解，且命题 11.4.1 的能量下降成立。则：

1. $\{\mathcal{E}_k\}$ 收敛，且

$$\sum_{k=0}^{\infty} \|x^{k+1} - x^k\|^2 < \infty;$$

2. 每个弱聚点 $\bar{x}$ 都满足

$$0 \in \nabla h(\bar{x}) + \partial g(\bar{x});$$

3. 若解集退化为单点，或问题还满足额外的强凸/误差界条件，则整个序列弱收敛到该解。

证明 由命题 11.4.1， $\{\mathcal{E}_k\}$ 单调不增且有下界，故收敛，并且

$$\sum_{k=0}^{\infty} \|x^{k+1} - x^k\|^2 < \infty.$$

于是

$$x^{k+1} - x^k \rightarrow 0, \quad y^k - x^k = \alpha_k(x^k - x^{k-1}) \rightarrow 0.$$

再利用 prox 最优性条件，

$$\frac{1}{\gamma}(y^k - x^{k+1}) - \nabla h(y^k) \in \partial g(x^{k+1}).$$

由于 $y^k - x^{k+1} \rightarrow 0$ ，而 ∇h 在有界集上连续，取弱聚点并使用次微分图像闭性，可得任意弱极限 $\bar{x}$ 满足

$$-\nabla h(\bar{x}) \in \partial g(\bar{x}),$$

也即

$$0 \in \nabla h(\bar{x}) + \partial g(\bar{x}).$$

这正是第 11.1 节定理 11.1.1 所对应的零点条件。

若解集为单点，或额外具备强凸/误差界等消除多重聚点的结构，则 Opial 型论证可把“所有聚点都是解”升级为整列弱收敛。换言之，Hilbert 空间中的加速并不是单靠外推就自动成功，而是建立在命题 11.4.1 的能量控制之上。

注[无穷维中的加速边界] 有限维文献常把“加速”表述为一种几乎普适的复杂度提升，但在无穷维问题里，这样的说法往往过于乐观。首先，弱拓扑下缺乏自动紧性，意味着外推可能制造长时间振荡而不产生强收敛；其次，许多 Nesterov 型估计序列依赖 Euclidean 范数、有限维谱界或额外紧性，离开这些条件后就不能原封不动照搬。第 12.1 节会从连续时间角度再次看到这一点：真正稳定的加速模板必须伴随明确的 Lyapunov 能量，而不是只凭一句“更快”。

11.4.3 典型例子

例题 11.10 惯性 proximal gradient 在复合模型

$$\min_x h(x) + g(x)$$

中，若 h 平滑、 g 可 prox，定义 11.4.1 就给出了惯性 proximal gradient。它与第 11.1 节的前向-后向分裂只有一步之差：多出的外推项提高了经验效率，但也迫使我们引入定义 11.4.2 的能量来控制稳定性。

例题 11.11 有限维 Nesterov 模板 在 $\mathbb{R}^n$ 中，取 $g \equiv 0$ 时，惰性 proximal 迭代退化为带动量的梯度法。把这个例子放在这里，是为了提醒读者：Boyd 和经典一阶法文献中的加速直觉确实来自有限维，但本节的重点是说明它在 Hilbert 空间中仍可保留哪些结构、必须舍弃哪些口号。

例题 11.12 最优控制离散化后的加速求解 在 PDE 约束或最优控制问题离散化后，常见的目标由光滑能量项和非光滑约束/正则项组成。惰性 proximal 更新往往能显著减少外层迭代数，但如果离散尺度变化导致条件数恶化，就必须重新检查命题 11.4.1 的参数条件。把这个例子放在这里，是为了强调“加速”始终是受模型与空间结构制约的。

有限维对照

Boyd 对加速算法的讨论通常以内点、梯度法或 Nesterov 迭代的复杂度估计为主，默认工作空间是 Euclidean 空间。本节的任务不是否认这些结论，而是把它们放回更准确的语境：在 Hilbert 空间里，能被安全继承的是 Lyapunov 能量、平均映射与零点结构；不能无条件继承的是所有基于有限维紧性和谱估计的复杂度口号。有限维结论仍然重要，但它们只是无穷维分析中的特例坍缩，而不是通用模板。

习题（待补）

- 🔥 **练习 11.7 Lyapunov 能量占位** 补一题：对一个具体的惰性 proximal gradient 迭代构造 Lyapunov 能量，并验证命题 11.4.1 的下降格式。
- 🔥 **练习 11.8 加速边界桥接题占位** 补一题：比较有限维 Nesterov 迭代和一个 Hilbert 空间惰性迭代，说明为什么后者必须额外检查 remark 11.4.2 中提到的稳定性边界。

第六部分

应用

第 12 章 最优控制与量化交易的泛函建模

从第 2 章到第 11 章，本书已经建立了无穷维凸优化的主要技术链：拓扑与测度负责给出合法环境，泛函分析与分离定理负责给出对偶与乘子对象，次微分、共轭与单调算子负责把最优性系统改写成可计算的原-对偶结构。到了这一章，目标不再是继续扩展抽象工具，而是把这些工具真正落到连续时间控制和量化交易的函数空间建模上。关键变化在于：决策变量不再是一个有限维向量，而是一条控制轨道、一族适应过程，或者某个随时间递推的价值函数。

本章沿三条主线展开。第 12.1 节先把连续时间最优控制写成标准的函数空间极小化问题，说明可容许控制、状态方程、成本泛函、伴随状态与一阶必要条件如何统一到第 6 章和第 8 章的语言里。第 12.2 节转向量化交易中的随机优化，把自融资策略、财富过程、风险度量与 CVaR 约束写成滤过概率空间上的凸优化模型，并用第 7 章的 Fenchel-Rockafellar 对偶与第 8.4 节的 KKT 系统解释影子价格和风险乘子。最后，第 12.3 节讨论随机控制与 Bellman 动态规划，说明价值函数、Bellman 算子和 HJB 极限怎样把第 3 章的 Itô 语法与第 11 章的算法语义连接起来。

本章依旧坚持“应用不脱离主线”的写法。最优控制并不会被写成一部控制理论专著，量化金融也不会被扩展成一部资产定价教材。我们只保留那些会反复回到无穷维凸优化主线中的对象：直接法存在性、伴随与最优性系统、风险约束下的原-对偶结构、以及由 Bellman 递推组织起来的动态规划接口。与第 9 章有限维坍塌的写法类似，Boyd 中的 LQR、MPC、均值-方差、交易成本和执行模型在本章都只是入口；真正重要的是弄清楚这些例子在函数空间、对偶空间和过程空间中分别对应什么对象。

12.1 连续时间最优控制论

连续时间最优控制最容易被有限维直觉遮蔽的地方，在于它的变量不是某个向量，而是整条控制轨道以及由状态方程生成的整条状态轨道。也正因为如此，正确的建模起点不是“写出 Hamiltonian 再求导”，而是先把控制集、状态空间、状态方程和成本泛函组织成一个真正的函数空间极小化问题，然后再讨论存在性、可微性与一阶必要条件。本节就是要把这条链条写完整。

12.1.1 控制空间、状态方程与标准型

定义 12.1.1 (可容许控制)

设 U 为 Hilbert 空间， $[0, T]$ 为给定时间区间， $K \subset U$ 为非空闭凸集。若控制函数

$$u \in L^2(0, T; U)$$

满足

$$u(t) \in K \quad \text{对几乎处处 } t \in [0, T]$$

成立，则称 u 为一个可容许控制。所有可容许控制组成的集合记为

$$\mathcal{U}_{\text{ad}}.$$

定义 12.1.2 (控制问题的泛函标准型)

设 X 为状态空间， U 为控制空间， $S: \mathcal{U}_{\text{ad}} \rightarrow L^2(0, T; X)$ 为由状态方程生成的控制到状态映射。给定运行成本 $\ell: [0, T] \times X \times U \rightarrow \mathbb{R} \cup \{+\infty\}$ 与终端成本 $\Phi: X \rightarrow \mathbb{R} \cup \{+\infty\}$ ，定义

$$J(u) := \int_0^T \ell(t, (Su)(t), u(t)) dt + \Phi((Su)(T)).$$

极小化问题

$$\min_{u \in \mathcal{U}_{\text{ad}}} J(u)$$

称为连续时间最优控制问题的泛函标准型。



注 定义 12.1.2 把最优控制重新挂回了第 6 章的 **proper** 泛函和第 8 章的约束标准型。控制约束体现在 $\mathcal{U}_{\text{ad}}$ 的闭凸性中，状态方程体现在映射 S 中，状态约束和运行成本则都可以被吸收到 J 的取值里。这样做的好处是：存在性和最优性条件可以直接调用定理 6.1.2、定义 6.2.2 与定义 8.4.1 的已有接口，而不必重新发明一套平行语法。

12.1.2 直接法存在性

定理 12.1.1 (最优控制问题的存在性)

设 U 为 Hilbert 空间， $\mathcal{U}_{\text{ad}} \subset L^2(0, T; U)$ 为非空闭凸集。假设：

1. 控制到状态映射 $S: \mathcal{U}_{\text{ad}} \rightarrow L^2(0, T; X)$ 弱连续；
2. 泛函 J 在 $L^2(0, T; U)$ 上 **proper**、下半连续且凸；
3. J 在 $\mathcal{U}_{\text{ad}}$ 上强制，即

$$\|u_n\|_{L^2} \rightarrow \infty \implies J(u_n) \rightarrow +\infty.$$

则控制问题

$$\min_{u \in \mathcal{U}_{\text{ad}}} J(u)$$

存在至少一个最优控制 $\bar{u} \in \mathcal{U}_{\text{ad}}$ 。



证明 取极小化列 $\{u_n\} \subset \mathcal{U}_{\text{ad}}$ ，使

$$J(u_n) \downarrow \inf_{u \in \mathcal{U}_{\text{ad}}} J(u).$$

由强制性， $\{u_n\}$ 在 $L^2(0, T; U)$ 中有界。由于 $L^2(0, T; U)$ 是 Hilbert 空间，特别是自反空间，故存在子列仍记为 $\{u_n\}$ 与某个 $\bar{u} \in L^2(0, T; U)$ 使

$$u_n \rightharpoonup \bar{u}.$$

又因为 $\mathcal{U}_{\text{ad}}$ 闭凸，所以它在弱拓扑下闭，从而 $\bar{u} \in \mathcal{U}_{\text{ad}}$ 。现在应用第 6.1 节定理 6.1.2 的直接法框架：由 J 的下半连续性，

$$J(\bar{u}) \leq \liminf_{n \rightarrow \infty} J(u_n) = \inf_{u \in \mathcal{U}_{\text{ad}}} J(u).$$

故 $\bar{u}$ 达到极小值。

注 定理 12.1.1 的重点不是“控制问题总有最优解”，而是指出最优解来自三个具体机制：可容许控制集的弱闭性、目标泛函的弱下半连续性，以及强制性把极小化列困在一个弱紧区域中。这正是第 6.1 节直接法在控制情形中的标准落地。

12.1.3 伴随状态与一阶必要条件

定义 12.1.3 (伴随状态)

设控制问题可写成

$$J(u) = F(Su, u),$$

其中 F 在 (x, u) 变量上 Fréchet 可微， S 为有界线性算子。若对某个控制 $\bar{u}$ ，存在函数或过程 p 满足

$$S^* D_x F(S\bar{u}, \bar{u}) = p,$$

则称 p 为与 $\bar{u}$ 对应的伴随状态。在具体微分方程模型中，它往往满足一个反向终端值问题，这正是第 4.3 节定义 4.3.2 在控制中的具体化。

定理 12.1.2 (凸控制问题的 Pontryagin/KKT 型必要条件)

设 $\mathcal{U}_{\text{ad}} \subset L^2(0, T; U)$ 为非空闭凸集, $S: L^2(0, T; U) \rightarrow L^2(0, T; X)$ 为有界线性算子, $F: L^2(0, T; X) \times L^2(0, T; U) \rightarrow \mathbb{R}$ 为凸且 Fréchet 可微。若

$$\bar{u} \in \operatorname{argmin}_{u \in \mathcal{U}_{\text{ad}}} F(Su, u),$$

则存在伴随状态 p , 使得对任意 $u \in \mathcal{U}_{\text{ad}}$ 都有

$$\langle S^* D_x F(S\bar{u}, \bar{u}) + D_u F(S\bar{u}, \bar{u}), u - \bar{u} \rangle \geq 0.$$

若再把约束集写成指标函数 $\iota_{\mathcal{U}_{\text{ad}}}$, 则上式等价于

$$0 \in S^* D_x F(S\bar{u}, \bar{u}) + D_u F(S\bar{u}, \bar{u}) + N_{\mathcal{U}_{\text{ad}}}(\bar{u}),$$

这就是控制问题的 Pontryagin/KKT 型一阶必要条件。

证明 定义复合泛函

$$\mathcal{J}(u) := F(Su, u).$$

由链式法则和定义 12.1.3,

$$\begin{aligned} D\mathcal{J}(\bar{u})h &= \langle D_x F(S\bar{u}, \bar{u}), Sh \rangle + \langle D_u F(S\bar{u}, \bar{u}), h \rangle \\ &= \langle S^* D_x F(S\bar{u}, \bar{u}) + D_u F(S\bar{u}, \bar{u}), h \rangle. \end{aligned}$$

由于 $\bar{u}$ 在闭凸集 $\mathcal{U}_{\text{ad}}$ 上最优, 应用第 6.2 节定义 6.2.2 所刻画的一阶变分和凸集上的最优性条件, 得到对任意 $u \in \mathcal{U}_{\text{ad}}$,

$$D\mathcal{J}(\bar{u})(u - \bar{u}) \geq 0.$$

代入上式便得

$$\langle S^* D_x F(S\bar{u}, \bar{u}) + D_u F(S\bar{u}, \bar{u}), u - \bar{u} \rangle \geq 0.$$

再由法锥与指标函数的次微分关系, 可将其改写为

$$0 \in S^* D_x F(S\bar{u}, \bar{u}) + D_u F(S\bar{u}, \bar{u}) + N_{\mathcal{U}_{\text{ad}}}(\bar{u}).$$

这与第 8.4 节定义 8.4.1 的驻点条件完全同型, 只是这里的原变量是控制轨道而不是有限维向量。

12.1.4 典型例子

例题 12.1 Hilbert 空间上的 LQR 考虑线性动力系统

$$\dot{x}(t) = Ax(t) + Bu(t), \quad x(0) = x_0,$$

以及二次成本

$$J(u) = \frac{1}{2} \int_0^T (\langle Qx(t), x(t) \rangle + \langle Ru(t), u(t) \rangle) dt + \frac{1}{2} \langle Gx(T), x(T) \rangle.$$

在 Q, R, G 正定时, J 是 Hilbert 空间上的严格凸二次泛函。把这个例子放在这里, 是为了把第 9.2 节二次规划与第 4.3 节伴随算子直接桥接到控制论。

例题 12.2 离散时间 MPC 的有限维坍塌 若把时间区间离散为有限网格, 并把状态方程改写为

$$x_{k+1} = A_k x_k + B_k u_k,$$

则整个控制问题坍塌为一个有限维约束优化或二次规划问题。把这个例子放在这里, 是为了说明 Boyd 中的 MPC

公式并不是另一套平行理论，而是定义 12.1.2 在离散时间与欧氏空间上的直接坍塌。

例题 12.3 库存-产能平滑控制 设 $x(t)$ 为库存水平， $u(t)$ 为生产速度，系统满足

$$\dot{x}(t) = u(t) - d(t),$$

并以

$$\int_0^T (c_1 x(t)^2 + c_2 u(t)^2) dt$$

为成本。该模型既可理解为管理科学中的资源调度，也可理解为最小量级的连续时间二次控制。把这个例子放在这里，是为了给第 12.2 节交易库存惩罚模型一个确定性基线。

有限维对照

Boyd 在有限维控制与 MPC 语境下更习惯直接写矩阵递推、Lagrangian 和 KKT 方程。本节的结论是：这些公式之所以成立，是因为离散时间与有限维把函数空间问题压缩成了标准 QP。一旦回到连续时间，真正需要先做的是定义 12.1.1 与定义 12.1.2 这样的对象整理，然后再用定理 12.1.1 和定理 12.1.2 把存在性与一阶条件接回 Boyd 的母语。有限维图像仍然重要，但它只是无穷维主线的坍塌形态。

习题（待补）

- 练习 12.1 直接法存在性占位 补一题：对一个给定的连续时间二次控制问题，验证定理 12.1.1 的假设，并说明极小化列为何在弱拓扑下预紧。
- 练习 12.2 伴随系统桥接题占位 补一题：从定理 12.1.2 出发，推导一个线性二次控制模型中的伴随方程，并写出其有限维矩阵坍塌。

12.2 量化金融中的随机优化

与上一节的确定性控制相比，量化交易中的真正难点并不只是噪声，而是决策本身必须适应信息流。策略是一个适应过程，财富是一个随机过程，风险约束则通常是终端损益或整个路径上的凸泛函。本节因此不把金融问题拆成“定价”和“交易”两本书，而是只保留与本书主线最贴合的部分：自融资策略、财富过程、凸风险度量、CVaR 约束，以及它们如何进入 Fenchel 对偶和 KKT 语言。

12.2.1 策略、财富过程与风险泛函

定义 12.2.1 (自融资策略)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为定义 3.4.1 的概率空间， $\{\mathcal{F}_t\}_{t \in [0, T]}$ 为滤过， $S = \{S_t\}_{t \in [0, T]}$ 为资产价格过程。若过程 $\pi = \{\pi_t\}_{t \in [0, T]}$ 适应于该滤过，并满足财富变化完全由持仓收益和交易成本决定，即

$$X_t^\pi = x_0 + \int_0^t \pi_s dS_s - \int_0^t c_s(\pi_s) ds,$$

则称 π 为一个自融资策略。

定义 12.2.2 (财富过程泛函)

在定义 12.2.1 的背景下，称

$$\pi \mapsto X_T^\pi$$

为与策略 π 对应的终端财富过程泛函。若再给定库存或冲击惩罚 $G(\pi)$ ，则随机优化目标常写成

$$\mathcal{J}(\pi) := \rho(-X_T^\pi) + G(\pi),$$

其中 ρ 是某个风险泛函。

定义 12.2.3 (凸风险度量)

定义在 $L^1(\Omega, \mathcal{F}, \mathbb{P})$ 上的泛函 ρ 称为一个凸风险度量, 若对任意随机损失 L, L_1, L_2 和 $\lambda \in [0, 1]$ 满足:

1. 单调性: 若 $L_1 \leq L_2$ a.s., 则 $\rho(L_1) \leq \rho(L_2)$;
2. 平移不变性: 对任意常数 m ,

$$\rho(L + m) = \rho(L) + m;$$

3. 凸性:

$$\rho(\lambda L_1 + (1 - \lambda)L_2) \leq \lambda \rho(L_1) + (1 - \lambda)\rho(L_2).$$

定义 12.2.4 (CVaR)

设损失随机变量 $L \in L^1$, 置信水平 $\alpha \in (0, 1)$ 。定义

$$\text{CVaR}_\alpha(L) := \inf_{\eta \in \mathbb{R}} \left\{ \eta + \frac{1}{1 - \alpha} \mathbb{E}[(L - \eta)_+] \right\}.$$

它称为损失 L 在水平 α 下的条件风险价值。

12.2.2 CVaR 的对偶表达与风险约束

命题 12.2.1 (CVaR 的对偶表示)

对任意 $L \in L^1$ 与 $\alpha \in (0, 1)$,

$$\text{CVaR}_\alpha(L) = \sup \left\{ \mathbb{E}[ZL] : Z \geq 0, \mathbb{E}[Z] = 1, Z \leq \frac{1}{1 - \alpha} \text{ a.s.} \right\}.$$

证明 由定义 12.2.4,

$$\text{CVaR}_\alpha(L) = \inf_{\eta \in \mathbb{R}} \left\{ \eta + \frac{1}{1 - \alpha} \mathbb{E}[(L - \eta)_+] \right\}.$$

对函数 $\varphi(r) = (r)_+$, 其共轭满足

$$\varphi^*(z) = \begin{cases} 0, & 0 \leq z \leq 1, \\ +\infty, & \text{otherwise.} \end{cases}$$

因此

$$\frac{1}{1 - \alpha} (L - \eta)_+ = \sup_{0 \leq Z \leq \frac{1}{1 - \alpha}} Z(L - \eta)$$

逐点成立。把该式代回并交换积分与上确界, 得到

$$\text{CVaR}_\alpha(L) = \inf_{\eta} \sup_{0 \leq Z \leq \frac{1}{1 - \alpha}} \{ \eta + \mathbb{E}[ZL] - \eta \mathbb{E}[Z] \}.$$

若 $\mathbb{E}[Z] \neq 1$, 则右侧关于 η 的仿射函数无下界; 故只有满足 $\mathbb{E}[Z] = 1$ 的 Z 才可能给出有限值。于是

$$\text{CVaR}_\alpha(L) = \sup \left\{ \mathbb{E}[ZL] : Z \geq 0, \mathbb{E}[Z] = 1, Z \leq \frac{1}{1 - \alpha} \text{ a.s.} \right\}.$$

结论成立。

注 命题 12.2.1 说明, CVaR 并不只是一个工程上“好算”的风险指标, 它本质上也是一个对偶对象。约束

$$\text{CVaR}_\alpha(L) \leq \tau$$

等价于一族有界密度权重下的最坏情形期望约束。这正是第 7.4 节定理 7.4.1 在风险建模中的典型落点。

12.2.3 交易执行与风险对偶

定理 12.2.1 (投资组合风险模型的对偶表达)

设 $\mathcal{A}$ 为一组自融资策略构成的非空闭凸集, $\pi \mapsto X_T^\pi$ 为从 $\mathcal{A}$ 到 L^1 的连续仿射映射, $G: \mathcal{A} \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函, ρ 为凸风险度量。若资格条件满足, 则原问题

$$\inf_{\pi \in \mathcal{A}} \{\rho(-X_T^\pi) + G(\pi)\}$$

与对偶问题

$$\sup_{Z \in L^\infty} \{-\rho^*(Z) - G^*(K^*Z)\}, \quad K\pi := -X_T^\pi,$$

具有相同最优值。任意最优原-对偶对 $(\bar{\pi}, \bar{Z})$ 还满足

$$\bar{Z} \in \partial\rho(-X_T^{\bar{\pi}}), \quad 0 \in K^*\bar{Z} + \partial G(\bar{\pi}) + N_{\mathcal{A}}(\bar{\pi}).$$

证明 把原问题写成

$$\inf_{\pi \in \mathcal{A}} \{\rho(K\pi) + G(\pi)\}.$$

由于 K 连续仿射且 $\mathcal{A}$ 闭凸, 可以把约束通过指标函数 $\iota_{\mathcal{A}}$ 吸收到 G 中, 从而得到标准的复合凸优化模板

$$\inf_{\pi} \{\rho(K\pi) + \tilde{G}(\pi)\}, \quad \tilde{G} := G + \iota_{\mathcal{A}}.$$

现在直接应用第 7.4 节定理 7.4.1, 得到

$$\inf_{\pi} \{\rho(K\pi) + \tilde{G}(\pi)\} = \sup_Z \{-\rho^*(Z) - \tilde{G}^*(K^*Z)\}.$$

又因为 $\tilde{G} = G + \iota_{\mathcal{A}}$, 其最优性条件由第 8.4 节推论 8.4.1 改写为

$$\bar{Z} \in \partial\rho(-X_T^{\bar{\pi}}), \quad 0 \in K^*\bar{Z} + \partial G(\bar{\pi}) + N_{\mathcal{A}}(\bar{\pi}).$$

这正是所述原-对偶条件。对偶变量 $\bar{Z}$ 因而可以被解释为风险约束下的影子价格或极端情景权重。

12.2.4 典型例子

例题 12.4 单期均值-方差组合作为有限维坍塌 若交易只发生在一个时点, 策略退化为有限维向量 w , 则问题

$$\min_w \left\{ -\mu^\top w + \frac{\lambda}{2} w^\top \Sigma w \right\}$$

正是 Boyd 书中最熟悉的均值-方差模型。把这个例子放在这里, 是为了说明定义 12.2.1 和定义 12.2.2 在单期下会完全压缩成有限维投资组合优化。

例题 12.5 CVaR 约束下的策略优化 若把终端损失写成 $L(\pi)$, 并加入约束

$$\text{CVaR}_\alpha(L(\pi)) \leq \tau,$$

则命题 12.2.1 把它改写成有界密度约束下的最坏期望控制。把这个例子放在这里, 是为了把无穷维随机策略与第 7 章共轭理论真正接起来。

例题 12.6 带交易成本与库存惩罚的执行模型 设 π_t 为交易速度, q_t 为库存, 系统满足

$$\dot{q}_t = -\pi_t,$$

成本由冲击项 $\int_0^T c(\pi_t) dt$ 与库存风险项 $\int_0^T \gamma q_t^2 dt$ 组成。该模型是量化交易执行与风险控制的标准原型。把这个例子放在这里, 是为了给下一节的 Bellman 动态规划一个直接前导。

例题 12.7 风险中性测度作为背景例子 在无套利定价里, 对偶变量常被解释为等价鞅测度。把这个例子放在这里, 只是为了提醒读者: 金融中的“对偶价格”并不总是抽象泛函, 它有时可以被识别为某种情景加权或测度变换; 但本章主线仍然是交易执行与风险控制, 而不是一般 FTAP 理论。

有限维对照

Boyd 中的均值-方差、鲁棒优化和 CVaR 常以向量权重、样本平均和线性约束出现，因此读者很容易把它们理解成纯粹的有限维数据分析模型。本节说明，一旦把策略扩展成适应过程，真正控制问题结构的对象就变成了定义 12.2.1 的策略空间、定义 12.2.2 的财富泛函以及定理 12.2.1 的原-对偶接口。有限维模型依旧是 Boyd 母语，但它只是过程空间优化的坍塌版本。

习题（待补）

- 练习 12.3 CVaR 对偶表示占位 补一题：从定义 12.2.4 出发，重复命题 12.2.1 的推导，并解释有界密度约束的经济含义。
- 练习 12.4 交易执行桥接题占位 补一题：把一个带库存惩罚的交易执行模型写成定理 12.2.1 的标准形式，并指出对偶变量对应的影子价格。

12.3 随机控制与 Bellman 动态规划

上一节已经把交易执行与风险控制写成了适应过程上的凸优化问题，但这还没有回答一个更动态的问题：当决策要在每个时刻随状态和信息更新时，如何把整个问题拆成逐时递推的结构？Bellman 动态规划给出的答案是价值函数。它把“从当前状态出发的最优剩余成本”重新编码成一个函数，于是控制问题不再只是单个极小化，而是一个由 Bellman 算子驱动的递推系统。本节因此既是随机控制的结构入口，也是从 Itô 分析走向 HJB 方程的过渡层。

12.3.1 价值函数与 Bellman 算子

定义 12.3.1 (随机控制的价值函数)

考虑离散时间随机控制系统

$$X_{k+1} = F_k(X_k, u_k, \xi_{k+1}), \quad k = 0, 1, \dots, N-1,$$

其中 $\{\xi_k\}$ 为噪声序列，控制 u_k 对给定滤过适应。若阶段成本为 $\ell_k(x, u)$ ，终端成本为 $g(x)$ ，则从时刻 k 和状态 x 出发的价值函数定义为

$$V_k(x) := \inf_{u_k, \dots, u_{N-1}} \mathbb{E} \left[\sum_{j=k}^{N-1} \ell_j(X_j, u_j) + g(X_N) \mid X_k = x \right].$$

定义 12.3.2 (Bellman 算子)

对任意函数 φ ，定义时刻 k 的 Bellman 算子为

$$(\mathcal{T}_k \varphi)(x) := \inf_{u \in \mathcal{U}(x)} \mathbb{E} [\ell_k(x, u) + \varphi(F_k(x, u, \xi_{k+1}))],$$

其中 $\mathcal{U}(x)$ 是状态 x 下允许的控制集合。

注 定义 12.3.1 的关键不在于“递归求值”，而在于它把原本住在策略空间中的优化问题压缩成了状态空间上的函数问题。这样一来，第 12.2 节的自融资策略可以被视作 Bellman 递推中的控制输入，而策略空间的复杂性则被转移到价值函数和 Bellman 算子的性质分析中。

12.3.2 动态规划原理

定理 12.3.1 (动态规划原理)

在定义 12.3.1 的离散时间框架下, 对每个 $k = 0, 1, \dots, N-1$ 都有

$$V_k = \mathcal{T}_k V_{k+1}, \quad V_N = g.$$

换言之,

$$V_k(x) = \inf_{u \in \mathcal{U}(x)} \mathbb{E}[\ell_k(x, u) + V_{k+1}(F_k(x, u, \xi_{k+1}))].$$

证明 固定时刻 k 与状态 x . 对任意 admissible 策略序列 $(u_k, \dots, u_{N-1})$, 先把总成本拆成第一步成本与剩余成本:

$$\sum_{j=k}^{N-1} \ell_j(X_j, u_j) + g(X_N) = \ell_k(x, u_k) + \sum_{j=k+1}^{N-1} \ell_j(X_j, u_j) + g(X_N).$$

对条件期望应用定义 3.4.2 的塔性质, 得到

$$\begin{aligned} & \mathbb{E} \left[\sum_{j=k}^{N-1} \ell_j(X_j, u_j) + g(X_N) \mid X_k = x \right] \\ &= \mathbb{E} \left[\ell_k(x, u_k) + \mathbb{E} \left[\sum_{j=k+1}^{N-1} \ell_j(X_j, u_j) + g(X_N) \mid X_{k+1} \right] \mid X_k = x \right]. \end{aligned}$$

内层条件期望按定义恰好不小于 $V_{k+1}(X_{k+1})$, 于是对任意第一步控制 u 都有

$$V_k(x) \geq \inf_{u \in \mathcal{U}(x)} \mathbb{E}[\ell_k(x, u) + V_{k+1}(F_k(x, u, \xi_{k+1}))].$$

反过来, 对任意 $\varepsilon > 0$, 可为下一阶段选取 ε -最优策略, 使剩余成本不超过 V_{k+1} 加上 ε . 再把第一步控制与该近似最优尾部策略拼接, 就得到反向不等式. 令 $\varepsilon \downarrow 0$ 即得

$$V_k = \mathcal{T}_k V_{k+1}.$$

12.3.3 Bellman 迭代下的凸性保持

命题 12.3.1 (Bellman 算子的凸性保持)

假设状态动力学对 (x, u) 仿射, 控制集 $\mathcal{U}(x)$ 在相应意义下凸, 阶段成本 $\ell_k(x, u)$ 关于 (x, u) 凸且下半连续, 且 φ 为凸下半连续函数. 则 Bellman 算子 $\mathcal{T}_k$ 仍将 φ 送到一个凸下半连续函数:

$$\varphi \text{ 凸下半连续} \implies \mathcal{T}_k \varphi \text{ 凸下半连续}.$$

证明 固定任意两个状态 x_1, x_2 与 $\lambda \in [0, 1]$, 记

$$x_\lambda := \lambda x_1 + (1 - \lambda)x_2.$$

任取 $u_i \in \mathcal{U}(x_i)$, 并令

$$u_\lambda := \lambda u_1 + (1 - \lambda)u_2 \in \mathcal{U}(x_\lambda).$$

由动力学的仿射性,

$$F_k(x_\lambda, u_\lambda, \xi) = \lambda F_k(x_1, u_1, \xi) + (1 - \lambda)F_k(x_2, u_2, \xi).$$

再由 ℓ_k 与 φ 的凸性,

$$\begin{aligned} & \ell_k(x_\lambda, u_\lambda) + \varphi(F_k(x_\lambda, u_\lambda, \xi)) \\ & \leq \lambda [\ell_k(x_1, u_1) + \varphi(F_k(x_1, u_1, \xi))] + (1 - \lambda) [\ell_k(x_2, u_2) + \varphi(F_k(x_2, u_2, \xi))]. \end{aligned}$$

对噪声取期望，并在两边分别对控制取下确界，即得

$$(\mathcal{T}_k \varphi)(x_\lambda) \leq \lambda(\mathcal{T}_k \varphi)(x_1) + (1 - \lambda)(\mathcal{T}_k \varphi)(x_2).$$

因此 $\mathcal{T}_k \varphi$ 凸。下半连续性由期望的线性、积分型下半连续性以及对控制取下确界的稳定性得到。

注[HJB 极限接口] 若把离散时间步长缩小到 Δt ，并将状态递推写成

$$X_{k+1} = X_k + b(X_k, u_k)\Delta t + \sigma(X_k, u_k)\Delta W_k,$$

则动态规划原理配合定理 3.4.1 的 Itô 展开，在形式上导出连续时间 HJB 方程

$$-\partial_t V(t, x) = \inf_u \left\{ \ell(x, u) + \langle b(x, u), \nabla_x V(t, x) \rangle + \frac{1}{2} \text{Tr}(\sigma \sigma^\top(x, u) \nabla_x^2 V(t, x)) \right\}.$$

这一极限接口是随机控制和 PDE 之间最重要的桥，但本书不在此展开完整的 viscosity solution 理论；本节只强调它与 Bellman 递推的结构联系。

12.3.4 典型例子

例题 12.8 最优执行的离散 Bellman 递推 设状态为当前库存 q_k 和价格因子 Y_k ，控制为交易速度 u_k ，并满足

$$q_{k+1} = q_k - u_k.$$

若阶段成本由冲击项、库存风险项和成交偏差组成，则价值函数满足一个显式的 Bellman 递推。把这个例子放在这里，是为了说明第 12.2 节的交易执行模型一旦按时间展开，就自然进入定义 12.3.2 的框架。

例题 12.9 连续时间二次执行模型的 HJB 影子 在 Almgren–Chriss 型连续时间执行模型中，价值函数通常满足一个二次结构的 HJB 方程。把这个例子放在这里，是为了说明 remark 12.3.3 不是形式游戏，而是交易执行与随机控制之间的真实接口。

例题 12.10 受风险约束的随机控制 若在 Bellman 递推中额外引入

$$\text{CVaR}_\alpha$$

或其他凸风险度量，就会得到一个扩展状态变量或拉格朗日乘子的动态规划系统。把这个例子放在这里，是为了把第 12.2 节的风险约束与本节的价值函数方法真正闭环。

有限维对照

Boyd 更常从有限维动态规划、LQR 递推或最短路式 Bellman 方程讲起，因此状态和控制都默认是向量。本节说明，这些写法依旧是正确的，但它们只是定义 12.3.1 和定理 12.3.1 在有限维 Markov 控制中的坍塌版本。真正重要的是：Bellman 方法把策略空间极小化重新编码成状态空间上的函数递推，而这一点在无穷维控制、过程控制和量化交易中同样成立。与第 11.1 节前向–后向分裂一样，它的核心不是公式多漂亮，而是结构能否稳定传递。

习题（待补）

- 🔥 **练习 12.5 Bellman 递推占位** 补一题：对一个有限时域最优清算模型写出价值函数和 Bellman 算子，并从定理 12.3.1 推导递推公式。
- 🔥 **练习 12.6 HJB 接口桥接题占位** 补一题：从离散时间执行模型出发，解释 remark 12.3.3 中 HJB 方程的 formal limit 是如何出现的，并指出其中用到了哪一步 Itô 语法。

第 13 章 图网络、表示学习与智能推荐系统

到第 12 章为止，本书已经把无穷维凸优化的主要技术链搭建完成：第 4 章给出 Hilbert 空间与谱论工作台，第 6 章和第 7 章给出次微分与共轭对偶语言，第 10 章和第 11 章把这些对象组织成可计算的算子分裂与 ADMM 模板，第 12 章则说明它们如何落到控制与金融建模。本章继续沿着这条主线向前推进，不过对象从控制轨道与财富过程换成了现代学习系统中的函数表示、图结构与分布式一致性。

本章沿四条线索展开。第 13.1 节讨论 RKHS 与 Representer Theorem，说明为什么“在无限维函数空间学习”仍可坍塌为有限样本系数问题。第 13.2 节把图拉普拉斯、Dirichlet 能量与消息传递放进谱论和邻近算子的语言，解释图学习中真正可被凸优化准确接口化的部分。第 13.3 节转向多塔表示与匹配问题，用核化或 lifted 的凸 surrogate 解释双塔检索、对比学习与影子价格。最后，第 13.4 节把第 11 章的 ADMM 与原-对偶分裂落到推荐系统中的共识训练、分片嵌入与图正则模型。

本章不是独立的机器学习教材，也不会把一般深度非凸训练硬写成凸优化。我们只处理那些能够被无穷维凸分析、谱论、单调算子或 ADMM 语言稳定刻画的结构：核方法、图平滑、凸匹配 surrogate 和分布式一致性。Boyd 的有限维表达依旧是重要母语，但在这里，它们被用来说明欧氏模型如何坍塌自更一般的函数空间与算子框架，而不是作为唯一舞台。

13.1 再生核 Hilbert 空间

本节的任务是把表示学习中最稳定的一条主线写回泛函分析：不是直接讨论网络参数，而是先讨论函数类本身。RKHS 的重要性在于，它允许我们一方面保留无限维函数空间的表达力，另一方面又通过样本点评价把问题压缩到有限参数。这个压缩并不是经验技巧，而是 Hilbert 空间几何、直接法存在性和正则化共同作用的结果。

13.1.1 正定核与 RKHS

定义 13.1.1 (正定核)

设 X 为非空集合。函数

$$K: X \times X \rightarrow \mathbb{R}$$

称为 X 上的正定核，如果对任意有限点集 $x_1, \dots, x_m \in X$ 与任意系数 $c_1, \dots, c_m \in \mathbb{R}$ ，都有

$$\sum_{i,j=1}^m c_i c_j K(x_i, x_j) \geq 0.$$

定义 13.1.2 (再生核 Hilbert 空间)

设 K 为定义 13.1.1 的正定核。若 Hilbert 空间 $\mathcal{H}_K$ 由定义在 X 上的实值函数组成，并满足：

1. 对任意 $x \in X$ ，函数 $K_x := K(x, \cdot)$ 属于 $\mathcal{H}_K$ ；
2. 对任意 $f \in \mathcal{H}_K$ 与任意 $x \in X$ ，

$$f(x) = \langle f, K_x \rangle_{\mathcal{H}_K},$$

则称 $\mathcal{H}_K$ 为核 K 的再生核 Hilbert 空间。

命题 13.1.1 (点评价泛函连续)

在定义 13.1.2 的条件下，对任意 $x \in X$ ，点评价映射

$$\delta_x: \mathcal{H}_K \rightarrow \mathbb{R}, \quad \delta_x(f) = f(x)$$

是连续线性泛函，并满足估计

$$|f(x)| \leq \|f\|_{\mathcal{H}_K} \sqrt{K(x, x)}, \quad \forall f \in \mathcal{H}_K.$$

证明 线性性显然。由再生性质，

$$f(x) = \langle f, K_x \rangle_{\mathcal{H}_K}.$$

再由 Cauchy–Schwarz 不等式，

$$|f(x)| \leq \|f\|_{\mathcal{H}_K} \|K_x\|_{\mathcal{H}_K}.$$

而

$$\|K_x\|_{\mathcal{H}_K}^2 = \langle K_x, K_x \rangle_{\mathcal{H}_K} = K(x, x),$$

故结论成立。

注 命题 13.1.1 把 RKHS 与第 4.1 节定义 4.1.3 及定理 4.1.2 直接接了起来：样本点评价之所以能够被写成内积，不是因为数据科学中特殊的坐标技巧，而是因为在 Hilbert 空间里连续线性泛函本来就能由向量表示。

13.1.2 Tikhonov 正则化与表示定理

在样本 $x_1, \dots, x_m \in \mathcal{X}$ 上，考虑带 Tikhonov 项的学习问题

$$\min_{f \in \mathcal{H}_K} \left\{ \Phi(f(x_1), \dots, f(x_m)) + \lambda \|f\|_{\mathcal{H}_K}^2 \right\}, \quad \lambda > 0,$$

其中 $\Phi: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函。由于正则项强制了 $\mathcal{H}_K$ 范数，结合命题 13.1.1 的连续性，上式正是第 6.1 节定理 6.1.2 可处理的 Hilbert 空间直接法模型。

定理 13.1.1 (Representer Theorem)

设 Φ 与 λ 如上。若 $f_\star$ 是问题

$$\min_{f \in \mathcal{H}_K} \left\{ \Phi(f(x_1), \dots, f(x_m)) + \lambda \|f\|_{\mathcal{H}_K}^2 \right\}$$

的极小元，则存在系数 $\alpha_1, \dots, \alpha_m \in \mathbb{R}$ 使

$$f_\star(\cdot) = \sum_{i=1}^m \alpha_i K(x_i, \cdot).$$

换言之，极小元一定落在有限维子空间

$$\text{span}\{K(x_1, \cdot), \dots, K(x_m, \cdot)\}$$

中。

证明 记

$$M := \text{span}\{K(x_1, \cdot), \dots, K(x_m, \cdot)\} \subset \mathcal{H}_K.$$

由第 4.1 节定理 4.1.1，任意 $f \in \mathcal{H}_K$ 都可唯一分解为

$$f = f_M + f_\perp, \quad f_M \in M, \quad f_\perp \in M^\perp.$$

由于 $f_\perp \perp K(x_i, \cdot)$ ，对每个样本点 x_i 有

$$f_\perp(x_i) = \langle f_\perp, K(x_i, \cdot) \rangle_{\mathcal{H}_K} = 0.$$

因此

$$f(x_i) = f_M(x_i), \quad i = 1, \dots, m,$$

从而数据项只依赖于 f_M ：

$$\Phi(f(x_1), \dots, f(x_m)) = \Phi(f_M(x_1), \dots, f_M(x_m)).$$

另一方面，由正交分解，

$$\|f\|_{\mathcal{H}_K}^2 = \|f_M\|_{\mathcal{H}_K}^2 + \|f_\perp\|_{\mathcal{H}_K}^2 \geq \|f_M\|_{\mathcal{H}_K}^2.$$

故对任意 $f \in \mathcal{H}_K$ ，

$$\Phi(f(x_1), \dots, f(x_m)) + \lambda \|f\|_{\mathcal{H}_K}^2 \geq \Phi(f_M(x_1), \dots, f_M(x_m)) + \lambda \|f_M\|_{\mathcal{H}_K}^2.$$

这说明把 f 替换成其在 M 上的正交投影不会增大目标值。于是任何极小元都可取在 M 中。由于 M 由核截面张成，结论成立。

注 定理 13.1.1 是本章最关键的有限样本坍缩结论。它告诉我们：无限维函数学习并没有被偷偷地变成有限维，而是在样本驱动与二次正则的共同作用下，自然塌缩到了一个由数据决定的有限维截面空间。若把目标写成

$$F(f) := \Phi(Cf) + \lambda \|f\|_{\mathcal{H}_K}^2,$$

则最优性条件可以进一步写成

$$0 \in C^* \partial \Phi(Cf_\star) + 2\lambda f_\star,$$

这正是第 6.3 节定义 6.3.1 的函数空间版本。

13.1.3 典型例子

例题 13.1 核岭回归 取

$$\Phi(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m (z_i - y_i)^2.$$

则相应问题为

$$\min_{f \in \mathcal{H}_K} \left\{ \frac{1}{m} \sum_{i=1}^m (f(x_i) - y_i)^2 + \lambda \|f\|_{\mathcal{H}_K}^2 \right\}.$$

由定理 13.1.1，极小元可写成

$$f_\star(\cdot) = \sum_{i=1}^m \alpha_i K(x_i, \cdot).$$

把它代回目标，即得到关于系数向量 α 的有限维二次规划。把这个例子放在这里，是为了说明 RKHS 并不排斥可计算性；相反，它给出了核岭回归这类算法的最自然理论母体。

例题 13.2 有限维线性回归的坍缩 若核取为线性核

$$K(x, x') = \langle x, x' \rangle_{\mathbb{R}^d},$$

则 $\mathcal{H}_K$ 与 $\mathbb{R}^d$ 等同，函数 f 由向量 w 表示为 $f(x) = \langle w, x \rangle$ 。此时定理 13.1.1 退化为

$$w_\star \in \text{span}\{x_1, \dots, x_m\},$$

这正是有限维线性回归的经典结论。

例题 13.3 文本与政策匹配中的核表示 在政策文本检索或企业画像匹配中，常把文档先映射到高维语义特征，再以核函数近似相似性。若学习目标是正则化经验风险，则定理 13.1.1 说明最优匹配函数只由训练样本对应的核截面张成。把这个例子放在这里，是为了给第 13.3 节的多塔匹配问题准备一个函数空间入口。

有限维对照

Boyd 在有限维正则化模型里常把岭回归写成矩阵方程或二次规划；这当然是正确的，但它默认参数已经是一个向量。本节的结论说明，Boyd 的有限维公式并不是与函数学习平行的一套理论，而是 RKHS 正则化经过定理 13.1.1 坍缩后的欧氏版本。正因为如此，后文谈图表示、检索匹配与分布式训练时，才能不断把现代学习对象重新翻译回 Hilbert 空间与凸优化语法。

习题（待补）

- 🔥 **练习 13.1 表示定理占位** 补一题：把定理 13.1.1 中的二次正则替换成严格单调的范数函数，说明表示定理仍如何成立。
- 🔥 **练习 13.2 核岭回归系数占位** 补一题：对例 13.1 写出 Gram 矩阵形式的系数方程，并说明它如何退化为有限维岭回归。

13.2 图神经网络的泛函算子解释

图神经网络最常见的工程描述是“聚合邻居再更新表示”，但若只停留在这个层面，很多关键结构都会被遮蔽：为什么图卷积总要与拉普拉斯或归一化邻接联系在一起，为什么平滑、扩散和低通滤波会反复出现，以及哪些图学习步骤真的能够被第 10 章和第 11 章的算子语言准确接口化。本节选择从图拉普拉斯与 Dirichlet 能量出发，抓住那些可被谱论、prox 和分裂方法稳定描述的部分。

13.2.1 图信号、拉普拉斯与能量

定义 13.2.1 (图拉普拉斯算子)

设 $\mathcal{G} = (V, E, w)$ 为有限加权无向图，其中 $V = \{1, \dots, n\}$ ，边权满足 $w_{ij} = w_{ji} \geq 0$ 。记图信号空间

$$H_V := \mathbb{R}^n$$

并赋予标准内积。定义图拉普拉斯算子 $L_{\mathcal{G}}: H_V \rightarrow H_V$ 为

$$(L_{\mathcal{G}}u)_i := \sum_{j=1}^n w_{ij}(u_i - u_j), \quad i = 1, \dots, n.$$

♣

定义 13.2.2 (图 Dirichlet 能量)

在定义 13.2.1 的条件下，称泛函

$$\mathcal{E}_{\mathcal{G}}(u) := \frac{1}{2} \sum_{i,j=1}^n w_{ij}(u_i - u_j)^2$$

为图 $\mathcal{G}$ 上信号 u 的 Dirichlet 能量。

♣

命题 13.2.1 (图拉普拉斯的正性)

算子 $L_{\mathcal{G}}$ 是 H_V 上的自伴正半定算子，并满足

$$\langle L_{\mathcal{G}}u, u \rangle = \mathcal{E}_{\mathcal{G}}(u), \quad \forall u \in H_V.$$

♣

证明 由权重对称性，

$$\langle L_{\mathcal{G}}u, v \rangle = \sum_{i=1}^n \sum_{j=1}^n w_{ij}(u_i - u_j)v_i = \frac{1}{2} \sum_{i,j=1}^n w_{ij}(u_i - u_j)(v_i - v_j),$$

交换 u, v 可知它自伴。令 $v = u$ ，得到

$$\langle L_{\mathcal{G}}u, u \rangle = \frac{1}{2} \sum_{i,j=1}^n w_{ij}(u_i - u_j)^2 = \mathcal{E}_{\mathcal{G}}(u) \geq 0.$$

故 $L_{\mathcal{G}}$ 正半定。

注 由于 H_V 是有限维 Hilbert 空间， $L_{\mathcal{G}}$ 同时还是紧自伴算子。于是第 4.4 节定理 4.4.1 可直接应用于它：图傅里叶基、特征值平滑强度和谱滤波，本质上都是紧自伴谱理论在图上的有限维坍塌。

13.2.2 消息传递与图滤波

命题 13.2.2 (消息传递是图滤波的一种线性原型)

设 p 为一元多项式, 则算子

$$T_p := p(L_{\mathcal{G}})$$

与 $L_{\mathcal{G}}$ 共享同一组特征向量, 因此是一个图谱滤波器。特别地, 线性消息传递层

$$u^+ = (I - \tau L_{\mathcal{G}})u, \quad 0 < \tau < \|L_{\mathcal{G}}\|^{-1},$$

对应于一阶低通图滤波; 若再附加逐点非线性与通道权矩阵, 就得到常见 GNN 层的线性骨架。

证明 由定理 4.4.1, 存在正交基 $\{e_k\}_{k=1}^n$ 与实特征值 $\lambda_k \geq 0$, 使

$$L_{\mathcal{G}} e_k = \lambda_k e_k.$$

于是

$$T_p e_k = p(\lambda_k) e_k,$$

故 T_p 与 $L_{\mathcal{G}}$ 同时对角化。特别地, 当 $p(\lambda) = 1 - \tau\lambda$ 时,

$$T_p = I - \tau L_{\mathcal{G}},$$

它衰减高频特征模态, 正是一阶低通滤波。

定理 13.2.1 (图扩散与学习接口)

设 $\tau > 0$, $y \in H_V$ 。则问题

$$\min_{u \in H_V} \left\{ \frac{1}{2} \|u - y\|^2 + \tau \mathcal{E}_{\mathcal{G}}(u) \right\}$$

有唯一极小元 u_τ , 并满足

$$u_\tau = (I + \tau L_{\mathcal{G}})^{-1} y = \text{prox}_{\tau \mathcal{E}_{\mathcal{G}}}(y).$$

此外, 映射

$$y \mapsto (I - \tau L_{\mathcal{G}})y$$

是上述 resolvent 的一阶显式近似, 因此线性图扩散、图平滑和一类 GNN 消息传递层都可被看成第 11.1 节定义 11.1.2 在图信号空间上的具体接口。

证明 由命题 13.2.1,

$$\mathcal{E}_{\mathcal{G}}(u) = \langle L_{\mathcal{G}} u, u \rangle$$

是凸二次型。故目标是严格凸连续函数, 唯一极小元存在。对极小元 u_τ 写一阶最优性条件,

$$0 = u_\tau - y + \tau L_{\mathcal{G}} u_\tau.$$

于是

$$(I + \tau L_{\mathcal{G}})u_\tau = y, \quad u_\tau = (I + \tau L_{\mathcal{G}})^{-1} y.$$

另一方面, 由定义 10.2.1, $\text{prox}_{\tau \mathcal{E}_{\mathcal{G}}}(y)$ 正是上式的唯一极小元, 故

$$u_\tau = \text{prox}_{\tau \mathcal{E}_{\mathcal{G}}}(y).$$

最后, 由 resolvent 展开

$$(I + \tau L_{\mathcal{G}})^{-1} y = y - \tau L_{\mathcal{G}} y + O(\tau^2),$$

可见显式一步 $y \mapsto y - \tau L_{\mathcal{G}} y$ 是对应的前向近似。

注 定理 13.2.1 只 formalize 那些可嵌入凸能量或算子分裂语言的图学习部分。一般深层 GNN 训练包含参数共享、

非线性组合与非凸优化；本节并不把这些内容伪装成凸问题，而是只抽取其中最稳定的图滤波、平滑与扩散骨架。

13.2.3 典型例子

例题 13.4 图平滑最小化 若 y 是带噪观测信号，则定理 13.2.1 给出的极小元平衡了数据保真和图平滑。这正是半监督学习、标签传播与图正则回归中的基础模型。

例题 13.5 邻接矩阵与归一化拉普拉斯的有限维坍塌 在有限图上，常见 GCN 层写作

$$H^+ = \sigma(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H W).$$

把

$$\tilde{L} := I - \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$$

代入，就得到

$$\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} = I - \tilde{L},$$

因此消息传递矩阵本质上就是一阶图滤波器。

例题 13.6 知识图谱与 item-item 推荐中的关系传播 在知识图谱推荐或 item-item 推荐中，边权编码相似度、共现或关系强度。若只保留图传播的线性骨架，则每一步更新都可解释为对邻域一致性和局部平滑的近似求解。把这个例子放在这里，是为了把 GNN 直接接到推荐系统的图结构接口上。

有限维对照

Boyd 不会直接讲 GNN，但他关于二次型、谱分解和分布式平滑的有限维母语，在这里仍然有效。区别只在于：工程上常把“邻接矩阵乘一次”当成一个架构模块，而本节说明它其实是图拉普拉斯谱滤波、Dirichlet 能量最小化以及 prox/前向步的一种坍塌实现。理解这一点以后，第 13.4 节的分布式图推荐模型就不再只是经验配方，而能重新接回 ADMM 与原-对偶分裂。

习题（待补）

- 🔴 **练习 13.3 图拉普拉斯正性占位** 补一题：证明命题 13.2.1，并说明常数信号为什么总落在零特征值对应空间中。
- 🔴 **练习 13.4 图扩散与 prox 占位** 补一题：从定理 13.2.1 出发，说明图扩散为何可以被写成定义 10.2.1 的邻近算子。

13.3 多塔模型与无限维特征匹配

推荐与检索系统中的双塔、多塔模型通常以工程术语出现：用户塔、物品塔、内积打分、负样本、对比学习。若直接沿着这条叙事线展开，很容易把关键数学结构埋进网络细节里。本节的做法是先把匹配问题写成 Hilbert 空间中的配对风险，再说明当我们采用核化特征、固定编码器或 lifted convex surrogate 时，这些工程对象如何进入第 7 章的对偶和第 8 章的 KKT 语言。

13.3.1 双塔表示与配对风险

定义 13.3.1 (双塔嵌入模型)

设 $\mathcal{X}, \mathcal{Y}$ 为两类对象的样本空间， $\mathcal{H}_X, \mathcal{H}_Y$ 为对应的 RKHS，核分别为 K_X, K_Y 。记张量积 Hilbert 空间

$$\mathcal{H} := \mathcal{H}_X \otimes \mathcal{H}_Y.$$

对任意 $M \in \mathcal{H}$ ，定义匹配得分

$$s_M(x, y) := \langle M, K_X(x, \cdot) \otimes K_Y(y, \cdot) \rangle_{\mathcal{H}}.$$

若

$$M = \sum_{r=1}^R u_r \otimes v_r,$$

则

$$s_M(x, y) = \sum_{r=1}^R u_r(x) v_r(y),$$

这给出一个 R 维双塔或多塔型表示。

定义 13.3.2 (配对损失泛函)

给定训练样本

$$\{(x_i, y_i, \varepsilon_i)\}_{i=1}^m \subset \mathcal{X} \times \mathcal{Y} \times \{-1, 1\},$$

以及凸损失函数 $\ell_i: \mathbb{R} \rightarrow \mathbb{R} \cup \{+\infty\}$, 定义配对损失

$$\mathcal{L}(M) := \sum_{i=1}^m \ell_i(\varepsilon_i s_M(x_i, y_i)).$$

其中 $\varepsilon_i = 1$ 表示正匹配, $\varepsilon_i = -1$ 表示负匹配。

定义 13.3.3 (对比风险泛函)

在定义 13.3.2 的背景下, 给定正则参数 $\lambda > 0$, 称

$$\mathcal{R}_\lambda(M) := \mathcal{L}(M) + \frac{\lambda}{2} \|M\|_{\mathcal{H}}^2$$

为对比风险泛函。它把配对损失与 Tikhonov 正则统一到同一个 Hilbert 空间优化模板中。

13.3.2 表示定理与对偶解释

命题 13.3.1 (双塔模型的表示定理)

设 $\mathcal{R}_\lambda$ 如定义 13.3.3, 并设其在 $\mathcal{H}$ 上有极小元 $M_\star$ 。则存在系数 $\alpha_1, \dots, \alpha_m \in \mathbb{R}$ 使

$$M_\star = \sum_{i=1}^m \alpha_i (K_X(x_i, \cdot) \otimes K_Y(y_i, \cdot)).$$

也就是说, 最优匹配算子总落在训练样本所张成的有限维张量子空间中。

证明 张量积空间 $\mathcal{H}$ 仍是 Hilbert 空间。令

$$\psi_i := K_X(x_i, \cdot) \otimes K_Y(y_i, \cdot), \quad M_0 := \text{span}\{\psi_1, \dots, \psi_m\}.$$

由定义 13.3.1,

$$s_M(x_i, y_i) = \langle M, \psi_i \rangle_{\mathcal{H}}.$$

因此对任意分解

$$M = M_0^\parallel + M_0^\perp, \quad M_0^\perp \in M_0^\perp,$$

都有

$$s_M(x_i, y_i) = s_{M_0^\parallel}(x_i, y_i), \quad i = 1, \dots, m.$$

于是配对损失只依赖 $M_0^\parallel$ 。另一方面,

$$\|M\|_{\mathcal{H}}^2 = \|M_0^\parallel\|_{\mathcal{H}}^2 + \|M_0^\perp\|_{\mathcal{H}}^2 \geq \|M_0^\parallel\|_{\mathcal{H}}^2.$$

故把 M 替换为 $M_0^\parallel$ 不会增大定义 13.3.3 的值。于是极小元可以取在 M_0 中。这个结论也可被视为定理 13.1.1 在

张量积 RKHS 上的直接应用。

定理 13.3.1 (正则化匹配模型的对偶表示)

设 $C: \mathcal{H} \rightarrow \mathbb{R}^m$ 为采样算子

$$CM := (\varepsilon_1 s_M(x_1, y_1), \dots, \varepsilon_m s_M(x_m, y_m)),$$

并设 $\Phi: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{+\infty\}$ 为 proper、凸且下半连续泛函。考虑原问题

$$\inf_{M \in \mathcal{H}} \left\{ \Phi(CM) + \frac{\lambda}{2} \|M\|_{\mathcal{H}}^2 \right\}.$$

则其对偶问题为

$$\sup_{\alpha \in \mathbb{R}^m} \left\{ -\Phi^*(\alpha) - \frac{1}{2\lambda} \|C^* \alpha\|_{\mathcal{H}}^2 \right\}.$$

若资格条件满足，则原-对偶最优解 $(M_\star, \alpha_\star)$ 满足

$$M_\star = -\frac{1}{\lambda} C^* \alpha_\star, \quad \alpha_\star \in \partial \Phi(CM_\star).$$

证明 设

$$f(M) := \frac{\lambda}{2} \|M\|_{\mathcal{H}}^2, \quad g(z) := \Phi(z), \quad A := C.$$

则原问题正是

$$\inf_{M \in \mathcal{H}} \{f(M) + g(AM)\}.$$

由于 $\mathcal{H}$ 是 Hilbert 空间， f 的共轭为

$$f^*(\Xi) = \frac{1}{2\lambda} \|\Xi\|_{\mathcal{H}}^2.$$

于是由第 7.4 节定理 7.4.1，

$$\inf_M \{f(M) + g(AM)\} = \sup_{\alpha \in \mathbb{R}^m} \{-f^*(-A^* \alpha) - g^*(\alpha)\}.$$

代入 f^* 与 $g^* = \Phi^*$ ，得到

$$\sup_{\alpha \in \mathbb{R}^m} \left\{ -\Phi^*(\alpha) - \frac{1}{2\lambda} \|C^* \alpha\|_{\mathcal{H}}^2 \right\}.$$

再由推论 8.4.1，原-对偶最优性等价于

$$-C^* \alpha_\star \in \partial f(M_\star), \quad \alpha_\star \in \partial \Phi(CM_\star).$$

而

$$\partial f(M) = \{\lambda M\},$$

故

$$M_\star = -\frac{1}{\lambda} C^* \alpha_\star.$$

结论成立。

注 定理 13.3.1 说明，对比学习中的负样本权重、困难样本放大和约束影子价格，都可以通过对偶变量 α 统一理解。这里的关键不是把所有深度 encoder 证明成凸的，而是识别出当特征固定、核化近似或 lifted surrogate 成立时，匹配问题的确能进入 Fenchel 与 KKT 框架。

13.3.3 典型例子

例题 13.7 矩阵分解与双线性匹配的有限维坍塌 若

$$\mathcal{H}_X = \mathbb{R}^P, \quad \mathcal{H}_Y = \mathbb{R}^Q,$$

则 $\mathcal{H}_X \otimes \mathcal{H}_Y$ 可识别为 $p \times q$ 矩阵空间, M 退化为双线性打分矩阵,

$$s_M(x, y) = x^\top M y.$$

工业界常见的双塔参数化 $M = UV^\top$ 是它的低秩非凸特化; 而本节讨论的是对完整矩阵或其凸 surrogate 的优化。

例题 13.8 双塔检索的核化解释 在用户检索和召回场景中, 常把查询与文档分别映射到公共向量空间, 再用内积评分。若我们固定编码特征, 只优化最终匹配算子 M , 则定义 13.3.3 就给出了该模型的凸风险版本。

例题 13.9 政策-企业匹配 把政策文本与企业画像分别看成 $\mathcal{X}$ 与 $\mathcal{Y}$ 中的对象, 匹配目标是学得一个高分表示“政策适配”的双塔得分函数。把这个例子放在这里, 是为了强调第 13.1 节的 RKHS 入口并不是抽象装饰, 而可以直接进入政企推荐和政策匹配等实际建模。

有限维对照

Boyd 并不直接讲双塔检索, 但他关于正则化经验风险、线性算子复合和对偶变量的有限维语言, 在本节仍然完全适用。差别只在于: 现代推荐系统把“参数向量”换成了表示函数、张量特征与配对算子。理解这一点以后, 双塔、多塔、对比学习就不再只是模型工程术语, 而是可以被看成 RKHS 表示定理加上 Fenchel 对偶后的有限维坍缩。

习题 (待补)

- 练习 13.5 张量表示定理占位 补一题: 证明命题 13.3.1, 并写出最优算子所在的有限维张量子空间。
- 练习 13.6 匹配对偶占位 补一题: 对平方损失或 logistic 型对比学习 surrogate, 写出定理 13.3.1 的对偶问题, 并解释对偶变量的负样本权重含义。

13.4 大型系统的分布式求解

前两节把表示函数和图结构都放回了 Hilbert 空间与谱论语言; 真正的大型推荐系统还需要最后一步: 把这些模型拆到多机、多分片和多数数据块上求解。此时关键对象不再只是单个目标函数, 而是局部子问题、全局一致性约束和乘子更新。本节把这部分内容统一写成第 11.3 节 ADMM 的应用层接口。

13.4.1 共识模型与分片嵌入

定义 13.4.1 (分布式共识模型)

设 Z 为 Hilbert 空间, $Z_1, \dots, Z_N$ 为局部副本空间, $P_i: Z \rightarrow Z_i$ 为有界线性算子。若优化问题写成

$$\min_{z \in Z, z_i \in Z_i} \left\{ \sum_{i=1}^N F_i(z_i) + G(z) : z_i = P_i z, i = 1, \dots, N \right\},$$

其中 F_i, G 为 proper、凸且下半连续泛函, 则称其为一个分布式共识模型。

定义 13.4.2 (分片嵌入问题)

在定义 13.4.1 的背景下, 若 z 表示全局 embedding 参数, z_i 表示第 i 个工作节点上的局部参数副本, 而 F_i 编码该节点的局部样本损失、图正则或匹配风险, 则称该模型为分片嵌入问题。

13.4.2 ADMM 形式与局部更新

命题 13.4.1 (共识模型的 ADMM 分裂)

定义 13.4.1 的问题可写成第 8.2 节定义 8.2.1 的线性约束标准型。对给定罚参数 $\rho > 0$ ，其 ADMM 迭代可写为

$$\begin{aligned} z_i^{k+1} &\in \arg \min_{z_i} \left\{ F_i(z_i) + \langle y_i^k, z_i - P_i z^k \rangle + \frac{\rho}{2} \|z_i - P_i z^k\|^2 \right\}, \\ z^{k+1} &\in \arg \min_z \left\{ G(z) - \sum_{i=1}^N \langle y_i^k, P_i z \rangle + \frac{\rho}{2} \sum_{i=1}^N \|z_i^{k+1} - P_i z\|^2 \right\}, \\ y_i^{k+1} &= y_i^k + \rho(z_i^{k+1} - P_i z^{k+1}), \quad i = 1, \dots, N. \end{aligned}$$

证明 令

$$X := Z_1 \times \dots \times Z_N, \quad x := (z_1, \dots, z_N), \quad f(x) := \sum_{i=1}^N F_i(z_i).$$

再令

$$Bz := (P_1 z, \dots, P_N z) \in X, \quad g(z) := G(z).$$

则原问题等价于

$$\min_{x, z} \{f(x) + g(z) : x - Bz = 0\}.$$

这正是第 11.3 节定义 11.3.2 的两块线性约束模型，其中 $A = I$ 、 $B = -B$ 、 $b = 0$ 。把定义 11.3.2 直接展开到乘积空间，即得到所述更新式。

定理 13.4.1 (分布式推荐模型的收敛模板)

设定义 13.4.1 的问题存在鞍点，且命题 13.4.1 给出的各步极小化子问题都可解。则相应 ADMM 序列满足：

1. 原残差

$$r_i^k := z_i^k - P_i z^k$$

收敛到 0；

2. 对偶残差收敛到 0；

3. 任意弱聚点都是该共识模型的原-对偶解。

特别地，若解集为单点，则整个序列弱收敛到该解。

证明 把命题 13.4.1 中的乘积空间模型视为第 11.3 节两块问题的特例。此时

$$f(x) = \sum_{i=1}^N F_i(z_i), \quad g(z) = G(z),$$

而约束算子是有界线性的。于是第 11.3 节定理 11.3.1 可直接应用，得到原残差和对偶残差都收敛到零，且每个弱聚点满足相应 KKT 系统。由于这里的 KKT 系统恰是共识约束

$$z_i = P_i z$$

与局部/全局次微分最优性条件的组合，故结论成立。

推论 13.4.1 (图推荐与表示匹配的分布式模板)

若局部目标取为

$$F_i(z_i) = \ell_i(z_i) + \tau_i \mathcal{E}_{\mathcal{G}_i}(z_i)$$

或

$$F_i(z_i) = \mathcal{R}_{\lambda_i}(M_i),$$

其中 $\mathcal{E}_{\mathcal{G}_i}$ 是第 13.2 节定义 13.2.2 的图能量, $\mathcal{R}_{\lambda_i}$ 是第 13.3 节定义 13.3.3 的对比风险, 则相应图推荐、检索匹配和分片 embedding 训练都属于定义 13.4.1 的范畴。因而, 在定理 13.4.1 的假设下, 这些模型可由 ADMM 获得一个统一的分布式收敛模板。



证明 图能量与对比风险都已在前两节被写成 proper、凸且下半连续泛函; 把它们放到局部节点上, 再加上共识约束 $z_i = P_i z$, 就正好落入定义 13.4.1。于是直接应用定理 13.4.1 即可。

注 从第 10.4 节推论 10.4.1 的角度看, ADMM 仍然是在解一个原-对偶零点问题; 只是这里的零点被通信拓扑和参数分片重新组织了。也因此, 本节并不扩展到参数服务器、在线排序或工业服务架构细节, 而只保留凸分块模型可稳定复用的求解接口。

13.4.3 典型例子

例题 13.10 共识矩阵分解 把用户块、物品块或时间块分别放到不同节点上, 每个节点维护局部矩阵变量, 再通过全局一致性约束保证公共因子对齐。这是分布式矩阵分解最常见的抽象形式。

例题 13.11 图正则推荐 若每个节点还带有本地图结构, 则局部目标中自然出现第 13.2 节的图 Dirichlet 能量。这样得到的模型同时耦合了图平滑与全局共识, 正是图推荐系统里经常出现的结构。

例题 13.12 分片 embedding 训练 在大规模推荐系统中, embedding 表往往按词表、用户或物品分片存储。把局部匹配损失写成第 13.3 节的对比风险, 再通过全局变量协调共享参数, 就得到定义 13.4.2 的典型实例。

有限维对照

Boyd 关于共识 ADMM 的有限维叙述, 仍然是理解本节最好的入口: 局部子问题、全局平均和残差监控都保留了下来。但本节的关键补充是, 推荐系统中的“参数分片”“图正则”“多塔一致性”并不是新的数学对象, 它们只是被重新装进了第 11.3 节 ADMM 和第 8.2 节标准型接口中。换言之, 工业推荐系统里的分布式训练并不是脱离理论的工程技巧, 而是 Boyd 母语在无穷维与乘积空间中的一次延伸。

习题 (待补)

- 🔥 **练习 13.7 共识 ADMM 占位** 补一题: 从定义 13.4.1 出发, 完整推出命题 13.4.1 的三组更新式。
- 🔥 **练习 13.8 图推荐桥接题占位** 补一题: 把一个带图平滑正则的推荐模型写成推论 13.4.1 的形式, 并指出局部项与全局一致性项分别来自哪里。

第七部分

附录

附录 A 附录 A：实分析速查手册

内容提要

- ❑ 定位：收纳正文高频调用但不宜在主线中反复展开的实分析工具。

❑ 与正文接口：这里只放高频查表内容、证明残件和速查模板，不承担主线叙事。；正文若标记“放附录”，应优先落到本附录，不回流污染章节主线。

定义 A.0.1 (收录范围)

- 基本不等式与范数估计
- 绝对连续、可积性与极限交换的常用模板
- 正文中所有“放附录”的证明残件入口

例题 A.1 使用时机

- 第 2 章积分与收敛定理
- 第 5 章 l.s.c. 与直接法
- 第 10 章收敛估计与能量不等式

附录 B 附录 B：矩阵分析基础

内容提要

- ❑

定位：服务第 8 章坍缩阅读，把矩阵型符号、分解与内积统一回顾一遍。

❑

与正文接口：这里只放高频查表内容、证明残
- 件和速查模板，不承担主线叙事。；正文若标记“放附录”，应优先落到本附录，不回流污染章节主线。

定义 B.0.1 (收录范围)

- 特征值分解、SVD 与迹内积
- 矩阵范数、条件数与半正定判定
- 向量-矩阵版本的 KKT 与 Schur 补速查

例题 B.1 使用时机

- 第 8 章 LP/QP/SOCP/SDP
- 第 10 章有限维算法坍缩
- 第 12 章工程实现中的矩阵写法

附录 C 附录 C：常用函数的共轭表与次微分表

内容提要

- ❑ 定位：把正文频繁使用的共轭、次微分与 prox 公式汇成可查询表。

❑ 与正文接口：这里只放高频查表内容、证明残

件和速查模板，不承担主线叙事。；正文若标记“放附录”，应优先落到本附录，不回流污染章节主线。

定义 C.0.1 (收录范围)

- 范数、指示函数、熵、KL 散度、Wasserstein 型项
- 常见正则项的共轭、次微分与 prox
- 在不同环境层级下的适用条件备注

例题 C.1 使用时机

- 第 5-6 章共轭与次微分
- 第 9-10 章 prox 与包络
- 第 11-12 章应用模型的快速查表